




一元线性回归（上）

经济贸易学院 张呈磊

Email:chenglei_zhang@gduf.edu.cn

2025年9月



A solid red arrow pointing to the right, positioned to the left of the title.

目录

CONTENTS



1 回归的含义



2 最小二乘法



3 样本回归线与总体回归线

- 什么是回归分析？如何理解？
- 什么是最小二乘法？基本原理是什么？
- 什么是样本和总体回归线？有什么区别？

1 回归的含义



1.1 故事的开始



- **确定性关系或函数关系：**研究的是确定性现象非随机变量间的关系。

$$\text{圆面积} = f(\pi, \text{半径}) = \pi \cdot \text{半径}^2$$

- **统计依赖或相关关系：**研究的是非确定性现象随机变量间的关系。

$$\text{农作物产量} = f(\text{气温}, \text{降雨量}, \text{阳光}, \text{施肥量})$$



1.1 故事的开始





1.1 故事的开始




- 比如：
 - 到底什么因素决定了家庭的收入？
 - $Wage = f(\text{education, age, gender, experience, ability.....})$
 - $Wage = f(\text{education}) + \text{其他}$




1.2 回归



	education	wage
1	12	11.73913
2	12	6.400963
3	12	5.016723
4	17	9.033813
5	12	8.083731
6	12	4.62963
7	12	10.49114
8	18	17.20612
9	14	13.08374
10	15	7.745568
11	16	16.79548
12	15	15.48309
13	15	5.233495
14	15	10.16103
15	15	9.661837
16	15	9.057972
17	15	8.05153
18	14	11.09501
19	14	9.581316
20	12	4.180602



>> 1.2 回归



红色线的方程为: $\text{Wage} = 6000 + 1500\text{education}$




1.2 回归



回归分析是计量经济学中的一种统计方法，用于研究一个或多个自变量与因变量之间的数量关系。

它通过建立数学模型，将离散的、带有随机波动的数据抽象成一条最优拟合线，从而**量化各个解释变量对因变量的平均影响，并揭示隐藏在数据背后的系统性规律。**




>> 1.3 小故事



Courtesy of the Wellcome Institute Library, London.
Noncommercial, educational use only.

达尔文




高尔顿

2 最小二乘法



2.1 最小二乘法



思考：如何理解随机误差项？



2.1 最小二乘法




加帽子表示估计值，读作hat

回归线方程

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$$

样本点表示

$$Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i + \hat{u}_i$$



>> 2.1 最小二乘法




$$\hat{u}_i = Y_i - \hat{Y}_i = Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i$$

残差

拟合值

参数估计值

$$\min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)^2$$



Ordinary Least Squares Method (OLS)



2.1 最小二乘法




$$\min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)^2 = \min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n \hat{u}_i^2 = \text{RSS (残差平方和)}$$

RSS Surface over Beta0 and Beta1

求一阶偏导：

$$\frac{\partial \text{RSS}}{\partial \beta_0} = -2 \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i) = 0$$

$$\frac{\partial \text{RSS}}{\partial \beta_1} = -2 \sum_{i=1}^n X_i (Y_i - \beta_0 - \beta_1 X_i) = 0$$





2.1 最小二乘法




$$\min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)^2 = \min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n \hat{u}_i^2 = \text{RSS} \text{ (残差平方和)}$$

求一阶偏导：

$$\frac{\partial \text{RSS}}{\partial \beta_0} = -2 \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i) = 0 \quad \Longrightarrow \quad \sum_{i=1}^n \hat{u}_i = 0$$

$$\frac{\partial \text{RSS}}{\partial \beta_1} = -2 \sum_{i=1}^n X_i (Y_i - \beta_0 - \beta_1 X_i) = 0 \quad \Longrightarrow \quad \sum_{i=1}^n X_i \hat{u}_i = 0$$

2.1 最小二乘法





2.1 最小二乘法




$$\min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)^2 = \min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n \hat{u}_i^2 = \text{RSS (残差平方和)}$$

$$\hat{\beta}_1 = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2} \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

$$\hat{\beta}_1 = \frac{\text{样本中X与Y偏离平均值的“共同变化”}}{\text{样本中X偏离平均值的大小}}$$

2.1 最小二乘法





2.2 拟合优度 R^2





问题：这条回归线对样本数据“拟合”得好不好？它是否真的揭示了X与Y之间的主要趋势？

$$Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i + \hat{u}_i$$

可解释的部分

不可解释的部分



拟合优度（可决系数）：

$$R^2 = \frac{SSE \text{ (解释平方和)}}{SST \text{ (总平方和)}} = 1 - \frac{SSR \text{ (残差平方和)}}{SST \text{ (总平方和)}}$$


$$SSR = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)^2$$

$$SST = \sum_{i=1}^n (Y_i - \bar{Y})^2$$

>> 2.3 小故事



高斯



3 样本回归线与总体回归线


>> 3.1 从样本到总体



问题： $\hat{\beta}_0$ 和 $\hat{\beta}_1$ 明明是根据解方程精确计算出来的，为什么叫参数**估计**？

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$$

我们想要什么？ 我们拥有什么？










3.1 从样本到总体



Three Random Samples with Different Fitted Lines



>> 3.2 随机变量及其性质



样本回归线 (蓝色)

$$Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$$

总体回归线 (红色)

$$Y_i = \beta_0 + \beta_1 X_i$$


>> 3.2 随机变量及其性质



真实的回归线我们是不知道的，样本数据带概率也只有这一个，那么如何证明单次得到的参数估计值是可靠的？

什么样的估计值是可靠的？

什么是随机变量？如何确定随机变量的基本性质？




3.2 随机变量及其性质




- 可以证明，一定情况下，最小二乘估计量是最好的：兼具无偏性和有效性！

- 无偏性：样本估计量的期望等于总体真实值（或者样本估计量均值等于总体真实值）
- 有效性：样本估计量方差最小（虽然是随机变量，但很稳定，在真实值附近波动）


无偏 + 高效




有偏 + 高效



无偏 + 低效



有偏 + 低效






3.3 练习



```
clear // 清空当前数据集，开始新的空白工作环境
set seed 20250703 // 设置随机数种子，保证结果可重复
set obs 100 // 设定样本容量为100个观测值
gen x = runiform(0,10) // 生成x变量，均匀分布于0到10之间的随机数
gen u = rnormal(0,1) // 生成误差项u，服从均值0，标准差1的正态分布
gen y = 2 + 0.5*x + u // 根据线性模型生成y变量，截距为2，斜率为0.5，包含误差项u
reg y x // 对y进行关于x的线性回归，估计样本回归系数
twoway (scatter y x, msymbol(circle) mcolor(gs8)) ///
      (lfit y x, lcolor(blue)) ///
      (function y = 2 + 0.5*x, range(0 10) lcolor(red) lpattern(dash))), ///
      legend(label(2 "样本回归线") label(3 "总体回归线")) ///
      title("一次抽样：样本回归线 vs 总体回归线") // 绘制图形：
          // 散点图（灰色圆点）
          // 样本回归线（蓝色实线）
          // 理论总体回归线（红色虚线）
          // 添加图例区分两条回归线
          // 添加图标题
```






3.3 练习



```
clear all           // 清除内存中的所有数据和程序
set seed 20250703    // 设置随机种子，使得模拟结果可重复
set more off         // 关闭分页显示，避免输出时中断
tempname bstore      // 创建一个临时名字，用于储存模拟结果的后备文件
postfile `bstore' beta1 using betasim.dta, replace
                    // 创建一个名为 betasim.dta 的临时数据文件，储存每次模拟中回归系数 x 的估计值 (beta1)
forval i = 1/1000 {  // 循环进行1000次模拟
    clear           // 每次模拟前清除数据
    set obs 100      // 设置样本容量为100
    gen x = runiform(0,10) // 生成解释变量 x，服从区间为 [0,10] 的均匀分布
    gen u = rnormal(0,1) // 生成误差项 u，服从标准正态分布 N(0,1)
    gen y = 2 + 0.5*x + u // 构造因变量 y，真实模型为  $y = 2 + 0.5x + u$ 
    reg y x          // 对 y 和 x 进行一元线性回归
    post `bstore' (_b[x]) // 将当前回归中估计得到的 x 的系数（斜率）存入后备文件
}
postclose `bstore'   // 关闭 postfile，完成数据写入
use betasim.dta, clear // 读取刚才生成的包含1000个斜率估计值的数据集
sum beta1            // 对估计的斜率 beta1 进行描述性统计（如平均值、标准差等）
histogram beta1, bin(40) normal ///
    title("斜率估计值的分布（1000次模拟）")
                    // 绘制斜率估计值的直方图，设置为40个柱子，并叠加正态密度曲线
                    // 图标题为“斜率估计值的分布（1000次模拟）”
```





3.4 小故事



在计量经济学和统计学中，DGP 是 Data Generating Process（数据生成过程）的缩写。它指的是观测数据背后的真实机制或模型，也就是数据是如何“生成”的，包括哪些变量影响了结果、误差项的分布形式、以及这些变量之间的关系。换句话说，DGP描述了如果我们能知道整个世界的规律，我们会如何得到我们观测到的数据。

举个例子：

假设你想研究教育年限（Education）对收入（Income）的影响。一个简单的 DGP 可以是：

$$Income_i = \beta_0 + \beta_1 \cdot Education_i + u_i$$

这里：

- β_0 和 β_1 是真实的参数（世界真实的关系）。
- u_i 是随机扰动项，可能代表运气、能力等无法观测因素。
- DGP 就是这个公式，以及 Education 和 u 的真实分布。

特点：

1. 真实世界的假设：DGP是理论上的真实模型，我们通常不知道。
2. 用于模拟或理论分析：在蒙特卡洛模拟里，我们假设一个DGP，然后生成数据，看看某些估计方法表现如何。
3. 区分估计量与真值：通过DGP我们知道真参数值，可以检查估计量是否无偏、有效。

简单总结：DGP就是“数据是如何生成的真实规则”，是我们研究和模拟的基础。

如果你想，我可以画一张DGP与观测数据和估计量关系的示意图，帮助更直观理解。你希望我画吗？



3.4 小故事



你觉得人类社会存在所谓的DGP吗？
如果存在计量经济学可以识别出来吗？
人类有自我意识吗？还是行为已经被DGP设定好了？



3.4 小故事



你的问题涉及哲学、经济学和认知科学的交叉，非常深刻。我来分开讨论，每一层都仔细分析。

1. DGP (Data Generating Process) 在人类社会中是否存在？

在计量经济学里，DGP指的是“生成数据的真实过程”，即某个变量 Y 如何由其他变量 X 和随机扰动 ε 决定的机制。理论上，它要求：

- 一套规则或机制能解释 Y 的产生。
- 这个机制通常可用函数形式（线性或非线性）描述，并且有噪声项。

把这个概念套到人类社会行为上，就会出现以下问题：

- 人类行为复杂，受心理、社会、文化、历史等多重因素影响。
- 很多因素无法被完全观测或量化，噪声可能非常大。
- “规则”可能是非固定的、随时间演化的，而不像物理实验那样稳定。

所以，从严格计量角度看，人类社会可能没有一个单一、稳定的DGP。更现实的观点是：社会行为可能遵循局部、短期、近似的DGP，比如：

- 经济学中的消费函数 $C = a + bY + \varepsilon$ 在短期内大体成立，但长期会随偏好、制度和心理预期变化。
- 政策实验中我们能估计一个“局部平均处理效应”，但不能得到普适的DGP。



3.4 小故事



2. 计量经济学能否识别人类社会的DGP?

计量经济学的方法本质是在有限数据和假设下逼近DGP:

- 如果社会行为确实存在某种稳定规律, 而且我们观测到足够的变量和数据, 理论上可以估计逼近DGP的模型。
- 但现实问题:
 1. 不可观测变量: 很多心理或社会机制无法测量。
 2. 非稳定性: 规则可能随环境或文化改变。
 3. 因果识别问题: 相关不等于因果, 观测数据可能混淆了因果关系。
 4. 高维复杂性: 规则可能涉及成千上万的因素, 传统回归难以捕捉。

所以, 计量经济学可以捕捉局部规律和因果效应, 但很难完整“识别”整个人类社会的DGP。



3.4 小故事



3. 人类是否有自我意识？还是行为被DGP设定？

这是哲学上的自由意志问题。结合你的问题：

- 如果社会行为存在某种DGP，是否意味着我们被“程序化”？
 - 不完全。即便存在规律，人类仍有意识、反思能力和创新行为，可以选择偏离规律。
- 自我意识是人类可以感知自己行为、规划未来、修改策略的能力。
 - DGP描述的是规律或趋势，但不能完全决定个体选择。
 - 在统计意义上，你的行为可能大概率遵循某种模式，但个体仍可能偏离。

换句话说，DGP更像统计规律而非“命运书”：它可以告诉我们大多数人可能如何行动，但不等于完全决定你的选择。

◆ 总结

1. 社会行为的DGP可能存在，但非常复杂、局部、动态。
2. 计量经济学可以逼近局部规律，但难以识别完整DGP。
3. 人类有自我意识，能偏离统计规律，行为不完全由DGP决定。
4. DGP不是宿命论，而是概率性的描述。

- 什么是回归分析？如何理解？
- 什么是最小二乘法？基本原理是什么？
- 什么是样本和总体回归线？有什么区别？

1. 请解释总体回归线和样本回归线的区别是什么？为什么我们需要用样本回归线去估计总体回归线？
2. 假设我们想知道“学习时间”和“考试成绩”之间的关系。为什么不能只画一个散点图就下结论，而要用回归方法？在回归模型里，误差项 u_i 可以代表哪些因素？如果我们发现回归结果中学习时间的系数为正，你会如何解释这个结果？你觉得“为正”是不是就意味着“多学习一定会提高成绩”？为什么？
3. 在 OLS 中，残差和拟合值之间有什么关系？为什么残差的平均值一定等于 0？如果你画出残差与自变量 X 的散点图，理论上应该看到什么？这对回归模型的设定意味着什么？

4. 在一元回归模型 $Y_i = \beta_0 + \beta_1 X_i + u_i$ 中，假设满足经典回归条件。

- (1) 什么叫做“估计量是无偏的”？请用自己的话解释。
- (2) 用“掷骰子”的类比说明无偏性：如果我们多次抽样做回归， $\hat{\beta}_1$ 的平均值和真实值 β_1 的关系是什么？
- (3) 如果误差项的均值不为零，会对无偏性造成什么影响（下周内容）？

5. 说明总平方和（SST）、残差平方和（SSR）和拟合优度 R^2 的计算公式及其经济意义。假设一个样本中， $SST = 200$ ， $SSR = 50$ ，计算模型的拟合优度。



下期预告

- 一元线性回归的经典假设
- 高斯马尔科夫定理

作业与思考

- 预习经典假设
- 了解蒙特卡洛模拟的基本原理

谢谢，欢迎交流讨论！