




一元线性回归（下）

经济贸易学院 张呈磊

Email:chenglei_zhang@gduf.edu.cn

2025年9月



A solid red arrow pointing to the right, positioned to the left of the title.

目录

CONTENTS



1 无偏性与有效性



2 经典假设



3 高斯马尔可夫定理



- 如何理解无偏性和有效性？
- 经典假设的内涵？为什么是这些假设？
- 如何理解高斯马尔可夫定理？

1 无偏性与有效性

>> 1.0 随机变量及其性质



参数估计量并不是一个确定的值，而是一个随机变量！！！！



样本回归线（蓝色）

$$Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$$

总体回归线（红色）

$$Y_i = \beta_0 + \beta_1 X_i$$

面临的问题: 参数估计值 $\neq$ 参数真实值

- 对参数估计式的优劣需要有评价的标准，为什么呢？
 - 参数无法直接观测，只能通过样本去估计，样本的获得存在抽样波动，不同样本的估计结果不一致。
 - 估计参数的方法有多种，不同方法的估计结果可能不相同，通过样本估计参数时，估计方法及所确定的估计量不一定完备，不一定能得到理想的总体参数估计值。
- 估计准则的基本要求
 - 参数估计值应“尽可能地接近”总体参数真实值”
- 什么是“尽可能地接近” 原则呢？判断标准是什么？


无偏性

- **前提：**重复抽样中估计方法不变、由重复抽样得到的观测值，可得一系列参数估计值 $\hat{\beta}$ ， $\hat{\beta}$ 的分布称为 $\hat{\beta}$ 的抽样分布
- **概念：**
 - 如果 $E(\hat{\beta}) = \beta$ ，则称 $\hat{\beta}$ 是参数 β 的无偏估计量
 - 如果 $E(\hat{\beta}) \neq \beta$ ，则称 $\hat{\beta}$ 是有偏的估计，其偏倚为 $E(\hat{\beta}) - \beta$
- 无偏性意味着：如果我们能反复从总体中抽样并用OLS进行估计，那么估计值的平均就是总体的真实参数。虽然单次估计有可能偏高或偏低，但从长期来看，它“不会错方向”。

>> 1.1 无偏性



无偏性






1.2 有效性



有效性

- **前提：** 样本相同、用不同的方法估计参数，可以找到若干个不同的无偏估计式，但估计量的方差不同
- **目标：** 努力寻求其抽样分布具有最小方差的估计量
- 无偏性只是“正确”，但还不够。我们还希望估计值不要“东一下、西一下”，而是在真实值周围紧密波动。也就是说，我们不仅要“对”，还要“稳”。
- 有效性指的正是这个“波动性”的问题：在所有无偏的估计方法中，我们希望找到那个具有最小方差的。一旦误差项的方差不相等，也就是存在异方差时，这一最小方差的性质就不成立了：同样是用最小二乘法估计出来的系数，它的波动可能比其他方法更大。

>> 1.2 有效性




>> 1.3 无偏性和有效性




- 一个好的估计量需要兼具无偏性和有效性！

- 无偏性：样本估计量接近总体真实值（或者样本估计量均值等于总体真实值）
- 有效性：样本估计量波动小（虽然是随机变量，但很稳定，在真实值附近波动）


无偏 + 高效




有偏 + 高效



无偏 + 低效



有偏 + 低效



>> 1.3 无偏性和有效性



那么，最小二乘估计量具有这两个性质吗？

2 经典假设

>> 2.1 为什么需要假设



- 为保证参数估计量具有良好的统计性质，通常对模型提出若干基本假设。
- 实际上这些假设与所采用的估计方法紧密相关。
- 下面的假设主要是针对采用普通最小二乘法 (Ordinary Least Squares, OLS) 估计而提出的。所以，在有些教科书中称为 “The Assumption Underlying the Method of Least Squares”。
- 在不同的教科书上关于基本假设的陈述略有不同，下面进行了重新归纳，包括对模型设定的假设、对解释变量 X 的假设以及对随机干扰项 μ 的假设。



2.2 经典假设



假设1（模型设定）：回归模型是正确设定的，一般是线性。

（1）模型选择了正确的变量：指在设定总体回归函数时，既没有遗漏重要的相关变量，也没有多选无关的变量。

（2）模型选择了正确的函数形式：指当被解释变量与解释变量间呈现什么样的函数形式时，设定的总体回归方程恰为该函数形式。

满足假设1，则模型没有设定偏误（specification error），这个是基本前提。



2.2 经典假设



假设2（数据要求）：样本是随机抽取的。

- 每个样本 (X_i, Y_i) 都是随机抽取的，这意味着样本中的每个观测值都像是从总体中“随手一抓”的结果，没有人为筛选或偏向。这个假设的作用是确保我们通过样本推断出的规律有可能推广到总体。
- 两个隐含假设
 - ✓ X 要有足够变异性：要通过解释变量X的变化来解释被解释变量Y的变化，则要求解释变量X要有足够的变异性。
 - ✓ X要不能有异常值：极端异常值会导致结果估计有偏。



2.2 经典假设



假设3（随机扰动项期望）： 给定解释变量的任何值，随机干扰项的均值为零，即

$$E(u_i|X_i) = 0$$

- 随机干扰项的条件零均值假设意味着 μ 的期望不依赖于 X 的任何观测点取值的变化而变化，且总为常数零，也表明 μ 与 X 不存在任何形式的相关性，因此该假设成立时称 X 为**外生解释变量**。
- 那些被我们遗漏的因素，它们的平均影响不应该随着解释变量 X 的不同而系统地变化。如果这个假设成立，我们就可以证明：最小二乘法估计量是无偏的，即：



$$E(\hat{\beta}_0) = \beta_0, \quad E(\hat{\beta}_1) = \beta_1$$




2.2 经典假设




Illustration of u trend and OLS bias



2.2 经典假设



U与X不相关时估计量的分布




U与X相关时估计量的分布

>> 2.2 经典假设



假设4（随机扰动项方差）：随机干扰项具有给定任何值条件下的同方差性

$$\text{Var}(u_i|X_i) = \sigma^2$$





2.2 经典假设




假设4（随机扰动项方差）：随机干扰项具有给定任何值条件下的同方差性

$$\text{Var}(u_i|X_i) = \sigma^2$$

- 一旦误差项的方差不相等，也就是存在异方差时，这一最小方差的性质就不成立了：同样是用最小二乘法估出来的系数，它的波动可能比其他方法更大。也就是说，即使我们的估计是无偏的，它也可能不够精确、不够可靠。



2.2 经典假设



3 高斯马尔科夫定理

>> 3 高斯马尔科夫定理



- 上述4个假设可以称为**高斯-马尔可夫假设 (Gauss-Markov assumption)**。
在这些假设之下，我们可以得出一个极为重要的结论：高斯-马尔可夫定理 (Gauss-Markov Theorem)。
高斯-马尔可夫定理指出：在上述假设成立的前提下，普通最小二乘法所得的估计量是所有线性无偏估计量中方差最小的，即 OLS 是最佳线性无偏估计量 (Best Linear Unbiased Estimator, 简称BLUE)。
- 换言之，只要经典假设成立，我们不仅可以相信OLS给出的估计值“方向正确”（无偏），还可以相信它在同类估计方法中“尽可能精确”（最小方差）。



- 如何理解高斯马尔可夫定理
 - 只有满足这些经典假设，最小二乘法才是一种好的方法
 - 在使用最小二乘法之前，必须确保这些假设满足（或者姑且可以接受）
 - 如果这些假设无法被满足，那么需要创造条件去满足，或者选择其他方法

>> 3 高斯马尔科夫定理



(1) 线性性。即估计量 $\hat{\beta}_0, \hat{\beta}_1$ 是 Y_i 的线性组合。

证:
$$\hat{\beta}_1 = \frac{\sum x_i y_i}{\sum x_i^2} = \frac{\sum x_i (Y_i - \bar{Y})}{\sum x_i^2} = \frac{\sum x_i Y_i}{\sum x_i^2} - \frac{\bar{Y} \sum x_i}{\sum x_i^2} = \sum k_i Y_i$$

其中,
$$k_i = \frac{x_i}{\sum x_i^2}$$

同样可得

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X} = \frac{1}{n} \sum Y_i - \sum k_i Y_i \bar{X} = \sum \left(\frac{1}{n} - \bar{X} k_i \right) Y_i = \sum w_i Y_i$$

其中,
$$w_i = \frac{1}{n} - \bar{X} k_i$$

3 高斯马尔科夫定理



(2) 无偏性。即以 X 的所有样本值为条件，估计量 $\hat{\beta}_0, \hat{\beta}_1$ 的期望等于总体回归参数真值 β_0, β_1 。

证：由线性性得 $\hat{\beta}_1 = \sum k_i Y_i = \sum k_i (\beta_0 + \beta_1 X_i + \mu_i) = \beta_0 \sum k_i + \beta_1 \sum k_i X_i + \sum k_i \mu_i$

易知
$$\sum k_i = \sum \frac{x_i}{\sum x_i^2} = \frac{\sum x_i}{\sum x_i^2} = 0, \quad \sum k_i X_i = 1$$

故
$$\hat{\beta}_1 = \beta_1 + \sum k_i \mu_i$$

$$E(\hat{\beta}_1 | X) = E\left[\left(\beta_1 + \sum k_i \mu_i\right) | X\right] = \beta_1 + \sum k_i E(\mu_i | X) = \beta_1$$

同样地，容易得出

$$E(\hat{\beta}_0 | X) = E\left[\left(\beta_0 + \sum w_i \mu_i\right) | X\right] = \beta_0 + \sum w_i E(\mu_i | X) = \beta_0$$

>> 3 高斯马尔科夫定理



(3) 有效性 (最小方差性)。即在所有线性无偏估计量中, 普通最小二乘估计量 $\hat{\beta}_0, \hat{\beta}_1$ 具有最小方差。

证: 首先求 $\hat{\beta}_0, \hat{\beta}_1$ 的条件方差。

$$\begin{aligned} Var(\hat{\beta}_1 | X) &= Var\left(\sum k_i Y_i | X\right) = \sum Var(k_i Y_i | X) = \sum k_i^2 Var(Y_i | X) \\ &= \sum k_i^2 Var[(\beta_0 + \beta_1 X_i + \mu_i) | X] = \sum k_i^2 Var(\mu_i | X) \\ &= \sum \left(\frac{x_i}{\sum x_i^2}\right)^2 \sigma^2 = \frac{\sigma^2}{\sum x_i^2} \end{aligned}$$

>> 3 高斯马尔科夫定理



(3) 有效性 (最小方差性)。即在所有线性无偏估计量中, 普通最小二乘估计量 $\hat{\beta}_0, \hat{\beta}_1$ 具有最小方差。

证: 其次证明最小方差性。

假设 $\hat{\beta}_1^*$ 是其他估计方法得到的关于 β_1 的线性无偏估计量: $\hat{\beta}_1^* = \sum c_i Y_i$ 。

其中, $c_i = k_i + d_i$, d_i 为不全为0的常数, 则容易证明:


$$Var(\hat{\beta}_1^* | X) \geq Var(\hat{\beta}_1 | X)$$

同理, 设 $\hat{\beta}_0^*$ 是其他估计方法得到的关于 β_0 的线性无偏估计量, 则有

$$Var(\hat{\beta}_0^* | X) \geq Var(\hat{\beta}_0 | X)$$



3. 在 OLS 中，残差和拟合值之间有什么关系？为什么残差的平均值一定等于 0？如果你画出残差与自变量 X 的散点图，理论上应该看到什么？这对回归模型的设定意味着什么？






本讲总结



- 我们想知道总体的X对Y的影响，即理论上的真实值 β
- 但是我们永远不可能知道总体，只能通过样本估计出一个 $\hat{\beta}$
- 样本估计量 $\hat{\beta}$ 是一个随机变量，我们可以得到其期望和方差
- 在经典假定下，通过最小二乘法得到的样本估计量 $\hat{\beta}$ 既是无偏的（期望等于真实值），也是有效的（具有最小方差）
- 换言之，只要这些假定满足，OLS方法就是一种简单且可靠的方法

3. 在 OLS 中，残差和拟合值之间有什么关系？为什么残差的平均值一定等于 0？如果你画出残差与自变量 X 的散点图，理论上应该看到什么？这对回归模型的设定意味着什么？



6. 设定模型: $Y_i = \beta_0 + \beta_1 X_i + u_i$, $u_i \sim N(0,1)$, $X_i \sim N(0,10)$,

- (1) 在 Stata 中生成 30 个样本, 回归 Y 对 X, 记录系数。
- (2) 改为 300 个样本, 再回归一次。
- (3) 比较两次结果的标准误差 (Std. Err.) 。
- (4) 解释为什么样本量增加时, 估计更 “有效” 。

7. 考虑数据生成过程：

$$Y_i = 5 + 2X_i + u_i, u_i \sim N(0,1), X_i \sim N(0,10)$$

- (1) 在 Stata 中生成 100 个样本，设定如上模型，回归 Y 对 X，记录回归系数。
- (2) 将这个过程重复 1000 次，收集所有的回归系数。
- (3) 画出估计系数的直方图，并计算它们的平均值，比较平均值和真实值。
- (4) 改变误差项方差（例如 $u_i \sim N(0,3)$ ），再重复实验，比较估计结果的分布。
- (5) 根据模拟结果，回答：为什么我们说 OLS 是无偏的？为什么误差变大时，OLS 仍然无偏，但“有效性”降低了？

8. 考虑模型： $Y_i = 1 + 2X_i + 3Z_i + u_i$ 其中 X_i 和 Z_i 正相关。

(1) 在 Stata 中模拟 200 个样本，先回归 Y 对 X（遗漏 Z），再回归 Y 对 X, Z（完整模型）。

(2) 比较两次回归中 $\hat{\beta}_1$ 的结果。

(3) 解释为什么遗漏变量会使估计有偏？

下期预告

- 多元回归分析
- 遗漏变量问题

作业与思考

- 讲义第2章课后习题

谢谢，欢迎交流讨论！