




多元线性回归：估计（下）

经济贸易学院 张呈磊

Email: chenglei_zhang@gduf.edu.cn

2025年10月



1. 在一元线性回归模型 $Y_i = \beta_0 + \beta_1 X_i + u_i$ 中，最小二乘法 (OLS) 的核心思想是：

- ☐ A 使得残差的和为零
- ☐ B 使得每个残差最小
- ☒ C 使残差平方和最小
- ☐ D 使得每个预测值尽可能接近平均数

提交

2. 在一元回归如果所有 X_i 都相同，OLS能否估计出斜率 β_1

- ☐ A 可以，因为Y仍然有变化
- ☒ B 不可以，因为没有X的变动来解释Y
- ☐ C 可以，只要样本够大
- ☐ D 可以，但结果没有意义

提交

3. 在二元回归模型 $Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + u_i$ 中， β_1 的含义是

- ☐ A X1增加1个单位时Y的平均变化
- ☐ B X1和X2同时增加时Y的变化
- ☒ C X2保持不变，X1增加1个单位时Y的平均变化
- ☐ D X1增加1个单位时Y的变化

提交

4. 在多元回归中引入新的变量 X_3 后，原先的发生了较大变化，可能的原因是

- ☒ A X_3 和 X_1 相关
- ☐ B X_3 与 Y 相关
- ☐ C X_3 和 X_2 相关
- ☐ D X_3 和 X_1 、 X_2 都不相关

提交

5. 在多元回归中，如果遗漏了一个和X有关的控制变量Z，会导致

- ☒ A X的估计系数有偏
- ☐ B X的估计系数无偏
- ☐ C 同方差假定不满足
- ☐ D 以上都不对

提交

A solid red arrow pointing to the right, positioned to the left of the title.

目录

CONTENTS



1 多元情况下的经典假设



2 偏差和方差的平衡



3 模拟案例



- 多元回归下经典假设有何变化？
- 如何从控制变量的角度理解估计的偏差和方差？

1 多元情况下的经典假设问题

>> 1.1 一元情况下的经典假设



假设1（模型设定）：回归模型形式是正确设定的，一般是线性。

模型选择了正确的函数形式：指当被解释变量与解释变量间呈现什么样的函数形式时，设定的总体回归方程恰为该函数形式，一般是线性。

假设2（数据要求）：样本是随机抽取的。

- 每个样本 (X_i, Y_i) 都是随机抽取的，这意味着样本中的每个观测值都像是从总体中“随手一抓”的结果，没有人为筛选或偏向。这个假设的作用是确保我们通过样本推断出的规律有可能推广到总体。
- 两个隐含假设
 - ✓ X 要有足够变异性：要通过解释变量 X 的变化来解释被解释变量 Y 的变化，则要求解释变量 X 要有足够的变异性。
 - ✓ X 要不能有异常值：极端异常值会导致结果估计有偏。

>> 1.1 一元情况下的经典假设



假设3（随机扰动项期望）：给定解释变量的任何值，随机干扰项的均值为零，即 $E(u_i|X_i) = 0$



- 随机干扰项的条件零均值假设意味着 μ 的期望不依赖于 X 的任何观测点取值的变化而变化，且总为常数零，也表明 μ 与 X 不存在任何形式的相关性，因此该假设成立时称 X 为**外生解释变量**。
- 那些被我们遗漏的因素，它们的平均影响不应该随着解释变量 X 的不同而系统地变化。如果这个假设成立，我们就可以证明：最小二乘法估计量是无偏的，即：

$$E(\hat{\beta}_0) = \beta_0, \quad E(\hat{\beta}_1) = \beta_1$$

>> 1.1 一元情况下的经典假设



Illustration of u trend and OLS bias




>> 1.1 一元情况下的经典假设




假设4（随机扰动项方差）：随机干扰项具有给定任何值条件下的同方差性

$$\text{Var}(u_i|X_i) = \sigma^2$$



>> 1.1 一元情况下的经典假设



3-2. 设多元回归模型为

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + u$$

请回答：

- (1) β_1 的含义是什么？为什么说它是在“控制 X_2 的情况下”估计的？
- (2) 如果 X_1 与 X_2 高度相关，会对 $\hat{\beta}_1$ 的估计有什么影响？

假设5（解释变量关系）：各解释变量之间不存在完全共线

- 完全共线性是指在多元回归模型中，两个或两个以上的自变量之间存在完全线性相关关系，导致这些变量在统计上提供的信息重复。这种情况下需要多估计一个参数，但没有提供额外的信息，OLS方法无解。
- 比如同时控制消费、投资、政府购买和净出口
- 比如同时控制了第一产业比重、第二产业比重和第三产业比重
- 比如同时控制了男性和女性

>> 1.3 高斯马尔科夫定理



- 上述5个假设可以称为多元情况下的**高斯-马尔可夫假设 (Gauss-Markov assumption)**。在这些假设之下，我们可以得出一个极为重要的结论：高斯-马尔可夫定理 (Gauss-Markov Theorem)。

高斯-马尔可夫定理指出：在上述假设成立的前提下，普通最小二乘法所得的估计量是所有线性无偏估计量中方差最小的，即 OLS 是最佳线性无偏估计量 (Best Linear Unbiased Estimator, 简称BLUE)。

- 换言之，只要经典假设成立，我们不仅可以相信OLS给出的估计值“方向正确”（无偏），还可以相信它在同类估计方法中“尽可能精确”（最小方差）。

>> 1.3 高斯马尔科夫定理



- 如何理解高斯马尔可夫定理
 - 在使用最小二乘法之前，必须确保这些假设满足（或者姑且可以接受）
 - 如果这些假设无法被满足，那么需要创造条件去满足，或者选择其他方法

2 偏差和方差的平衡



2.1 多重共线问题



完全共线问题一般只是意外，更常见的是多重共线（不完全共线）

- 在多元回归 $Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + u_i$ 中，核心解释变量可以用其他解释变量线性表示（ $\alpha_1, \alpha_2 \dots \alpha_k$ 中至少有一个不为 0）

$$X_{1i} = \alpha_0 + \alpha_1 X_{2i} + \alpha_2 X_{3i} + \cdots + \alpha_k X_{ki} + \epsilon_i$$

- 多重共线性是指在多元回归模型中，两个或两个以上的自变量之间存在较强的线性相关关系，导致这些变量在统计上提供的信息高度重复。虽然这种情况不会使回归系数产生偏误，估计结果仍然有效，但会导致系数估计标准误变大，从而使一些变量估计结果不稳定，影响对单个自变量作用的准确解释。

2.1 多重共线问题



- 估计量的系数可以通过最小二乘法得到（数学上是求偏导后解方程）
- 那么系数的方差或者标准差呢？（估计系数的标准差我们叫做标准误差，se）

$$\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{SST_j(1 - R_j^2)}$$

- 其中 σ^2 是随机扰动项的方差，衡量误差的波动
- SST_j 是解释变量 X_j 的方差，衡量 X_j 的波动
- R_j^2 是 X_j 对其他解释变量回归的得到的可决系数，衡量解释变量共线问题



2.1 多重共线问题



$\frac{1}{1 - R_j^2}$ 为方差膨胀因子 (VIF, 一般大于10为存在共线性问题)

- **数学上**, 多重共线越严重, R_j^2 越大, 分母越小, 估计量的方差越大, 估计结果越不稳定
- **直觉上**, 增加控制变量需要多估计一个系数, 但没有提供这么多信息 (X_1 和 X_2 共享了部分信息), 所以估计量波动大, 不稳定
 - 比如, 在房价影响中, 地段和交通都控制, 其实无法说明到底是地段近还是交通好对房价的影响, 会互相干扰

- 多元回归中的“多”到底应该是多少？
 - 如果控制变量和核心解释变量相关，不控制会导致遗漏变量偏误，估计系数是有偏的
 - 如果控制变量和核心解释变量相关，控制起来会存在多重共线问题，估计结果虽然也是有效的，但方差会变大，估计结果不稳定
 - 注意：存在多重共线问题时，方差虽然会变大，但已经是所有无偏估计中方差最小的那个，仍然符合高斯马尔可夫定理

2.2 偏差和方差的平衡问题



- 引申讨论：估计量偏差和方差的平衡问题 (bias-variance tradeoff)
 - 一个好的估计量的两个特征
 - ✓ 平均来讲是正确的，即无偏（一般来讲是因为模型太简单）
 - ✓ 每次估计的结果很稳定，方差小（一般来讲是因为模型越复杂）
 - 但这两个目标往往不能同时做到
 - ✓ 遗漏变量偏误问题：偏差大，方差小（系统性错误但是很稳定）
 - ✓ 高度共线问题（模型过拟合）：偏差小，方差极大（无系统错误但波动太大）
 - 为了降低估计的不稳定性（方差），我们往往需要容忍一定的系统误差（偏差）

2.2 偏差和方差的平衡问题



- 具体问题具体分析：一个例子

- 在研究教育对收入的影响时，如果我们同时有认知能力、IQ得分、非认知能力和MBTI测试结果

- ✓ **偏差大于方差需要控制：**能力会同时影响教育和收入，如果不控制能力，偏差很大，所以需要同时控制教育和能力（包括认知和非认知能力）

- ✓ **方差大于偏差则减少控制：**认知能力和IQ高度相关，非认知能力和MBTI高度相关，所以认知和IQ选一个控制，非认知能力和MBT I选一个控制

>> 2.2 偏差和方差的平衡问题



- 思考：

- 如果 X_2 和 X_3 相关，是否影响 X_1 的估计？
- 那有没有一个相对客观的指标去衡量到底什么样的偏差是可以接受的？

3 模拟案例



- 遗漏变量偏误模拟
 - 漏掉了和核心解释变量 X 相关的某个关键控制变量
- 多重共线模拟
 - 加入了和核心解释变量 X 相关的控制变量
- 二者的权衡



- 一元回归说明其他因素都放入了随机扰动项，导致扰动项和核心解释变量 X 相关，带来遗漏变量偏误问题，估计结果有偏
- 为了缓解遗漏变量偏误问题我们加入控制变量进行多元回归
- 如果控制变量和核心解释变量完全共线，估计OLS无解，所以多了无完全共线这第五个假定
- 完全共线一般是意外，但多重共线是常态，多重共线情况下依然无偏有效，但方差会变大，所以存在偏差和方差取舍问题，需要具体情况具体分析

3. 以数字经济对地区GDP增长的影响为研究背景，假设解释变量包含互联网普及率、数字基础设施投资和电子商务交易额。

(1) 请从理论上详细说明为什么这几个变量之间可能存在多重共线性，以及这种现象为什么会给多元回归的估计带来困难。

(2) 结合多重共线性对参数估计不确定性的影响，探讨在实际研究中如何平衡控制变量的全面性和多重共线性带来的问题。

5. 利用Stata自带数据集auto.dta（自带数据集）分析汽车价格price与油耗mpg、重量weight、长度length的关系。

- (1) 载入数据并浏览数据，查看price、mpg、weight、length的描述性统计；
- (2) 对price回归mpg、weight、length，写出回归命令并记录输出结果；
- (3) 解释回归系数截距和mpg的系数的含义；
- (4) 生成残差并画残差与拟合值的散点图；
- (5) 根据残差图，简述残差分析可以提供哪些模型信息。

6. 利用Stata自带数据集nlsw88.dta演示控制变量如何改变回归系数解释。因变量为工资wage，自变量包括经验ttl_exp、教育grade、工作时间hours和年龄age。

- (1) 载入数据并浏览wage、ttl_exp、grade、female的描述性统计。
- (2) 仅用工资wage对教育grade进行回归，记录估计值。
- (3) 再用工资对教育grade和经验ttl_exp进行，观察估计值是否变化。
- (4) 再加入年龄age，观察教育系数是否进一步变化，年龄和经验是否存在共线问题？你如何考虑这个问题？
- (5) 总结控制变量在多元回归中的作用。

7. 利用Stata模拟数据体验遗漏变量偏误的问题，请完成以下步骤：

- (1) 生成一个包含三个解释变量 (X_1 、 X_2 、 X_3) 和一个因变量 Y 的虚拟数据集，其中 Y 由 X_1 、 X_2 、 X_3 线性决定并加上随机误差；
- (2) 分别估计包括全部三个解释变量的多元回归模型和只包括部分解释变量（如仅 X_1 和 X_2 ，或仅 X_1 ）的回归模型；
- (3) 比较不同模型中 X_1 的系数估计，观察遗漏变量对系数的影响；
- (4) 绘制 X_1 与 Y 的散点图，并结合回归线说明遗漏变量偏误的直观表现；
- (5) 总结遗漏变量偏误在多元回归分析中的表现及其对结论可靠性的影响。

8. 使用配套的房地产数据housing.dta，使用多元回归方法分析该数据，并完成以下问题：

- (1) 浏览数据，观察各变量的分布情况。请计算主要变量的均值、中位数、最大值和最小值，并用散点图或直方图初步观察房价与其他变量的关系；
- (2) 设计一个多元回归模型，对所选模型进行回归分析，记录回归系数并解释主要系数的经济含义，分析哪些因素对房价影响显著；
- (3) 绘制残差与拟合值的散点图，观察是否存在异方差或异常值。
- (4) 利用回归结果预测一套具体房子的价格，并计算预测残差。结合分析结果，提出合理的市场解释或定价建议。

下期预告

- 多元回归分析：推断

作业与思考

- 如何判断样本估计的系数是否能代表总体？

谢谢，欢迎交流讨论！