




多元线性回归：推断（上）

经济贸易学院 张呈磊

Email: chenglei_zhang@gduf.edu.cn

2025年10月



A solid red arrow pointing to the right, positioned to the left of the title.

目录

CONTENTS



1 OLS估计量的统计性质



2 假设检验的基本思想



3 t检验

- 作为一个随机变量，OLS估计量的统计性质有哪些？
- 什么是假设检验？为什么需要假设检验？基本思想是什么？
- 什么是t检验？

1 OLS估计量的统计性质



1.1 随机变量



一个随机变量的基本特征有哪些？

结果 (x)	1	2	3	4	5	6
概率 $P(X=x)$	1 / 6	1 / 6	1 / 6	1 / 6	1 / 6	1 / 6

- 这张表就叫做 “分布”，它告诉我们：这个随机变量可能取哪些值，以及每个值的可能性。
- 从这里我们可以：
 - 计算期望（均值）：平均结果，反映“长期平均趋势”；
 - 计算方差：结果波动有多大，反映“离均值的分散程度”。

层次	概念	含义	信息量
① 分布	描述随机变量的所有可能结果及其概率	最完整的信息	★★★★★
② 期望	分布的“中心”	分布的一个特征	★★
③ 方差	分布的“宽度”	分布的另一个特征	★★



1.1 随机变量



为什么OLS估计量会有随机性呢？原因在于回归模型中包含了随机误差项。

考虑一个最简单的多元回归模型：

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + u_i$$

其中 $\beta_0 \dots \beta_k$ 是总体中的真实参数，而 u_i 是不可控的随机因素。我们用OLS计算出的 $\beta_0 \dots \beta_k$ 是基于样本的。当样本不同，误差项 u_i 的具体取值也不同，于是估计结果自然会随之变化。换句话说， $\beta_0 \dots \beta_k$ 本身是随机变量，它们会有一个分布，这个分布就是**抽样分布**。



1.2 期望



满足经典假设的前提下：

$$E(\hat{\beta}_k) = \beta_k$$

即如果重复抽样很多次，估计量的均值等于真实值



1.3 方差



满足经典假设的前提下：

$$\text{Var}(\hat{\beta}_k) = \frac{\sigma^2}{\sum (X_{ki} - \bar{X})^2} \quad (\text{不考虑多重共线情况下})$$

即如果重复抽样很多次，并不会每次都是真实值，而是围绕真实值上下波动，波动幅度取决于随机扰动项波动和X的方差



1.4 分布



在高斯马尔科夫假定下，**增加误差项 u_i 服从正态分布的假定**，那么OLS估计量也服从正态分布。即：


$$\hat{\beta}_k \sim N(\beta_k, Var(\hat{\beta}_k))$$

- 分布即为该随机变量在不同取值处出现的概率，知道分布即知晓了这个随机变量的一般规律
- **正态分布式最有代表性、最常见、最有用的分布之一**，正态分布知道其期望和方差就可以进行标准化，然后据此进行统计推断

>> 1.4 分布



$$z = \frac{\hat{\beta} - \beta}{se(\hat{\beta})}$$



OLS估计量并不是一个确定值，而是一个具有抽样分布的随机变量。在经典假设条件下，它是无偏的，具有一定的方差，并且在样本量足够大时近似服从正态分布。



1.4 分布



在经典假设下，如果误差项 u_i 服从正态分布，那么OLS估计量也服从正态分布。即：

$$\hat{\beta}_k \sim N(\beta_k, \text{Var}(\hat{\beta}_k))$$

- 误差项 u_i 服从正态分布的假定是否成立呢？
- 根据中心极限定理，无论 u_i 是何分布，当n很大的时候， $\hat{\beta}_k$ 也趋近于正态分布

为什么中心极限定理会成立？
(模拟与现实解释)

2 假设检验的基本思想

什么是假设检验？为什么要假设检验？

>> 2.1 女士品茶的故事



□ 一、故事背景

- 主角：植物学家 Muriel Bristol
- Fisher 设计实验验证她能否分辨“先加奶还是后加茶”

🔬 二、实验设计


- 共 8 杯茶：4 杯先加茶后加奶，4 杯先加奶后加茶
- 随机排列，请女士选出哪4杯是“先加奶”的

📊 三、统计推断

- 假设：她是随机猜的
- 反面：她确实能分辨
- 全对的随机概率约 $1/70 \approx 1.4\%$ ，→ 如果随便就能才对，假设错误

💡 四、意义与启示

- 现代统计思想的起点：用实验与概率验证假设
- Fisher《实验设计原理》（1935）奠定假设检验基础



>> 2.1 女士品茶的故事



论迹不论心，论心无完人

很多时候直接证明一件事是困难的（或者说几乎不可能的），但否定一件事是很容易的，因此，有时候我们为了证明一件事是正确的，往往从否定它的反面开始。



2.1 假设检验



- 什么是假设检验？


- 对回归系数假设检验的基本思想是，总体真实值 β 无法知道，对总体回归系数进行某种假设（一般假设 $\beta = 0$ ），然后在所估计样本回归系数概率分布性质已确定的基础上，利用适当地有明确概率分布的统计量和给定的显著性水平，构造一个小概率事件，判断原假设结果合理与否。
- 基于“小概率事件不易发生”的原理，可以认为小概率事件在一次观察中基本不会发生，如果该小概率事件竟然发生了，就认为原假设不真，从而拒绝原假设，不拒绝备择假设。



2.1 假设检验



$$Z = \frac{\hat{\beta} - \beta}{se(\hat{\beta})}$$



2.3 假设检验的基本步骤



- 先提出原假设（一般是 $\beta = 0$ ）
- 再原假设条件下推导得出一个基本结论
- 如果这个结论很显然是错误的（或者是极小概率事件）
- 极小概率事件随便就发生了，那只能说明原假设是错误的
- 拒绝原假设，说明 β 不为0，即X对Y有显著（统计意义上）的影响

3 t检验



3.1 t检验



$$z = \frac{\hat{\beta} - \beta}{se(\hat{\beta})} \sim N(0,1)$$


- 估计值 $\hat{\beta}$ 减去其期望（即真实值 β ）后，再除以其标准差即得到一个均值为0，方差为1的标准正态分布
- 但是，因为估计值的标准误计算中需要知道扰动项的方差 σ^2 ，而总体扰动项的方差未知，只能用样本残差方差去估计，增加了不确定性
- 用残差方差替代总体扰动项方差后z统计量变成了t统计量



3.1 检验



$$t = \frac{\hat{\beta} - \beta}{se(\hat{\beta})}$$



- t分布的形状和标准正态分布很像，也是对称的钟形曲线，但尾部略微更厚。这意味着在小样本情况下，它给极端值留出更大的可能性。
- 随着样本量增加，t分布会逐渐逼近标准正态分布。大样本下，t检验与正态分布几乎没有区别。

3.2 t检验基本步骤



第一步：构造统计量

我们构造统计量：

$$t = \frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)}$$

其中 $se(\hat{\beta}_j)$ 是 $\hat{\beta}_j$ 的标准误差，衡量估计值的波动范围。

第二步：提出原假设与备择假设

原假设通常是解释变量没有作用：

$$H_0: \beta_j = 0$$

备择假设则是它确实有作用：


$$H_1: \beta_j \neq 0$$



3.2 t检验基本步骤



第三步：画出估计量的分布




3.2 t检验基本步骤



第四步：做出统计推断

- 有了估计量的分布，我们便能制定决策规则，有两种等价做法
- 其一是“临界值法”（**先定标准**）：给定显著性水平 α （常用10%、5%、1%），查分布表给定显著性水平下的临界值 T 。当 $|t| > T$ 就拒绝 H_0 。




>> 3.2 t检验基本步骤




第四步：做出统计推断

- 其二是“p值法”（计算概率）：计算在 H_0 成立时，观察到当前 $|t|$ （或更极端）的概率，这个概率就是p值。p值（p-value）是在原假设 H_0 为真的前提下，我们观察到当前样本结果，或比当前结果更极端的结果出现的概率。换句话说：p值衡量的是「当前数据与原假设的冲突程度」。



>> 3.2 t检验基本步骤



红色阴影部分：在 H_0 为真时，落在 $|t| \geq 2.09$ 的区域的概率



3.2 t检验基本步骤



注意事项:

- 正确理解p值很重要：它是在原假设为真时，看到“当前样本结果或更极端结果”的概率；它不是“原假设为真的概率”。当p很小（例如小于0.05），表明在 H_0 为真时出现如此极端样本的机会很低，我们才据此拒绝 H_0 。
- 如果P值小于0.05，解释为在5%的显著性水平上拒绝原假设。
- 显著性水平 α 是“我们能接受多大错判风险的标准”；p值是“数据实际给出的证据强度”。

3.3 t检验的进一步理解



$$t = \frac{\hat{\beta}}{se(\hat{\beta})}$$

- 在t统计量中，分子衡量的是估计值和真实值之间的偏差（信号），分母衡量的是估计值的估计误差（噪音），如果相对于误差来说，这种偏差越大，相对于噪声，信号越强，即通过该样本得到的估计结果在统计上越可信
- 不从分布的角度来看，直观理解：t值越大，相对与系数来说，误差越小表示结果越稳定，样本估计结果越可靠
- 比如 $\hat{\beta} = 0.05$ ， $se(\hat{\beta}) = 0.1$ 对比 $\hat{\beta} = 5$ ， $se(\hat{\beta}) = 1$

>> 3.3 t检验的进一步理解



一个蒙特卡洛模拟



本讲总结



- 样本回归得到的系数只是样本估计量，不能代表总体真实值
- 但样本估计量是期望和方差可计算的随机变量，且估计量服从期望为真实值的正态分布
- 假设真实值为0得到t统计量（n很大时t统计量接近正态分布）
- 根据计算出的t统计量和t分布的特征就能知道小概率事件是否发生（即是否拒绝原假设）
- 如果拒绝原假设，说明估计量统计上是显著不为0
- 即X和Y的关系在统计上成立，X对Y的影响是显著的

下期预告

- 多元回归分析：推断（下）
 - ✓ 区间估计和F检验

作业与思考

- 为什么假设 β 为0?
- 课后习题1-6题

1. 请用自己的话解释：为什么在OLS中，即使回归系数估计值很大，也不能直接断言变量有显著影响？
2. 如果OLS回归误差不服从正态分布，但样本量很大，为什么t检验仍然可以使用？如何理解中心极限定理？请用生活中的例子说明。
3. 已知某企业对50名员工进行培训，收集了培训前后的销售额（单位：千元）。通过简单回归，得到：

$$\widehat{\beta}_1 = 2.5, \quad SE(\widehat{\beta}_1) = 1.0$$

写出原假设 H_0 和备择假设 H_1 。

- (1) 计算t统计量，并在5%显著水平下判断是否拒绝 H_0 。
- (2) 解释结论：培训对销售额是否有显著影响。

4. 假设你想研究广告类型对产品销量的影响，请设计一个完整的回归分析方案，包括：

- (1) 样本设计与数据收集方法
- (2) 原假设与备择假设
- (3) 回归分析步骤和t检验计算
- (4) 如何解释显著性结果及经济意义

5. 利用Stata自带数据集auto.dta完成如下任务：

- (1) 回归分析 price 对 weight、length、mpg 和 foreign 的影响。
- (2) 写出原假设和备择假设，说明每个自变量的经济含义。
- (3) 判断各回归系数的显著性，并解释 t 值含义。
- (4) 手动计算t值并和回归表格给出的t值进行比较。



6. 某研究者想检验培训时间对员工销售额的影响。假设销售额与培训时间有正向关系，并且有一定随机波动。为了帮助理解回归系数的 t 检验和 p 值，设计如下蒙特卡洛模拟实验。

(1) 模拟数据生成：每次生成一个小样本（30个观测值）的培训时间数据。根据设定的规律生成相应的销售额数据，每个观测值的销售额等于基础值加上培训时间影响，再加上随机误差。

(2) 回归分析：对每次模拟数据进行简单线性回归，得到培训时间的回归系数和标准误。根据回归结果计算 t 值，用于判断培训时间是否对销售额有显著影响。

(3) 重复模拟：重复步骤 1-2 共 1000 次，记录每次的回归系数和 t 值。

(4) 分析 t 值分布：绘制 t 值直方图，并与理论 t 分布曲线比较。观察小样本（10个观测值）时 t 值分布比大样本更宽、更“胖尾”，并说明原因。

(5) p 值统计与显著性分析：根据每次 t 值计算双侧 p 值。统计在 5% 显著性水平下拒绝原假设的次数，并计算比例。用简单语言解释 p 值的含义，以及拒绝原假设比例与显著性水平的关系。

(6) 扩展思考：将样本量增加到 300个观测值，重复模拟，并比较 t 值分布与小样本的差异。讨论样本量对 t 值分布和显著性判断的影响。

谢谢，欢迎交流讨论！