




多元回归分析：模型扩展（下）

经济贸易学院 张呈磊

Email:chenglei_zhang@gdufe.edu.cn

2025年11月





对数模型

- 什么是对数模型？
- 什么情况要用对数模型？
- 对数模型结果如何解释？

二次项模型

- 什么是二次项模型？
- 什么情况要用二次项模型？
- 二次项模型结果如何解释？

A solid red arrow pointing to the right, positioned to the left of the title.

目录

CONTENTS



1 虚拟变量



2 交互项模型



3 案例讨论

1 虚拟变量



1.1 虚拟变量



- 一个小问题
 - 我想知道男性和女性工资谁更高，用回归怎么体现性别？
- 两个思考：
 - 什么是数据？什么是变量？
 - 从数值表现来讲，变量有哪些类型？



1.1

虚拟变量



	gender...	birth...	education	educa...	grad...	experi...	mbti	ability	citypo...	citygdp	firmtype	wage
1	Female	1971	Middle	9	1980	3.916997	ESTP	108.4235	801.2543	4464.343	Private	52761.43
2	Male	1982	Master	18	2000	9.42499	ISFP	121.7162	1015.886	6367.354	Private	60347.14
3	Male	1975	Associate	15	1990	5.28265	ENFJ	97.87888	823.5532	6610.193	State	55607.09
4	Female	1965	Associate	15	1980	4.599297	ESTJ	102.965	1356.151	2582.283	Private	51510.8
5	Female	1976	Middle	9	1985	6.349008	ENTJ	98.14072	807.1536	5841.85	Private	46708.39
6	Male	1971	Bachelor	16	1987	8.286954	ISTJ	112.7187	906.7626	2844.329	Private	56201.11
7	Female	1970	Middle	9	1979	6.221437	INFP	115.7356	1256.966	2114.868	Private	54528.08
8	Female	1985	Middle	9	1994	4.785918	ENFP	119.1783	880.0414	6104.27	State	58730.57
9	Male	1983	HighSchool	12	1995	4.790965	ENFP	120.2651	1182.652	5446.978	Foreign	64308.24
10	Male	1995	Bachelor	16	2011	7.84984	ESTJ	86.61054	430.0151	6321.131	Private	42854.74
11	Male	1990	HighSchool	12	2002	4.4248278	ISTJ	116.6593	1327.53	5094.626	Private	81200
12	Female	1996	HighSchool	12	2008	4.171651	ESTJ	121.3023	979.2507	5300.323	Private	56263.31
13	Male	1998	Bachelor	16	2014	7.040967	ESFP	116.3759	378.7365	5214.359	State	49846.18
14	Male	1974	Bachelor	16	1990	1.747456	INTJ	104.2829	1027.034	6438.874	State	46153.16
15	Male	1981	Middle	9	1990	1.375925	ENFJ	98.37462	461.7137	6306.961	State	51221.46
16	Female	1980	Associate	15	1995	9.372436	ENFJ	53.59501	863.0228	5114.441	Private	24780.29
17	Male	1998	Associate	15	2013	4.293701	ISTJ	79.74339	543.6167	2663.566	Private	37768.49
18	Male	1965	Bachelor	16	1981	8.353954	ESFP	97.12944	716.2447	2402.319	Private	49348.05
19	Female	1970	Master	18	1988	0.0140358	ISFJ	120.1311	906.2034	3637.575	Private	56005.3
20	Female	1968	PhD	21	1989	11.72006	INFJ	132.2591	685.5906	1981.578	Foreign	68429.41
21	Female	1971	Master	18	1989	0.6327555	INFP	75.21772	789.9431	3701.779	State	35544.1
22	Female	1970	HighSchool	12	1982	3.869529	INTJ	109.2263	1408.004	6058.354	Private	54414.58
23	Female	1966	Master	18	1984	9.992805	INFP	106.687	894.5957	4081.193	Private	50445.05
24	Female	1994	Bachelor	16	2010	7.866602	ENTJ	119.7752	1330.341	5667.106	Private	.
25	Female	1973	Middle	9	1982	7.96143	INFP	93.34099	180.8827	6689.989	State	49659.9
26	Male	1971	nan	.	1987	4.514349	ISFP	78.1505	670.601	6344.068	Private	.



1.1 虚拟变量



- 许多经济变量是**可以定量度量**，一些影响经济变量的因素是**无法定量度量**（比如性别、地区、学历）。
- 为了在模型中能够反映这些因素的影响，并提高模型的精度，需要将它们“量化”。
- 这种“量化”通常是通过引入“虚拟变量”来完成的。根据这些因素的属性类型，**构造只取“0”或“1”的变量**，通常称为**虚拟变量**或**哑变量**，记为D (Dummy Variable)。



1.1 虚拟变量



dummy variable为什么叫做虚拟变量？如何理解？一段话告诉我。

Dummy variable 之所以叫“虚拟变量”，是因为它本身并不是一个真实可度量的数量，而是人为将类别信息（如性别、行业、是否受政策影响等）用 0/1 等数字替换，使统计模型能够对不同类别进行计算；它起到一种“占位符”或“开关”的作用，代表“属于/不属于某类”，让回归方程在不同组之间切换不同的截距，因此被称为“虚拟”——它不是实际数值，只是为了模型运行而构造的符号化变量。



dummy英文不是愚蠢的意思吗？

是的，**dummy** 在日常英语中确实有“愚蠢/傻子”的意思，但在统计学里它有一个完全不同且专业的含义。

在统计、数学、工程领域，dummy 更接近下面这些含义：

- 占位、临时、代替
- 没有真实含义、只是为了让计算成立而引入
- 形式化的辅助符号



1.1

虚拟变量



grad_year	experience	mbti	ability	citypopula~n	citygdp	firmttype	wage	male	female
1980	3.916997	ESTP	108.4235	801.2543	4464.343	Private	52761.43	0	1
2000	9.42499	ISFP	121.7162	1015.886	6367.354	Private	60347.14	1	0
1990	5.28265	ENFJ	97.87888	823.5532	6610.193	State	55607.09	1	0
1980	4.599297	ESTJ	102.965	1356.151	2582.283	Private	51510.8	0	1
1985	6.349008	ENTJ	98.14072	807.1536	5841.85	Private	46708.39	0	1
1987	8.286954	ISTJ	112.7187	906.7626	2844.329	Private	56201.11	1	0
1979	6.221437	INFP	115.7356	1256.966	2114.868	Private	54528.08	0	1
1994	4.785918	ENFP	119.1783	880.0414	6104.27	State	58730.57	0	1
1995	4.790965	ENFP	120.2651	1182.652	5446.978	Foreign	64308.24	1	0
2011	7.84984	ESTJ	86.61054	430.0151	6321.131	Private	42854.74	1	0
2002	.4248278	ISTJ	116.6593	1327.53	5094.626	Private	81200	1	0
2008	4.171651	ESTJ	121.3023	979.2507	5300.323	Private	56263.31	0	1
2014	7.040967	ESFP	116.3759	378.7365	5214.359	State	49846.18	1	0
1990	1.747456	INTJ	104.2829	1027.034	6438.874	State	46153.16	1	0
1990	1.375925	ENFJ	98.37462	461.7137	6306.961	State	51221.46	1	0
1995	9.372436	ENFJ	53.59501	863.0228	5114.441	Private	24780.29	0	1
2013	4.293701	ISTJ	79.74339	543.6167	2663.566	Private	37768.49	1	0
1981	8.353954	ESFP	97.12944	716.2447	2402.319	Private	49348.05	1	0
1988	.0140358	ISFJ	120.1311	906.2034	3637.575	Private	56005.3	0	1
1989	11.72006	INFJ	132.2591	685.5906	1981.578	Foreign	68429.41	0	1
1989	.6327555	INFP	75.21772	789.9431	3701.779	State	35544.1	0	1
1982	3.869529	INTJ	109.2263	1408.004	6058.354	Private	54414.58	0	1
1984	9.992805	INFP	106.687	894.5957	4081.193	Private	50445.05	0	1
2010	7.866602	ENTJ	119.7752	1330.341	5667.106	Private	.	0	1
1982	7.96143	INFP	93.34099	180.8827	6689.989	State	49659.9	0	1
1987	4.514349	ISFP	78.1505	670.601	6344.068	Private	.	1	0
2014	3.597337	ENTP	94.15485	1546.487	3663.532	Private	49613.86	1	0
1974	3.414345	ESFJ	117.2063	694.1439	7577.646	State	57741.13	1	0
2010	10.27054	ISTP	97.55472	855.6958	5463.62	Private	56816.61	1	0



1.1 虚拟变量



- 虚拟变量的设置原则

- 一般将基准组设置为0，观察组设置为1

- ✓ $D=1$ ，男性

- ✓ $D=0$ ，女性

- ✓ 思考：虚拟变量能否取1、0以外的数值？在Stata软件中如何设置虚拟变量？

- 两个类别是不是要设置两个虚拟变量？

- ✓ 避免完全多重共线，虚拟变量个数需要比定性类别少一个



1.1

虚拟变量



	gender...	birth...	education	educa...	grad_...	experi...	mbti	ability	citypo...	citygdp	firmtype	wage	gender
1	Female	1971	Middle	9	1980	3.916997	ESTP	108.4235	801.2543	4464.343	Private	52761.43	1
2	Male	1982	Master	18	2000	9.42499	ISFP	121.7162	1015.886	6367.354	Private	60347.14	0
3	Male	1975	Associate	15	1990	5.28265	ENFJ	97.87888	823.5532	6610.193	State	55607.09	0
4	Female	1965	Associate	15	1980	4.599297	ESTJ	102.965	1356.151	2582.283	Private	51510.8	1
5	Female	1976	Middle	9	1985	6.349008	ENTJ	98.14072	807.1536	5841.85	Private	46708.39	1
6	Male	1971	Bachelor	16	1987	8.286954	ISTJ	112.7187	906.7626	2844.329	Private	56201.11	0
7	Female	1970	Middle	9	1979	6.221437	INFP	115.7356	1256.966	2114.868	Private	54528.08	1
8	Female	1985	Middle	9	1994	4.785918	ENFP	119.1783	880.0414	6104.27	State	58730.57	1
9	Male	1983	HighSchool	12	1995	4.790965	ENFP	120.2651	1182.652	5446.978	Foreign	64308.24	0
10	Male	1995	Bachelor	16	2011	7.84984	ESTJ	86.61054	430.0151	6321.131	Private	42854.74	0
11	Male	1990	HighSchool	12	2002	.4248278	ISTJ	116.6593	1327.53	5094.626	Private	81200	0
12	Female	1996	HighSchool	12	2008	4.171651	ESTJ	121.3023	979.2507	5300.323	Private	56263.31	1
13	Male	1998	Bachelor	16	2014	7.040967	ESFP	116.3759	378.7365	5214.359	State	49846.18	0
14	Male	1974	Bachelor	16	1990	1.747456	INTJ	104.2829	1027.034	6438.874	State	46153.16	0
15	Male	1981	Middle	9	1990	1.375925	ENFJ	98.37462	461.7137	6306.961	State	51221.46	0
16	Female	1980	Associate	15	1995	9.372436	ENFJ	53.59501	863.0228	5114.441	Private	24780.29	1
17	Male	1998	Associate	15	2013	4.293701	ISTJ	79.74339	543.6167	2663.566	Private	37768.49	0
18	Male	1965	Bachelor	16	1981	8.353954	ESFP	97.12944	716.2447	2402.319	Private	49348.05	0
19	Female	1970	Master	18	1988	.0140358	ISFJ	120.1311	906.2034	3637.575	Private	56005.3	1
20	Female	1968	PhD	21	1989	11.72006	INFJ	132.2591	685.5906	1981.578	Foreign	68429.41	1
21	Female	1971	Master	18	1989	.6327555	INFP	75.21772	789.9431	3701.779	State	35544.1	1
22	Female	1970	HighSchool	12	1982	3.869529	INTJ	109.2263	1408.004	6058.354	Private	54414.58	1
23	Female	1966	Master	18	1984	9.992805	INFP	106.687	894.5957	4081.193	Private	50445.05	1
24	Female	1994	Bachelor	16	2010	7.866602	ENTJ	119.7752	1330.341	5667.106	Private	.	1



1.1 虚拟变量



- 虚拟变量陷阱（回忆多元线性回归经典假设5）

- 每一定性变量所需的虚拟变量个数要比该定性变量的状态类别数少1。即如果有m种状态，只在模型中引入m-1个虚拟变量。
- 例如，季节定性变量有春、夏、秋、冬4种状态，只需要设置3个虚变量：

$$D_1 = \begin{cases} 1 & \text{春季} \\ 0 & \text{其它} \end{cases} \quad D_2 = \begin{cases} 1 & \text{夏季} \\ 0 & \text{其它} \end{cases} \quad D_3 = \begin{cases} 1 & \text{秋季} \\ 0 & \text{其它} \end{cases}$$

>> 1.2 虚拟变量的经济含义



虚拟变量的最简单形式是二元虚拟变量。例如，考虑性别对工资的影响，可以将女性设为1，男性设为0，得到虚拟变量gender。回归模型为：

$$wage_i = \beta_0 + \beta_1 gender_i + u_i$$

其中i表示个体， u_i 为随机误差项。**在该模型中，截距 β_0 表示男性的平均工资， β_1 表示女性相对于男性的平均工资差异。**若回归结果显示 $\hat{\beta}_0=5000$ 元， $\hat{\beta}_1=-300$ 元，则可解释为男性平均工资为5000元，女性平均工资为4700元。这种设置的优点是系数具有明确的经济含义：虚拟变量为1的群体与基准群体（虚拟变量为0）之间的差异。

>> 1.2 虚拟变量的经济含义



当类别变量具有多个水平时，例如行业类型包括A、B、C三类，处理方式类似。若生成三个虚拟变量 D_A, D_B, D_C 并包含截距项，同样会产生共线性问题。标准做法是选择一个基准类别，例如行业A，然后只生成 $k-1=2$ 个虚拟变量 D_B, D_C 。回归模型为：

$$wage_i = \beta_0 + \beta_1 D_{Bi} + \beta_2 D_{Ci} + u_i$$

此时， β_0 表示基准行业A的平均工资， β_1 表示B行业相对于A行业的平均工资差异， β_2 表示C行业相对于A行业的差异。通过这种处理，不仅避免了共线性，还保证了系数的经济解释性。例如，若 $\hat{\beta}_0=4800$ ， $\hat{\beta}_1=200$ ， $\hat{\beta}_2=-100$ ，则行业A工资为4800元，B行业为5000元，C行业为4700元。

>> 1.2 虚拟变量的经济含义



- 在工资决定中同时引入性别和行业：

$$wage_i = \beta_0 + \beta_1 D_{Bi} + \beta_2 D_{Ci} + \beta_3 D_i + u_i$$

此时， β_1 表示B行业相对于A行业的平均工资差异（控制性别）， β_2 表示C行业相对于A行业的差异（控制性别）， β_3 表示女性相对于男性的平均工资差异（控制行业）。

小提示：如果是地区（比如省份）虚拟变量呢？Stata中如何实现？



1.3 思考与讨论



如果定性变量涉及排序呢？

如果被解释变量是虚拟变量呢？（比如是否创业）

如果我们怀疑X对Y的影响存在性别差异，一般怎么做？

2 交互项模型



2.1 交互项模型



受教育程度对工资的回报（Mincer 方程）

基础模型：

$$wage = \beta_0 + \beta_1 education + \beta_2 female + u$$

用一句通俗解释：

- β_1 ：教育每增加 1 年工资提升多少
- β_2 ：女性相比男性平均工资差多少


隐含了教育回报对男女是一样的，但是现实中，大学学历的男女工资差一样吗？



2.1 交互项模型



- 虚拟变量与回归异质性问题
 - 定性变量如何控制?
 - 回归结果是否在不同群体之间有差异?





2.1 交互项模型



$$wage_i = \beta_0 + \beta_1 gender_i + \beta_2 educ_i + \beta_3 gender_i \times educ_i + u_i$$

其中gender为性别虚拟变量（女性为1），当gender=0（女性）时，模型简化为

$$wage_i = \beta_0 + \beta_2 educ_i + u_i$$

此时工资随教育变化的斜率为 β_2

当gender=1（男性）时，模型简化为

$$wage_i = \beta_0 + \beta_1 + \beta_2 educ_i + \beta_3 educ_i + u_i$$

此时工资随教育变化的斜率为 $\beta_2 + \beta_3$

>> 2.2 交互项模型的解释



变量	工资 (log)
教育年限 (Educ)	0.08*** (0.010)
性别 (gender=1)	0.12*** (0.030)
Educ × gender	-0.03** (0.015)
工作经验	0.02*** (0.003)
常数	1.20*** (0.120)
观测值 N	2,000
(R ²)	0.34

1. 基准组是谁？

如果：性别 gender = 1 表示男性，那么基准组 = 女性

所以：教育系数 0.08 表示：在女性群体中，每增加一年教育，工资提高 8%（其他条件相同）

2. 如何读性别系数（gender = 0 vs 1）？

性别系数 0.12 的含义：“在教育水平为 0 年、其他控制变量相同时”，男性工资比女性高 0.12（即12%）

3. 如何解读交互项？

交互项系数-0.03（统计上显著）

含义：男性的教育回报比女性低0.03%（即3%）

换句话说：女性学历每提高一年收入增加8%，男性学历每提高一年，收入增加5%

>> 2.2 交互项模型的解释



为什么需要交互项？

如果一个因素（教育）对不同组（男女）的影响不同，我们就需要让回归“认识到”这种差异——靠交互项。

>> 2.3 交互项的推广



- 斜率的变化可通过以乘法的方式引入虚拟变量来测度。

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \mu_i \quad \frac{\partial Y}{\partial X_1} = \beta_1$$

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{1i} X_{2i} + \mu_i \quad \frac{\partial Y}{\partial X_1} = \beta_1 + \beta_3 X_2$$



2.3 交互项的推广



$$\ln(\text{wage}) = \beta_0 + \beta_1 \cdot \text{educ} + \beta_2 \cdot \text{exper} + \beta_3 \cdot (\text{educ} \times \text{exper}) + u$$

$\beta_3 > 0$ （正号）：

- X_1 和 X_2 是互补的（complementary）
- X_2 越大， X_1 的边际效应越大，正向调节

$\beta_3 < 0$ （负号）：

- X_1 和 X_2 是替代的（substitutes）
- X_2 越大， X_1 的边际效应越小，负向调节

>> 2.3 交互项的推广



课后思考：

- 异质性分析时：交互项与分组回归？
- 交互项的实际应用场景？

- 定性变量用虚拟变量刻画
- 虚拟变量的设置遵循 $k-1$ 原则防止完全共线
- 异质性分析可以考虑虚拟变量构造交互项

3 案例讨论



【计量模型与预期】

根据本章的分析，由于工资数据通常存在偏态分布，我们对工资取自然对数（lnwage）以便系数可解释为近似百分比变化；考虑到工资随工作经验可能呈倒U型趋势，引入经验二次项（experience²）；同时，为分析教育在不同性别中的回报差异，我们引入教育与性别的交互项。我们建立以下多元线性回归模型作为理论基础：

$$\begin{aligned} \lnwage = & \beta_0 + \beta_1 \text{educ_years} + \beta_2 \text{experience} + \beta_3 \text{experience}^2 + \beta_4 \text{age} + \beta_5 \text{gender} \\ & + \beta_6 \text{educ_years} * \text{gender} + u \end{aligned}$$

其中：lnwage为工资的自然对数（被解释变量），educ_years为个体受教育年限，experience为工作经验（年），experience²为工作经验的平方，age为年龄（年），gender为性别，educ_years*gender为受教育年限和性别构造的交互项，u为随机误差项。在回归结果中：



【变量构造与处理】

(1) 对数模型: `gen lnwage = ln(wage) if wage > 0`

对数工资 `ln_wage` 的优势在于, 当其他变量增加一个单位时, 工资的相应变化可以近似解释为百分比变化, 使经济含义更直观。

(2) 二次项模型: `gen exper_sq= exper_sq^2`

回归模型中的系数符号将告诉我们是 U 型还是倒 U 型。

(3) 虚拟变量与交互项: 由于性别只有两类, 只需要设置一个虚拟变量, 避免多重共线问题 (如果同时设置男性和女性两个虚拟变量, 会导致完全共线, 即虚拟变量陷阱)。

接下来, 我们考虑教育与性别的交互项, 用于分析教育对工资的性别异质性。

`gen edu_years_gender = edu_years * gender`

交互项允许模型在不同性别中, 教育对工资的边际效应不同。



1. 工资对数模型:

```
regress lnwage educ_years experience age gender firm_id extrovert, robust
```

2. 二次项模型

```
regress lnwage edu_years experience exper_sq age gender firm_id extrovert, robust
```

3. 交互项模型

```
regress lnwage edu_years experience exper_sq age gender edu_years_gender firm_id extrovert,  
robust
```

进一步，我们还可以讨论教育是否在城市规模直接存在异质性。

下期预告

- 多元回归分析：模型的诊断

作业与思考

- 持续推进实证作业

谢谢，欢迎交流讨论！