




多元回归分析：模型设定与诊断

经济贸易学院 张呈磊

Email:chenglei_zhang@gdufe.edu.cn

2025年11月





什么是高斯马尔科夫定理？

多元回归的五个经典假设是哪些？

A solid red arrow pointing to the right, positioned to the left of the title.

目录

CONTENTS



1 模型设定偏误



2 多重共线问题



3 异方差问题



4 模型的内部有效性和外部有效性

1 模型设定偏误



1.1 模型设定



- 什么是计量模型？

- 计量模型是用数学方程描述经济变量间的关系，并通过统计方法（如多元回归）进行参数估计、假设检验和预测的工具，核心是将经济理论（定性）转化为可量化、可验证的实证框架。


- 计量模型从哪里来？

- 经济理论
- 经济现实

$$\ln(wage_i) = \beta_0 + \beta_1 gender_i + \beta_2 educ_i + \beta_3 exper_i + u_i$$




1.2 模型形式问题




>> 1.2 模型形式问题




Underfitting



Overfitting



Good Fit





- 常见的函数形式

- 简单线性模型 $Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \mu_i$

- 对数模型 $\ln Y = \beta_0 + \beta_1 \ln X + u$

- 二次项模型 $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + u$

- 交互项模型 $Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{1i} X_{2i} + \mu_i$



1.3 控制变量问题



- **控制变量太少带来遗漏变量偏误**

- 遗漏变量偏误是实践中最为常见且危害最大的设定偏误。它是指当某个对因变量 Y 有重要影响的变量 Z 被排除在模型之外，且该变量 Z 与模型中包含的解释变量 X 相关时所产生的系统性误差。其核心后果是导致核心解释变量 X 的系数估计值 $\hat{\beta}$ 不再是无偏的。
- 这意味着，即使样本容量无限增大，估计值也不会收敛到其真实值 β ，而是系统地偏离真实值。
- **即内生性问题！（经典假设3不满足）**



1.3 控制变量问题



- **控制变量太多**

- 控制了和Y无关的变量：吃亏不讨好
- 控制了和Y有关和X无关的变量：酌情考虑
- 控制了太多和Y有关，和X也相关的变量：慎重考虑

2 多重共线问题



2.1 多重共线性问题



- 一个案例

- 为了分析各主要因素对财政收入的影响，建立财政收入(亿元) (CZSR)为被解释变量，财政支出（亿元）（CZZC）、国内生产总值(亿元)(GDP)、税收总额(亿元)(SSZE)等为解释变量的计量模型。设定的理论模型为：

$$CZSR_i = \beta_0 + \beta_1 CZZC_i + \beta_2 GDP_i + \beta_3 SSZE_i + \mu_i$$

- 采用普通最小二乘法得到以下估计结果



2.1 多重共线性问题



```
. reg CZSR CZZC GDP SSZE
```

Source	SS	df	MS	Number of obs	=	50
				F(3, 46)	=	28.75
Model	2568.3241	3	856.108033	Prob > F	=	0.0000
Residual	1372.6759	46	29.8407804	R-squared	=	0.6523
				Adj R-squared	=	0.6328
Total	3941.0000	49	80.4285714	Root MSE	=	5.4627

CZSR	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
CZZC	0.321	0.284	1.13	0.263	-0.250	0.892
GDP	0.215	0.198	1.08	0.285	-0.184	0.614
SSZE	0.452	0.316	1.43	0.159	-0.184	1.088
_cons	12.568	8.342	1.51	0.138	-4.226	29.362



2.1 多重共线性问题



- **模型估计与检验结果分析**

- 拟合优度 R^2 为0.65，调整 R^2 为0.63，模型拟合较好。
- F统计量为28.75，说明0.05水平下回归方程整体上很显著。
- t检验结果表明，各个解释变量对财政收入的影响均不显著，这显然与理论分析和实践经验不相符。为什么会出现这样的异常结果？
- **如果模型设定和数据真实性没问题，问题会出在哪里呢？**



2.1 多重共线性问题



- **多重共线性问题（解释变量之间存在不完全线性相关）**

- 在多元回归 $Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + u_i$ 中，核心解释变量可以用其他解释变量线性表示（ $\alpha_1, \alpha_2 \dots \alpha_k$ 中至少有一个不为 0）

$$X_{1i} = \alpha_0 + \alpha_1 X_{2i} + \alpha_2 X_{3i} + \cdots + \alpha_k X_{ki} + \epsilon_i$$

- 多重共线性是指在多元回归模型中，两个或两个以上的自变量之间存在较强的线性相关关系，导致这些变量在统计上提供的信息高度重复。

多重共线的主要来源

1. 变量本身的关联性

- 例如：GDP、财政收入、社会消费总额本身就是经济系统中高度联动的指标。

2. 数据收集的局限性

- 样本中变量的取值范围过窄（如仅收集某一行业 / 地区数据），放大了变量间的相关性。

3. 模型设定冗余

- 同时引入“总收入”和“可支配收入”等本质重叠的变量。

2.2 多重共线性的后果



- 衡量估计结果稳定性看估计量的方差

$$\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{SST_j(1 - R_j^2)}$$

- 其中 σ^2 是随机扰动项的方差，衡量误差的波动
- SST_j 是解释变量 X_j 的方差，衡量 X_j 的波动
- R_j^2 是 X_j 对其他解释变量回归的得到的可决系数，衡量解释变量共线问题


2.3 多重共线性的后果



$\frac{1}{1 - R_j^2}$ 为方差膨胀因子 (VIF, 一般大于10为存在共线性问题)

- **数学上**, 多重共线越严重, R_j^2 越大, 分母越小, 估计量的方差越大, 估计结果越不稳定
- **直觉上**, 增加控制变量需要多估计一个系数, 但没有提供这么多信息 (X_1 和 X_2 共享了部分信息), 而且信息之间互相干扰, 所以估计量波动大, 不稳定
 - 比如, 在房价影响中, 地段和交通都控制, 其实无法说明到底是地段近还是交通好对房价的影响, 会互相干扰

>> 2.3 多重共线性的后果





多重共线问题的处理

- 1、如果是设定冗余的带来的共线，可以直接删掉冗余变量
- 2、多重共线的后果是方差变大，增加样本容量，可使参数估计量的方差减小。
- 3、使用机器学习方法降维：比如岭回归法

拓展补充：

- **控制变量个数、多重共线性与数据降维**
- **现实研究中对多重共线性的处理**



2.4 多重共线的处理



- 第一，如果是多重共线性，则模型没有违背任何假设，OLS估计量仍是最佳线性无偏估计量（BLUE）；只不过多重共线性的存在导致了某些估计量的方差较大以至影响了估计精度，如果模型已经显著，可以不用处理。
- 第二，可以证明，多元回归中即使某几个解释变量相关性较强，但这不会影响与这几个变量无相关性的其他变量的参数估计的方差。因此，如果只关心那些与其他变量没有相关性的变量或相关性很弱的变量的估计精度时，可以不去理会其他变量的相关性。
- 第三，多重共线性更可能是一种样本现象。同一个模型在一个样本下可能表现出多重共线性，而在另一个样本下可能就不存在多重共线性，因此增加样本容量就有可能消除多重共线性。

3 异方差问题



3.1 异方差问题



$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_k X_{ik} + \mu_i$$

$$\text{Var}(\mu_i) = \sigma^2$$


Homoskedasticity

$$\text{Var}(\mu_i) = \sigma_i^2$$

Heteroskedasticity


即对于不同的样本点，随机误差项的方差不再是常数，而互不相同，则认为出现了**异方差性(Heteroskedasticity)**。

>> 3.1 异方差问题







3.1 异方差问题




同方差



递增方差




递减方差



复杂型



3.2 异方差的后果





3.2 异方差的后果



- OLS 假设所有的误差项方差是相同的，但实际情况是误差项的方差并不相同
 - 高方差观测点（误差较大的点）：这些点对回归的影响应当较小，因为它们的误差项较大，回归系数估计不那么精确。然而，OLS 会低估它们的影响，没有正确修正它们的较大误差。
 - 低方差观测点（误差较小的点）：这个点的误差项较小，应该对回归的影响较大，但 OLS 认为所有点的误差方差相同，所以高估了低方差点的影响。
 - 由于高方差观测点的影响被低估，而低方差观测点的影响被过度高估，最终导致 OLS 对回归模型标准误的估计整体偏小，因为高方差的点对标准误的贡献应该更大，但 OLS 低估了它们的贡献。



3.2 异方差的后果



注意：

- **存在异方差问题，同方差假定不满足，OLS估计量不再是有效的。**
- 一般来说，异方差情况下OLS估计量的标准误会被低估（真实标准误会更大），导致本来不显著的结果容易变得显著。
- 对比多重共线问题，多重共线问题存在估计量方差会变大（标准误被高估），显著的结果容易变得不显著。



3.3 异方差的处理



1、第一类方法：加权最小二乘（谨慎使用）

- 加权最小二乘法是对原模型加权，使之变成一个新的不存在异方差性的模型，然后采用OLS估计其参数。
- 在采用OLS方法时：
 - ✓ 对较小的残差平方赋予较大的权数；
 - ✓ 对较大的残差平方赋予较小的权数。



2、第二类方法：white稳健标准误

- 仍然采用OLS，但对OLS估计量的标准差进行修正。
- 与原始OLS估计比较，参数估计量没有变化，但是参数估计量的方差和标准差变化明显。
- 即使存在异方差问题，在异方差稳健标准误法下，各种传统的显著性检验都是适用的，区间预测也是有效的。



1.1 模型形式问题



表 3 基础模型

变量名	国内大循环					国内国际双循环	
	产品市场一体化			要素市场一体化		全球价值链参与度	
	<i>Nup</i>	<i>Ndown</i>	<i>Friction</i>	<i>Abstauk</i>	<i>Abstaul</i>	<i>Gup</i>	<i>Gdown</i>
	(1)	(2)	(3)	(4)	(5)	(6)	(7)
<i>Digi</i> × <i>Int_{it}</i>	0.008 (0.007)	0.012** (0.006)	-0.167** (0.084)	-4.038* (2.333)	-8.331* (4.496)	-0.003 (0.009)	0.013** (0.006)
常数项	0.005*** (0.001)	0.002*** (0.001)	0.0133 (0.0087)	1.489*** (0.204)	2.196*** (0.497)	0.004*** (0.001)	0.000 (0.001)
样本量	48600	48600	48600	1620	1620	48600	48600
R ²	0.668	0.788	0.014	0.967	0.878	0.830	0.785

注：(1) *Digi_{it}*、*Int_{it}* 低阶解释变量的回归系数已被固定效应吸收，详见模型(11)~(13)；
(2) 括号中为稳健标准误 ***、**、* 分别表示在 1%、5%、10% 水平上显著；(3) 所有回归均在省份层面聚类。下同。

4 内部有效性和外部有效性

>> 4.1 内部有效性



假设1（模型设定）：回归模型是正确设定的，一般是线性。

假设2（数据要求）：样本是随机抽取的。

假设3（随机扰动项期望）：给定解释变量的任何值，随机干扰项的均值为零，即 $E(u_i|X_i) = 0$

假设4（随机扰动项方差）：随机干扰项具有给定任何值条件下的同方差性，即 $Var(u_i|X_i) = \sigma^2$

假设5（无多重共线）：解释变量之间不存在高度线性相关性



4.1 内部有效性



所谓内部有效性，是指模型在研究样本范围内是否能够正确识别并估计所关注变量之间的因果效应。换言之，当我们在样本内得到一个估计结果时，这个结果能否真实反映自变量对因变量的因果影响？若模型本身设定合理、估计方法恰当、样本信息充足，那么模型就具有较高的内部有效性。反之，如果估计存在系统性偏误，模型就失去了在样本内解释因果关系的能力。

内部有效性依赖于回归模型满足一系列关键假设，也就是所谓的“经典线性模型假设”。这些假设共同保证了OLS估计量的无偏性（unbiasedness）和有效性（efficiency）。若这些条件成立，则OLS不仅在样本内能够提供正确的平均估计，而且在所有线性无偏估计量中具有最小方差（即高斯马尔科夫定理）。



4.2 外部有效性



外部有效性关注的是研究结果能否推广到样本之外的其他群体、地区或时间。一个研究可能在特定样本中识别出稳健的因果关系，但若这种关系只在特定环境下成立，则其外部有效性就有限。

外部有效性的实质，是无偏识别在不同环境下的可复制性与稳定性。影响外部有效性的因素包括样本代表性、制度与文化差异、时间变动等。例如，基于城市数据的教育回报率研究，若样本主要来自沿海地区，那么结果是否适用于农村地区？这一问题直接关系到结论的推广能力。



本案例使用的数据集 wage_data.dta 包含劳动者个体信息及所在城市经济指标。主要变量包括工资 (wage)、教育年限 (educ)、是否参加职业培训 (train)、工作经验 (experience)、性别 (gender)、所在城市人均GDP (city_gdp)、城市失业率 (city_unemp) 和地区类别 (region)。我们希望通过分析教育和培训对工资的影响，揭示个人特征与城市经济条件对工资的作用机制。**案例要我们不仅建立多元回归模型，还需关注模型诊断和有效性，使结论在样本内具有因果解释力，并评估在其他环境下的适用性。**



在劳动经济学理论中，教育和培训被视为主要影响工资的因素。工作经验、性别及城市经济条件则作为控制变量，以减少潜在的遗漏变量偏误。基于此，可以提出如下基准回归模型：

$$wage_i = \beta_0 + \beta_1 education_i + \beta_2 experience_i + \beta_3 gender_i + \beta_4 age_i + \beta_5 firm_i + \beta_6 city_i + u_i$$

在模型设定时应注意三个核心问题。

- **首先，模型形式正确性：**需要增加控制变量，同时考虑对数、二次项和交互项模型等。
- **其次，解释变量外生性：**教育年限可能与误差项相关，出现内生性问题，此时OLS估计将不再无偏，需要考虑修正。
- **第三，异方差性和多重共线问题：**若存在异方差，标准误将失真，从而影响显著性判断。城市宏观变量虽然增加解释力，但可能引发多重共线性问题，需要通过VIF等方法检测并适当调整。



1. 数据浏览与描述性统计

在Stata中，可先加载数据并观察变量基本特征：

```
use wage_data.dta, clear
```

```
summarize wage educationyears experience gender age frimtype citypopulation citygdp
```

```
scatter wage educationyears
```

```
scatter wage train
```

通过描述性统计可了解变量均值、标准差及分布情况，散点图有助于初步判断工资与教育、培训的关系。通常可以观察到工资随教育年限增加而上升，同时接受培训的个体工资普遍偏高。



2. 基准回归与系数解释

```
reg wage educ train experience gender city_gdp city_unemp
```

回归结果示例显示，教育每增加一年，工资平均增加约320元；接受培训的个体工资平均比未接受者高450元；经验、性别及城市经济指标均对工资有显著影响。经济意义明确，且系数方向符合理论预期。

3. 多重共线性诊断

通过计算VIF检验变量间高度相关性：

```
vif
```

若发现 city_population 与 city_gdp VIF值过高，可剔除一个或合并指标，避免系数估计不稳定。

4. 异方差检验与稳健标准误

使用Breusch-Pagan或White检验：estat hettest

若存在异方差，可使用稳健标准误修正：

```
reg wage educationyears experience gender age frimtype citypopulation citygdp, robust
```

稳健标准误可以纠正异方差带来的标准误偏差，使显著性判断更可靠。



5. 模型设定检验

使用Ramsey RESET检验检验模型设定：

ovtest

若检验显著，说明模型可能存在非线性或遗漏变量，可考虑加入经验平方项或教育与培训交互项：

$\text{gen experience2} = \text{experience}^2$

$\text{gen educ_gender} = \text{educationyears} * \text{gender}$

`reg wage educationyears experience experience2 educ_gender gender age frimtype citygdp, robust`

6. 内生性与工具变量

教育年限可能存在内生性，讨论内生性问题，并思考如何进行修正。

下期预告

- 面板数据模型

作业与思考

- 持续推进实证作业

谢谢，欢迎交流讨论！