
第二讲 计量复习一：三个基本问题

中级计量经济学 | 张呈磊

回归 · 估计 · 推断

本科计量学过很多东西，你还记得它们为什么存在吗？



本科计量学过很多东西，你还记得它们为什么存在吗？



今天不是重新记公式，而是重新把它们**连起来**。

今天只回答三个问题

① 什么是回归？

我们到底想从数据中知道什么？

今天只回答三个问题

① 什么是回归？

我们到底想从数据中知道什么？

② 什么是参数估计？

那条回归线到底怎么来的？

今天只回答三个问题

① 什么是回归？

我们到底想从数据中知道什么？

② 什么是参数估计？

那条回归线到底怎么来的？

③ 什么是假设检验？

估出来以后，凭什么相信它？

今天只回答三个问题

① 什么是回归？

我们到底想从数据中知道什么？

② 什么是参数估计？

那条回归线到底怎么来的？

③ 什么是假设检验？

估出来以后，凭什么相信它？

回归 → 估计 → 推断

一个你们每天都会遇到的问题

AI 用得越多，成绩会越好吗？

A. 越用越好 B. 越用越差 C. 不一定

为什么大家会有不同答案？

AI 可能提高成绩

搜索资料 解释概念 编程辅助 修改语言 提高效率

AI 也可能降低成绩

直接复制 减少思考 形成依赖 虚假信息 注意力分散

这些都很有道理，但现在只是“故事”。

经济学要进一步问：数据怎么说？


我们有了一份数据

假设调查了 $N = 120$ 名学生。

变量	含义
<i>score</i>	课程成绩
<i>AI</i>	每周用于学习的 AI 时间

如果把 120 名学生画出来，会看到什么？

不要急着下结论：先看数据



有关系吗？
方向如何？
强还是弱？

分析的第一步不是急着套方法，而是先理解数据。

问题一

什么是回归？


从一堆散点中寻找什么？

回归 ▶ 估计 ▶ 推断

数据分析的基本流程



数据分析的基本流程



数据分析的基本流程



数据分析的基本流程




回归分析从**理解数据**开始，而不是从输入 `reg` 开始。

从散点到趋势


能不能用一条线概括
120 个学生背后的总体规律？

从散点到趋势



能不能用一条线概括
120 个学生背后的总体规律？


从散点到趋势



能不能用一条线概括
120 个学生背后的总体规律？

个体观察值很杂乱，但平均关系可能是系统性的。

使用 AI 5 小时，成绩应该是多少？



同样使用 AI 5 小时，为什么成绩还不一样？

回归线不是“命运线”——它不落在任何一个学生身上。

回归描述的是“平均规律”

$$E(score \mid AI)$$

回归关心的是：给定 AI 使用时间时，学生的**平均成绩**如何变化。

回归线 $\neq$ 每一个学生

回归线 = 条件平均关系

$$score_i = \beta_0 + \beta_1 AI_i + u_i$$

$$score_i = \beta_0 + \beta_1 AI_i + u_i$$

β_0

基准水平

从图到模型

$$score_i = \beta_0 + \beta_1 AI_i + u_i$$

β_0

基准水平

β_1

AI 使用时间增加 1 小时，
平均成绩变化多少

从图到模型

$$score_i = \beta_0 + \beta_1 AI_i + u_i$$

β_0

基准水平

β_1

AI 使用时间增加 1 小时，
平均成绩变化多少

u_i

模型没有解释掉的部分

u_i 里面装了什么？

u_i : 没有进入模型，但会影响成绩的因素

学习基础

学习能力

努力程度

出勤

学习时间

睡眠

学习动机


AI 使用方式

考试发挥

其他不可观察因素

如果这些因素和 AI 使用时间有关，会发生什么？ ——先不回答

为什么叫 Regression?



横轴：父母身高

纵轴：子女身高

45 度线

斜率小于 1 的回归线

极高父母的子女通常仍较高，但
平均**没有父母那么极端**。

Regression toward the mean

今天说的“回归”已经不同

Galton

回归均值

现代回归分析

利用数据刻画变量之间的系统性平均关系

什么是回归？

从大量**个体差异**中寻找**平均规律**。


问题二

什么是参数估计？

想要一条回归线，可是谁告诉我们这条线在哪里？

回归 ▶ 估计 ▶ 推断

到底哪条线最好？



A: 明显过陡


B: 明显过平

C: ? 你来判断

三条线都能画，凭什么选其中一条？


继续追问：什么叫“离数据最近”？

从一个学生理解残差



$$AI = 3.94$$


从一个学生理解残差



$AI = 3.94$

实际成绩: $score = 81.2$

从一个学生理解残差




$AI = 3.94$

实际成绩: $score = 81.2$

预测: $\hat{y} = 75.92$

从一个学生理解残差




$$AI = 3.94$$

实际成绩: $score = 81.2$

预测: $\hat{y} = 75.92$

$$\hat{u}_i = y_i - \hat{y}_i = +5.3$$

从一个学生理解残差



$$AI = 3.94$$


实际成绩: $score = 81.2$

预测: $\hat{y} = 75.92$

$$\hat{u}_i = y_i - \hat{y}_i = +5.3$$

残差 = 数据没有被这条线解释掉的部分。

每个学生都有残差



任何一条回归线
都会犯错。

我们不是寻找一条“完全不犯错的线”，而是寻找一条**总体犯错尽可能小**的线。

为什么不直接把残差相加?

$$\sum_i \hat{u}_i$$

为什么不直接把残差相加？

$$\sum_i \hat{u}_i$$

正负会抵消

为什么不直接把残差相加?

$$\sum_i \hat{u}_i$$

正负会抵消

$$\sum_i \hat{u}_i^2$$

为什么不直接把残差相加?

$$\sum_i \hat{u}_i$$

正负会抵消

$$\sum_i \hat{u}_i^2$$

把误差**平方**，再加总。

OLS 的全部直觉

$$\min_{\beta_0, \beta_1} \sum_i \hat{u}_i^2$$

(闭式解不推导。)

OLS 的全部直觉

$$\min_{\beta_0, \beta_1} \sum_i \hat{u}_i^2$$

在所有可能的直线中，找到使残差平方和最小的那一条。

(闭式解不推导。)

OLS 的全部直觉


$$\min_{\beta_0, \beta_1} \sum_i \hat{u}_i^2$$

在所有可能的直线中，找到使**残差平方和最小**的那一条。

这个方法叫 **OLS**：Ordinary Least Squares，**普通最小二乘法**。

(闭式解不推导。)

终于得到这条线



$$\widehat{score} = 70.97 + 1.26 AI$$

每周用于学习的 AI 时间多 1 小时，学生成绩**平均高** 1.26 分。

注意用词：是“**平均高**”，不是“提高”。

一个更基本的问题

$\hat{\beta}_1 = 1.26$ 是精确算出来的一个数，
为什么我们叫它“参数估计”？

一个更基本的问题

$\hat{\beta}_1 = 1.26$ 是精确算出来的一个数，
为什么我们叫它“参数估计”？



换一批学生，这个数就会变—— $\hat{\beta}_1$ 其实是一个随机变量。

总体规律其实看不见

总体

β_0, β_1

未知



用样本认识总体

样本

(x_i, y_i)

可观测

这就是**参数估计**的基本任务。

三个最容易混淆的概念

参数 Parameter

β_1

总体真实关系

固定，但未知

三个最容易混淆的概念

参数 Parameter

β_1
总体真实关系
固定，但未知



估计量 Estimator

$\hat{\beta}_1$
利用样本估计总体参数
的**规则**
是随机变量

三个最容易混淆的概念

参数 Parameter

β_1
总体真实关系
固定，但未知



估计量 Estimator

$\hat{\beta}_1$
利用样本估计总体参数
的**规则**
是随机变量



估计值 Estimate

1.26
这**一次**样本得到的具体
数字

三个最容易混淆的概念

参数 Parameter

β_1
总体真实关系
固定，但未知

估计量 Estimator

$\hat{\beta}_1$
利用样本估计总体参数
的**规则**
是随机变量

估计值 Estimate

1.26
这**一次**样本得到的具体
数字

同一条回归线，三个层次：数字 → 规则 → 规律。

算得出来，不等于估得对

OLS 几乎总能给你一个答案。
但这个答案什么时候值得相信？

Computational question

系数能不能算出来？
通常可以。

Statistical question

这个系数是不是对总体关系的**好估计**？
需要条件。

那么什么是好的估计？要实现好的估计需要什么条件？

“好估计”要过两道关

统计问题问的是：这个系数是不是对总体关系的**好估计**。

那“好”，到底指什么？

（一）期望 准不准

平均来看， $\hat{\beta}_1$ 离真值有多远？

→ 对应后面的**无偏**。

（二）方差 稳不稳

换一批学生， $\hat{\beta}_1$ 波动有多大？

→ 对应后面的**有效**。

准与稳，是“好估计”的两条标准；能不能做到，取决于后面的**经典假设**。

经典线性回归假设：重新看一次

1. 参数线性

模型对**参数**线性。

2. 随机抽样

样本能够代表研究总体。

3. X 有足够变异

不能所有学生 AI 使用时间都相同。

多元回归中推广为： X 各列不能完全共线。

经典线性回归假设：重新看一次

1. 参数线性

模型对**参数**线性。

2. 随机抽样

样本能够代表研究总体。

3. X 有足够变异

不能所有学生 AI 使用时间都相同。

多元回归中推广为： X 各列不能完全共线。

4. 零条件均值 今天最重要

$$E(u|X) = 0$$

5. 同方差 第二重点

$$Var(u|X) = \sigma^2$$

零条件均值到底在说什么？

没有进入模型的因素

学习能力 努力程度 基础成绩
学习动机

?

模型里的自变量

AI 使用时间

这些没进入模型的因素，会不会**系统地**与 AI 使用时间一起变化？

$$E(u \mid AI) = 0$$

给定 AI 使用时间以后，误差项中的其他因素**平均**不应再系统地偏高或偏低。


如果零条件均值不成立?

学习能力
(未观测, 进入 u)


AI 使用时间 X

成绩 Y

如果零条件均值不成立?




如果零条件均值不成立?



学习能力既推高 AI 使用时间，又直接推高成绩。

于是 X 与 u **相关**——OLS 会把学习能力的部分作用**错误地算到 AI 头上**。

如果零条件均值不成立?



学习能力既推高 AI 使用时间, 又直接推高成绩。

于是 X 与 u 相关——OLS 会把学习能力的部分作用错误地算到 AI 头上。


$$E(u|X) = 0$$



OLS 无偏


(不做证明。)

同方差：不是为了保证系数“对”



$$\text{Var}(u | X) = \sigma^2$$

左：宽度基本相同




$$\text{Var}(u | X) \text{ 随 } X \text{ 变化}$$

右：呈“喇叭口”

同方差主要关系到效率和传统标准误，而不是 OLS 无偏性的核心条件。


“准”与“稳”是两个不同问题



无偏：长期来看，**中心对不对**？

无偏 = **不系统性地**猜高或猜低

都无偏，谁更好？



A (较宽): Less efficient

B (较窄): **More efficient**

有效性：在都无偏的情况下，谁的抽样波动更小。

无偏：准不准

有效：稳不稳

Gauss-Markov 定理：只需要理解它在说什么

基本线性模型 + 随机抽样 + X 有足够变异 + 零条件均值

Gauss-Markov 定理：只需要理解它在说什么

基本线性模型 + 随机抽样 + X 有足够变异 + 零条件均值



OLS 无偏

Gauss-Markov 定理：只需要理解它在说什么

基本线性模型 + 随机抽样 + X 有足够变异 + 零条件均值

↓
OLS 无偏

↓
再加：同方差

Gauss-Markov 定理：只需要理解它在说什么

基本线性模型 + 随机抽样 + X 有足够变异 + 零条件均值

OLS 无偏

再加：同方差

OLS 是 BLUE

Best Linear Unbiased Estimator

在线性无偏估计量中，OLS 的方差最小。


如果符合假设，样本得到的估计量就一定能代表总体吗？

$$\hat{\beta}_1 = 1.26$$

这个 1.26 是**真实关系**，还是**这一批学生恰好如此**？

如果换 120 名学生呢？

换一个样本，答案会变




1.25 0.89 1.43 0.72

样本在变，估计值也在变。

所以 $\hat{\beta}_1$ 本身是随机变量。

换一个样本，答案会变



1.25 0.89 1.43 0.72

样本在变，估计值也在变。

所以 $\hat{\beta}_1$ 本身是**随机变量**。

这一次算出来的 1.26，能代表**总体**吗？

问题三

什么是假设检验？

如何区分真实关系和抽样偶然？

回归 ▶ 估计 ▶ 推断

1.26 是真实关系，还是抽样偶然？

这一次样本，我们得到： $\hat{\beta}_1 = 1.26$

1.26 是真实关系，还是抽样偶然？

这一次样本，我们得到： $\hat{\beta}_1 = 1.26$

但前面已经看到：换一个样本，估计值就会变。

1.26 是真实关系，还是抽样偶然？

这一次样本，我们得到： $\hat{\beta}_1 = 1.26$

但前面已经看到：换一个样本，估计值就会变。

那这一次的 1.26，究竟有多稳定？

1.26 是真实关系，还是抽样偶然？


这一次样本，我们得到： $\hat{\beta}_1 = 1.26$

但前面已经看到：换一个样本，估计值就会变。

那这一次的 1.26，究竟有多稳定？

点估计告诉我们「估多少」；
还需要一个指标，告诉我们「这个估计会晃多大」。

标准误：估计值有多不稳定？




$$SE(\hat{\beta}_1) = 0.385$$

标准误描述：如果从**同一个总体**不断重新抽样、重新估计， $\hat{\beta}_1$ 通常会**波动多大**。

概念	含义
残差	某一个学生实际成绩与模型预测之间的差
标准误	某一个 系数估计量 在重复抽样中的 波动程度

标准误：估计值有多不稳定？



$$SE(\hat{\beta}_1) = 0.385$$

标准误描述：如果从**同一个总体**不断重新抽样、重新估计， $\hat{\beta}_1$ 通常会**波动多大**。

概念	含义
残差	某一个学生实际成绩与模型预测之间的差
标准误	某一个 系数估计量 在重复抽样中的 波动程度

但知道了 $SE = 0.385$ 以后，就能直接断言 $\beta_1 \neq 0$ 吗？

不能。 β_1 的真实值我们**看不见**，正面证实做不到。

看不见真实值，那就反过来问

我们想知道 β_1 究竟是多少，
可总体的真实值**看不见**，也没有办法**直接证实**。

看不见真实值，那就反过来问

我们想知道 β_1 究竟是多少，
可总体的真实值**看不见**，也没有办法**直接证实**。

那就**反其道而行之**：
先假设一个世界，再看数据打不打它的脸。

看不见真实值，那就反过来问

我们想知道 β_1 究竟是多少，
可总体的真实值**看不见**，也没有办法**直接证实**。

那就**反其道而行之**：
先**假设**一个世界，再看数据打不打它的脸。

最自然的基准世界：AI 使用时间和成绩之间**没有系统关系** $H_0 : \beta_1 = 0$

看不见真实值，那就反过来问

我们想知道 β_1 究竟是多少，
可总体的真实值**看不见**，也没有办法**直接证实**。

那就反其道而行之：
先假设一个世界，再看数据打不打它的脸。

最自然的基准世界：AI 使用时间和成绩之间**没有系统关系** $H_0: \beta_1 = 0$

如果这个世界是真的， $\hat{\beta}_1$ 就是一个服从某种分布的**随机变量**。

看不见真实值，那就反过来问

我们想知道 β_1 究竟是多少，
可总体的真实值**看不见**，也没有办法**直接证实**。

那就反其道而行之：
先假设一个世界，再看数据打不打它的脸。

最自然的基准世界：AI 使用时间和成绩之间**没有系统关系** $H_0 : \beta_1 = 0$

如果这个世界是真的， $\hat{\beta}_1$ 就是一个服从某种分布的**随机变量**。
于是可以问：出现今天这么极端结果的概率有多大？

看不见真实值，那就反过来问

我们想知道 β_1 究竟是多少，
可总体的真实值**看不见**，也没有办法**直接证实**。

那就反其道而行之：
先假设一个世界，再看数据打不打它的脸。

最自然的基准世界：AI 使用时间和成绩之间**没有系统关系** $H_0 : \beta_1 = 0$

如果这个世界是真的， $\hat{\beta}_1$ 就是一个服从某种分布的**随机变量**。

于是可以问：出现今天这么极端结果的概率有多大？

如果这个概率**极小**，就是撞上了「小概率事件」——
这时我们**宁愿不信**这个假设，「**没有关系**」也就站不住了。

看不见真实值，那就反过来问

我们想知道 β_1 究竟是多少，
可总体的真实值**看不见**，也没有办法**直接证实**。

那就反其道而行之：
先假设一个世界，再看数据打不打它的脸。

最自然的基准世界：AI 使用时间和成绩之间**没有系统关系** $H_0 : \beta_1 = 0$


如果这个世界是真的， $\hat{\beta}_1$ 就是一个服从某种分布的**随机变量**。

于是可以问：出现今天这么极端结果的概率有多大？

如果这个概率**极小**，就是撞上了「小概率事件」——
这时我们**宁愿不信**这个假设，「**没有关系**」也就站不住了。

原假设不是「我们相信它是真的」，而是一个暂时待检验的基准世界；也可以换成 $\beta_1 = 1$ 、 2 等有理论意义的值。


1.26 离 0 究竟有多远？



$$t = \frac{\hat{\beta}_1 - \beta_{1,0}}{SE(\hat{\beta}_1)}$$

t 值 = 估计值距离原假设值有多少个标准误
(信号 ÷ 噪音)

1.26 离 0 究竟有多远？




$$t = \frac{\hat{\beta}_1 - \beta_{1,0}}{SE(\hat{\beta}_1)}$$

$$t = \frac{1.26 - 0}{0.385} \approx 3.27$$

t 值 = 估计值距离原假设值有多少个标准误
(信号 ÷ 噪音)

1.26 离 0 究竟有多远？




$$t = \frac{\hat{\beta}_1 - \beta_{1,0}}{SE(\hat{\beta}_1)}$$

$$t = \frac{1.26 - 0}{0.385} \approx 3.27$$

t 值 = 估计值距离原假设值有多少个标准误
(信号 ÷ 噪音)


3.27 个标准误，到底算不算「很远」？

如果原假设真的成立，3.27 有多罕见？



若 $H_0 : \beta_1 = 0$ 成立，重复抽样得到的 t 应主要围绕 0 波动；
图中标出 -3.27 与 $+3.27$ ，并填充两侧尾部。


如果原假设真的成立，3.27 有多罕见？



若 $H_0 : \beta_1 = 0$ 成立，重复抽样得到的 t 应主要围绕 0 波动；
图中标出 -3.27 与 $+3.27$ ，并填充两侧尾部。

$$p \approx 0.001$$

如果原假设真的成立，3.27 有多罕见？




若 $H_0 : \beta_1 = 0$ 成立，重复抽样得到的 t 应主要围绕 0 波动；
图中标出 -3.27 与 $+3.27$ ，并填充两侧尾部。

$$p \approx 0.001$$

如果原假设真的成立，得到今天这么极端或**更加极端**结果的概率有多大？

如果原假设真的成立，3.27 有多罕见？



若 $H_0 : \beta_1 = 0$ 成立，重复抽样得到的 t 应主要围绕 0 波动；
图中标出 -3.27 与 $+3.27$ ，并填充两侧尾部。

$$p \approx 0.001$$

如果原假设真的成立，得到今天这么极端或**更加极端**结果的概率有多大？

在「AI 与成绩**没有系统关系**」的世界里，出现这么极端的结果**非常罕见**。

既然这么罕见，我们还愿意继续保留「**没有关系**」这个假设吗？

证据够不够强？——做出统计决策

$$H_0 : \beta_1 = 0$$

证据够不够强? ——做出统计决策

$$H_0 : \beta_1 = 0$$

↓

$$t = 3.27$$

证据够不够强? ——做出统计决策

$$H_0 : \beta_1 = 0$$

↓

$$t = 3.27$$

↓

$$p = 0.001$$

证据够不够强? ——做出统计决策

$$H_0 : \beta_1 = 0$$



$$t = 3.27$$



$$p = 0.001$$



事先约定「足够罕见」的门槛 $\alpha = 0.05$, 现在 $p < \alpha$

证据够不够强？——做出统计决策

$$H_0 : \beta_1 = 0$$



$$t = 3.27$$



$$p = 0.001$$



事先约定「足够罕见」的门槛 $\alpha = 0.05$ ，现在 $p < \alpha$



拒绝 H_0

证据够不够强？——做出统计决策

$$H_0 : \beta_1 = 0$$



$$t = 3.27$$



$$p = 0.001$$



事先约定「足够罕见」的门槛 $\alpha = 0.05$ ，现在 $p < \alpha$



拒绝 H_0

证据够不够强？——做出统计决策

$$H_0 : \beta_1 = 0$$



$$t = 3.27$$



$$p = 0.001$$



事先约定「足够罕见」的门槛 $\alpha = 0.05$ ，现在 $p < \alpha$



拒绝 H_0

数据提供了较强证据，反对「AI 与成绩**没有系统关系**」；
两者之间存在**统计显著的正相关**。

但拒绝 $\beta_1 = 0$ ，不等于真实参数一定等于 1.26。

换一种问法：哪些参数值与当前数据仍然相容？

$$\hat{\beta}_1 = 1.26, \quad SE(\hat{\beta}_1) = 0.385$$

换一种问法：哪些参数值与当前数据仍然相容？

$$\hat{\beta}_1 = 1.26, \quad SE(\hat{\beta}_1) = 0.385$$

$$\begin{aligned} 95\% \text{ 置信区间 } &\approx 1.26 \pm 1.96 \times 0.385 \\ &= [0.51, 2.01] \end{aligned}$$

换一种问法：哪些参数值与当前数据仍然相容？

$$\hat{\beta}_1 = 1.26, \quad SE(\hat{\beta}_1) = 0.385$$

$$\begin{aligned} 95\% \text{ 置信区间 } &\approx 1.26 \pm 1.96 \times 0.385 \\ &= [0.51, 2.01] \end{aligned}$$



区间不包含 0

换一种问法：哪些参数值与当前数据仍然相容？

$$\hat{\beta}_1 = 1.26, \quad SE(\hat{\beta}_1) = 0.385$$

$$\begin{aligned} 95\% \text{ 置信区间} &\approx 1.26 \pm 1.96 \times 0.385 \\ &= [0.51, 2.01] \end{aligned}$$



区间不包含 0

点估计告诉我们**中心位置**，标准误告诉我们**不确定性**；
置信区间把两者合起来，给出一组与当前数据**较为相容**的参数值。

假设检验和置信区间：同一套信息的两种表达

假设检验问

「0 这个**特定候选值**还说得通吗？」

$$p = 0.001$$

⇒ 拒绝 $H_0 : \beta_1 = 0$

置信区间问

「**哪些**候选值整体上还说得通？」

$$95\% \text{ CI} = [0.51, 2.01]$$

⇒ 其中**不包含 0**

$$0 \notin 95\% \text{ CI} \iff 5\% \text{ 双侧检验拒绝 } H_0 : \beta_1 = 0$$

假设检验盯住**一个特定值**；置信区间一次展示**一组**与数据相容的值。

最后一个提醒：统计显著 $\neq$ 经济重要

模型 A

$$\hat{\beta} = 0.05, \quad p < 0.001$$

系数**大小** / 置信区间
回答：效应到底**有多大**？
——经济意义的问题

模型 B

$$\hat{\beta} = 2.50, \quad p = 0.08$$

SE / t / p 值
回答：估计**有多准**、证据**有多强**？
——统计不确定性的问题

Magnitude $\neq$ Significance

样本很大时，很小的效应也可能高度显著；样本较小或噪音很大时，较大的效应也可能不显著。

真正完整的结果，不只问「**显不显著**」，还要问「**效应有多大、估得有多准**」。

现在重新看一张最普通的回归表

Variable	Coef.	Std. Err.	<i>t</i>	<i>p</i> -value	[95% Conf. Interval]	
AI time	1.26	0.385	3.27	0.001	0.494	2.018
Constant	70.971	2.275	31.19	0.000	66.466	75.476

$N = 120,$ $R^2 = 0.083$

现在你能逐列解释这张表了吗？

一张表，三个问题

Variable	Coef.	Std. Err.	t	p -value	[95% Conf. Interval]	
AI time	1.26	0.385	3.27	0.001	0.494	2.018
Constant	70.971	2.275	31.19	0.000	66.466	75.476

Coef. → 参数估计 **Std. Err. / t / p -value / 置信区间** → 统计推断

整张表 → 整个模型来自一个**回归问题**。

回归 → 估计 → 推断

AI 用得越多，成绩会越好吗？

$$\hat{\beta}_1 = 1.26, \quad p = 0.001$$

“多使用 AI 一小时，会让成绩提高 1.26 分” 吗？

还不能。

我们漏掉了什么？

学习能力

基础成绩

努力程度

学习时间

学习动机

AI 使用方式

出勤

其他因素

如果这些因素既影响 **AI 使用时间**，也影响**成绩**呢？

$$E(u \mid AI) \neq 0 ?$$

我们漏掉了什么？

学习能力

基础成绩

努力程度

学习时间

学习动机

AI 使用方式

出勤

其他因素

如果这些因素既影响 **AI 使用时间**，也影响**成绩**呢？

$$E(u \mid AI) \neq 0 ?$$

那么，我们的**第一反应**是什么？

那怎么办？——把能观测的因素放进来

现在： $score = \beta_0 + \beta_1 AI + u$



再放几个能观测的因素： $score = \beta_0 + \beta_1 AI + \beta_2 \cdot \text{自习} + \beta_3 \cdot \text{出勤} + u$

方法一模一样

还是让 $\sum \hat{u}_i^2$ 最小 (OLS);
标准误、 t 值、 p 值的做法**完全一样**。

变的只有解释

β_1 从「AI 多的学生平均高多少」
变成「**其他条件不变**，平均高多少」。

那怎么办？——把能观测的因素放进来

现在： $score = \beta_0 + \beta_1 AI + u$



再放几个能观测的因素： $score = \beta_0 + \beta_1 AI + \beta_2 \cdot \text{自习} + \beta_3 \cdot \text{出勤} + u$

方法一模一样

还是让 $\sum \hat{u}_i^2$ 最小（OLS）；
标准误、 t 值、 p 值的做法**完全一样**。

变的只有解释

β_1 从「AI 多的学生平均高多少」
变成「**其他条件不变**，平均高多少」。

多元回归能**彻底解决**遗漏变量偏误吗？ 先带着这个问题下去跑案例；
下一讲「模型设定」再重点说。

相关 $\neq$ 因果

今天能够说

AI 使用时间更多的学生，平均成绩更高；这种相关关系在**统计上显著**。

今天还不能说

多使用 AI 会**使**成绩提高。

Correlation $\neq$ Causation

从“显著相关”到“因果效应”，还需要**更强的研究设计**。

今天只需要带走三句话

1. 什么是回归？

从个体差异中寻找**平均规律**。

2. 什么是参数估计？

用样本去认识**未知的总体**。

3. 什么是假设检验？

判断观察到的关系是否超出了**随机波动**。

回归 → 估计 → 推断

会做回归不难，**知道自己为什么这样做**，才是真正进入中级计量。

下一讲预告：计量复习二

依然是三个基本问题

下一讲预告：计量复习二

依然是三个基本问题

① 模型的变化

同一个变量换一种写法：
对数、交互项、虚拟变量。

下一讲预告：计量复习二

依然是三个基本问题

① 模型的变化

同一个变量换一种写法：
对数、交互项、虚拟变量。

② 模型的设定

该放哪些变量？函数形式
对不对？含控制变量与多元回归。

下一讲预告：计量复习二

依然是三个基本问题

① 模型的变化

同一个变量换一种写法：
对数、交互项、虚拟变量。

② 模型的设定

该放哪些变量？函数形式
对不对？含控制变量与多元回归。

③ 模型的诊断

假设还成不成立？异方差、多重共线、异常值怎么办。

下一讲预告：计量复习二

依然是三个基本问题

① 模型的变化

同一个变量换一种写法：
对数、交互项、虚拟变量。

② 模型的设定

该放哪些变量？函数形式
对不对？含**控制变量与多元回归**。

③ 模型的诊断

假设还成不成立？异方差、多重共线、异常值怎么办。

今天：回归 → 估计 → 推断

下一讲：变化 → 设定 → 诊断

下一讲预告：计量复习二

依然是三个基本问题

① 模型的变化

同一个变量换一种写法：
对数、交互项、虚拟变量。

② 模型的设定

该放哪些变量？函数形式
对不对？含**控制变量与多元回归**。

③ 模型的诊断

假设还成不成立？异方差、多重共线、异常值怎么办。

今天：回归 → 估计 → 推断

下一讲：变化 → 设定 → 诊断

今天学会**读**一个回归，下一讲学会**改**一个回归、**查**一个回归。

教材第 1-3 章案例综合

从蒙特卡洛模拟，到参数估计，再到假设检验——走一遍完整流程

教材第 1-3 章案例综合

从蒙特卡洛模拟，到参数估计，再到假设检验——走一遍完整流程

① 蒙特卡洛模拟

先造一个“真相已知”的世界。

教材第 1-3 章案例综合

从蒙特卡洛模拟，到参数估计，再到假设检验——走一遍完整流程

① 蒙特卡洛模拟

先造一个“真相已知”的世界。

② 参数估计

用样本把真相估出来。

教材第 1-3 章案例综合

从蒙特卡洛模拟，到参数估计，再到假设检验——走一遍完整流程

① 蒙特卡洛模拟

先造一个“真相已知”的世界。

② 参数估计

用样本把真相估出来。

③ 假设检验

判断估计可不可信。

教材第 1-3 章案例综合

从蒙特卡洛模拟，到参数估计，再到假设检验——走一遍完整流程

① 蒙特卡洛模拟

先造一个“真相已知”的世界。

② 参数估计

用样本把真相估出来。

③ 假设检验

判断估计可不可信。

全程以**最小 AI Agent 工作流**为载体：自己动手搭一次，让 AI 帮你把这三步跑通。

会用工具不是目的——**知道每一步在干什么**才是。