

---

## 第三讲 模型设定与诊断


从「会回归」到「会建模」

中级计量经济学 | 张呈磊

形式 · 控制 · 诊断


## 第二讲我们做了什么？

---



## 第二讲我们做了什么？


---



第二讲解决了一个问题：

## 第二讲我们做了什么？

---



第二讲解决了一个问题：

给你一个模型，你会不会估？

## 但我们偷偷假设了一件事

---

$$Y = \beta_0 + \beta_1 X + u$$

## 但我们偷偷假设了一件事

---

$$Y = \beta_0 + \beta_1 X + u$$

这个模型是谁告诉我们的？

## 但我们偷偷假设了一件事

---

$$Y = \beta_0 + \beta_1 X + u$$

这个模型是谁告诉我们的？

为什么是线性的？

为什么用  $Y$  而不是  $\ln Y$ ？

为什么只有  $X$ ？

为什么控制这些变量？

为什么没有另外一些变量？

## 现实研究没有标准答案

---

没有人会把「正确模型」提前交给研究者。

## 现实研究没有标准答案

---

没有人会把「正确模型」提前交给研究者。

真正的应用计量首先是一个建模问题。

## 今天三个问题

---

① 经济关系应该  
怎样写进模型？

函数形式

## 今天三个问题

---

① 经济关系应该怎样写进模型？

函数形式

② 多元回归究竟在「控制」什么？

模型设定与 FWL

## 今天三个问题

---

① 经济关系应该怎样写进模型？

函数形式

② 多元回归究竟在「控制」什么？

模型设定与 FWL

③ 怎样发现模型可能出了问题？

诊断与处理

## 今天三个问题

---

① 经济关系应该怎样写进模型？

函数形式

② 多元回归究竟在「控制」什么？

模型设定与 FWL

③ 怎样发现模型可能出了问题？

诊断与处理

形式 → 控制 → 诊断 → 因果？

---


问题一

# 经济关系应该怎样写进模型？

现实关系一定是一条直线吗？


形式 ▶ 控制 ▶ 诊断

## 我们最熟悉的模型




$$Y = \beta_0 + \beta_1 X + u$$

## 我们最熟悉的模型



$$Y = \beta_0 + \beta_1 X + u \quad \Delta X = 1 \Rightarrow \Delta Y = \beta_1$$


## 我们最熟悉的模型



$$Y = \beta_0 + \beta_1 X + u \quad \Delta X = 1 \Rightarrow \Delta Y = \beta_1$$


这个模型背后有一个很强的假定： $X$  在任何位置增加 1 单位， $Y$  的变化都一样。

## 对数：我们到底关心「多少」还是「百分比」？



同样增加 1 万元，经济意义完全不同

## 对数：我们到底关心「多少」还是「百分比」？



有时候我们真正关心的不是「增加多少」，而是「增加百分之多少」。

## 为什么经济学喜欢 $\ln$ ?

---

有时候经济主体对比例变化比对绝对变化更敏感。

## 为什么经济学喜欢 $\ln$ ?

---

有时候经济主体对比例变化比对绝对变化更敏感。

|     |   |     |
|-----|---|-----|
| 水平  | → | 水平  |
| 水平  | → | 百分比 |
| 百分比 | → | 水平  |
| 百分比 | → | 百分比 |

## 四种基本解释


|        | $X$ 水平                                                                      | $X$ 对数                                                                       |
|--------|-----------------------------------------------------------------------------|------------------------------------------------------------------------------|
| $Y$ 水平 | <b>Level–Level</b><br>$Y = \beta_0 + \beta_1 X + u$<br>单位 $\rightarrow$ 单位  | <b>Log–Level</b><br>$\ln Y = \beta_0 + \beta_1 X + u$<br>单位 $\rightarrow$ %  |
| $Y$ 对数 | <b>Level–Log</b><br>$Y = \beta_0 + \beta_1 \ln X + u$<br>% $\rightarrow$ 单位 | <b>Log–Log</b><br>$\ln Y = \beta_0 + \beta_1 \ln X + u$<br>% $\rightarrow$ % |

## 四种基本解释


|        | $X$ 水平                                                                      | $X$ 对数                                                                       |
|--------|-----------------------------------------------------------------------------|------------------------------------------------------------------------------|
| $Y$ 水平 | <b>Level–Level</b><br>$Y = \beta_0 + \beta_1 X + u$<br>单位 $\rightarrow$ 单位  | <b>Log–Level</b><br>$\ln Y = \beta_0 + \beta_1 X + u$<br>单位 $\rightarrow$ %  |
| $Y$ 对数 | <b>Level–Log</b><br>$Y = \beta_0 + \beta_1 \ln X + u$<br>% $\rightarrow$ 单位 | <b>Log–Log</b><br>$\ln Y = \beta_0 + \beta_1 \ln X + u$<br>% $\rightarrow$ % |

看到模型以后，先要知道  $\beta$  究竟回答什么经济问题。

## 另一种非线性




## 另一种非线性



对数是一种非线性；还有另一种——**关系本身就弯**。


## 另一种非线性



对数是一种非线性；还有另一种——**关系本身就弯**。

AI 从 0 增加到 1，与从 8 增加到 9，对成绩的作用一定一样吗？

## 另一种非线性




对数是一种非线性；还有另一种——**关系本身就弯**。


AI 从 0 增加到 1，与从 8 增加到 9，对成绩的作用一定一样吗？

**函数形式本身就是经济假设。**

## 二次项：如果边际效应不是恒定的呢？




## 二次项：如果边际效应不是恒定的呢？



AI 使用增加 1 单位，在曲线的不同位置作用一样吗？

## 二次项：如果边际效应不是恒定的呢？



AI 使用增加 1 单位，在曲线的不同位置作用一样吗？

同一张图里， $\Delta X$  相同而  $\Delta Y$  截然不同。

## 加了 $X^2$ ，还是线性回归吗？

---

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + u$$

- ▶  $Y$  与  $X$  的关系**不是直线**；
- ▶ 但对参数  $\beta_0, \beta_1, \beta_2$  **仍然是线性的**；
- ▶ 所以仍然是线性回归，可以用 OLS 估计。

$$Y = \beta_0 + X^{\beta_1} + u$$

- ▶ 参数  $\beta_1$  以**非线性方式**进入模型；
- ▶ 这已经**不是**普通线性回归框架。

## 加了 $X^2$ ，还是线性回归吗？

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + u$$

- ▶  $Y$  与  $X$  的关系**不是直线**；
- ▶ 但对参数  $\beta_0, \beta_1, \beta_2$  **仍然是线性的**；
- ▶ 所以仍然是线性回归，可以用 OLS 估计。

$$Y = \beta_0 + X^{\beta_1} + u$$

- ▶ 参数  $\beta_1$  以**非线性方式**进入模型；
- ▶ 这已经**不是**普通线性回归框架。

线性回归里的「线性」，核心是**对参数线性**，  
而不是要求  $Y$  与  $X$  必须是一条直线。

## 二次项：影响可以改变

---

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + u$$

## 二次项：影响可以改变

---

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + u$$

$$\frac{\partial Y}{\partial X} = \beta_1 + 2\beta_2 X$$

## 二次项：影响可以改变

---

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + u$$

$$\frac{\partial Y}{\partial X} = \beta_1 + 2\beta_2 X$$

二次项： $X$  的边际效应随  $X$  自身的位置而改变。

## 二次项：影响可以改变

---


$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + u$$

$$\frac{\partial Y}{\partial X} = \beta_1 + 2\beta_2 X$$


二次项： $X$  的边际效应随  $X$  自身的位置而改变。

有二次项以后，不能只看  $\beta_1$  解释  $X$  的作用。

## 交互项：所有人的 $\beta$ 都一样吗？



## 交互项：所有人的 $\beta$ 都一样吗？



AI 对基础好的学生和基础弱的学生，作用一定一样吗？

## 交互项：作用可以因人而异

---

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + \beta_3 XZ + u$$

## 交互项：作用可以因人而异

---

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + \beta_3 XZ + u$$

$$\frac{\partial Y}{\partial X} = \beta_1 + \beta_3 Z$$

## 交互项：作用可以因人而异

---

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + \beta_3 XZ + u$$

$$\frac{\partial Y}{\partial X} = \beta_1 + \beta_3 Z$$

$X$  的作用**取决于**  $Z$ 。

二次项：边际效应随  $X$  改变      交互项：边际效应随  $Z$  改变

## 交互项：作用可以因人而异

---

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + \beta_3 XZ + u$$

$$\frac{\partial Y}{\partial X} = \beta_1 + \beta_3 Z$$

$X$  的作用**取决于**  $Z$ 。

二次项：边际效应随  $X$  改变

交互项：边际效应随  $Z$  改变

这其实已经是最简单的「**异质性分析**」——为以后的实证论文埋伏笔。

## 交互项：两组中的 $X$ 作用是否不同？

---

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + \beta_3 (X \times Z) + u$$
$$Z = 0/1$$

## 交互项：两组中的 $X$ 作用是否不同？

---

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + \beta_3 (X \times Z) + u$$
$$Z = 0/1$$

$Z = 0$ :  $X$  的作用  $= \beta_1$

$Z = 1$ :  $X$  的作用  $= \beta_1 + \beta_3$

## 交互项：两组中的 $X$ 作用是否不同？

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + \beta_3 (X \times Z) + u$$
$$Z = 0/1$$

$Z = 0$ :  $X$  的作用  $= \beta_1$

$Z = 1$ :  $X$  的作用  $= \beta_1 + \beta_3$

$$(\beta_1 + \beta_3) - \beta_1 = \beta_3$$

$\beta_3 =$  两组中  $X$  作用的差

## 交互项：两组中的 $X$ 作用是否不同？

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + \beta_3 (X \times Z) + u$$

$Z = 0/1$

$Z = 0$ :  $X$  的作用  $= \beta_1$


$Z = 1$ :  $X$  的作用  $= \beta_1 + \beta_3$

$$(\beta_1 + \beta_3) - \beta_1 = \beta_3$$

$\beta_3 =$  两组中  $X$  作用的差

$Z = 0$ :  $X$  的作用

$Z = 1$ :  $X$  的作用



## 交互项：两组中的 $X$ 作用是否不同？

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + \beta_3 (X \times Z) + u$$

$Z = 0/1$

$Z = 0$ :  $X$  的作用 =  $\beta_1$

$Z = 1$ :  $X$  的作用 =  $\beta_1 + \beta_3$

$$(\beta_1 + \beta_3) - \beta_1 = \beta_3$$


$\beta_3 =$  两组中  $X$  作用的差

$\beta_1 =$  基准组斜率,  $\beta_3 =$  斜率之差,  $\beta_1 + \beta_3 =$  另一组斜率

$\beta_3$  显著, 说明两组中  $X$  的作用确实存在显著差异。

$Z = 0$ :  $X$  的作用

$Z = 1$ :  $X$  的作用



交互项为正, 表示从  $Z = 0$  到  $Z = 1$ ,  
 $X$  的作用向「更正」的方向移动。

如果  $Z$  是连续变量：斜率会随  $Z$  改变

---

## 如果 $Z$ 是连续变量：斜率会随 $Z$ 改变

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + \beta_3 XZ + u \Rightarrow$$
$$\frac{\partial Y}{\partial X} = \beta_1 + \beta_3 Z$$

$\beta_3 > 0$ :  $Z$  越大,  $X$  的边际效应越往正方向「拉」。

$\beta_3 < 0$ :  $Z$  越大,  $X$  的边际效应越往负方向「拉」。

## 如果 $Z$ 是连续变量：斜率会随 $Z$ 改变

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + \beta_3 XZ + u \Rightarrow$$
$$\frac{\partial Y}{\partial X} = \beta_1 + \beta_3 Z$$

$\beta_3 > 0$ :  $Z$  越大,  $X$  的边际效应越往正方向「拉」。

$\beta_3 < 0$ :  $Z$  越大,  $X$  的边际效应越往负方向「拉」。

$$\hat{\beta}_1 = -2, \quad \hat{\beta}_3 = 0.5 \Rightarrow ME_X = -2 + 0.5Z$$

$$Z = 0 : -2 \quad Z = 2 : -1 \quad Z = 4 : 0$$

$$Z = 6 : +1$$

$$-2 \rightarrow -1 \rightarrow 0 \rightarrow +1$$

## 如果 $Z$ 是连续变量：斜率会随 $Z$ 改变

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + \beta_3 XZ + u \Rightarrow$$

$$\frac{\partial Y}{\partial X} = \beta_1 + \beta_3 Z$$

$\beta_3 > 0$ :  $Z$  越大,  $X$  的边际效应越往**正**方向「拉」。


$\beta_3 < 0$ :  $Z$  越大,  $X$  的边际效应越往**负**方向「拉」。

$$\hat{\beta}_1 = -2, \quad \hat{\beta}_3 = 0.5 \Rightarrow ME_X = -2 + 0.5Z$$

$$Z = 0 : -2 \quad Z = 2 : -1 \quad Z = 4 : 0$$

$$Z = 6 : +1$$

$$-2 \rightarrow -1 \rightarrow 0 \rightarrow +1$$



$\beta_3 > 0 \Rightarrow$  边际效应随  $Z$  上移

## 如果 $Z$ 是连续变量：斜率会随 $Z$ 改变

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + \beta_3 XZ + u \Rightarrow$$

$$\frac{\partial Y}{\partial X} = \beta_1 + \beta_3 Z$$

$\beta_3 > 0$ :  $Z$  越大,  $X$  的边际效应越往**正**方向「拉」。


$\beta_3 < 0$ :  $Z$  越大,  $X$  的边际效应越往**负**方向「拉」。

$$\hat{\beta}_1 = -2, \quad \hat{\beta}_3 = 0.5 \Rightarrow ME_X = -2 + 0.5Z$$

$$Z = 0 : -2 \quad Z = 2 : -1 \quad Z = 4 : 0$$

$$Z = 6 : +1$$

$$-2 \rightarrow -1 \rightarrow 0 \rightarrow +1$$




$\beta_3 > 0 \Rightarrow$  边际效应随  $Z$  上移


$\beta_3$  决定「效应**怎么变**」;  $\beta_1 + \beta_3 Z$  决定「效应**是什么**」。

虚拟变量交互：比较「两条斜率」; 连续变量交互：斜率随  $Z$  连续变化。

# 函数形式不是数学装饰




# 函数形式不是数学装饰



| 形式  | 代表公式                                                   | 边际效应     |
|-----|--------------------------------------------------------|----------|
| 线性  | $Y = \beta_0 + \beta_1 X + u$                          | 恒定       |
| 对数  | $\ln Y = \beta_0 + \beta_1 \ln X + u$                  | 比例变化     |
| 二次项 | $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + u$            | 随 $X$ 改变 |
| 交互项 | $Y = \beta_0 + \beta_1 X + \beta_2 Z + \beta_3 XZ + u$ | 随 $Z$ 改变 |

## 函数形式不是数学装饰



| 形式  | 代表公式                                                   | 边际效应     |
|-----|--------------------------------------------------------|----------|
| 线性  | $Y = \beta_0 + \beta_1 X + u$                          | 恒定       |
| 对数  | $\ln Y = \beta_0 + \beta_1 \ln X + u$                  | 比例变化     |
| 二次项 | $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + u$            | 随 $X$ 改变 |
| 交互项 | $Y = \beta_0 + \beta_1 X + \beta_2 Z + \beta_3 XZ + u$ | 随 $Z$ 改变 |

选择函数形式，本质上是在表达**我们认为经济关系是什么样的**。

## 那么模型形式怎么选？

---

+

经济理论

数据特征

研究问题

+

## 那么模型形式怎么选？

---

+

经济理论

数据特征

研究问题

+

不能只看散点图决定模型；也不能完全脱离数据机械套理论。

## 那么模型形式怎么选？

---

+

经济理论

数据特征

研究问题

+

不能只看散点图决定模型；也不能完全脱离数据机械套理论。

即使函数形式选好了，模型里面到底应该放哪些变量？

---

问题二

# 多元回归究竟在「控制」什么？

「其他条件不变」到底是怎么做到的？

形式 ▶ 控制 ▶ 诊断

## 最简单的回归

---

$$\text{Score}_i = \beta_0 + \beta_1 \text{AI}_i + u_i$$

## 最简单的回归

---

$$\text{Score}_i = \beta_0 + \beta_1 \text{AI}_i + u_i$$

假设  $\hat{\beta}_1 = 2.5$

## 最简单的回归

---

$$\text{Score}_i = \beta_0 + \beta_1 \text{AI}_i + u_i$$

假设  $\hat{\beta}_1 = 2.5$

这个 2.5 到底包含了什么？

## 一个被遗漏的变量

---


学习能力  
Ability

AI 使用程度  
AI


学习成绩  
Score

## 一个被遗漏的变量


---



## 一个被遗漏的变量




## 一个被遗漏的变量



但 Ability 没有进入模型  $\Rightarrow$  它落进了  $u$

## 一个被遗漏的变量



但 Ability 没有进入模型  $\Rightarrow$  它落进了  $u$

如果回归中没有 Ability, **AI** 的系数会包含什么?

## 回到第二讲最重要的那个条件

---

$$E(u \mid X) = 0$$

## 回到第二讲最重要的那个条件

---

$$E(u \mid X) = 0$$

如果 Ability 进入  $u$ ，而且 Ability 与 AI 有关……

## 回到第二讲最重要的那个条件

---

$$E(u \mid X) = 0$$

如果 Ability 进入  $u$ ，而且 Ability 与 AI 有关……

$$E(u \mid AI) \neq 0$$

## 回到第二讲最重要的那个条件

---

$$E(u \mid X) = 0$$


如果 Ability 进入  $u$ ，而且 Ability 与 AI 有关……

$$E(u \mid AI) \neq 0$$

模型设定问题可以直接破坏 **OLS** 的基本假设——这是第二讲与第三讲最重要的连接点。


## 加入控制变量以后

$$\text{Score}_i = \beta_0 + \beta_1 \text{AI}_i + \beta_2 \text{Ability}_i + u_i$$



## 加入控制变量以后

$$\text{Score}_i = \beta_0 + \beta_1 \text{AI}_i + \beta_2 \text{Ability}_i + u_i$$



为什么一个变量进入模型，AI 的系数就变了？

## 最常见的解释

---

「控制 Ability 不变以后，AI 对 Score 的影响。」

## 最常见的解释

---

「控制 Ability 不变以后，AI 对 Score 的影响。」

这句话大家本科就会说。

## 最常见的解释

---

「控制 Ability 不变以后，AI 对 Score 的影响。」

这句话大家本科就会说。

但 OLS 究竟是怎么做到「控制不变」的？

## FWL Theorem

---

# Frisch–Waugh–Lovell

多元回归背后的「净化比较」

## 我们想知道

---

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + u$$

## 我们想知道

---

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + u$$

目标：  $\beta_1 = ?$

## 我们想知道


---

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + u$$


目标：  $\beta_1 = ?$

怎样把  $Z$  的影响拿掉？

## FWL 第 1 步：先净化 $X$




## FWL 第 1 步：先净化 $X$




$X \leftarrow Z$  得到  $\tilde{X}$  「不能被  $Z$  解释的那部分 variation」

## FWL 第 2 步：再净化 $Y$




## FWL 第 2 步：再净化 $Y$




$Y \leftarrow Z$  得到  $\tilde{Y}$  「不能被  $Z$  解释的那部分 variation」

## FWL 第 3 步：剩余解释剩余




## FWL 第 3 步：剩余解释剩余



$$\tilde{Y} = \beta_1 \tilde{X} + \text{error} \quad Z \text{ 已被两边同时剔除}$$

## FWL 第 3 步：剩余解释剩余




$$\tilde{Y} = \beta_1 \tilde{X} + \text{error} \quad Z \text{ 已被两边同时剔除}$$

这个回归的斜率，**恰好等于**原多元回归中  $X$  的系数。

## FWL 真正告诉了我们什么？

---




## FWL 真正告诉了我们什么？

---



# 控制 = Partialling Out


## FWL 真正告诉了我们什么？




# 控制 = Partialling Out

先剔除控制变量能够解释的部分，再利用**剩余 variation** 进行比较。

## 「其他条件不变」的真正含义




## 「其他条件不变」的真正含义



不要再停在抽象的 hold  $Z$  constant。

OLS 寻找的是  $Z$  相似、但  $X$  仍然存在差异的那部分 variation。

## 「其他条件不变」的真正含义




$$X = \underbrace{\hat{X}(Z)}_{\text{能被控制变量解释}} + \underbrace{\tilde{X}}_{\text{净 variation}}$$

不要再停在抽象的 hold  $Z$  constant。

OLS 寻找的是  $Z$  相似、但  $X$  仍然存在差异的那部分 variation。

## 「其他条件不变」的真正含义




$$X = \underbrace{\hat{X}(Z)}_{\text{能被控制变量解释}} + \underbrace{\tilde{X}}_{\text{净 variation}}$$

不要再停在抽象的 hold  $Z$  constant。

OLS 寻找的是  $Z$  相似、但  $X$  仍然存在差异的那部分 variation。

一个回归系数不是由  $X$  的**全部** variation 识别出来的，  
而是由**控制其他变量后仍然剩下的 variation** 识别出来的。

## 「其他条件不变」的真正含义



$$X = \underbrace{\hat{X}(Z)}_{\text{能被控制变量解释}} + \underbrace{\tilde{X}}_{\text{净 variation}}$$

不要再停在抽象的 hold  $Z$  constant。

OLS 寻找的是  $Z$  相似、但  $X$  仍然存在差异的那部分 variation。

**Which variation identifies  $\beta$ ?**

以后学 FE、IV、DiD、DML 都要追问：  
Where does the identifying variation come from?

一个回归系数不是由  $X$  的**全部** variation 识别出来的，  
而是由**控制其他变量后仍然剩下的 variation** 识别出来的。

## 一个更远的伏笔：Machine Learning

---

$$X \leftarrow Z \Rightarrow \tilde{X}$$

$$Y \leftarrow Z \Rightarrow \tilde{Y}$$

## 一个更远的伏笔：Machine Learning

---

$$X \leftarrow Z \Rightarrow \tilde{X}$$

$$Y \leftarrow Z \Rightarrow \tilde{Y}$$

今天：用线性回归剔除  $Z$ 。      以后：如果  $Z$  很多、关系很复杂呢？

## 一个更远的伏笔：Machine Learning

$$X \leftarrow Z \Rightarrow \tilde{X}$$

$$Y \leftarrow Z \Rightarrow \tilde{Y}$$

今天：用线性回归剔除  $Z$ 。      以后：如果  $Z$  很多、关系很复杂呢？

Machine Learning



Partialling Out



DML

## 一个更远的伏笔：Machine Learning

$$X \leftarrow Z \Rightarrow \tilde{X}$$

$$Y \leftarrow Z \Rightarrow \tilde{Y}$$

今天：用线性回归剔除  $Z$ 。以后：如果  $Z$  很多、关系很复杂呢？


Machine Learning

Partialling Out

DML


记住「先净化，再比较」这个思想就够了。

## 三类变量



**Confounder**

通常要认真控制



**Precision Variable**


可能提高估计精度



**Mediator**


不能机械控制

## 三类变量



**Confounder**

通常要认真控制



**Precision Variable**

可能提高估计精度



**Mediator**

不能机械控制

重点不是背英文，而是：不同变量进入模型的理由完全不同。

## 一个看起来「应该控制」的变量

---



## 一个看起来「应该控制」的变量

---



## 一个看起来「应该控制」的变量



如果我们研究 AI 对成绩的**总影响**，应该控制学习时间吗？

## 一个看起来「应该控制」的变量



如果我们研究 AI 对成绩的**总影响**，应该控制学习时间吗？

先别急着给答案——记住这条链，最后我们会回到它。

## Controls 越多越好吗？

---

控制变量不是「越多越好」。

## Controls 越多越好吗？

---

控制变量不是「越多越好」。

控制谁，取决于你想回答什么问题，  
以及你认为数据是怎样产生的。

## Controls 越多越好吗？

---

控制变量不是「越多越好」。

控制谁，取决于你想回答什么问题，  
以及你认为数据是怎样产生的。

控制变量不仅影响精度，也可能改变我们究竟在估计什么。  
这个问题会在后面的因果识别与实证设计中再次出现。

---


问题三

# 怎样发现模型可能出了问题？


从坏控制说起：先看共线，再看误差

形式 ▶ 控制 ▶ 诊断

## 如果两个 $X$ 几乎说的是同一件事




## 如果两个 $X$ 几乎说的是同一件事




模型怎么知道到底是谁在解释  $Y$ ?

## 共线性伤害什么？




## 共线性伤害什么？



$\text{Var}(\hat{\beta}) \uparrow$     标准误变大 · 系数不稳定 · 单个变量可能不显著

## 共线性伤害什么？



$\text{Var}(\hat{\beta}) \uparrow$     标准误变大 · 系数不稳定 · 单个变量可能不显著

**Multicollinearity  $\neq$  Bias**

# VIF 告诉我们什么?

---

Correlation · VIF

## VIF 告诉我们什么?

---

### Correlation · VIF

VIF 高，意味着某个  $X$  的大量 variation 已经能够被其他  $X$  解释。

## VIF 告诉我们什么？

---

### Correlation · VIF

VIF 高，意味着某个  $X$  的大量 variation 已经能够被其他  $X$  解释。

回到 FWL：留给这个  $X$  自己的「净 variation」越来越少。

## VIF 很高，怎么办？

---

- ① 变量在理论上**必须控制** ⇒ 可以保留，接受较大的标准误
- ② 两个变量在测量**同一概念** ⇒ 重新定义变量，或构造综合指标
- ③ 真正缺乏**独立 variation** ⇒ 需要更多数据，或更好的研究设计

## VIF 很高，怎么办？

---

- ① 变量在理论上**必须控制** ⇒ 可以保留，接受较大的标准误
- ② 两个变量在测量**同一概念** ⇒ 重新定义变量，或构造综合指标
- ③ 真正缺乏**独立 variation** ⇒ 需要更多数据，或更好的研究设计

高 VIF 本身不是机械删变量的理由。


## VIF 很高，怎么办？

- ① 变量在理论上**必须控制**  $\Rightarrow$  可以保留，接受较大的标准误
- ② 两个变量在测量**同一概念**  $\Rightarrow$  重新定义变量，或构造综合指标
- ③ 真正缺乏**独立 variation**  $\Rightarrow$  需要更多数据，或更好的研究设计


高 VIF 本身不是机械删变量的理由。

Multicollinearity  $\neq$  Bias

## 同方差 vs 异方差



## 同方差 vs 异方差



复习:  $\text{Var}(u | X) = \sigma^2$

## 异方差到底伤害了什么？

---

先自己判断——下面这些，哪些会受影响？

 $\hat{\beta}$ 

标准误

 $t$  $p$ 

假设检验

## 异方差到底伤害了什么？


---

先自己判断——下面这些，哪些会受影响？




## 异方差到底伤害了什么？

先自己判断——下面这些，哪些会受影响？



## 异方差到底伤害了什么？


先自己判断——下面这些，哪些会受影响？



在外生性等条件仍成立时，异方差**并不自动使 OLS 系数有偏**；  
主要问题之一是传统标准误可能不再可靠。

## 异方差到底伤害了什么？

先自己判断——下面这些，哪些会受影响？




在外生性等条件仍成立时，异方差并不自动使 OLS 系数有偏；  
主要问题之一是传统标准误可能不再可靠。


$\hat{\beta}$  大体还在，但它有多可信变了。

## 那我们为什么用 robust?

---




## 那我们为什么用 robust?



```
reg score ai ability study_time, robust
```

## 那我们为什么用 robust?



```
reg score ai ability study_time, robust
```

Robust 不是让系数「更正确」，而是在相应条件下让推断更可靠。

## 如果观测之间本身还相关呢？

---

$$\text{Cov}(u_{ig}, u_{jg}) \neq 0$$

### 什么时候会出现？

同一家企业不同年份

同一个学校里的学生

同一个城市里的企业

## 如果观测之间本身还相关呢？

### 什么时候会出现？

同一家企业不同年份

同一个学校里的学生

同一个城市里的企业

$$\text{Cov}(u_{ig}, u_{jg}) \neq 0$$

**Cluster SE：** 允许组内误差相关

```
vce(cluster firm)
```

## 如果观测之间本身还相关呢？

### 什么时候会出现？

同一家企业不同年份

同一个学校里的学生

同一个城市里的企业

$$\text{Cov}(u_{ig}, u_{jg}) \neq 0$$

**Cluster SE：允许组内误差相关**

```
vce(cluster firm)
```

普通 heteroskedasticity-robust SE 主要处理异方差；

同一组内部误差可能相关时，要考虑

**Cluster-Robust SE。**

## 如果观测之间本身还相关呢？

### 什么时候会出现？

同一家企业不同年份

同一个学校里的学生

同一个城市里的企业

$$\text{Cov}(u_{ig}, u_{jg}) \neq 0$$

**Cluster SE：允许组内误差相关**

```
vce(cluster firm)
```

普通 heteroskedasticity-robust SE 主要处理异方差；

同一组内部误差可能相关时，要考虑

**Cluster-Robust SE。**

**Later** 面板数据还有另一个问题：企业自身不随时间变化的特征如果与  $X$  有关怎么办？ → **Fixed Effects**

FE 管模型中的不可观测异质性，Cluster SE 管标准误与推断——两者解决的不是同一个问题。这部分留到面板数据与固定效应专题再系统讲。

## 不同问题，不同处理

| 问题            | 主要伤害什么            | 怎么发现                    | 怎么处理                      |
|---------------|-------------------|-------------------------|---------------------------|
| 函数形式错误        | $E(Y   X)$ 的设定    | residual · RESET theory | 重新设定函数形式                  |
| 控制变量<br>(坏控制) | 估计的是 <b>什么</b>    | 理论 · 有向无环图              | 重新决定控制谁                   |
| 多重共线性         | 精度、SE、稳定性         | correlation · VIF       | 不机械删变量，<br>寻找有效 variation |
| 异方差           | SE、 $t$ 、 $p$ 、CI | residual · BP · White   | Robust SE                 |
| 组内误差相关        | SE、推断             | 数据结构 · 研究设计             | Cluster SE （后面详讲）         |

## 不同问题，不同处理

| 问题            | 主要伤害什么            | 怎么发现                    | 怎么处理                      |
|---------------|-------------------|-------------------------|---------------------------|
| 函数形式错误        | $E(Y   X)$ 的设定    | residual · RESET theory | 重新设定函数形式                  |
| 控制变量<br>(坏控制) | 估计的是 <b>什么</b>    | 理论 · 有向无环图              | 重新决定控制谁                   |
| 多重共线性         | 精度、SE、稳定性         | correlation · VIF       | 不机械删变量，<br>寻找有效 variation |
| 异方差           | SE、 $t$ 、 $p$ 、CI | residual · BP · White   | Robust SE                 |
| 组内误差相关        | SE、推断             | 数据结构 · 研究设计             | Cluster SE （后面详讲）         |

BP / White 是**诊断**，Robust SE 是**推断修正**；  
诊断工具告诉我们「**哪里可能有问题**」，但不会自动给出「**正确模型是什么**」。

## 现在我们已经做了很多

---

✓ 选择了合理函数形式

## 现在我们已经做了很多

---

- ✓ 选择了合理函数形式
- ✓ 加入了控制变量

## 现在我们已经做了很多

---

- ✓ 选择了合理函数形式
- ✓ 加入了控制变量
- ✓ 理解了 FWL

## 现在我们已经做了很多

---

- ✓ 选择了合理函数形式
- ✓ 加入了控制变量
- ✓ 理解了 FWL
- ✓ 检查了残差

## 现在我们已经做了很多

---

- ✓ 选择了合理函数形式
- ✓ 加入了控制变量
- ✓ 理解了 FWL
- ✓ 检查了残差
- ✓ 检查了共线性

## 现在我们已经做了很多

---

- ✓ 选择了合理函数形式
- ✓ 加入了控制变量
- ✓ 理解了 FWL
- ✓ 检查了残差
- ✓ 检查了共线性
- ✓ 检查了异方差

## 现在我们已经做了很多

---

- ✓ 选择了合理函数形式
- ✓ 加入了控制变量
- ✓ 理解了 FWL
- ✓ 检查了残差
- ✓ 检查了共线性
- ✓ 检查了异方差
- ✓ 使用了 Robust SE

## 今天三个问题

---

① 经济关系应该怎样写进模型？  
函数形式表达经济关系。

## 今天三个问题

---

① 经济关系应该怎样写进模型？  
函数形式表达经济关系。

② 多元回归究竟在控制什么？  
利用净化后的 **variation** 进行比较。

## 今天三个问题

---

① 经济关系应该怎样写进模型？  
函数形式表达经济关系。

② 多元回归究竟在控制什么？  
利用净化后的 **variation** 进行比较。


③ 怎样发现模型可能出了问题？  
发现问题 → 判断伤害 → 选择处理。

## 把第二讲和第三讲放在一起


### 第二讲



### 第三讲



## 把第二讲和第三讲放在一起



现在，我们已经有了一个「不错的回归模型」。

## 结果也非常漂亮

---

|           |                           |
|-----------|---------------------------|
| AI 的系数    | $\hat{\beta}_{AI} = 1.50$ |
| Robust SE | 0.30                      |
| $p$ 值     | $< 0.01$                  |
| Controls  | YES                       |
| 函数形式      | checked                   |
| 诊断        | PASS                      |

## 结果也非常漂亮

---

|           |                           |
|-----------|---------------------------|
| AI 的系数    | $\hat{\beta}_{AI} = 1.50$ |
| Robust SE | 0.30                      |
| $p$ 值     | $< 0.01$                  |
| Controls  | YES                       |
| 函数形式      | checked                   |
| 诊断        | PASS                      |

这个 1.50 是因果效应吗？

## 结果也非常漂亮

---

|           |                           |
|-----------|---------------------------|
| AI 的系数    | $\hat{\beta}_{AI} = 1.50$ |
| Robust SE | 0.30                      |
| $p$ 值     | $< 0.01$                  |
| Controls  | YES                       |
| 函数形式      | checked                   |
| 诊断        | PASS                      |

这个 1.50 是因果效应吗？

(问题不在  $p$  值有多小。)

显著  $\neq$  因果

---

**Statistical Significance**

$\neq$

**Causality**

# 显著 $\neq$ 因果

---

Statistical Significance

$\neq$

Causality

能不能把  $\hat{\beta}$  读成因果效应，取决于  $E(u | X) = 0$ ，  
而不取决于  $p$  值有多小。

# 显著 $\neq$ 因果

---

## Statistical Significance

$\neq$

## Causality

能不能把  $\hat{\beta}$  读成因果效应，取决于  $E(u | X) = 0$ ，  
而不取决于  $p$  值有多小。

未观测的遗漏变量 · 反向因果 · 选择偏差  
控制变量清掉的是  $u$  里可观测的部分；上面这些，它够不着。

# 显著 $\neq$ 因果

## Statistical Significance

$\neq$

## Causality


能不能把  $\hat{\beta}$  读成因果效应，取决于  $E(u | X) = 0$ ，  
而不取决于  $p$  值有多小。

未观测的遗漏变量 · 反向因果 · 选择偏差  
控制变量清掉的是  $u$  里可观测的部分；上面这些，它够不着。

给  $\hat{\beta}$  因果资格的，是识别，不是显著性。

但是……

---



## 三个更大的问题

---

为什么相关不等于因果？

## 三个更大的问题

---

为什么相关不等于因果？

因果效应到底是什么？

## 三个更大的问题

---

为什么相关不等于因果？

因果效应到底是什么？

我们怎样从数据中识别因果？

## 下一讲

---

# 第四讲 从相关到因果

现代计量经济学真正想解决什么问题？

## 下一讲

---

# 第四讲 从相关到因果

现代计量经济学真正想解决什么问题？

一个好的回归模型，是**因果分析的起点**，而不是终点。