

---

## 第四讲 从相关到因果

现代计量经济学真正想解决什么问题？

$\hat{\beta} \stackrel{?}{=} \text{因果效应}$

中级计量经济学 | 张呈磊

相关 · 反事实 · 识别

# 从「会回归」到「会建模」

---

第二讲 回归 → 参数估计 → 假设检验



第三讲 函数形式 → 控制变量 → FWL → 模型诊断

## 从「会回归」到「会建模」

---

第二讲 回归 → 参数估计 → 假设检验



第三讲 函数形式 → 控制变量 → FWL → 模型诊断

我们已经可以做出一个「统计上不错」的回归模型。

## 从「会回归」到「会建模」

---

第二讲 回归 → 参数估计 → 假设检验



第三讲 函数形式 → 控制变量 → FWL → 模型诊断

我们已经可以做出一个「统计上不错」的回归模型。

这就够了吗？

## 一个看起来很漂亮的结果

---

被解释变量: Score

---

|        |                   |
|--------|-------------------|
| AI use | 1.50***<br>(0.30) |
|--------|-------------------|

---

|                        |     |
|------------------------|-----|
| Controls (控制变量)        | 已控制 |
| Functional form (函数形式) | 已检验 |
| Diagnostics (模型诊断)     | 通过  |

---

与第三讲末尾那张「完美」结果卡是同一个模型。

## 一个看起来很漂亮的结果

---

被解释变量: Score

---

|        |                   |
|--------|-------------------|
| AI use | 1.50***<br>(0.30) |
|--------|-------------------|

---

|                 |     |
|-----------------|-----|
| Controls (控制变量) | 已控制 |
|-----------------|-----|

|                        |     |
|------------------------|-----|
| Functional form (函数形式) | 已检验 |
|------------------------|-----|

|                    |    |
|--------------------|----|
| Diagnostics (模型诊断) | 通过 |
|--------------------|----|

---

与第三讲末尾那张「完美」结果卡是同一个模型。

一个显著、稳健、诊断良好的系数，  
为什么仍然可能只是**相关关系**？

## 一个看起来很漂亮的结果

---

被解释变量: Score

---

|        |                   |
|--------|-------------------|
| AI use | 1.50***<br>(0.30) |
|--------|-------------------|

---

|                 |     |
|-----------------|-----|
| Controls (控制变量) | 已控制 |
|-----------------|-----|

|                        |     |
|------------------------|-----|
| Functional form (函数形式) | 已检验 |
|------------------------|-----|

|                    |    |
|--------------------|----|
| Diagnostics (模型诊断) | 通过 |
|--------------------|----|

---

与第三讲末尾那张「完美」结果卡是同一个模型。

一个显著、稳健、诊断良好的系数，  
为什么仍然可能只是**相关关系**？

$\hat{\beta} \stackrel{?}{=} \text{Causal Effect (因果效应)}$

# 我们已经从数据得到信息，然后呢？

---



## 我们已经从数据得到信息，然后呢？

---



**Data** AI 使用时间、学生成绩、学生能力、其他  
观测变量  
数据只是观测记录。

## 我们已经从数据得到信息，然后呢？



**Data** AI 使用时间、学生成绩、学生能力、其他观测变量

数据只是观测记录。

**Information**  $\hat{\beta}_{AI} = 1.50^{***}$ , 即  $AI\ use \uparrow \iff Score \uparrow$

这属于统计规律 / 相关信息。

## 我们已经从数据得到信息，然后呢？



**Data** AI 使用时间、学生成绩、学生能力、其他观测变量

数据只是观测记录。

**Information**  $\hat{\beta}_{AI} = 1.50^{***}$ , 即  $AI\ use \uparrow \iff Score \uparrow$

这属于统计规律 / 相关信息。

**Knowledge** 如果我们真的改变一个学生的 AI 使用，他的成绩会怎样？

**What happens if we intervene?**

## 我们已经从数据得到信息，然后呢？



**Data** AI 使用时间、学生成绩、学生能力、其他观测变量

数据只是观测记录。

**Information**  $\hat{\beta}_{AI} = 1.50^{***}$ ，即  $AI\ use \uparrow \iff Score \uparrow$

这属于统计规律／相关信息。

**Knowledge** 如果我们真的改变一个学生的 AI 使用，他的成绩会怎样？

**What happens if we intervene?**

相关告诉我们「世界呈现出什么规律」；

因果帮助我们理解「如果改变一个因素，会发生什么」。

## 我们已经从数据得到信息，然后呢？



**Data** AI 使用时间、学生成绩、学生能力、其他观测变量

数据只是观测记录。

**Information**  $\hat{\beta}_{AI} = 1.50^{***}$ ，即  $AI\ use \uparrow \iff Score \uparrow$

这属于统计规律／相关信息。

**Knowledge** 如果我们真的改变一个学生的 AI 使用，他的成绩会怎样？

**What happens if we intervene?**

相关告诉我们「世界呈现出什么规律」；

因果帮助我们理解「如果改变一个因素，会发生什么」。

经验经济学要从相关信息走向可解释、可干预的知识，**因果推断是关键一步**。

# 为什么经济学不能满足于相关关系？

---

延长教育年限，会不会提高收入？

给企业补贴，会不会增加创新？

降息，会不会刺激投资？

## 为什么经济学不能满足于相关关系？

---

延长教育年限，会不会提高收入？

给企业补贴，会不会增加创新？

降息，会不会刺激投资？

一旦问题变成「如果改变  $X$ ，会发生什么」，我们就在问**因果问题**。

## 今天三个问题

---

① 为什么一个「好回归」

仍然不等于因果？

发现问题

观察到的比较可能被污染

## 今天三个问题

---

① 为什么一个「好回归」

仍然不等于因果？

发现问题

观察到的比较可能被污染

② 因果效应  
到底是什么？

定义目标

真正需要的是反事实比较

# 今天三个问题

---

① 为什么一个「好回归」  
仍然不等于因果？  
发现问题  
观察到的比较可能被污染

② 因果效应  
到底是什么？  
定义目标  
真正需要的是反事实比较

③ 现代计量方法  
究竟在寻找什么？  
解决问题  
寻找可信比较与可信  
variation

## 今天三个问题

---

① 为什么一个「好回归」  
仍然不等于因果？  
发现问题  
观察到的比较可能被污染

② 因果效应  
到底是什么？  
定义目标  
真正需要的是反事实比较

③ 现代计量方法  
究竟在寻找什么？  
解决问题  
寻找可信比较与可信  
variation

发现问题 → 定义目标 → 寻找解决方案

相关 → 反事实 → 识别

---



问题一

# 为什么一个「好回归」仍然不等于因果？

Controls + Robust SE + Diagnostics, 为什么还不够？



相关 ▶ 反事实 ▶ 识别

## 遗漏变量：最熟悉的麻烦





总体相关（Overall correlation）／能力相同者之间（Within-ability）

## 遗漏变量：最熟悉的麻烦



总体相关（Overall correlation）／能力相同者之间（Within-ability）

## 遗漏变量：最熟悉的麻烦





总体相关（Overall correlation）／能力相同者之间（Within-ability）

AI 使用多的学生成绩更高，这背后可能是 AI，也可能只是能力（Ability）。

也就是说：X 与其他影响 Y 的因素纠缠在一起，因此回归系数可能混入其他作用。

## 遗漏变量：最熟悉的麻烦



总体相关（Overall correlation）／能力相同者之间（Within-ability）

AI 使用多的学生成绩更高，这背后可能是 AI，也可能只是能力（Ability）。

也就是说：X 与其他影响 Y 的因素纠缠在一起，因此回归系数可能混入其他作用。

$$E(u \mid AI) \neq 0 \quad \text{线性简化情形下即 } Cov(AI, u) \neq 0$$

总体斜率（slope）里混入了能力差异带来的那部分。

「用不用 AI」，是谁决定的？

---

那把能力这样的因素测出来、控制住，  
两组学生就真的可比了吗？

「用不用 AI」，是谁决定的？

---

那把能力这样的因素测出来、控制住，  
两组学生就真的可比了吗？

用不用 AI，是学生自己决定的。

觉得自己需要补的人更会用；本来就有动力的人，也更会用。

「用不用 AI」，是谁决定的？

---

那把能力这样的因素**测出来、控制住**，  
两组学生就真的可比了吗？

用不用 AI，是学生**自己决定**的。

觉得自己需要补的人更会用；本来就有动力的人，也更会用。

**Self-selection**（自选择）

谁进入处理**不是随机的**，而这个「决定」本身就带着信息。

「用不用 AI」，是谁决定的？

---

那把能力这样的因素**测出来、控制住**，  
两组学生就真的可比了吗？

用不用 AI，是学生**自己决定**的。

觉得自己需要补的人更会用；本来就有动力的人，也更会用。

**Self-selection（自选择）**

谁进入处理**不是随机的**，而这个「决定」本身就带着信息。

遗漏变量是**没测到**；自选择是**谁进入处理不是随机的** ——  
就算能测的都测了，这个问题还在。

## 还有一种麻烦：方向可能反过来

---



## 还有一种麻烦：方向可能反过来



成绩较差的学生，  
会不会反而**更依赖 AI**？

## 还有一种麻烦：方向可能反过来




$AI \leftrightarrow Score$

成绩较差的学生，  
会不会反而**更依赖 AI**？

两种机制都说得通，  
数据本身不会告诉你哪一个是真的。

## 还有一种麻烦：方向可能反过来




$AI \leftrightarrow Score$

成绩较差的学生，  
会不会反而**更依赖 AI**？

两种机制都说得通，  
数据本身不会告诉你哪一个是真的。

相关关系本身不能告诉我们**因果方向**。


## 还有一个更隐蔽的：我们真的测准了吗？



实线 = 真实关系

虚线 = 用测不准的变量估出来

## 还有一个更隐蔽的：我们真的测准了吗？




我们说的「AI 使用」，  
其实来自学生自己报的使用时长。

实线 = 真实关系

虚线 = 用测不准的变量估出来

## 还有一个更隐蔽的：我们真的测准了吗？




实线 = 真实关系

虚线 = 用测不准的变量估出来

我们说的「AI 使用」，  
其实来自学生**自己报**的使用时长。  
记不清、口径不一、甚至虚报——  
这个变量**本身就测不准**。

## 还有一个更隐蔽的：我们真的测准了吗？



实线 = 真实关系


虚线 = 用测不准的变量估出来

我们说的「AI 使用」，  
其实来自学生**自己报**的使用时长。

记不清、口径不一、甚至虚报——  
这个变量**本身就测不准**。

后果（只看直觉）：真实关系被**稀释**——  
本来 1.50 的效应，测出来可能只剩 0.8。

## 还有一个更隐蔽的：我们真的测准了吗？



实线 = 真实关系

虚线 = 用测不准的变量估出来

我们说的「AI 使用」，  
其实来自学生**自己报**的使用时长。

记不清、口径不一、甚至虚报——  
这个变量**本身就测不准**。

后果（只看直觉）：真实关系被**稀释**——  
本来 1.50 的效应，测出来可能只剩 0.8。

### Measurement Error（衡量偏误）

测不准通常让效应看起来**更小**，但它同样是内生性的一种。

## 这四种麻烦，有一个共同的名字

---

**遗漏变量**

该测的没测到

**自选择**

谁用不是随机的

**反向因果**

方向可能是反的

**衡量偏误**

变量本身没测准

## 这四种麻烦，有一个共同的名字

遗漏变量

该测的没测到

自选择

谁用不是随机的

反向因果

方向可能是反的

衡量偏误

变量本身没测准

它们都在做同一件事：让估出来的  $\beta$   
与其他影响成绩的因素**纠缠**在一起。

## 这四种麻烦，有一个共同的名字

遗漏变量

该测的没测到

自选择

谁用不是随机的

反向因果

方向可能是反的

衡量偏误

变量本身没测准

它们都在做同一件事：让估出来的  $\beta$   
与其他影响成绩的因素**纠缠**在一起。

这四种麻烦，就是大家经常听到的 **内生性**（Endogeneity）问题

$$E(u \mid X) \neq 0 \quad \text{线性简化情形下即 } Cov(X, u) \neq 0$$

## 这四种麻烦，有一个共同的名字

遗漏变量

该测的没测到

自选择

谁用不是随机的

反向因果

方向可能是反的

衡量偏误

变量本身没测准

它们都在做同一件事：让估出来的  $\beta$   
与其他影响成绩的因素**纠缠**在一起。

这四种麻烦，就是大家经常听到的 **内生性**（Endogeneity）问题

$E(u | X) \neq 0$       线性简化情形下即  $Cov(X, u) \neq 0$

问题就变成：估出来的这个  $\beta$ ，**值得相信**吗？

## 问题一收束：只需要记住两句话

---

规范的回归  $\neq$  可信的因果效应

## 问题一收束：只需要记住两句话

---

规范的回归  $\neq$  可信的因果效应

控制变量越多  $\neq$  识别越好

## 问题一收束：只需要记住两句话

---

规范的回归  $\neq$  可信的因果效应

控制变量越多  $\neq$  识别越好

那么，我们到底想识别的「因果效应」是什么？

我们已经知道「什么不够」——但「因果」究竟是什么？

---

$\hat{\beta} \stackrel{?}{=} \text{因果效应}$

我们已经知道

显著  $\neq$  因果

控制很多变量  $\neq$  因果

诊断通过  $\neq$  因果

## 我们已经知道「什么不够」——但「因果」究竟是什么？

$\hat{\beta} \stackrel{?}{=} \text{因果效应}$

我们已经知道

显著  $\neq$  因果

控制很多变量  $\neq$  因果

诊断通过  $\neq$  因果

但还缺一个更基本的问题

我们所谓的「因果效应」，  
到底是什么？

## 我们已经知道「什么不够」——但「因果」究竟是什么？

$\hat{\beta} \stackrel{?}{=} \text{因果效应}$

我们已经知道

显著  $\neq$  因果

控制很多变量  $\neq$  因果

诊断通过  $\neq$  因果

但还缺一个更基本的问题

我们所谓的「因果效应」，  
到底是什么？

在讨论「如何识别」之前，必须先知道**我们到底想识别什么。**

---

问题二

# 因果效应到底是什么？

因果不是「两个不同的人有差异」。

相关 ▶ 反事实 ▶ 识别

## 先区分两句话

---

AI 使用更多的学生，  
平均成绩更高。

**Correlation**（相关关系）

## 先区分两句话

---

AI 使用更多的学生，  
平均成绩更高。

**Correlation**（相关关系）

如果让同一个学生  
使用 AI、而不是不使用 AI，  
他的成绩会怎样？

**Causal Question**（因果问题）

## 先区分两句话

---

AI 使用更多的学生，  
平均成绩更高。

**Correlation**（相关关系）

如果让同一个学生  
使用 AI、而不是不使用 AI，  
他的成绩会怎样？

**Causal Question**（因果问题）

关联（Association）  $\neq$  干预（Intervention）

## 同一个学生，两个可能世界

为了把反事实讲清楚，下面暂时把 AI 使用简化为二元处理 (treatment)：使用 AI 记为  $D = 1$ ，不使用 AI 记为  $D = 0$ 。

同一个学生

World 1  
使用 AI  
 $Y_i(1)$

World 0  
不使用 AI  
 $Y_i(0)$

## 同一个学生，两个可能世界

为了把反事实讲清楚，下面暂时把 AI 使用简化为二元处理（treatment）：使用 AI 记为  $D = 1$ ，不使用 AI 记为  $D = 0$ 。

同一个学生

World 1  
使用 AI  
 $Y_i(1)$

World 0  
不使用 AI  
 $Y_i(0)$

$$\tau_i = Y_i(1) - Y_i(0) \quad \text{个体因果效应}$$

本讲最重要的公式

## 同一个学生，两个可能世界

为了把反事实讲清楚，下面暂时把 AI 使用简化为二元处理（treatment）：使用 AI 记为  $D = 1$ ，不使用 AI 记为  $D = 0$ 。

同一个学生

World 1  
使用 AI  
 $Y_i(1)$

World 0  
不使用 AI  
 $Y_i(0)$

$$\tau_i = Y_i(1) - Y_i(0) \quad \text{个体因果效应}$$

本讲最重要的公式

因果效应问的不是「张三和李四差多少？」  
而是：同一个单位在两个可能世界中的差异。

# Fundamental Problem of Causal Inference

---

因果推断的根本问题

对于同一个  $i$ :

# Fundamental Problem of Causal Inference

---

因果推断的根本问题

对于同一个  $i$ :

如果  $D_i = 1$ , 我们看到  $Y_i(1)$ ;      但  $Y_i(0) = ?$

# Fundamental Problem of Causal Inference

---

因果推断的根本问题

对于同一个  $i$ :

如果  $D_i = 1$ , 我们看到  $Y_i(1)$ ; 但  $Y_i(0) = ?$   
反过来也一样。

# Fundamental Problem of Causal Inference

---

因果推断的根本问题

对于同一个  $i$ :

如果  $D_i = 1$ , 我们看到  $Y_i(1)$ ;      但  $Y_i(0) = ?$   
反过来也一样。

同一个人不可能同时处在两个世界

# Fundamental Problem of Causal Inference

因果推断的根本问题

对于同一个  $i$ :

如果  $D_i = 1$ , 我们看到  $Y_i(1)$ ;      但  $Y_i(0) = ?$   
反过来也一样。

同一个人不可能同时处在两个世界

我们永远缺少一个潜在结果。

观测到的结果 + 缺失的反事实

Observed + Missing Counterfactual

# Fundamental Problem of Causal Inference

因果推断的根本问题

对于同一个  $i$ :

如果  $D_i = 1$ , 我们看到  $Y_i(1)$ ; 但  $Y_i(0) = ?$   
反过来也一样。

同一个人不可能同时处在两个世界

我们永远缺少一个潜在结果。

观测到的结果 + 缺失的反事实

Observed + Missing Counterfactual

因果推断本质上是一个反事实缺失问题。

所以真正的问题不是「拟合得多好」

---

**Prediction (预测)**

给定  $D$ ,  $Y$  是多少?

**Causal Inference (因果推断)**

如果改变  $D$ ,  $Y$  会怎样?

所以真正的问题不是「拟合得多好」

---

**Prediction (预测)**

给定  $D$ ,  $Y$  是多少?

**Causal Inference (因果推断)**

如果改变  $D$ ,  $Y$  会怎样?

预测关注「会发生什么」; 因果关注「如果我改变它, 会发生什么」。

## 两种常见的因果推断语言

### Potential Outcomes / Rubin

潜在结果框架 / Rubin 框架

核心问题：我们真正想比较什么？

$$Y_i(1), \quad Y_i(0)$$

$$\tau_i = Y_i(1) - Y_i(0)$$

用「两个潜在世界」定义因果效应。

## 两种常见的因果推断语言

### Potential Outcomes / Rubin

潜在结果框架 / Rubin 框架

核心问题：我们真正想比较什么？

$$Y_i(1), \quad Y_i(0)$$

$$\tau_i = Y_i(1) - Y_i(0)$$

用「两个潜在世界」定义因果效应。

### Causal DAG / Causal Structure

因果图 / 因果结构

核心问题：为什么现实比较可能不可信？

$$Ability \rightarrow AI, \quad Ability \rightarrow Score, \\ AI \rightarrow Score$$

用它分析哪些变量该控制、哪些不该。

## 两种常见的因果推断语言

### Potential Outcomes / Rubin

潜在结果框架 / Rubin 框架

核心问题：我们真正想比较什么？

$$Y_i(1), \quad Y_i(0)$$

$$\tau_i = Y_i(1) - Y_i(0)$$

用「两个潜在世界」定义因果效应。

### Causal DAG / Causal Structure

因果图 / 因果结构

核心问题：为什么现实比较可能不可信？

$$\text{Ability} \rightarrow \text{AI}, \quad \text{Ability} \rightarrow \text{Score}, \\ \text{AI} \rightarrow \text{Score}$$

用它分析哪些变量该控制、哪些不该。


Potential Outcomes 与 Causal DAG 不是互相排斥的两种方法，  
而是现代因果推断中常见的两种表达语言，可以**互补使用**。

因果图告诉我们：张三和李四为什么可能不能直接比；

Potential Outcomes 告诉我们：理想情况下应该让「张三和另一个世界的张三」相比。

Further Reading: Imbens & Rubin — Potential Outcomes / Pearl — Causal DAG、SCM

## 从「两种语言」到 Identification



这不是说三个框架有严格的理论先后顺序，而是**本课程的认知顺序**：  
先发现现实比较为什么会出问题；再定义理想的因果比较；最后问如何从数据中恢复它。

## 谁可以替代看不到的反事实？

---

**思考** 一个使用 AI 的学生，  
他「如果不用 AI」的成绩从哪里来？

## 谁可以替代看不到的反事实？

---

**思考** 一个使用 AI 的学生，  
他「如果不用 AI」的成绩从哪里来？

另一个没用 AI 的学生？

为什么另一个学生可以代表他的**反事实**？

## 谁可以替代看不到的反事实？

---

**思考** 一个使用 AI 的学生，  
他「如果不用 AI」的成绩从哪里来？

另一个没用 AI 的学生？

为什么另一个学生可以代表他的**反事实**？

他们真的**可比**吗？

## 谁可以替代看不到的反事实？

---

**思考** 一个使用 AI 的学生，  
他「如果不用 AI」的成绩从哪里来？

另一个没用 AI 的学生？

为什么另一个学生可以代表他的**反事实**？

他们真的**可比**吗？

因果推断 = 找到可信的比较对象

## 从个体效应到平均效应

$$ATE = E[Y(1) - Y(0)]$$


ATE: 平均处理效应 (Average Treatment Effect)

个体反事实不可同时观察，  
但可能识别某个群体的**平均效应**。

拓展：ATT（处理组平均处理效应）——已经接受 treatment 的人，平均处理效应是多少？


## 为什么 Randomized Experiment (随机实验) 是基准?

---



Random Assignment /  
Treatment / Control

## 为什么 Randomized Experiment (随机实验) 是基准?



Random Assignment /  
Treatment / Control


平均意义上, 处理组与对照组  
在 treatment 之前**可比**。

不是: 让回归更显著。

$$D \perp \{Y(1), Y(0)\}$$

随机分配使 treatment 与潜在结果  
在平均意义上没有系统关系。

# 为什么 Randomized Experiment (随机实验) 是基准?



Random Assignment /  
Treatment / Control

理想的反事实不可见 → 需要可信的比较组 → 随机实验提供一个基准答案。

平均意义上, 处理组与对照组  
在 treatment 之前**可比**。

不是: 让回归更显著。

$$D \perp \{Y(1), Y(0)\}$$

随机分配使 treatment 与潜在结果  
在平均意义上没有系统关系。

Randomization 创造了可信的**比较组**

在**平均意义**上, 对照组帮助我们估计  
处理组**缺失的反事实**结果。

## 现实中通常没有随机实验

---

教育不能随意随机分配  
城市政策不是随机出台  
企业选择融资方式并不随机  
AI 使用也通常是自选择

## 现实中通常没有随机实验

---

教育不能随意随机分配  
城市政策不是随机出台  
企业选择融资方式并不随机  
AI 使用也通常是自选择

观测数据 (Observational Data)

## 现实中通常没有随机实验

---

教育不能随意随机分配  
城市政策不是随机出台  
企业选择融资方式并不随机  
AI 使用也通常是自选择

观测数据 (Observational Data)

没有随机实验时，我们怎样从**观测数据**中找到可信比较？

## 现实中通常没有随机实验

教育不能随意随机分配  
城市政策不是随机出台  
企业选择融资方式并不随机  
AI 使用也通常是自选择

观测数据 (Observational Data)

没有随机实验时，我们怎样从**观测数据**中找到可信比较？

这就是 Identification 问题

## 问题二结束后，我们面临一个新的难题

---

### 1. 我们已经定义了因果效应

$$\tau_i = Y_i(1) - Y_i(0)$$

$Y_i(1)$  和  $Y_i(0)$  不能同时看到

谁可以替代那个看不到的反事实？

## 问题二结束后，我们面临一个新的难题

---

### 1. 我们已经定义了因果效应

$$\tau_i = Y_i(1) - Y_i(0)$$

### 2. 但反事实不可观察

$Y_i(1)$  和  $Y_i(0)$  不能同时看到

谁可以替代那个看不到的反事实？

## 问题二结束后，我们面临一个新的难题

---

### 1. 我们已经定义了因果效应

$$\tau_i = Y_i(1) - Y_i(0)$$

### 2. 但反事实不可观察

$Y_i(1)$  和  $Y_i(0)$  不能同时看到

### 3. 所以现实研究必须回答

谁可以替代那个看不到的反事实？

## 问题二结束后，我们面临一个新的难题

### 1. 我们已经定义了因果效应

$$\tau_i = Y_i(1) - Y_i(0)$$

### 2. 但反事实不可观察

$Y_i(1)$  和  $Y_i(0)$  不能同时看到

### 3. 所以现实研究必须回答

谁可以替代那个看不到的反事实？

问题二定义了「想要什么」；问题三开始解决「怎样得到它」。

---

问题三

# 现代计量方法究竟在寻找什么？

后面的 FE、IV、DID、RD 为什么都在解决同一个问题？

相关 ▶ 反事实 ▶ 识别

# 理想的比较看不见，现实数据能给我们什么？

---

理想的因果比较

$$Y_i(1) - Y_i(0)$$

同一个单位的两个可能世界

?

数据中的现实比较

$$D = 1 \quad \text{vs.} \quad D = 0$$

两组不同的人

## 理想的比较看不见，现实数据能给我们什么？

---

理想的因果比较

$$Y_i(1) - Y_i(0)$$

同一个单位的两个可能世界

?

数据中的现实比较

$$D = 1 \quad \text{vs.} \quad D = 0$$

两组不同的人

什么时候「现实中的比较」可以替代理想的反事实比较？

## 理想的比较看不见，现实数据能给我们什么？

理想的因果比较

$$Y_i(1) - Y_i(0)$$

同一个单位的两个可能世界

?

数据中的现实比较

$$D = 1 \quad \text{vs.} \quad D = 0$$

两组不同的人

什么时候「现实中的比较」可以替代理想的反事实比较？

这就是 Identification

# 一个经验研究其实有四个层次

我们已经知道「想估计什么」；但「想估计什么」与「数据能不能告诉我们」不是一回事。

## Estimand (估计目标)

我到底想估计什么？

## Identification (识别)

为什么数据能够告诉我？

## Estimator (估计量)

怎么计算？

## Inference (推断)

这个估计有多不确定？

估计目标  $\neq$  识别  $\neq$  估计  $\neq$  推断 (Estimand 这一格，第二部分已经答了：ATE)

## 一个经验研究其实有四个层次

我们已经知道「想估计什么」；但「想估计什么」与「数据能不能告诉我们」不是一回事。

### Estimand (估计目标)

我到底想估计什么？

### Identification (识别)

为什么数据能够告诉我？

### Estimator (估计量)

怎么计算？

### Inference (推断)

这个估计有多不确定？

估计目标  $\neq$  识别  $\neq$  估计  $\neq$  推断      (Estimand 这一格，第二部分已经答了：ATE)

Research Design 的核心任务，  
是让 **Identification Assumptions** 更可信，  
而不是让系数更显著。

## 一个经验研究其实有四个层次

我们已经知道「想估计什么」；但「想估计什么」与「数据能不能告诉我们」不是一回事。

### Estimand (估计目标)

我到底想估计什么？

### Identification (识别)

为什么数据能够告诉我？

### Estimator (估计量)

怎么计算？

### Inference (推断)

这个估计有多不确定？

估计目标  $\neq$  识别  $\neq$  估计  $\neq$  推断      (Estimand 这一格，第二部分已经答了：ATE)

Research Design 的核心任务，  
是让 **Identification Assumptions** 更可信，  
而不是让系数更显著。

现代计量要找的：可信的比较 + 可信的 identifying variation

## 控制变量什么时候可能帮助因果识别？

---

问题二的结论：因果效应是反事实比较，而我们永远缺少一个潜在结果——所以要找**可信的比较组**。

### 一、要「可比」

控制处理前特征以后，  
处理组和对照组要**足够相似**

## 控制变量什么时候可能帮助因果识别？

---

问题二的结论：因果效应是反事实比较，而我们永远缺少一个潜在结果——所以要找**可信的比较组**。

### 一、要「可比」

控制处理前特征以后，  
处理组和对照组要**足够相似**

### 二、要「有得比」

相似的人中，最好  
**既有人接受处理，也有人没有**

## 控制变量什么时候可能帮助因果识别？

问题二的结论：因果效应是反事实比较，而我们永远缺少一个潜在结果——所以要找**可信的比较组**。

### 一、要「可比」

控制处理前特征以后，  
处理组和对照组要**足够相似**

### 二、要「有得比」

相似的人中，最好  
**既有人接受处理，也有人没有**

控制变量**不会自动**创造因果识别；  
关键在于「控制以后是否真的形成**可信比较**」。

## 控制变量什么时候可能帮助因果识别？

问题二的结论：因果效应是反事实比较，而我们永远缺少一个潜在结果——所以要找**可信的比较组**。

### 一、要「可比」

控制处理前特征以后，  
处理组和对照组要**足够相似**

### 二、要「有得比」

相似的人中，最好  
既有人接受处理，也有人没有

控制变量**不会自动**创造因果识别；  
关键在于「控制以后是否真的形成**可信比较**」。

后面的现代计量方法，就是在不同场景下寻找不同的**可信比较**。

## 从 FWL 的直觉再往前走一步

---

$$X \longrightarrow \tilde{X} \quad Y \longrightarrow \tilde{Y}$$

## 从 FWL 的直觉再往前走一步

---

$$\begin{aligned} X &\longrightarrow \tilde{X} & Y &\longrightarrow \tilde{Y} \\ \tilde{Y} &= \beta \tilde{X} + \tilde{u} \end{aligned}$$

## 从 FWL 的直觉再往前走一步

---

$$X \longrightarrow \tilde{X} \quad Y \longrightarrow \tilde{Y}$$

$$\tilde{Y} = \beta \tilde{X} + \tilde{u}$$

控制以后，OLS 使用的是  $X$  剩余的 **variation**。

## 从 FWL 的直觉再往前走一步

$$X \longrightarrow \tilde{X} \quad Y \longrightarrow \tilde{Y}$$

$$\tilde{Y} = \beta \tilde{X} + \tilde{u}$$

控制以后，OLS 使用的是  $X$  剩余的 **variation**。

这部分 variation  
从哪里来？

Where does the identifying variation come from?

## 从 FWL 的直觉再往前走一步

$$X \longrightarrow \tilde{X} \quad Y \longrightarrow \tilde{Y}$$

$$\tilde{Y} = \beta \tilde{X} + \tilde{u}$$

控制以后, OLS 使用的是  $X$  剩余的 **variation**。

这部分 variation  
从哪里来?

Where does the identifying variation come from?

为什么值得相信?

Why should we trust it?

## 后面的中级计量，其实都在回答同一个问题

---

这一讲不要求你学会这些方法——只要求看懂它们**共同在问什么**。

### 第一层 Identification / Research Design (识别 & 研究设计)

Controls  
条件可比

Fixed Effects  
组内变化

IV  
外部推动

DID  
相对变化

RD  
阈值附近


## 后面的中级计量，其实都在回答同一个问题

这一讲不要求你学会这些方法——只要求看懂它们**共同在问什么**。



## 后面的中级计量，其实都在回答同一个问题


这一讲不要求你学会这些方法——只要求看懂它们**共同在问什么**。



六种方法，是六种不同的「反事实替代」方式（ML/DML 只做调整，不创造识别）。

## 后面的中级计量，其实都在回答同一个问题


这一讲不要求你学会这些方法——只要求看懂它们**共同在问什么**。



六种方法，是六种不同的「反事实替代」方式（ML/DML 只做调整，不创造识别）。

## 后面的中级计量，其实都在回答同一个问题

这一讲不要求你学会这些方法——只要求看懂它们**共同在问什么**。



六种方法，是六种不同的「反事实替代」方式（ML/DML 只做调整，不创造识别）。

谁和谁在比较？      这部分 identifying variation 为什么可信？

## 后面的每一种方法，都问同样两个问题

**Q1** 它用谁来替代**看不到的反事实**？

**Q2** 为什么这个替代**值得相信**？

| 方法            | 用什么替代看不到的反事实                             |
|---------------|------------------------------------------|
| Controls      | 在条件相似的人之间寻找反事实                           |
| Fixed Effects | 从同一个体的组内变化中寻找更可信的比较                      |
| IV            | 利用外部推动带来的 variation                      |
| DID           | 用未处理组的相对变化构造反事实趋势                        |
| RD            | 用 cutoff 附近非常相似的人构造局部比较                  |
| ML / DML      | 更灵活地做调整与残差化，但本身不创造 <b>Identification</b> |

## 后面的每一种方法，都问同样两个问题


**Q1** 它用谁来替代**看不到的反事实**？

**Q2** 为什么这个替代**值得相信**？

| 方法            | 用什么替代看不到的反事实                             |
|---------------|------------------------------------------|
| Controls      | 在条件相似的人之间寻找反事实                           |
| Fixed Effects | 从同一个体的组内变化中寻找更可信的比较                      |
| IV            | 利用外部推动带来的 variation                      |
| DID           | 用未处理组的相对变化构造反事实趋势                        |
| RD            | 用 cutoff 附近非常相似的人构造局部比较                  |
| ML / DML      | 更灵活地做调整与残差化，但本身不创造 <b>Identification</b> |


识别假设来自研究设计——这两个问题，整门中级计量课都会一直问下去。

## Fixed Effects: 利用同一个体的组内变化



不同企业 / 个人之间，存在大量**不随时间变化**的固定差异。

## Fixed Effects: 利用同一个体的组内变化




不同企业／个人之间，存在大量**不随时间变化**的固定差异。

$X_{it} - \bar{X}_i$  **组内变异**

within variation

去掉不随时间变化的固定差异后，  
利用同一个体随时间发生的变化。

## Fixed Effects: 利用同一个体的组内变化



不同企业／个人之间，存在大量**不随时间变化**的固定差异。


$X_{it} - \bar{X}_i$  **组内变异**

within variation

去掉不随时间变化的固定差异后，  
利用同一个体随时间发生的变化。

可以粗略理解为：更多利用「同一个体不同时期」的比较，而不是不同个体之间的水平差异。

## Fixed Effects: 利用同一个体的组内变化



不同企业／个人之间，存在大量**不随时间变化**的固定差异。

$X_{it} - \bar{X}_i$  **组内变异**


within variation

去掉不随时间变化的固定差异后，  
利用同一个体随时间发生的变化。

可以粗略理解为：更多利用「同一个体不同时期」的比较，而不是不同个体之间的水平差异。

**思考** 组内 variation 也**不自动**等于因果——时间变化的遗漏变量、反向因果、同时性仍然可能存在。

## Fixed Effects: 利用同一个体的组内变化



不同企业／个人之间，存在大量**不随时间变化**的固定差异。

$X_{it} - \bar{X}_i$  **组内变异**

within variation

去掉不随时间变化的固定差异后，  
利用同一个体随时间发生的变化。

可以粗略理解为：更多利用「同一个体不同时期」的比较，而不是不同个体之间的水平差异。

**思考** 组内 variation 也**不自动**等于因果——时间变化的遗漏变量、反向因果、同时性仍然可能存在。

我们仍然需要问：为什么这部分 within variation **值得相信**？

## Instrumental Variables (工具变量): 只用「外部推动」的部分

---



后面 IV 专题再正式定义这些条件。

## Instrumental Variables (工具变量): 只用「外部推动」的部分



一个好的工具变量  $Z$  需要:

- ▶ 能够推动  $X$ ;
- ▶ 不与影响  $Y$  的其他未观测因素纠缠;
- ▶ 对  $Y$  的影响只能通过  $X$ 。

后面 IV 专题再正式定义这些条件。

## Instrumental Variables (工具变量): 只用「外部推动」的部分



一个好的工具变量  $Z$  需要:

- ▶ 能够推动  $X$ ;
- ▶ 不与影响  $Y$  的其他未观测因素纠缠;
- ▶ 对  $Y$  的影响只能通过  $X$ 。

只使用由外部因素推动的那部分 variation

后面 IV 专题再正式定义这些条件。

## Instrumental Variables (工具变量): 只用「外部推动」的部分



一个好的工具变量  $Z$  需要:

- ▶ 能够推动  $X$ ;
- ▶ 不与影响  $Y$  的其他未观测因素纠缠;
- ▶ 对  $Y$  的影响只能通过  $X$ 。

只使用由外部因素推动的那部分 variation

外部推动的变异

Externally Induced Variation

后面 IV 专题再正式定义这些条件。

## Instrumental Variables (工具变量): 只用「外部推动」的部分



一个好的工具变量  $Z$  需要:

- ▶ 能够推动  $X$ ;
- ▶ 不与影响  $Y$  的其他未观测因素纠缠;
- ▶ 对  $Y$  的影响只能通过  $X$ 。

只使用由外部因素推动的那部分 variation


外部推动的变异

Externally Induced Variation

后面 IV 专题再正式定义这些条件。


Q1 → 外部推动的那部分 variation;    Q2 → 与影响  $Y$  的其他因素不纠缠。

## DID: 比较相对变化，而不是直接比较水平



后续正式学习平行趋势（Parallel Trends）。


## DID: 比较相对变化，而不是直接比较水平



$\Delta Y_T - \Delta Y_C$ : 比较相对变化，而不是直接比较水平

后续正式学习平行趋势（Parallel Trends）。

## DID: 比较相对变化，而不是直接比较水平




$\Delta Y_T - \Delta Y_C$ : 比较相对变化，而不是直接比较水平

后续正式学习平行趋势（Parallel Trends）。


Q1 → 未处理组的相对变化； Q2 → 平行趋势是否成立（后续专题展开）。

## RD (断点回归): 只比较 **cutoff** (断点) 附近



断点两侧非常接近的人，处理状态（treatment status）却不同。


## RD (断点回归): 只比较 **cutoff** (断点) 附近



比较 cutoff 两侧**非常接近**的单位

断点两侧非常接近的人，处理状态 (treatment status) 却不同。


## RD (断点回归): 只比较 **cutoff** (断点) 附近



比较 cutoff 两侧**非常接近**的单位

断点两侧非常接近的人，处理状态 (treatment status) 却不同。  
局部比较 (**Local Comparison**)

## RD (断点回归): 只比较 cutoff (断点) 附近




比较 cutoff 两侧非常接近的单位

断点两侧非常接近的人，处理状态 (treatment status) 却不同。

**局部比较 (Local Comparison)**


Q1 → cutoff 另一侧非常接近的人;    Q2 → 断点两侧在附近足够相似。

## ML / DML (机器学习 / 双重机器学习): 更灵活地净化



FWL  
线性残差化  
(Linear partialling out)

## ML / DML (机器学习 / 双重机器学习): 更灵活地净化



FWL

线性残差化


(Linear partialling out)

DML (双重机器学习)

更灵活地估计 nuisance  
functions

(模型里不关心的那部分)、  
做 residualization

## ML / DML (机器学习 / 双重机器学习): 更灵活地净化



FWL  
线性残差化  
(Linear partialling out)

DML (双重机器学习)  
更灵活地估计 nuisance  
functions  
(模型里不关心的那部分)、  
做 residualization

机器学习本身不是 Identification Strategy (识别策略)

识别假设来自研究设计, 机器学习主要帮助估计。

## 把 AI—成绩案例重新走一遍



---

|       |                                                         |
|-------|---------------------------------------------------------|
| 研究问题  | AI 是否提高成绩?                                              |
| 估计目标  | 平均因果效应                                                  |
| 识别的威胁 | Ability / Motivation /<br>Reverse causality / Selection |
| 研究设计  | Controls? FE? IV? Other design?                         |
| 估计量   | 对应估计方法                                                  |
| 推断    | Robust / Cluster SE<br>(稳健 / 聚类标准误) 等                   |

---

Research Design (研究设计) 的作用,  
是让 identification assumptions 更可信。

## 把 AI—成绩案例重新走一遍



---

|       |                                                         |
|-------|---------------------------------------------------------|
| 研究问题  | AI 是否提高成绩?                                              |
| 估计目标  | 平均因果效应                                                  |
| 识别的威胁 | Ability / Motivation /<br>Reverse causality / Selection |
| 研究设计  | Controls? FE? IV? Other design?                         |
| 估计量   | 对应估计方法                                                  |
| 推断    | Robust / Cluster SE<br>(稳健 / 聚类标准误) 等                   |

---

Research Design (研究设计) 的作用,  
是让 identification assumptions 更可信。

不是: 回归  $\rightarrow$  p 值  $\rightarrow$  结论。

## 把 AI—成绩案例重新走一遍



---

|       |                                                         |
|-------|---------------------------------------------------------|
| 研究问题  | AI 是否提高成绩?                                              |
| 估计目标  | 平均因果效应                                                  |
| 识别的威胁 | Ability / Motivation /<br>Reverse causality / Selection |
| 研究设计  | Controls? FE? IV? Other design?                         |
| 估计量   | 对应估计方法                                                  |
| 推断    | Robust / Cluster SE<br>(稳健 / 聚类标准误) 等                   |

---

Research Design (研究设计) 的作用,  
是让 identification assumptions 更可信。

不是: 回归  $\rightarrow$  p 值  $\rightarrow$  结论。


先问识别, 再跑回归。

## 回到第一讲：我们如何从数据走向知识？



相关 → 反事实 → 识别  
可信比较 + 可信 variation

# 回到第一讲：我们如何从数据走向知识？



相关 → 反事实 → 识别  
可信比较 + 可信 variation

## 回到第一讲：我们如何从数据走向知识？



**Data** 观测数据

**Information** 统计规律 / 相关关系

相关 → 反事实 → 识别  
可信比较 + 可信 variation

## 回到第一讲：我们如何从数据走向知识？



**Data** 观测数据

**Information** 统计规律 / 相关关系

**Causal Knowledge** 如果改变  $X$ ,  $Y$  会怎样?

相关  $\rightarrow$  反事实  $\rightarrow$  识别  
可信比较 + 可信 variation

## 回到第一讲：我们如何从数据走向知识？



**Data** 观测数据

**Information** 统计规律 / 相关关系

**Causal Knowledge** 如果改变  $X$ ,  $Y$  会怎样?

相关  $\rightarrow$  反事实  $\rightarrow$  识别  
可信比较 + 可信 variation

## 回到第一讲：我们如何从数据走向知识？



**Data** 观测数据

**Information** 统计规律 / 相关关系

**Causal Knowledge** 如果改变  $X$ ,  $Y$  会怎样？

相关  $\rightarrow$  反事实  $\rightarrow$  识别  
可信比较 + 可信 variation

问题一 为什么相关不够？  
现实比较被污染

问题二 真正想比较什么？  
 $Y_i(1) - Y_i(0)$

问题三 反事实看不见？  
可信比较 + 可信 variation

## 回到第一讲：我们如何从数据走向知识？



**Data** 观测数据

**Information** 统计规律 / 相关关系

**Causal Knowledge** 如果改变  $X$ ,  $Y$  会怎样?

相关  $\rightarrow$  反事实  $\rightarrow$  识别  
可信比较 + 可信 variation

问题一 为什么相关不够?  
现实比较被**污染**


问题二 真正想比较什么?  
 $Y_i(1) - Y_i(0)$

问题三 反事实看不见?  
可信比较 + 可信 variation

现代计量不只是从数据中寻找相关;  
而是在识别假设下努力获得**可信的因果知识**。

因果推断让我们从「描述世界」, 进一步走向「理解世界如何运行」。


## 一条逻辑链



## 真正需要带走的五句话

- ① 显著回归不等于因果效应
- ② 因果问题问的是「如果改变  $X$ ，会发生什么?」
- ③ 因果效应本质上是反事实比较
- ④ 根本困难是反事实不可同时观察
- ⑤ 现代计量的核心是寻找可信比较，并解释 identifying variation 为什么可信

## 一条逻辑链



## 真正需要带走的五句话

- ① 显著回归不等于因果效应
- ② 因果问题问的是「如果改变  $X$ ，会发生什么?」
- ③ 因果效应本质上是反事实比较
- ④ 根本困难是反事实不可同时观察
- ⑤ 现代计量的核心是寻找可信比较，并解释 identifying variation 为什么可信

以前看到结果问「显著吗?」——  
现在还要问「为什么它可以解释成因果效应?」

# 第五讲 面板数据与固定效应



### 第五讲 面板数据与固定效应

如果个体之间存在大量  
不随时间变化的不可观测差异，  
我们能不能转而利用  
「**同一个体随时间的变化**」？



### 第五讲 面板数据与固定效应

如果个体之间存在大量  
不随时间变化的不可观测差异，  
我们能不能转而利用  
「**同一个体随时间的变化**」？



从 within variation 的角度理解 Fixed Effects（固定效应）

## 附录 A1 | Unconfoundedness 与 Overlap (正式条件)

---

$$\{Y(1), Y(0)\} \perp D \mid W$$

Conditional Independence (条件独立) / Unconfoundedness (无混淆性)

$$0 < P(D = 1 \mid W) < 1$$

Overlap / Common Support (重叠 / 共同支撑)

以后正式学习 treatment effects / PSM / DML 时再展开。

## 附录 A1 | Unconfoundedness 与 Overlap (正式条件)

$$\{Y(1), Y(0)\} \perp D \mid W$$

Conditional Independence (条件独立) / Unconfoundedness (无混淆性)

$$0 < P(D = 1 \mid W) < 1$$

Overlap / Common Support (重叠 / 共同支撑)

每类  $W$  中最好**同时存在** treatment (处理) 与 control (对照)。

以后正式学习 treatment effects / PSM / DML 时再展开。

## 附录 A2 | Pre-treatment vs Post-treatment (处理前 vs 处理后)

---

### Pre-treatment (处理前变量)

家庭背景  
入学前能力  
出生地区

### Post-treatment (处理后变量)

职业  
当前户籍  
treatment 后行为

## 附录 A2 | Pre-treatment vs Post-treatment (处理前 vs 处理后)

### Pre-treatment (处理前变量)

家庭背景  
入学前能力  
出生地区


### Post-treatment (处理后变量)

职业  
当前户籍  
treatment 后行为

Post-treatment variables (处理后变量) 要**高度谨慎**。


## 附录 A3 | 总效应与直接效应

---



## 附录 A3 | 总效应与直接效应

---



总效应 (Total effect)  $\neq$  直接效应 (Direct effect)

## 附录 A4 | 控制变量的系数为什么通常不能做因果解释

---

主处理变量的 identification（识别）成立，  
不代表**每个 control（控制变量）的系数**都有因果含义。

## 附录 A5 | 术语对照（一）· 相关与反事实

| English           | 中文     | 一句话解释                                            |
|-------------------|--------|--------------------------------------------------|
| Confounder        | 混杂变量   | 同时影响 $X$ 与 $Y$ ，不控制会污染估计                         |
| Mediator          | 中介变量   | $X \rightarrow M \rightarrow Y$ 的作用路径；控制它会改变研究问题 |
| Selection Bias    | 选择偏误   | 样本进入方式本身与结果相关                                    |
| Reverse Causality | 反向因果   | 真实的因果方向与设想相反                                     |
| Measurement Error | 测量误差   | 变量测不准，估计被稀释                                      |
| Counterfactual    | 反事实    | 「若没做这个处理会怎样」的那个结果                                |
| Potential Outcome | 潜在结果   | $Y(1)$ 与 $Y(0)$ ：同一个人在两个世界的结果                    |
| ATE / ATT         | 平均处理效应 | 全体 / 处理组的平均因果效应                                  |

## 附录 A6 | 术语对照（二）· 识别与推断

| English                   | 中文        | 一句话解释                 |
|---------------------------|-----------|-----------------------|
| Overlap / Common Support  | 重叠 / 共同支撑 | 每类 $W$ 中处理组与对照组都得有人   |
| Unconfoundedness          | 无混淆性      | 控制 $W$ 后处理近似随机（即条件独立） |
| Estimand                  | 估计目标      | 你到底想估计哪一个量            |
| Identification            | 识别        | 凭什么说这份数据能回答这个问题       |
| Estimator                 | 估计量       | 具体用哪个公式去算             |
| Inference                 | 推断        | 这个估计有多不确定             |
| Research Design           | 研究设计      | 让识别假设更可信的整体安排         |
| Fixed Effects             | 固定效应      | 同一个体自己和自己比（组内变异）      |
| Instrumental Variables    | 工具变量      | 只用外部推动的那部分变异          |
| Difference-in-Differences | 双重差分      | 比较相对变化，而不是比较水平        |
| Regression Discontinuity  | 断点回归      | 只比较断点两侧非常接近的人         |
| DML                       | 双重机器学习    | 用机器学习更灵活地做残差化         |

符号约定： $D = \text{treatment}$ ， $W = \text{controls} / \text{covariates}$ ， $Y = \text{outcome}$ ；问题一的内生性四种来源沿用  $X$ （处理） /  $Z$ （混杂）记号。

# 参考文献

---

---

## 中文文献

张子尧、黄炜 (2025): 《实证研究中的控制变量选择: 原理与原则》, 《管理世界》2025 年第 10 期。

---

## 英文文献

Angrist, J. D., & Pischke, J.-S. (2009). *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton University Press.

Angrist, J. D., & Pischke, J.-S. (2015). *Mastering 'Metrics: The Path from Cause to Effect*. Princeton University Press.

Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68.

Imbens, G. W., & Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction*. Cambridge University Press.

Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2nd ed.). Cambridge University Press.

Rubin, D. B. (1974). Estimating causal effects of treatments in randomized and nonrandomized studies. *Journal of Educational Psychology*, 66(5), 688–701.

---