
第四讲 从相关到因果

现代计量经济学真正想解决什么问题？

$\hat{\beta} \stackrel{?}{=} \text{因果效应}$

中级计量经济学 | 张呈磊

相关 · 反事实 · 识别

从「会回归」到「会建模」

第二讲 回归 → 参数估计 → 假设检验



第三讲 函数形式 → 控制变量 → FWL → 模型诊断

从「会回归」到「会建模」

第二讲 回归 → 参数估计 → 假设检验



第三讲 函数形式 → 控制变量 → FWL → 模型诊断

我们已经可以做出一个「统计上不错」的回归模型。

从「会回归」到「会建模」

第二讲 回归 → 参数估计 → 假设检验



第三讲 函数形式 → 控制变量 → FWL → 模型诊断

我们已经可以做出一个「统计上不错」的回归模型。

这就够了吗？

一个看起来很漂亮的结果

被解释变量： Score	
AI use	1.50*** (0.30)
Controls (控制变量)	已控制
Functional form (函数形式)	已检验
Diagnostics (模型诊断)	通过

与第三讲末尾那张「完美」结果卡是同一个模型。

一个看起来很漂亮的结果

被解释变量： Score	
AI use	1.50*** (0.30)
Controls (控制变量)	已控制
Functional form (函数形式)	已检验
Diagnostics (模型诊断)	通过

与第三讲末尾那张「完美」结果卡是同一个模型。

可以说「AI 提高了学习成绩」吗？

今天真正的问题

$\hat{\beta} \stackrel{?}{=} \text{因果效应}$

今天真正的问题

$\hat{\beta} \stackrel{?}{=} \text{因果效应}$

一个显著、稳健、诊断良好的回归系数，
为什么仍然可能只是**相关关系**？

今天三个问题

① 为什么一个「好回归」

仍然不等于因果？

相关 $\neq$ 因果

今天三个问题

① 为什么一个「好回归」
仍然不等于因果？
相关 $\neq$ 因果

② 因果效应
到底是什么？
反事实比较

今天三个问题

① 为什么一个「好回归」
仍然不等于因果？
相关 $\neq$ 因果

② 因果效应
到底是什么？
反事实比较

③ 现代计量方法
究竟在寻找什么？
可信的比较

今天三个问题

① 为什么一个「好回归」
仍然不等于因果？
相关 $\neq$ 因果

② 因果效应
到底是什么？
反事实比较

③ 现代计量方法
究竟在寻找什么？
可信的比较

相关 $\rightarrow$ 反事实 $\rightarrow$ 识别


问题一

为什么一个「好回归」仍然不等于因果？


Controls + Robust SE + Diagnostics, 为什么还不够？

相关 ▶ 反事实 ▶ 识别

最熟悉的问题：遗漏变量




最熟悉的问题：遗漏变量



AI 使用多的学生成绩更高，
这背后可能是 AI，也可能只是能力
(Ability)。


最熟悉的问题：遗漏变量



AI 使用多的学生成绩更高，
这背后可能是 AI，也可能只是能力
(Ability)。

$$E(u \mid AI) \neq 0$$

最熟悉的问题：遗漏变量




AI 使用多的学生成绩更高，
这背后可能是 AI，也可能只是能力
(Ability)。

$$E(u \mid AI) \neq 0$$

这是第三讲已经认识的问题——但今天要把它问到底。


数据里会长什么样?



总体相关 (Overall correlation)

能力相同者之间 (Within-ability)

数据里会长什么样?



总体相关 (Overall correlation)

能力相同者之间 (Within-ability)

总体斜率 (slope) 中可能混入能力差异所带来的那部分。

第三讲给出的答案: **Control** (控制变量)

$$Score_i = \beta_0 + \beta_1 AI_i + \beta_2 Ability_i + u_i$$

第三讲给出的答案：Control（控制变量）

$$Score_i = \beta_0 + \beta_1 AI_i + \beta_2 Ability_i + u_i$$

$$AI = \widehat{AI}(Ability) + \widetilde{AI}$$

第三讲给出的答案: **Control** (控制变量)

$$Score_i = \beta_0 + \beta_1 AI_i + \beta_2 Ability_i + u_i$$

$$AI = \widehat{AI}(Ability) + \widetilde{AI}$$

β_1 利用的是 $\widetilde{AI}$

第三讲给出的答案: **Control** (控制变量)

$$Score_i = \beta_0 + \beta_1 AI_i + \beta_2 Ability_i + u_i$$

$$AI = \widehat{AI}(Ability) + \widetilde{AI}$$

β_1 利用的是 $\widetilde{AI}$

FWL (Frisch-Waugh-Lovell 定理): 先净化, 再比较。

但一个新的问题出现了

只要能控制，就应该控制吗？

但一个新的问题出现了

只要能控制，就应该控制吗？

控制变量越多 = 模型越好？

但一个新的问题出现了

只要能控制，就应该控制吗？

控制变量越多 = 模型越好？

未必如此

一个看起来「当然应该控制」的变量

研究教育对收入的影响，职业要不要控制？

Education

?

Income

一个看起来「当然应该控制」的变量

研究教育对收入的影响，职业要不要控制？

Education

?

Income

先不要急着回答——看两种可能的结构。

如果职业是一条作用路径?




如果职业是一条作用路径？



教育的一部分回报，
正是来自**进入更高薪职业的机会**。

如果职业是一条作用路径？



教育的一部分回报，
正是来自**进入更高薪职业的机会**。

如果研究的是教育对收入的**总效应**，控制职业意味着什么？

Mediator（中介变量）：控制会改变你估计的东西

总效应 = 直接效应 + 间接效应


Total Effect = Direct Effect + Indirect Effect

参考：张子尧、黄炜（2025）

Mediator (中介变量): 控制会改变你估计的东西

总效应 = 直接效应 + 间接效应

Total Effect = Direct Effect + Indirect Effect




参考: 张子尧、黄炜 (2025)

Mediator (中介变量): 控制会改变你估计的东西

总效应 = 直接效应 + 间接效应

Total Effect = Direct Effect + Indirect Effect




控制中介变量会阻断一部分因果路径。

参考: 张子尧、黄炜 (2025)

Mediator (中介变量): 控制会改变你估计的东西

总效应 = 直接效应 + 间接效应

Total Effect = Direct Effect + Indirect Effect




控制中介变量会阻断一部分因果路径。


控制变量可能改变 estimand (估计目标)

参考: 张子尧、黄炜 (2025)

更麻烦：职业还可能是 Collider（对撞变量）




更麻烦：职业还可能是 Collider（对撞变量）



在「同样进入高薪职业」的人中，
学历较低的人是否往往需要**更高能力**？

更麻烦：职业还可能是 Collider（对撞变量）



在「同样进入高薪职业」的人中，
学历较低的人是否往往需要**更高能力**？

$Education \not\perp Ability \mid Occupation$

统计上「控制得更干净」，因果上可能更糟

原来： Education 与 Ability 可不相关

统计上「控制得更干净」，因果上可能更糟

原来： Education 与 Ability 可不相关

控制 Occupation 后： Education 与 Ability 产生关联

统计上「控制得更干净」，因果上可能更糟

原来： Education 与 Ability 可不相关

控制 Occupation 后： Education 与 Ability 产生关联

而 Ability 又影响 Income

统计上「控制得更干净」，因果上可能更糟

原来： Education 与 Ability 可不相关

控制 Occupation 后： Education 与 Ability 产生关联

而 Ability 又影响 Income

Bad Control（错误控制） $\Rightarrow$ Selection Bias（选择偏误）

三种最基本的因果结构

Confounder (混杂变量)




通常需要认真控制

Mediator (中介变量)



是否控制取决于 estimand
(估计目标)

Collider (对撞变量)



机械控制可能制造偏误

三种最基本的因果结构

Confounder (混杂变量)




通常需要认真控制

Mediator (中介变量)



是否控制取决于 estimand
(估计目标)

Collider (对撞变量)



机械控制可能制造偏误

变量「好不好」取决于**因果结构**，而不是相关性本身。

还有一种麻烦：方向可能反过来



还有一种麻烦：方向可能反过来



成绩较差的学生，
会不会反而**更依赖 AI**？


还有一种麻烦：方向可能反过来



成绩较差的学生，
会不会反而**更依赖 AI**？

两种机制都说得通，
数据本身不会告诉你哪一个是真的。

还有一种麻烦：方向可能反过来



$AI \leftrightarrow Score$

成绩较差的学生，
会不会反而**更依赖 AI**？

两种机制都说得通，
数据本身不会告诉你哪一个是真的。

Correlation（相关关系）本身不告诉我们方向。

这些问题有什么共同点？——其实是两类

路径 A: Identification Problem
(识别问题)

Omitted Variables (遗漏变量)

Reverse Causality (反向因果)

Selection (样本选择)

Collider / Bad Control (对撞 / 错误控制)

Measurement Error (测量误差)

$$E(u | X) \neq 0$$

用于估计 β 的变异
与其他影响 Y 的因素纠缠

这些问题有什么共同点？——其实是两类

路径 A: Identification Problem (识别问题)

Omitted Variables (遗漏变量)

Reverse Causality (反向因果)

Selection (样本选择)

Collider / Bad Control (对撞 / 错误控制)

Measurement Error (测量误差)

$$E(u | X) \neq 0$$

用于估计 β 的变异
与其他影响 Y 的因素纠缠

路径 B: Estimand Problem (估计目标问题)

Mediator (中介变量)

Post-treatment Control (处理后控制)

控制以后，**研究问题本身**发生了变化

Total Effect (总效应)

→ Controlled / Direct-type (受控 / 直接效应)

这些问题有什么共同点？——其实是两类

路径 A: Identification Problem (识别问题)

Omitted Variables (遗漏变量)

Reverse Causality (反向因果)

Selection (样本选择)

Collider / Bad Control (对撞 / 错误控制)

Measurement Error (测量误差)

$$E(u | X) \neq 0$$

用于估计 β 的变异
与其他影响 Y 的因素纠缠

路径 B: Estimand Problem (估计目标问题)

Mediator (中介变量)

Post-treatment Control (处理后控制)

控制以后，**研究问题本身**发生了变化

Total Effect (总效应)

→ Controlled / Direct-type (受控 / 直接效应)

问题不同，但都会使 $\hat{\beta}$ 的因果解释变得困难。

把「内生性」重新理解一下

用于估计 β 的那部分**变异**，与误差项**纠缠在了一起**。

$$E(u | X) \neq 0$$

在线性相关的简化情形下，常表现为： $Cov(X, u) \neq 0$

把「内生性」重新理解一下

用于估计 β 的那部分**变异**，与误差项**纠缠在了一起**。

$$E(u | X) \neq 0$$

在线性相关的简化情形下，常表现为： $Cov(X, u) \neq 0$

所以问题不只是「有没有控制变量」，
而是：

把「内生性」重新理解一下

用于估计 β 的那部分**变异**，与误差项**纠缠在了一起**。

$$E(u | X) \neq 0$$

在线性相关的简化情形下，常表现为： $Cov(X, u) \neq 0$

所以问题不只是「有没有控制变量」，
而是：

这部分变异（variation）值得相信吗？

问题一小结

①

回归做得规范，不代表因果识别成立

②

控制变量越多，并不自动带来更好的识别

③

关键是理解变量在因果结构中的位置

问题一小结

①

回归做得规范，不代表因果识别成立

②

控制变量越多，并不自动带来更好的识别

③

关键是理解变量在因果结构中的位置

那么，「因果效应」本身到底是什么？

问题二

因果效应到底是什么？

因果不是「两个不同的人有差异」。

相关 ▶ 反事实 ▶ 识别

先区分两句话

AI 使用更多的学生，
平均成绩更高。

Correlation（相关关系）

先区分两句话

AI 使用更多的学生，
平均成绩更高。

Correlation（相关关系）

如果让同一个学生
使用 AI、而不是不使用 AI，
他的成绩会怎样？

Causal Question（因果问题）

先区分两句话

AI 使用更多的学生，
平均成绩更高。

Correlation (相关关系)

如果让同一个学生
使用 AI、而不是不使用 AI，
他的成绩会怎样？

Causal Question (因果问题)

关联 (Association) $\neq$ 干预 (Intervention)

同一个学生，两个可能世界

为了把反事实讲清楚，下面暂时把 AI 使用简化为二元处理 (treatment)：使用 AI 记为 $D = 1$ ，不使用 AI 记为 $D = 0$ 。

同一个学生

World 1

使用 AI

$Y_i(1)$

World 0


不使用 AI

$Y_i(0)$

同一个学生，两个可能世界

为了把反事实讲清楚，下面暂时把 AI 使用简化为二元处理（treatment）：使用 AI 记为 $D = 1$ ，不使用 AI 记为 $D = 0$ 。

同一个学生




不能同时看到

同一个学生，两个可能世界

为了把反事实讲清楚，下面暂时把 AI 使用简化为二元处理（treatment）：使用 AI 记为 $D = 1$ ，不使用 AI 记为 $D = 0$ 。

同一个学生



不能同时看到

$$\tau_i = Y_i(1) - Y_i(0)$$

这才是「个体因果效应」

$$\tau_i = Y_i(1) - Y_i(0)$$

这才是「个体因果效应」

$$\tau_i = Y_i(1) - Y_i(0)$$

因果效应问的不是：
「张三和李四差多少？」

这才是「个体因果效应」

$$\tau_i = Y_i(1) - Y_i(0)$$

因果效应问的不是：
「张三和李四差多少？」

而是：
「张三在两个不同处理（**treatment**）状态下会差多少？」

但我们遇到一个根本困难

对于同一个 i :

但我们遇到一个根本困难

对于同一个 i :

如果 $D_i = 1$, 我们看到 $Y_i(1)$

但我们遇到一个根本困难

对于同一个 i :

如果 $D_i = 1$, 我们看到 $Y_i(1)$

但 $Y_i(0) = ?$

但我们遇到一个根本困难

对于同一个 i :

如果 $D_i = 1$, 我们看到 $Y_i(1)$

但 $Y_i(0) = ?$

反过来也一样。

但我们遇到一个根本困难

对于同一个 i :

如果 $D_i = 1$, 我们看到 $Y_i(1)$

但 $Y_i(0) = ?$

反过来也一样。

同一个人不可能同时处在两个世界

Fundamental Problem of Causal Inference

因果推断的根本问题

我们永远缺少一个潜在结果。

观测到的结果 + 缺失的反事实

Observed + Missing Counterfactual

Fundamental Problem of Causal Inference

因果推断的根本问题

我们永远缺少一个潜在结果。

观测到的结果 + 缺失的反事实

Observed + Missing Counterfactual

因果推断本质上是一个反事实缺失问题。

所以真正的问题不是「拟合得多好」

Prediction (预测)

给定 X , Y 是多少?

Causal Inference (因果推断)

如果改变 X , Y 会怎样?

所以真正的问题不是「拟合得多好」

Prediction (预测)

给定 X , Y 是多少?

Causal Inference (因果推断)

如果改变 X , Y 会怎样?

因果推断要为**缺失的反事实**找到可信替代。

从个体效应到平均效应

$$ATE = E[Y(1) - Y(0)]$$

ATE: 平均处理效应 (Average Treatment Effect)

从个体效应到平均效应

$$ATE = E[Y(1) - Y(0)]$$

ATE: 平均处理效应 (Average Treatment Effect)

ATT (处理组平均处理效应): 对已经接受处理的人, 平均处理效应是多少?

从个体效应到平均效应

$$ATE = E[Y(1) - Y(0)]$$

ATE: 平均处理效应 (Average Treatment Effect)

ATT (处理组平均处理效应): 对已经接受处理的人, 平均处理效应是多少?

我们通常无法识别每个人的 τ_i ,
但可能识别某个群体的**平均效应**。

谁可以替代看不到的反事实？

一个使用 AI 的学生，
他「如果不用 AI」的成绩从哪里来？

谁可以替代看不到的反事实？

一个使用 AI 的学生，
他「如果不用 AI」的成绩从哪里来？

另一个没用 AI 的学生？

谁可以替代看不到的反事实？

一个使用 AI 的学生，
他「如果不用 AI」的成绩从哪里来？

另一个没用 AI 的学生？

他们真的可比吗？

谁可以替代看不到的反事实？


一个使用 AI 的学生，
他「如果不用 AI」的成绩从哪里来？

另一个没用 AI 的学生？

他们真的可比吗？


因果推断 = 找到可信的比较对象

为什么 Randomized Experiment (随机实验) 是基准?



Random Assignment /
Treatment / Control


为什么 Randomized Experiment (随机实验) 是基准?



Random Assignment /
Treatment / Control

平均意义上，处理组与对照组
在 treatment 之前可比。

为什么 Randomized Experiment (随机实验) 是基准?



Random Assignment /
Treatment / Control

平均意义上, 处理组与对照组
在 treatment 之前可比。

$$D \perp \{Y(1), Y(0)\}$$

Randomization（随机化）做了什么？

不是：让回归更显著

Randomization（随机化）做了什么？

不是：让回归更显著

创造了可信的反事实（counterfactual）

Randomization（随机化）做了什么？

不是：让回归更显著

创造了可信的反事实（counterfactual）

在平均意义上，对照组帮助我们估计
处理组缺失的反事实结果。

现实中通常没有随机实验

教育不能随意随机分配
城市政策不是随机出台
企业选择融资方式并不随机
AI 使用也通常是自选择

现实中通常没有随机实验

教育不能随意随机分配
城市政策不是随机出台
企业选择融资方式并不随机
AI 使用也通常是自选择

观测数据 (Observational Data)

现实中通常没有随机实验

教育不能随意随机分配
城市政策不是随机出台
企业选择融资方式并不随机
AI 使用也通常是自选择

观测数据 (Observational Data)

我们必须自己创造「可信比较」。

Control Variables (控制变量) 的因果解释

$$\{Y(1), Y(0)\} \perp D \mid X$$

Conditional Independence (条件独立) / Unconfoundedness (无混淆性)

Control Variables（控制变量）的因果解释

$$\{Y(1), Y(0)\} \perp D \mid X$$

如果在 X 相同的人中，treatment 近似随机，
那么我们可以在「相似的人」之间比较。

Conditional Independence（条件独立） / Unconfoundedness（无混淆性）

Control Variables（控制变量）的因果解释

$$\{Y(1), Y(0)\} \perp D \mid X$$

如果在 X 相同的人中，treatment 近似随机，
那么我们可以在「相似的人」之间比较。


除此之外，还需要「有得比」：同类 X 中最好**同时存在** treatment（处理）与 control（对照），即 Overlap / Common Support（重叠 / 共同支撑）。

Conditional Independence（条件独立） / Unconfoundedness（无混淆性）

「控制」的新理解




「控制」的新理解



剔除以后，比较真的更可信吗？

「控制」的新理解



剔除以后，比较真的更可信吗？

统计控制 → 因果识别

一个经验研究其实有四个层次

Estimand (估计目标)

我到底想估计什么？

Identification (识别)

为什么数据能够告诉我？

Estimator (估计量)

怎么计算？

Inference (推断)

这个估计有多不确定？

一个经验研究其实有四个层次

Estimand (估计目标)

我到底想估计什么？

Identification (识别)

为什么数据能够告诉我？

Estimator (估计量)

怎么计算？

Inference (推断)

这个估计有多不确定？

Research Design (研究设计) 位于 Identification (识别) 与 Estimator (估计量) 之间。

一个经验研究其实有四个层次

Estimand (估计目标)

我到底想估计什么？

Identification (识别)

为什么数据能够告诉我？

Estimator (估计量)

怎么计算？

Inference (推断)

这个估计有多不确定？

Research Design (研究设计) 位于 Identification (识别) 与 Estimator (估计量) 之间。

估计目标 $\neq$ 识别 $\neq$ 估计 $\neq$ 推断

问题二小结

①

因果效应是反事实比较

②

我们永远缺少一个潜在结果

③

核心是找到可信的比较组
(comparison group)

问题二小结

①

因果效应是反事实比较

②

我们永远缺少一个潜在结果

③

核心是找到可信的比较组
(comparison group)

后面的现代计量方法，
就是不同场景下寻找不同的「可信比较」。

问题三

现代计量方法究竟在寻找什么？

后面的 FE、IV、DID、RD 为什么都在解决同一个问题？

相关 ▶ 反事实 ▶ 识别

先回到 FWL (Frisch–Waugh–Lovell 定理)

$$X = \hat{X}(Z) + \tilde{X}$$

先回到 FWL (Frisch–Waugh–Lovell 定理)

$$X = \hat{X}(Z) + \tilde{X}$$

$$\tilde{Y} = \beta \tilde{X} + \text{error}$$

先回到 FWL (Frisch–Waugh–Lovell 定理)

$$X = \hat{X}(Z) + \tilde{X}$$

$$\tilde{Y} = \beta \tilde{X} + \text{error}$$

哪一部分**变异**在识别 β ?

第四讲再多问一步

识别用的变异
从哪里来？

Where does the identifying variation come from?

第四讲再多问一步

识别用的变异
从哪里来？

Where does the identifying variation come from?

不仅要有变异（variation），还要问：

第四讲再多问一步

识别用的变异
从哪里来？

Where does the identifying variation come from?

不仅要有变异（variation），还要问：

为什么值得相信？

Why should we trust it?

现代计量方法地图

Controls (控制变量)

DID (双重差分)

Fixed Effects (固定效应)


可信的比较
+
识别用的变异

RD (断点回归)


IV (工具变量)

ML / DML (机器学习)


现代计量方法地图




现代计量方法地图



现代计量方法地图



OLS（普通最小二乘）+ Controls（控制变量）




比较**条件相似**的人。

条件比较

Conditional Comparison

OLS（普通最小二乘）+ Controls（控制变量）




比较**条件相似**的人。

条件比较

Conditional Comparison


假设：控制 X 后，treatment（处理）足够接近随机。

Fixed Effects (固定效应): 自己和自己比



不同企业 / 个人之间
存在大量**固定差异**。

Fixed Effects (固定效应): 自己和自己比



不同企业／个人之间
存在大量**固定差异**。

$$X_{it} - \bar{X}_i$$

组内变异

within variation

后续面板数据专题系统讲。

Instrumental Variables (工具变量): 只用「外部推动」的部分



后面 IV 专题再正式定义这些条件。

Instrumental Variables (工具变量): 只用「外部推动」的部分



一个好的工具变量 Z 需要:

- ▶ 能够推动 X ;
- ▶ 不与影响 Y 的其他未观测因素纠缠;
- ▶ 对 Y 的影响只能通过 X 。

后面 IV 专题再正式定义这些条件。

Instrumental Variables (工具变量): 只用「外部推动」的部分



一个好的工具变量 Z 需要:

- ▶ 能够推动 X ;
- ▶ 不与影响 Y 的其他未观测因素纠缠;
- ▶ 对 Y 的影响只能通过 X 。

X 中由 Z 推动的那部分变异

后面 IV 专题再正式定义这些条件。

Instrumental Variables (工具变量): 只用「外部推动」的部分



一个好的工具变量 Z 需要:

- ▶ 能够推动 X ;
- ▶ 不与影响 Y 的其他未观测因素纠缠;
- ▶ 对 Y 的影响只能通过 X 。


X 中由 Z 推动的那部分变异

外部推动的变异

Externally Induced Variation


后面 IV 专题再正式定义这些条件。

DID (双重差分): 比较变化, 而不是水平



$$\Delta Y_T - \Delta Y_C$$

DID (双重差分): 比较变化, 而不是水平




$$\Delta Y_T - \Delta Y_C$$

差分变化


后续正式学习平行趋势 (Parallel Trends)。

RD (断点回归): 只比较 **cutoff** (断点) 附近



断点两侧非常接近的人，处理状态 (treatment status) 却不同。


RD (断点回归): 只比较 **cutoff** (断点) 附近



断点两侧非常接近的人，处理状态 (treatment status) 却不同。


局部比较 (Local Comparison)

ML / DML (机器学习 / 双重机器学习): 更灵活地净化



FWL
线性残差化
(Linear partialling out)

ML / DML (机器学习 / 双重机器学习): 更灵活地净化




FWL

线性残差化
(Linear partialling out)

DML (双重机器学习)

更灵活地估计
控制变量那部分

ML / DML (机器学习 / 双重机器学习): 更灵活地净化



FWL
线性残差化
(Linear partialling out)

DML (双重机器学习)
更灵活地估计
控制变量那部分

机器学习本身不是识别策略

这些方法都在回答同一个识别问题

可信的比较
+
识别用的变异

Controls (控制) → 条件可比
FE (固定效应) → 同一个体内部
IV (工具变量) → 外生推动

DID (双重差分) → 相对变化
RD (断点回归) → 阈值附近
ML/DML (机器学习) → 更好地净化

这些方法都在回答同一个识别问题

可信的比较
+
识别用的变异

Controls (控制) → 条件可比
FE (固定效应) → 同一个体内部
IV (工具变量) → 外生推动

DID (双重差分) → 相对变化
RD (断点回归) → 阈值附近
ML/DML (机器学习) → 更好地净化

方法不同，但都要回答：哪一部分变异在识别 β ? 为什么这部分变异值得相信?

现代计量的真正 workflow



Research Design（研究设计）的作用，
是让 identification assumptions（识别假设）更可信。

现代计量的真正 workflow



不是：

回归 → p 值 → 结论

Research Design（研究设计）的作用，
是让 identification assumptions（识别假设）更可信。

现代计量的真正 workflow



不是：

回归 $\rightarrow$ p 值 $\rightarrow$ 结论

先问识别，再跑回归。

Research Design（研究设计）的作用，
是让 identification assumptions（识别假设）更可信。

把 AI—成绩案例重新走一遍

Question
(研究问题)

AI 是否提高成绩?

Estimand
(估计目标)

平均因果效应?

Threats
(识别威胁)

Ability / Motivation /
Reverse causality /
Selection

把 AI—成绩案例重新走一遍

Question (研究问题)

AI 是否提高成绩?

Estimand (估计目标)

平均因果效应?

Threats (识别威胁)

Ability / Motivation /
Reverse causality /
Selection

Design (研究设计)

Controls? FE? IV?
Other design?

Estimator (估计量)

对应估计方法

Inference (推断)

Robust / Cluster SE
(稳健/聚类标准误) 等

把 AI—成绩案例重新走一遍

Question (研究问题)

AI 是否提高成绩?

Estimand (估计目标)

平均因果效应?

Threats (识别威胁)

Ability / Motivation /
Reverse causality /
Selection

Design (研究设计)

Controls? FE? IV?
Other design?

Estimator (估计量)

对应估计方法

Inference (推断)

Robust / Cluster SE
(稳健/聚类标准误) 等

先问识别，再跑回归。

本讲三个问题：现在能回答了吗？

① 好回归为何不等于因果？

相关关系可能混入混杂、反向因果、选择和错误控制。

本讲三个问题：现在能回答了吗？

① 好回归为何不等于因果？

相关关系可能混入混杂、反向因果、选择和错误控制。

② 因果效应是什么？

实际结果与反事实结果之间的比较。

本讲三个问题：现在能回答了吗？

① 好回归为何不等于因果？

相关关系可能混入混杂、反向因果、选择和错误控制。


② 因果效应是什么？

实际结果与反事实结果之间的比较。

③ 现代方法在寻找什么？

可信的比较对象与识别用的变异。

从这里开始，进入中级计量



Panel Data / FE · IV · DID · RD · ML / DML

第五讲 面板数据与固定效应

第五讲 面板数据与固定效应

如果个体之间有大量不可观测差异，
我们能不能让「同一个人自己和自己比」？

第五讲 面板数据与固定效应

如果个体之间有大量不可观测差异，
我们能不能让「同一个人自己和自己比」？

从识别用的变异出发理解 Fixed Effects（固定效应）

$$0 < P(D = 1 \mid X) < 1$$

$$0 < P(D = 1 \mid X) < 1$$

每类 X 中最好**同时存在** treatment (处理) 与 control (对照)。

附录 A2 | Pre-treatment vs Post-treatment (处理前 vs 处理后)

Pre-treatment (处理前变量)

家庭背景
入学前能力
出生地区

Post-treatment (处理后变量)

职业
当前户籍
treatment 后行为

附录 A2 | Pre-treatment vs Post-treatment (处理前 vs 处理后)

Pre-treatment (处理前变量)


家庭背景
入学前能力
出生地区

Post-treatment (处理后变量)


职业
当前户籍
treatment 后行为

Post-treatment variables (处理后变量) 要**高度谨慎**。

附录 A3 | 总效应与直接效应



附录 A3 | 总效应与直接效应



总效应 (Total effect) $\neq$ 直接效应 (Direct effect)

主处理变量的 identification（识别）成立，
不代表每个 **control**（控制变量）的系数都有因果含义。

附录 A5 | 术语对照 (一) · 相关与反事实

English	中文	一句话解释
Confounder	混杂变量	同时影响 X 与 Y ，不控制会污染估计
Mediator	中介变量	$X \rightarrow M \rightarrow Y$ 的作用路径；控制它会改变研究问题
Collider	对撞变量	同时被 X 与 Y 影响；控制它反而制造偏误
Bad Control	错误控制	控制了不该控制的变量，引入选择偏误
Selection Bias	选择偏误	样本进入方式本身与结果相关
Reverse Causality	反向因果	真实的因果方向与设想相反
Measurement Error	测量误差	变量测不准，估计被稀释
Counterfactual	反事实	「若没做这个处理会怎样」的那个结果
Potential Outcome	潜在结果	$Y(1)$ 与 $Y(0)$ ：同一个人在两个世界的结果
ATE / ATT	平均处理效应	全体 / 处理组的平均因果效应

附录 A6 | 术语对照 (二) · 识别与推断

English	中文	一句话解释
Overlap / Common Support	重叠 / 共同支撑	每类 X 中处理组与对照组都得有人
Unconfoundedness	无混淆性	控制 X 后处理近似随机 (即条件独立)
Estimand	估计目标	你到底想估计哪一个量
Identification	识别	凭什么说这份数据能回答这个问题
Estimator	估计量	具体用哪个公式去算
Inference	推断	这个估计有多不确定
Research Design	研究设计	让识别假设更可信的整体安排
Fixed Effects	固定效应	同一个体自己和自己比 (组内变异)
Instrumental Variables	工具变量	只用外部推动的那部分变异
Difference-in-Differences	双重差分	比较相对变化, 而不是比较水平
Regression Discontinuity	断点回归	只比较断点两侧非常接近的人
DML	双重机器学习	用机器学习更灵活地做残差化

参考文献

中文文献

张子尧、黄炜 (2025): 《实证研究中的控制变量选择: 原理与原则》, 《管理世界》2025 年第 10 期。

英文文献

Angrist, J. D., & Pischke, J.-S. (2009). *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton University Press.

Angrist, J. D., & Pischke, J.-S. (2015). *Mastering 'Metrics: The Path from Cause to Effect*. Princeton University Press.

Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68.

Imbens, G. W., & Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction*. Cambridge University Press.

Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2nd ed.). Cambridge University Press.

Rubin, D. B. (1974). Estimating causal effects of treatments in randomized and nonrandomized studies. *Journal of Educational Psychology*, 66(5), 688–701.
