
第四讲 从相关到因果

现代计量经济学真正想解决什么问题？

$\hat{\beta} \stackrel{?}{=} \text{因果效应}$

中级计量经济学 | 张呈磊

相关 · 反事实 · 识别

从「会回归」到「会建模」

第二讲 回归 → 参数估计 → 假设检验



第三讲 函数形式 → 控制变量 → FWL → 模型诊断

从「会回归」到「会建模」

第二讲 回归 → 参数估计 → 假设检验



第三讲 函数形式 → 控制变量 → FWL → 模型诊断

我们已经可以做出一个「统计上不错」的回归模型。

从「会回归」到「会建模」

第二讲 回归 → 参数估计 → 假设检验



第三讲 函数形式 → 控制变量 → FWL → 模型诊断

我们已经可以做出一个「统计上不错」的回归模型。

这就够了吗？

一个看起来很漂亮的结果

被解释变量: Score

AI use	1.50*** (0.30)
--------	-------------------

Controls (控制变量)	已控制
-----------------	-----

Functional form (函数形式)	已检验
------------------------	-----

Diagnostics (模型诊断)	通过
--------------------	----

与第三讲末尾那张「完美」结果卡是同一个模型。

一个看起来很漂亮的结果

被解释变量: Score

AI use	1.50*** (0.30)
--------	-------------------

Controls (控制变量)	已控制
-----------------	-----

Functional form (函数形式)	已检验
------------------------	-----

Diagnostics (模型诊断)	通过
--------------------	----

与第三讲末尾那张「完美」结果卡是同一个模型。

一个显著、稳健、诊断良好的系数，
为什么仍然可能只是**相关关系**？

一个看起来很漂亮的结果

被解释变量: Score

AI use	1.50*** (0.30)
--------	-------------------

Controls (控制变量)	已控制
-----------------	-----

Functional form (函数形式)	已检验
------------------------	-----

Diagnostics (模型诊断)	通过
--------------------	----

与第三讲末尾那张「完美」结果卡是同一个模型。

一个显著、稳健、诊断良好的系数，
为什么仍然可能只是**相关关系**？

$\hat{\beta} \stackrel{?}{=} \text{Causal Effect (因果效应)}$

我们已经从数据得到信息，然后呢？



我们已经从数据得到信息，然后呢？



Data AI 使用时间、学生成绩、学生能力、其他
观测变量
数据只是观测记录。

我们已经从数据得到信息，然后呢？



Data AI 使用时间、学生成绩、学生能力、其他观测变量

数据只是观测记录。

Information $\hat{\beta}_{AI} = 1.50^{***}$, 即 $AI\ use \uparrow \iff Score \uparrow$

这属于统计规律 / 相关信息。

我们已经从数据得到信息，然后呢？



Data AI 使用时间、学生成绩、学生能力、其他观测变量

数据只是观测记录。

Information $\hat{\beta}_{AI} = 1.50^{***}$, 即 $AI\ use \uparrow \iff Score \uparrow$

这属于统计规律 / 相关信息。

Knowledge 如果我们真的改变一个学生的 AI 使用，他的成绩会怎样？

What happens if we intervene?

我们已经从数据得到信息，然后呢？



Data AI 使用时间、学生成绩、学生能力、其他观测变量

数据只是观测记录。

Information $\hat{\beta}_{AI} = 1.50^{***}$ ，即 $AI\ use \uparrow \iff Score \uparrow$

这属于统计规律／相关信息。

Knowledge 如果我们真的改变一个学生的 AI 使用，他的成绩会怎样？

What happens if we intervene?

相关告诉我们「世界呈现出什么规律」；

因果帮助我们理解「如果改变一个因素，会发生什么」。

我们已经从数据得到信息，然后呢？



Data AI 使用时间、学生成绩、学生能力、其他观测变量

数据只是观测记录。

Information $\hat{\beta}_{AI} = 1.50^{***}$ ，即 $AI\ use \uparrow \iff Score \uparrow$

这属于统计规律／相关信息。

Knowledge 如果我们真的改变一个学生的 AI 使用，他的成绩会怎样？

What happens if we intervene?

相关告诉我们「世界呈现出什么规律」；

因果帮助我们理解「如果改变一个因素，会发生什么」。

经验经济学要从相关信息走向可解释、可干预的知识，**因果推断是关键一步**。

为什么经济学不能满足于相关关系？

延长教育年限，会不会提高收入？

给企业补贴，会不会增加创新？

降息，会不会刺激投资？

为什么经济学不能满足于相关关系？

延长教育年限，会不会提高收入？

给企业补贴，会不会增加创新？

降息，会不会刺激投资？

一旦问题变成「如果改变 X ，会发生什么」，我们就在问**因果问题**。

今天三个问题

① 为什么一个「好回归」
仍然不等于因果？
发现问题
观察到的比较可能被污染

今天三个问题

① 为什么一个「好回归」
仍然不等于因果？
发现问题
观察到的比较可能被污染

② 因果效应
到底是什么？
定义目标
真正需要的是反事实比较

今天三个问题

① 为什么一个「好回归」
仍然不等于因果？
发现问题
观察到的比较可能被污染

② 因果效应
到底是什么？
定义目标
真正需要的是反事实比较

③ 现代计量方法
究竟在寻找什么？
解决问题
寻找可信比较与可信
variation

今天三个问题

① 为什么一个「好回归」
仍然不等于因果？
发现问题
观察到的比较可能被污染

② 因果效应
到底是什么？
定义目标
真正需要的是反事实比较

③ 现代计量方法
究竟在寻找什么？
解决问题
寻找可信比较与可信
variation

发现问题 → 定义目标 → 寻找解决方案

相关 → 反事实 → 识别



问题一

为什么一个「好回归」仍然不等于因果？

Controls + Robust SE + Diagnostics, 为什么还不够？



相关 ▶ 反事实 ▶ 识别

遗漏变量：最熟悉的麻烦





总体相关（Overall correlation）／能力相同者之间（Within-ability）

遗漏变量：最熟悉的麻烦



总体相关（Overall correlation）／能力相同者之间（Within-ability）

遗漏变量：最熟悉的麻烦





总体相关（Overall correlation）／能力相同者之间（Within-ability）

AI 使用多的学生成绩更高，这背后可能是 AI，也可能只是能力（Ability）。

也就是说：X 与其他影响 Y 的因素纠缠在一起，因此回归系数可能混入其他作用。

遗漏变量：最熟悉的麻烦



总体相关（Overall correlation）／能力相同者之间（Within-ability）

AI 使用多的学生成绩更高，这背后可能是 AI，也可能只是能力（Ability）。

也就是说：X 与其他影响 Y 的因素纠缠在一起，因此回归系数可能混入其他作用。

$$E(u \mid AI) \neq 0 \quad \text{线性简化情形下即 } Cov(AI, u) \neq 0$$

总体斜率（slope）里混入了能力差异带来的那部分。

回忆第三讲：FWL 留下的一个重要直觉

$$X \longrightarrow \tilde{X} \quad Y \longrightarrow \tilde{Y}$$

回忆第三讲：FWL 留下的一个重要直觉

$$\begin{aligned} X &\longrightarrow \tilde{X} & Y &\longrightarrow \tilde{Y} \\ \tilde{Y} &= \beta \tilde{X} + \tilde{u} \end{aligned}$$

回忆第三讲：FWL 留下的一个重要直觉

$$X \longrightarrow \tilde{X} \quad Y \longrightarrow \tilde{Y}$$

$$\tilde{Y} = \beta \tilde{X} + \tilde{u}$$

控制 Z 之后， β 利用的是 X 剩余的 **variation**。

回忆第三讲：FWL 留下的一个重要直觉

$$X \longrightarrow \tilde{X} \quad Y \longrightarrow \tilde{Y}$$

$$\tilde{Y} = \beta \tilde{X} + \tilde{u}$$

控制 Z 之后， β 利用的是 X 剩余的 **variation**。



回忆第三讲：FWL 留下的一个重要直觉

$$X \longrightarrow \tilde{X} \quad Y \longrightarrow \tilde{Y}$$

$$\tilde{Y} = \beta \tilde{X} + \tilde{u}$$

控制 Z 之后， β 利用的是 X 剩余的 **variation**。



FWL：先净化，再比较——但第四讲要在它之上**再问一步**。

控制变量越多越好吗？

控制变量不是越多越好

控制变量越多越好吗？

控制变量不是越多越好

思考 研究教育对收入的影响，职业要不要控制？

Education

?

Income

控制变量越多越好吗？

控制变量不是越多越好

思考 研究教育对收入的影响，职业要不要控制？


Education

?

Income


先不要急着回答——看两种可能的结构。

Mediator（中介变量）：控制会改变你估计的东西



参考：张子尧、黄炜（2025）


Mediator（中介变量）：控制会改变你估计的东西



教育的一部分回报，正是来自**进入更高薪职业的机会**。

参考：张子尧、黄炜（2025）

Mediator（中介变量）：控制会改变你估计的东西




教育的一部分回报，正是来自**进入更高薪职业的机会**。

如果研究的是教育对收入的**总作用**，
控制职业可能**切断**教育的一部分作用路径。

参考：张子尧、黄炜（2025）

Mediator（中介变量）：控制会改变你估计的东西



教育的一部分回报，正是来自**进入更高薪职业的机会**。


如果研究的是教育对收入的**总作用**，
控制职业可能**切断**教育的一部分作用路径。

控制以后，我们回答的问题变了。

这实际上意味着 estimand（估计目标）发生了变化。


参考：张子尧、黄炜（2025）

更麻烦：职业还可能是 Collider（对撞变量）



拓展： $Education \not\perp Ability \mid Occupation$


更麻烦：职业还可能是 Collider（对撞变量）



在**所有进入相同高薪职业**的人中，
学历较低的人，是否往往需要**更高能力**？

拓展： $Education \not\perp Ability \mid Occupation$

更麻烦：职业还可能是 Collider（对撞变量）




在**所有进入相同高薪职业**的人中，
学历较低的人，是否往往需要**更高能力**？

原来：Education 与 Ability 可不相关

控制 Occupation 后：二者**反而产生关联**

拓展：Education $\not\propto$ Ability | Occupation

更麻烦：职业还可能是 Collider（对撞变量）



在**所有进入相同高薪职业**的人中，
学历较低的人，是否往往需要**更高能力**？


原来：Education 与 Ability 可不相关

控制 Occupation 后：二者**反而产生关联**

而 Ability 又影响 Income

拓展：Education $\not\propto$ Ability | Occupation

更麻烦：职业还可能是 Collider（对撞变量）



在**所有进入相同高薪职业**的人中，
学历较低的人，是否往往需要**更高能力**？

原来：Education 与 Ability 可不相关

控制 Occupation 后：二者**反而产生关联**


而 Ability 又影响 Income

Bad Control（错误控制） $\Rightarrow$ Selection Bias（选择偏误）

拓展：Education $\not\propto$ Ability | Occupation

三种最基本的因果结构

Confounder (混杂变量)




通常需要认真控制

Mediator (中介变量)



是否控制取决于研究问题


Collider (对撞变量)



机械控制可能制造偏误

三种最基本的因果结构

Confounder (混杂变量)




通常需要认真控制

Mediator (中介变量)



是否控制取决于研究问题

Collider (对撞变量)



机械控制可能制造偏误

变量该不该控制，取决于**因果结构**，而不是相关性大小。

还有一种麻烦：方向可能反过来



还有一种麻烦：方向可能反过来



成绩较差的学生，
会不会反而**更依赖 AI**？

还有一种麻烦：方向可能反过来



$AI \leftrightarrow Score$

成绩较差的学生，
会不会反而**更依赖 AI**？

两种机制都说得通，
数据本身不会告诉你哪一个是真的。

还有一种麻烦：方向可能反过来



$AI \leftrightarrow Score$

成绩较差的学生，
会不会反而**更依赖 AI**？

两种机制都说得通，
数据本身不会告诉你哪一个是真的。

相关关系本身不能告诉我们**因果方向**。

把「内生性」重新理解一下

Identification Problem (识别问题)

用于估计 β 的 variation
与其他影响 Y 的因素纠缠

把「内生性」重新理解一下

Identification Problem (识别问题)

用于估计 β 的 variation
与其他影响 Y 的因素**纠缠**

Estimand Problem (估计目标问题)

控制以后，我们实际上
改变了想估计的问题

把「内生性」重新理解一下

Identification Problem (识别问题)

用于估计 β 的 variation
与其他影响 Y 的因素**纠缠**

Estimand Problem (估计目标问题)

控制以后，我们实际上
改变了想估计的问题

$$E(u \mid X) \neq 0 \quad \text{线性简化情形下即 } Cov(X, u) \neq 0$$

把「内生性」重新理解一下

Identification Problem (识别问题)

用于估计 β 的 variation
与其他影响 Y 的因素**纠缠**

Estimand Problem (估计目标问题)

控制以后，我们实际上
改变了想估计的问题

$$E(u \mid X) \neq 0 \quad \text{线性简化情形下即 } Cov(X, u) \neq 0$$

问题就变成：这部分 variation **值得相信**吗？

问题一收束：只需要记住两句话

规范的回归 $\neq$ 可信的因果效应

问题一收束：只需要记住两句话

规范的回归 $\neq$ 可信的因果效应

控制变量越多 $\neq$ 识别越好

问题一收束：只需要记住两句话

规范的回归 $\neq$ 可信的因果效应

控制变量越多 $\neq$ 识别越好

那么，我们到底想识别的「因果效应」是什么？

我们已经知道「什么不够」——但「因果」究竟是什么？

$\hat{\beta} \stackrel{?}{=} \text{因果效应}$

我们已经知道

显著 $\neq$ 因果

控制很多变量 $\neq$ 因果

诊断通过 $\neq$ 因果

我们已经知道「什么不够」——但「因果」究竟是什么？

$\hat{\beta} \stackrel{?}{=} \text{因果效应}$

我们已经知道

显著 $\neq$ 因果

控制很多变量 $\neq$ 因果

诊断通过 $\neq$ 因果

但还缺一个更基本的问题

我们所谓的「因果效应」，
到底是什么？

我们已经知道「什么不够」——但「因果」究竟是什么？

$\hat{\beta} \stackrel{?}{=} \text{因果效应}$

我们已经知道

显著 $\neq$ 因果

控制很多变量 $\neq$ 因果

诊断通过 $\neq$ 因果

但还缺一个更基本的问题

我们所谓的「因果效应」，
到底是什么？

在讨论「如何识别」之前，必须先知道**我们到底想识别什么。**

问题二

因果效应到底是什么？

因果不是「两个不同的人有差异」。

相关 ▶ 反事实 ▶ 识别

先区分两句话

AI 使用更多的学生，
平均成绩更高。

Correlation（相关关系）

先区分两句话

AI 使用更多的学生，
平均成绩更高。

Correlation（相关关系）

如果让同一个学生
使用 AI、而不是不使用 AI，
他的成绩会怎样？

Causal Question（因果问题）

先区分两句话

AI 使用更多的学生，
平均成绩更高。

Correlation（相关关系）

如果让同一个学生
使用 AI、而不是不使用 AI，
他的成绩会怎样？

Causal Question（因果问题）

关联（Association） $\neq$ 干预（Intervention）

同一个学生，两个可能世界

为了把反事实讲清楚，下面暂时把 AI 使用简化为二元处理 (treatment)：使用 AI 记为 $D = 1$ ，不使用 AI 记为 $D = 0$ 。

同一个学生

World 1
使用 AI
 $Y_i(1)$

World 0
不使用 AI
 $Y_i(0)$

同一个学生，两个可能世界

为了把反事实讲清楚，下面暂时把 AI 使用简化为二元处理（treatment）：使用 AI 记为 $D = 1$ ，不使用 AI 记为 $D = 0$ 。

同一个学生

World 1
使用 AI
 $Y_i(1)$

World 0
不使用 AI
 $Y_i(0)$

$$\tau_i = Y_i(1) - Y_i(0) \quad \text{个体因果效应}$$

本讲最重要的公式

同一个学生，两个可能世界

为了把反事实讲清楚，下面暂时把 AI 使用简化为二元处理（treatment）：使用 AI 记为 $D = 1$ ，不使用 AI 记为 $D = 0$ 。

同一个学生

World 1
使用 AI
 $Y_i(1)$

World 0
不使用 AI
 $Y_i(0)$

$$\tau_i = Y_i(1) - Y_i(0) \quad \text{个体因果效应}$$

本讲最重要的公式

因果效应问的不是「张三和李四差多少？」
而是：同一个单位在两个可能世界中的差异。

Fundamental Problem of Causal Inference

因果推断的根本问题

对于同一个 i :

Fundamental Problem of Causal Inference

因果推断的根本问题

对于同一个 i :

如果 $D_i = 1$, 我们看到 $Y_i(1)$; 但 $Y_i(0) = ?$

Fundamental Problem of Causal Inference

因果推断的根本问题

对于同一个 i :

如果 $D_i = 1$, 我们看到 $Y_i(1)$; 但 $Y_i(0) = ?$
反过来也一样。

Fundamental Problem of Causal Inference

因果推断的根本问题

对于同一个 i :

如果 $D_i = 1$, 我们看到 $Y_i(1)$; 但 $Y_i(0) = ?$
反过来也一样。

同一个人不可能同时处在两个世界

Fundamental Problem of Causal Inference

因果推断的根本问题

对于同一个 i :

如果 $D_i = 1$, 我们看到 $Y_i(1)$; 但 $Y_i(0) = ?$
反过来也一样。

同一个人不可能同时处在两个世界

我们永远缺少一个潜在结果。

观测到的结果 + 缺失的反事实

Observed + Missing Counterfactual

Fundamental Problem of Causal Inference

因果推断的根本问题

对于同一个 i :

如果 $D_i = 1$, 我们看到 $Y_i(1)$; 但 $Y_i(0) = ?$
反过来也一样。

同一个人不可能同时处在两个世界

我们永远缺少一个潜在结果。

观测到的结果 + 缺失的反事实

Observed + Missing Counterfactual

因果推断本质上是一个反事实缺失问题。

所以真正的问题不是「拟合得多好」

Prediction (预测)

给定 D , Y 是多少?

Causal Inference (因果推断)

如果改变 D , Y 会怎样?

所以真正的问题不是「拟合得多好」

Prediction (预测)

给定 D , Y 是多少?

Causal Inference (因果推断)

如果改变 D , Y 会怎样?

预测关注「会发生什么」; 因果关注「如果我改变它, 会发生什么」。

从个体效应到平均效应

$$ATE = E[Y(1) - Y(0)]$$

ATE: 平均处理效应 (Average Treatment Effect)

个体反事实不可同时观察，
但可能识别某个群体的**平均效应**。

拓展：ATT（处理组平均处理效应）——已经接受 treatment 的人，平均处理效应是多少？

谁可以替代看不到的反事实？

思考 一个使用 AI 的学生，
他「如果不用 AI」的成绩从哪里来？

谁可以替代看不到的反事实？

思考 一个使用 AI 的学生，
他「如果不用 AI」的成绩从哪里来？

另一个没用 AI 的学生？

为什么另一个学生可以代表他的**反事实**？

谁可以替代看不到的反事实？

思考 一个使用 AI 的学生，
他「如果不用 AI」的成绩从哪里来？

另一个没用 AI 的学生？

为什么另一个学生可以代表他的**反事实**？

他们真的**可比**吗？

谁可以替代看不到的反事实？

思考 一个使用 AI 的学生，
他「如果不用 AI」的成绩从哪里来？

另一个没用 AI 的学生？

为什么另一个学生可以代表他的**反事实**？

他们真的**可比**吗？

因果推断 = 找到可信的比较对象

两种常见的因果推断语言

Potential Outcomes / Rubin

潜在结果框架 / Rubin 框架

核心问题：我们真正想比较什么？

$$Y_i(1), \quad Y_i(0)$$

$$\tau_i = Y_i(1) - Y_i(0)$$

用「两个潜在世界」定义因果效应。

两种常见的因果推断语言

Potential Outcomes / Rubin

潜在结果框架 / Rubin 框架

核心问题：我们真正想比较什么？

$$Y_i(1), \quad Y_i(0)$$

$$\tau_i = Y_i(1) - Y_i(0)$$

用「两个潜在世界」定义因果效应。

Causal DAG / Causal Structure

因果图 / 因果结构

核心问题：为什么现实比较可能不可信？

$$Ability \rightarrow AI, \quad Ability \rightarrow Score, \\ AI \rightarrow Score$$

用它分析哪些变量该控制、哪些不该。

两种常见的因果推断语言

Potential Outcomes / Rubin

潜在结果框架 / Rubin 框架

核心问题：我们真正想比较什么？

$$Y_i(1), \quad Y_i(0)$$

$$\tau_i = Y_i(1) - Y_i(0)$$

用「两个潜在世界」定义因果效应。

Causal DAG / Causal Structure

因果图 / 因果结构

核心问题：为什么现实比较可能不可信？

$$\text{Ability} \rightarrow AI, \quad \text{Ability} \rightarrow \text{Score}, \\ AI \rightarrow \text{Score}$$

用它分析哪些变量该控制、哪些不该。

Potential Outcomes 与 Causal DAG 不是互相排斥的两种方法，
而是现代因果推断中常见的两种表达语言，可以**互补使用**。

因果图告诉我们：张三和李四为什么可能不能直接比；

Potential Outcomes 告诉我们：理想情况下应该让「张三和另一个世界的张三」相比。


Further Reading: Imbens & Rubin — Potential Outcomes / Pearl — Causal DAG、SCM

从「两种语言」到 Identification




这不是说三个框架有严格的理论先后顺序，而是**本课程的认知顺序**：
先发现现实比较为什么会出问题；再定义理想的因果比较；最后问如何从数据中恢复它。

为什么 Randomized Experiment (随机实验) 是基准?



Random Assignment /
Treatment / Control

为什么 Randomized Experiment (随机实验) 是基准?



Random Assignment /
Treatment / Control


平均意义上, 处理组与对照组
在 treatment 之前**可比**。

不是: 让回归更显著。

$$D \perp \{Y(1), Y(0)\}$$

随机分配使 treatment 与潜在结果
在平均意义上没有系统关系。

为什么 Randomized Experiment (随机实验) 是基准?



Random Assignment /
Treatment / Control

理想的反事实不可见 → 需要可信的比较组 → 随机实验提供一个基准答案。

平均意义上, 处理组与对照组
在 treatment 之前**可比**。

不是: 让回归更显著。

$$D \perp \{Y(1), Y(0)\}$$

随机分配使 treatment 与潜在结果
在平均意义上没有系统关系。

Randomization 创造了可信的**比较组**

在**平均意义**上, 对照组帮助我们估计
处理组**缺失的反事实**结果。

现实中通常没有随机实验

教育不能随意随机分配
城市政策不是随机出台
企业选择融资方式并不随机
AI 使用也通常是自选择

现实中通常没有随机实验

教育不能随意随机分配
城市政策不是随机出台
企业选择融资方式并不随机
AI 使用也通常是自选择

观测数据 (Observational Data)

现实中通常没有随机实验

教育不能随意随机分配
城市政策不是随机出台
企业选择融资方式并不随机
AI 使用也通常是自选择

观测数据 (Observational Data)

没有随机实验时，我们怎样从**观测数据**中找到可信比较？

现实中通常没有随机实验

教育不能随意随机分配
城市政策不是随机出台
企业选择融资方式并不随机
AI 使用也通常是自选择

观测数据 (Observational Data)

没有随机实验时，我们怎样从**观测数据**中找到可信比较？

这就是 Identification 问题

问题二结束后，我们面临一个新的难题

1. 我们已经定义了因果效应

$$\tau_i = Y_i(1) - Y_i(0)$$

$Y_i(1)$ 和 $Y_i(0)$ 不能同时看到

谁可以替代那个看不到的反事实？

问题二结束后，我们面临一个新的难题

1. 我们已经定义了因果效应

$$\tau_i = Y_i(1) - Y_i(0)$$

2. 但反事实不可观察

$Y_i(1)$ 和 $Y_i(0)$ 不能同时看到

谁可以替代那个看不到的反事实？

问题二结束后，我们面临一个新的难题

1. 我们已经定义了因果效应

$$\tau_i = Y_i(1) - Y_i(0)$$

2. 但反事实不可观察

$Y_i(1)$ 和 $Y_i(0)$ 不能同时看到

3. 所以现实研究必须回答

谁可以替代那个看不到的反事实？

问题二结束后，我们面临一个新的难题

1. 我们已经定义了因果效应

$$\tau_i = Y_i(1) - Y_i(0)$$

2. 但反事实不可观察

$Y_i(1)$ 和 $Y_i(0)$ 不能同时看到

3. 所以现实研究必须回答

谁可以替代那个看不到的反事实？

问题二定义了「想要什么」；问题三开始解决「怎样得到它」。

问题三

现代计量方法究竟在寻找什么？

后面的 FE、IV、DID、RD 为什么都在解决同一个问题？

相关 ▶ 反事实 ▶ 识别

理想的比较看不见，现实数据能给我们什么？

理想的因果比较

$$Y_i(1) - Y_i(0)$$

同一个单位的两个可能世界

?

数据中的现实比较

$$D = 1 \quad \text{vs.} \quad D = 0$$

两组不同的人

理想的比较看不见，现实数据能给我们什么？

理想的因果比较

$$Y_i(1) - Y_i(0)$$

同一个单位的两个可能世界

?

数据中的现实比较

$$D = 1 \quad \text{vs.} \quad D = 0$$

两组不同的人

什么时候「现实中的比较」可以替代理想的反事实比较？

理想的比较看不见，现实数据能给我们什么？

理想的因果比较

$$Y_i(1) - Y_i(0)$$

同一个单位的两个可能世界

?

数据中的现实比较

$$D = 1 \quad \text{vs.} \quad D = 0$$

两组不同的人

什么时候「现实中的比较」可以替代理想的反事实比较？

这就是 Identification

一个经验研究其实有四个层次

我们已经知道「想估计什么」；但「想估计什么」与「数据能不能告诉我们」不是一回事。

Estimand (估计目标)

我到底想估计什么？

Identification (识别)

为什么数据能够告诉我？

Estimator (估计量)

怎么计算？

Inference (推断)

这个估计有多不确定？

估计目标 $\neq$ 识别 $\neq$ 估计 $\neq$ 推断 (Estimand 这一格，第二部分已经答了：ATE)

一个经验研究其实有四个层次

我们已经知道「想估计什么」；但「想估计什么」与「数据能不能告诉我们」不是一回事。

Estimand (估计目标)

我到底想估计什么？

Identification (识别)

为什么数据能够告诉我？

Estimator (估计量)

怎么计算？

Inference (推断)

这个估计有多不确定？

估计目标 $\neq$ 识别 $\neq$ 估计 $\neq$ 推断 (Estimand 这一格，第二部分已经答了：ATE)

Research Design 的核心任务，
是让 **Identification Assumptions** 更可信，
而不是让系数更显著。

一个经验研究其实有四个层次

我们已经知道「想估计什么」；但「想估计什么」与「数据能不能告诉我们」不是一回事。

Estimand (估计目标)

我到底想估计什么？

Identification (识别)

为什么数据能够告诉我？

Estimator (估计量)

怎么计算？

Inference (推断)

这个估计有多不确定？

估计目标 $\neq$ 识别 $\neq$ 估计 $\neq$ 推断 (Estimand 这一格，第二部分已经答了：ATE)

Research Design 的核心任务，
是让 **Identification Assumptions** 更可信，
而不是让系数更显著。

现代计量要找的：可信的比较 + 可信的 identifying variation

控制变量什么时候可能帮助因果识别？

问题二的结论：因果效应是反事实比较，而我们永远缺少一个潜在结果——所以要找**可信的比较组**。

一、要「可比」

控制处理前特征以后，
处理组和对照组要**足够相似**

控制变量什么时候可能帮助因果识别？

问题二的结论：因果效应是反事实比较，而我们永远缺少一个潜在结果——所以要找**可信的比较组**。

一、要「可比」

控制处理前特征以后，
处理组和对照组要**足够相似**

二、要「有得比」

相似的人中，最好
既有人接受处理，也有人没有

控制变量什么时候可能帮助因果识别？

问题二的结论：因果效应是反事实比较，而我们永远缺少一个潜在结果——所以要找**可信的比较组**。

一、要「可比」

控制处理前特征以后，
处理组和对照组要**足够相似**

二、要「有得比」

相似的人中，最好
既有人接受处理，也有人没有

控制变量**不会自动**创造因果识别；
关键在于「控制以后是否真的形成**可信比较**」。

控制变量什么时候可能帮助因果识别？

问题二的结论：因果效应是反事实比较，而我们永远缺少一个潜在结果——所以要找**可信的比较组**。

一、要「可比」

控制处理前特征以后，
处理组和对照组要**足够相似**

二、要「有得比」

相似的人中，最好
既有人接受处理，也有人没有

控制变量**不会自动**创造因果识别；
关键在于「控制以后是否真的形成**可信比较**」。

后面的现代计量方法，就是在不同场景下寻找不同的**可信比较**。

从 FWL 的直觉再往前走一步

$$X \longrightarrow \tilde{X} \quad Y \longrightarrow \tilde{Y}$$

从 FWL 的直觉再往前走一步

$$\begin{aligned} X &\longrightarrow \tilde{X} & Y &\longrightarrow \tilde{Y} \\ \tilde{Y} &= \beta \tilde{X} + \tilde{u} \end{aligned}$$

从 FWL 的直觉再往前走一步

$$X \longrightarrow \tilde{X} \quad Y \longrightarrow \tilde{Y}$$

$$\tilde{Y} = \beta \tilde{X} + \tilde{u}$$

控制以后，OLS 使用的是 X 剩余的 **variation**。

从 FWL 的直觉再往前走一步

$$X \longrightarrow \tilde{X} \quad Y \longrightarrow \tilde{Y}$$

$$\tilde{Y} = \beta \tilde{X} + \tilde{u}$$

控制以后，OLS 使用的是 X 剩余的 **variation**。

这部分 variation
从哪里来？

Where does the identifying variation come from?

从 FWL 的直觉再往前走一步

$$X \longrightarrow \tilde{X} \quad Y \longrightarrow \tilde{Y}$$

$$\tilde{Y} = \beta \tilde{X} + \tilde{u}$$

控制以后, OLS 使用的是 X 剩余的 **variation**。

这部分 variation
从哪里来?

Where does the identifying variation come from?

为什么值得相信?

Why should we trust it?

后面的中级计量，其实都在回答同一个问题

这一讲不要求你学会这些方法——只要求看懂它们**共同在问什么**。

第一层 Identification / Research Design (识别 & 研究设计)

Controls
条件可比

Fixed Effects
组内变化

IV
外部推动

DID
相对变化

RD
阈值附近


后面的中级计量，其实都在回答同一个问题

这一讲不要求你学会这些方法——只要求看懂它们**共同在问什么**。



后面的中级计量，其实都在回答同一个问题


这一讲不要求你学会这些方法——只要求看懂它们**共同在问什么**。



六种方法，是六种不同的「反事实替代」方式（ML/DML 只做调整，不创造识别）。

后面的中级计量，其实都在回答同一个问题


这一讲不要求你学会这些方法——只要求看懂它们**共同在问什么**。



六种方法，是六种不同的「反事实替代」方式（ML/DML 只做调整，不创造识别）。

后面的中级计量，其实都在回答同一个问题

这一讲不要求你学会这些方法——只要求看懂它们**共同在问什么**。



六种方法，是六种不同的「反事实替代」方式（ML/DML 只做调整，不创造识别）。

谁和谁在比较？ 这部分 identifying variation 为什么可信？

后面的每一种方法，都问同样两个问题

Q1 它用谁来替代**看不到的反事实**？

Q2 为什么这个替代**值得相信**？

方法	用什么替代看不到的反事实
Controls	在条件相似的人之间寻找反事实
Fixed Effects	从同一个体的组内变化中寻找更可信的比较
IV	利用外部推动带来的 variation
DID	用未处理组的相对变化构造反事实趋势
RD	用 cutoff 附近非常相似的人构造局部比较
ML / DML	更灵活地做调整与残差化，但本身不创造 Identification

后面的每一种方法，都问同样两个问题


Q1 它用谁来替代**看不到的反事实**？

Q2 为什么这个替代**值得相信**？

方法	用什么替代看不到的反事实
Controls	在条件相似的人之间寻找反事实
Fixed Effects	从同一个体的组内变化中寻找更可信的比较
IV	利用外部推动带来的 variation
DID	用未处理组的相对变化构造反事实趋势
RD	用 cutoff 附近非常相似的人构造局部比较
ML / DML	更灵活地做调整与残差化，但本身不创造 Identification


识别假设来自研究设计——这两个问题，整门中级计量课都会一直问下去。

Fixed Effects: 利用同一个体的组内变化



不同企业 / 个人之间，存在大量**不随时间变化**的固定差异。

Fixed Effects: 利用同一个体的组内变化




不同企业／个人之间，存在大量不随时间变化的固定差异。

$$X_{it} - \bar{X}_i \quad \text{组内变异}$$

within variation

去掉不随时间变化的固定差异后，
利用同一个体随时间发生的变化。

Fixed Effects: 利用同一个体的组内变化



不同企业／个人之间，存在大量**不随时间变化**的固定差异。


$X_{it} - \bar{X}_i$ **组内变异**

within variation

去掉不随时间变化的固定差异后，
利用同一个体随时间发生的变化。

可以粗略理解为：更多利用「同一个体不同时期」的比较，而不是不同个体之间的水平差异。

Fixed Effects: 利用同一个体的组内变化



不同企业／个人之间，存在大量**不随时间变化**的固定差异。

$X_{it} - \bar{X}_i$ **组内变异**


within variation

去掉不随时间变化的固定差异后，
利用同一个体随时间发生的变化。

可以粗略理解为：更多利用「同一个体不同时期」的比较，而不是不同个体之间的水平差异。

思考 组内 variation 也**不自动**等于因果——时间变化的遗漏变量、反向因果、同时性仍然可能存在。

Fixed Effects: 利用同一个体的组内变化



不同企业／个人之间，存在大量**不随时间变化**的固定差异。

$X_{it} - \bar{X}_i$ **组内变异**

within variation

去掉不随时间变化的固定差异后，
利用同一个体随时间发生的变化。

可以粗略理解为：更多利用「同一个体不同时期」的比较，而不是不同个体之间的水平差异。

思考 组内 variation 也**不自动**等于因果——时间变化的遗漏变量、反向因果、同时性仍然可能存在。

我们仍然需要问：为什么这部分 within variation **值得相信**？

Instrumental Variables (工具变量): 只用「外部推动」的部分



后面 IV 专题再正式定义这些条件。

Instrumental Variables (工具变量): 只用「外部推动」的部分



一个好的工具变量 Z 需要:

- ▶ 能够推动 X ;
- ▶ 不与影响 Y 的其他未观测因素纠缠;
- ▶ 对 Y 的影响只能通过 X 。

后面 IV 专题再正式定义这些条件。

Instrumental Variables (工具变量): 只用「外部推动」的部分



一个好的工具变量 Z 需要:

- ▶ 能够推动 X ;
- ▶ 不与影响 Y 的其他未观测因素纠缠;
- ▶ 对 Y 的影响只能通过 X 。

只使用由外部因素推动的那部分 variation

后面 IV 专题再正式定义这些条件。

Instrumental Variables (工具变量): 只用「外部推动」的部分



一个好的工具变量 Z 需要:

- ▶ 能够推动 X ;
- ▶ 不与影响 Y 的其他未观测因素纠缠;
- ▶ 对 Y 的影响只能通过 X 。

只使用由外部因素推动的那部分 variation

外部推动的变异

Externally Induced Variation

后面 IV 专题再正式定义这些条件。

Instrumental Variables (工具变量): 只用「外部推动」的部分



一个好的工具变量 Z 需要:

- ▶ 能够推动 X ;
- ▶ 不与影响 Y 的其他未观测因素纠缠;
- ▶ 对 Y 的影响只能通过 X 。

只使用由外部因素推动的那部分 variation


外部推动的变异

Externally Induced Variation

后面 IV 专题再正式定义这些条件。


Q1 → 外部推动的那部分 variation; Q2 → 与影响 Y 的其他因素不纠缠。

DID: 比较相对变化，而不是直接比较水平



后续正式学习平行趋势（Parallel Trends）。


DID: 比较相对变化，而不是直接比较水平



$\Delta Y_T - \Delta Y_C$: 比较相对变化，而不是直接比较水平

后续正式学习平行趋势（Parallel Trends）。

DID: 比较相对变化，而不是直接比较水平




$\Delta Y_T - \Delta Y_C$: 比较**相对变化**，而不是直接比较水平

后续正式学习平行趋势（Parallel Trends）。


Q1 → 未处理组的相对变化； Q2 → 平行趋势是否成立（后续专题展开）。

RD (断点回归): 只比较 **cutoff** (断点) 附近



断点两侧非常接近的人，处理状态（treatment status）却不同。


RD (断点回归): 只比较 **cutoff** (断点) 附近



比较 cutoff 两侧**非常接近**的单位

断点两侧非常接近的人，处理状态 (treatment status) 却不同。


RD (断点回归): 只比较 **cutoff** (断点) 附近



比较 cutoff 两侧**非常接近**的单位

断点两侧非常接近的人，处理状态 (treatment status) 却不同。
局部比较 (**Local Comparison**)

RD (断点回归): 只比较 cutoff (断点) 附近




比较 cutoff 两侧非常接近的单位

断点两侧非常接近的人，处理状态 (treatment status) 却不同。

局部比较 (Local Comparison)


Q1 → cutoff 另一侧非常接近的人; Q2 → 断点两侧在附近足够相似。

ML / DML (机器学习 / 双重机器学习): 更灵活地净化



FWL
线性残差化
(Linear partialling out)

ML / DML (机器学习 / 双重机器学习): 更灵活地净化




FWL

线性残差化
(Linear partialling out)

DML (双重机器学习)
更灵活地估计 nuisance
functions
(模型里不关心的那部分)、
做 residualization

ML / DML (机器学习 / 双重机器学习): 更灵活地净化



FWL
线性残差化
(Linear partialling out)

DML (双重机器学习)
更灵活地估计 nuisance
functions
(模型里不关心的那部分)、
做 residualization

机器学习本身不是 Identification Strategy (识别策略)

识别假设来自研究设计, 机器学习主要帮助估计。

把 AI—成绩案例重新走一遍



研究问题	AI 是否提高成绩?
估计目标	平均因果效应
识别的威胁	Ability / Motivation / Reverse causality / Selection
研究设计	Controls? FE? IV? Other design?
估计量	对应估计方法
推断	Robust / Cluster SE (稳健 / 聚类标准误) 等

Research Design (研究设计) 的作用,
是让 identification assumptions 更可信。

把 AI—成绩案例重新走一遍



研究问题	AI 是否提高成绩?
估计目标	平均因果效应
识别的威胁	Ability / Motivation / Reverse causality / Selection
研究设计	Controls? FE? IV? Other design?
估计量	对应估计方法
推断	Robust / Cluster SE (稳健 / 聚类标准误) 等

Research Design (研究设计) 的作用,
是让 identification assumptions 更可信。

不是: 回归 $\rightarrow$ p 值 $\rightarrow$ 结论。

把 AI—成绩案例重新走一遍



研究问题	AI 是否提高成绩?
估计目标	平均因果效应
识别的威胁	Ability / Motivation / Reverse causality / Selection
研究设计	Controls? FE? IV? Other design?
估计量	对应估计方法
推断	Robust / Cluster SE (稳健 / 聚类标准误) 等

Research Design (研究设计) 的作用,
是让 identification assumptions 更可信。

不是: 回归 $\rightarrow$ p 值 $\rightarrow$ 结论。


先问识别, 再跑回归。

回到第一讲：我们如何从数据走向知识？



相关 → 反事实 → 识别
可信比较 + 可信 variation

回到第一讲：我们如何从数据走向知识？



相关 → 反事实 → 识别
可信比较 + 可信 variation

回到第一讲：我们如何从数据走向知识？



Data 观测数据

Information 统计规律 / 相关关系

相关 → 反事实 → 识别
可信比较 + 可信 variation

回到第一讲：我们如何从数据走向知识？



Data 观测数据

Information 统计规律 / 相关关系

Causal Knowledge 如果改变 X , Y 会怎样?

相关 $\rightarrow$ 反事实 $\rightarrow$ 识别
可信比较 + 可信 variation

回到第一讲：我们如何从数据走向知识？



Data 观测数据

Information 统计规律 / 相关关系

Causal Knowledge 如果改变 X , Y 会怎样?

相关 $\rightarrow$ 反事实 $\rightarrow$ 识别
可信比较 + 可信 variation

回到第一讲：我们如何从数据走向知识？



Data 观测数据

Information 统计规律 / 相关关系

Causal Knowledge 如果改变 X , Y 会怎样?

相关 $\rightarrow$ 反事实 $\rightarrow$ 识别
可信比较 + 可信 variation

问题一 为什么相关不够?
现实比较被污染

问题二 真正想比较什么?
 $Y_i(1) - Y_i(0)$

问题三 反事实看不见?
可信比较 + 可信 variation

回到第一讲：我们如何从数据走向知识？



Data 观测数据

Information 统计规律 / 相关关系

Causal Knowledge 如果改变 X , Y 会怎样?

相关 $\rightarrow$ 反事实 $\rightarrow$ 识别
可信比较 + 可信 variation

问题一 为什么相关不够?
现实比较被**污染**


问题二 真正想比较什么?
 $Y_i(1) - Y_i(0)$

问题三 反事实看不见?
可信比较 + 可信 variation

现代计量不只是从数据中寻找相关;
而是在识别假设下努力获得**可信的因果知识**。

因果推断让我们从「描述世界」, 进一步走向「理解世界如何运行」。


一条逻辑链



真正需要带走的五句话

- ① 显著回归不等于因果效应
- ② 因果问题问的是「如果改变 X ，会发生什么？」
- ③ 因果效应本质上是反事实比较
- ④ 根本困难是反事实不可同时观察
- ⑤ 现代计量的核心是寻找可信比较，并解释 identifying variation 为什么可信

一条逻辑链



真正需要带走的五句话

- ① 显著回归不等于因果效应
- ② 因果问题问的是「如果改变 X ，会发生什么？」
- ③ 因果效应本质上是反事实比较
- ④ 根本困难是反事实不可同时观察
- ⑤ 现代计量的核心是寻找可信比较，并解释 identifying variation 为什么可信

以前看到结果问「显著吗？」——
现在还要问「为什么它可以解释成因果效应？」

第五讲 面板数据与固定效应



第五讲 面板数据与固定效应

如果个体之间存在大量
不随时间变化的不可观测差异，
我们能不能转而利用
「**同一个体随时间的变化**」？



第五讲 面板数据与固定效应

如果个体之间存在大量
不随时间变化的不可观测差异，
我们能不能转而利用
「**同一个体随时间的变化**」？



从 within variation 的角度理解 Fixed Effects（固定效应）

附录 A1 | Unconfoundedness 与 Overlap (正式条件)

$$\{Y(1), Y(0)\} \perp D \mid W$$

Conditional Independence (条件独立) / Unconfoundedness (无混淆性)

$$0 < P(D = 1 \mid W) < 1$$

Overlap / Common Support (重叠 / 共同支撑)

以后正式学习 treatment effects / PSM / DML 时再展开。

附录 A1 | Unconfoundedness 与 Overlap (正式条件)

$$\{Y(1), Y(0)\} \perp D \mid W$$

Conditional Independence (条件独立) / Unconfoundedness (无混淆性)

$$0 < P(D = 1 \mid W) < 1$$

Overlap / Common Support (重叠 / 共同支撑)

每类 W 中最好**同时存在** treatment (处理) 与 control (对照)。

以后正式学习 treatment effects / PSM / DML 时再展开。

附录 A2 | Pre-treatment vs Post-treatment (处理前 vs 处理后)

Pre-treatment (处理前变量)

家庭背景
入学前能力
出生地区

Post-treatment (处理后变量)

职业
当前户籍
treatment 后行为

附录 A2 | Pre-treatment vs Post-treatment (处理前 vs 处理后)

Pre-treatment (处理前变量)


家庭背景
入学前能力
出生地区

Post-treatment (处理后变量)


职业
当前户籍
treatment 后行为

Post-treatment variables (处理后变量) 要**高度谨慎**。

附录 A3 | 总效应与直接效应



附录 A3 | 总效应与直接效应



总效应 (Total effect) $\neq$ 直接效应 (Direct effect)

附录 A4 | 控制变量的系数为什么通常不能做因果解释

主处理变量的 identification（识别）成立，
不代表**每个 control（控制变量）的系数**都有因果含义。

附录 A5 | 术语对照（一）· 相关与反事实

English	中文	一句话解释
Confounder	混杂变量	同时影响 X 与 Y ，不控制会污染估计
Mediator	中介变量	$X \rightarrow M \rightarrow Y$ 的作用路径；控制它会改变研究问题
Collider	对撞变量	同时被 X 与 Y 影响；控制它反而制造偏误
Bad Control	错误控制	控制了不该控制的变量，引入选择偏误
Selection Bias	选择偏误	样本进入方式本身与结果相关
Reverse Causality	反向因果	真实的因果方向与设想相反
Measurement Error	测量误差	变量测不准，估计被稀释
Counterfactual	反事实	「若没做这个处理会怎样」的那个结果
Potential Outcome	潜在结果	$Y(1)$ 与 $Y(0)$ ：同一个人在两个世界的结果
ATE / ATT	平均处理效应	全体 / 处理组的平均因果效应

附录 A6 | 术语对照（二）· 识别与推断

English	中文	一句话解释
Overlap / Common Support	重叠 / 共同支撑	每类 W 中处理组与对照组都得有人
Unconfoundedness	无混淆性	控制 W 后处理近似随机（即条件独立）
Estimand	估计目标	你到底想估计哪一个量
Identification	识别	凭什么说这份数据能回答这个问题
Estimator	估计量	具体用哪个公式去算
Inference	推断	这个估计有多不确定
Research Design	研究设计	让识别假设更可信的整体安排
Fixed Effects	固定效应	同一个体自己和自己比（组内变异）
Instrumental Variables	工具变量	只用外部推动的那部分变异
Difference-in-Differences	双重差分	比较相对变化，而不是比较水平
Regression Discontinuity	断点回归	只比较断点两侧非常接近的人
DML	双重机器学习	用机器学习更灵活地做残差化

符号约定： D = treatment, W = controls / covariates, Y = outcome; 问题一的因果结构（Confounder / Mediator / Collider）沿用 X （处理） / Z （混杂）。

参考文献

中文文献

张子尧、黄炜 (2025): 《实证研究中的控制变量选择: 原理与原则》, 《管理世界》2025 年第 10 期。

英文文献

Angrist, J. D., & Pischke, J.-S. (2009). *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton University Press.

Angrist, J. D., & Pischke, J.-S. (2015). *Mastering 'Metrics: The Path from Cause to Effect*. Princeton University Press.

Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68.

Imbens, G. W., & Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction*. Cambridge University Press.

Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2nd ed.). Cambridge University Press.

Rubin, D. B. (1974). Estimating causal effects of treatments in randomized and nonrandomized studies. *Journal of Educational Psychology*, 66(5), 688–701.
