

---

## 第四讲 从相关到因果

现代计量经济学真正想解决什么问题？

$\hat{\beta} \stackrel{?}{=} \text{Causal Effect}$

中级计量经济学 | 张呈磊

相关 · 反事实 · 识别

# 从「会回归」到「会建模」

---

第二讲 回归 → 参数估计 → 假设检验



第三讲 函数形式 → 控制变量 → FWL → 模型诊断

## 从「会回归」到「会建模」

---

第二讲 回归 → 参数估计 → 假设检验



第三讲 函数形式 → 控制变量 → FWL → 模型诊断

我们已经可以做出一个「统计上不错」的回归模型。

## 从「会回归」到「会建模」

---

第二讲 回归 → 参数估计 → 假设检验



第三讲 函数形式 → 控制变量 → FWL → 模型诊断

我们已经可以做出一个「统计上不错」的回归模型。

这就够了吗？

## 一个看起来很漂亮的结果

---

| Dependent variable: Score |                   |
|---------------------------|-------------------|
| AI use                    | 1.50***<br>(0.30) |
| Controls                  | YES               |
| Functional form           | checked           |
| Diagnostics               | PASS              |

与第三讲末尾那张「完美」结果卡是同一个模型。

## 一个看起来很漂亮的结果

| Dependent variable: Score |                   |
|---------------------------|-------------------|
| AI use                    | 1.50***<br>(0.30) |
| Controls                  | YES               |
| Functional form           | checked           |
| Diagnostics               | PASS              |

与第三讲末尾那张「完美」结果卡是同一个模型。

可以说「AI 提高了学习成绩」吗？

## 今天真正的问题

---

$$\hat{\beta} \stackrel{?}{=} \text{Causal Effect}$$

## 今天真正的问题

---

$$\hat{\beta} \stackrel{?}{=} \text{Causal Effect}$$

一个显著、稳健、诊断良好的回归系数，  
为什么仍然可能只是**相关关系**？



## 今天三个问题

---

① 为什么一个「好回归」

仍然不等于因果？

相关  $\neq$  因果

# 今天三个问题

---

① 为什么一个「好回归」  
仍然不等于因果？  
相关  $\neq$  因果

② 因果效应  
到底是什么？  
反事实比较

# 今天三个问题

---

① 为什么一个「好回归」  
仍然不等于因果？  
相关  $\neq$  因果

② 因果效应  
到底是什么？  
反事实比较

③ 现代计量方法  
究竟在寻找什么？  
可信的比较

# 今天三个问题

---

① 为什么一个「好回归」  
仍然不等于因果？  
相关  $\neq$  因果

② 因果效应  
到底是什么？  
反事实比较

③ 现代计量方法  
究竟在寻找什么？  
可信的比较

相关  $\rightarrow$  反事实  $\rightarrow$  识别

---

问题一


# 为什么一个「好回归」仍然不等于因果？

Controls + Robust SE + Diagnostics, 为什么还不够？

相关 ▶ 反事实 ▶ 识别


## 最熟悉的问题：遗漏变量

---



## 最熟悉的问题：遗漏变量


---



AI 使用多的学生成绩更高，  
这背后可能是 AI，也可能是 Ability。

## 最熟悉的问题：遗漏变量

---




AI 使用多的学生成绩更高，  
这背后可能是 AI，也可能是 Ability。

$$E(u \mid AI) \neq 0$$



## 最熟悉的问题：遗漏变量




AI 使用多的学生成绩更高，  
这背后可能是 AI，也可能是 Ability。

$$E(u \mid AI) \neq 0$$

这是第三讲已经认识的问题——但今天要把它问到底。


# 数据里会长什么样?



Overall correlation

Within-ability comparison

# 数据里会长什么样?



Overall correlation

Within-ability comparison

总体 slope 中可能混入 **Ability** 所造成的差异。

### 第三讲给出的答案: Control

---

$$Score_i = \beta_0 + \beta_1 AI_i + \beta_2 Ability_i + u_i$$

### 第三讲给出的答案: Control

---

$$Score_i = \beta_0 + \beta_1 AI_i + \beta_2 Ability_i + u_i$$

$$AI = \widehat{AI}(Ability) + \widetilde{AI}$$

### 第三讲给出的答案: Control

---

$$Score_i = \beta_0 + \beta_1 AI_i + \beta_2 Ability_i + u_i$$

$$AI = \widehat{AI}(Ability) + \widetilde{AI}$$

$\beta_1$  利用的是  $\widetilde{AI}$

### 第三讲给出的答案: Control

---

$$Score_i = \beta_0 + \beta_1 AI_i + \beta_2 Ability_i + u_i$$

$$AI = \widehat{AI}(Ability) + \widetilde{AI}$$

$\beta_1$  利用的是  $\widetilde{AI}$

FWL: 先净化, 再比较。

但一个新的问题出现了

---

只要能控制，就应该控制吗？



但一个新的问题出现了

---

只要能控制，就应该控制吗？

More controls = Better model ?

但一个新的问题出现了

---

只要能控制，就应该控制吗？

More controls = Better model ?

**Not necessarily**

## 一个看起来「当然应该控制」的变量

---

研究教育对收入的影响，职业要不要控制？

Education

?

Income

## 一个看起来「当然应该控制」的变量

---

研究教育对收入的影响，职业要不要控制？

Education


?

Income

先不要急着回答——看两种可能的结构。


## 如果职业是一条作用路径?

---



## 如果职业是一条作用路径？


---



教育的一部分回报，  
正是来自**进入更高薪职业的机会**。

## 如果职业是一条作用路径？

---



教育的一部分回报，  
正是来自**进入更高薪职业的机会**。

如果研究的是教育对收入的**总效应**，控制职业意味着什么？

## Mediator: 控制会改变你估计的东西

---

$$\text{Total Effect} = \text{Direct Effect} + \text{Indirect Effect}$$


参考：张子尧、黄炜（2025）



## Mediator: 控制会改变你估计的东西

---

Total Effect = Direct Effect + Indirect Effect




参考：张子尧、黄炜（2025）

## Mediator: 控制会改变你估计的东西

---

Total Effect = Direct Effect + Indirect Effect




控制中介变量会阻断一部分因果路径。

参考：张子尧、黄炜（2025）

## Mediator: 控制会改变你估计的东西

---

Total Effect = Direct Effect + Indirect Effect




控制中介变量会阻断一部分因果路径。

控制变量可能改变 estimand

参考：张子尧、黄炜（2025）


## 更麻烦：职业还可能是 Collider

---




## 更麻烦：职业还可能是 Collider

---



在「同样进入高薪职业」的人中，  
学历较低的人是否往往需要**更高能力**？


## 更麻烦：职业还可能是 Collider



在「同样进入高薪职业」的人中，  
学历较低的人是否往往需要**更高能力**？

$Education \not\perp Ability \mid Occupation$

## 更麻烦：职业还可能是 Collider



在「同样进入高薪职业」的人中，  
学历较低的人是否往往需要**更高能力**？

$Education \not\perp Ability \mid Occupation$

这里只讲直觉，不讲 d-separation。

## 统计上「控制得更干净」，因果上可能更糟

---

原来： Education 与 Ability 可不相关



## 统计上「控制得更干净」，因果上可能更糟

---

原来： Education 与 Ability 可不相关

控制 Occupation 后： Education 与 Ability 产生关联

## 统计上「控制得更干净」，因果上可能更糟

---

原来： Education 与 Ability 可不相关

控制 Occupation 后： Education 与 Ability 产生关联

而 Ability 又影响 Income

## 统计上「控制得更干净」，因果上可能更糟

---

原来： Education 与 Ability 可不相关

控制 Occupation 后： Education 与 Ability 产生关联


而 Ability 又影响 Income

Bad Control  $\Rightarrow$  Selection Bias

## 三种最基本的因果结构

---

### Confounder




通常需要认真控制

### Mediator



是否控制取决于 estimand


### Collider



机械控制可能制造偏误

## 三种最基本的因果结构

### Confounder




通常需要认真控制

### Mediator



是否控制取决于 estimand

### Collider



机械控制可能制造偏误

变量「好不好」取决于**因果结构**，而不是相关性本身。

还有一种麻烦：方向可能反过来

---




## 还有一种麻烦：方向可能反过来

---



成绩较差的学生，  
会不会反而**更依赖 AI**？

## 还有一种麻烦：方向可能反过来




$AI \leftrightarrow Score$

成绩较差的学生，  
会不会反而**更依赖 AI**？

两种机制都说得通，  
数据本身不会告诉你哪一个是真的。



## 还有一种麻烦：方向可能反过来



*AI ↔ Score*

成绩较差的学生，  
会不会反而**更依赖 AI**？

两种机制都说得通，  
数据本身不会告诉你哪一个是真的。

Correlation 本身不告诉我们方向。

这些问题有什么共同点？——其实是两类

---

### 路径 A: Identification Problem

Omitted Variables · Reverse Causality  
Selection · Collider / Bad Control  
Measurement Error

$$E(u | X) \neq 0$$

用于估计  $\beta$  的 variation  
与其他影响  $Y$  的因素纠缠

## 这些问题有什么共同点？——其实是两类

### 路径 A: Identification Problem

Omitted Variables · Reverse Causality  
Selection · Collider / Bad Control  
Measurement Error

$$E(u | X) \neq 0$$

用于估计  $\beta$  的 variation  
与其他影响  $Y$  的因素纠缠

### 路径 B: Estimand Problem

Mediator · Post-treatment Control

控制以后，研究问题本身发生了变化

Total Effect  $\rightarrow$  Controlled / Direct-type

## 这些问题有什么共同点？——其实是两类

### 路径 A: Identification Problem

Omitted Variables · Reverse Causality  
Selection · Collider / Bad Control  
Measurement Error

$$E(u | X) \neq 0$$

用于估计  $\beta$  的 variation  
与其他影响  $Y$  的因素纠缠

### 路径 B: Estimand Problem

Mediator · Post-treatment Control  
控制以后，**研究问题本身**发生了变化  
Total Effect  $\rightarrow$  Controlled / Direct-type

问题不同，但都会使  $\hat{\beta}$  的因果解释变得困难。

## 把「内生性」重新理解一下

---

用于估计  $\beta$  的 variation，与误差项纠缠在了一起。

$$E(u | X) \neq 0$$

在线性相关的简化情形下，常表现为： $Cov(X, u) \neq 0$

## 把「内生性」重新理解一下

---

用于估计  $\beta$  的 variation，与误差项**纠缠在了一起**。

$$E(u | X) \neq 0$$

在线性相关的简化情形下，常表现为： $Cov(X, u) \neq 0$

所以问题不只是「有没有控制变量」，  
而是：

## 把「内生性」重新理解一下

---

用于估计  $\beta$  的 variation，与误差项**纠缠在了一起**。

$$E(u | X) \neq 0$$

在线性相关的简化情形下，常表现为： $Cov(X, u) \neq 0$

所以问题不只是「有没有控制变量」，  
而是：

这部分 variation 值得相信吗？

## 问题一小结

---

①

回归做得规范，不代表因果识别成立

②

More controls 并不自动带来更好的 identification

③

关键是理解变量在因果结构中的位置



## 问题一小结

---

①

回归做得规范，不代表因果识别成立

②

More controls 并不自动带来更好的 identification

③

关键是理解变量在因果结构中的位置

那么，「因果效应」本身到底是什么？

---

问题二

# 因果效应到底是什么？

因果不是「两个不同的人有差异」。

相关 ▶ 反事实 ▶ 识别

## 先区分两句话

---

AI 使用更多的学生，  
平均成绩更高。

**Correlation**

## 先区分两句话

---

AI 使用更多的学生，  
平均成绩更高。

**Correlation**

如果让同一个学生  
使用 AI、而不是不使用 AI，  
他的成绩会怎样？

**Causal Question**

## 先区分两句话

---

AI 使用更多的学生，  
平均成绩更高。

**Correlation**

如果让同一个学生  
使用 AI、而不是不使用 AI，  
他的成绩会怎样？

**Causal Question**

Association  $\neq$  Intervention

## 同一个学生，两个可能世界

---

为了把反事实讲清楚，下面暂时把 AI 使用简化为二元处理：使用 AI 记为  $D = 1$ ，不使用 AI 记为  $D = 0$ 。

同一个学生

World 1

使用 AI

$Y_i(1)$

World 0

不使用 AI


$Y_i(0)$

## 同一个学生，两个可能世界

---

为了把反事实讲清楚，下面暂时把 AI 使用简化为二元处理：使用 AI 记为  $D = 1$ ，不使用 AI 记为  $D = 0$ 。

同一个学生




不能同时看到

## 同一个学生，两个可能世界

---

为了把反事实讲清楚，下面暂时把 AI 使用简化为二元处理：使用 AI 记为  $D = 1$ ，不使用 AI 记为  $D = 0$ 。

同一个学生



不能同时看到

$$\tau_i = Y_i(1) - Y_i(0)$$



## 这才是「个体因果效应」

---

$$\tau_i = Y_i(1) - Y_i(0)$$

## 这才是「个体因果效应」

---

$$\tau_i = Y_i(1) - Y_i(0)$$

因果效应问的不是：  
「张三和李四差多少？」

## 这才是「个体因果效应」

---

$$\tau_i = Y_i(1) - Y_i(0)$$

因果效应问的不是：  
「张三和李四差多少？」

而是：  
「张三在两个不同 **treatment** 状态下会差多少？」

但我们遇到一个根本困难

---

对于同一个  $i$ :

## 但我们遇到一个根本困难

---

对于同一个  $i$ :

如果  $D_i = 1$ , 我们看到  $Y_i(1)$

## 但我们遇到一个根本困难

---

对于同一个  $i$ :

如果  $D_i = 1$ , 我们看到  $Y_i(1)$

但  $Y_i(0) = ?$

## 但我们遇到一个根本困难

---

对于同一个  $i$ :

如果  $D_i = 1$ , 我们看到  $Y_i(1)$

但  $Y_i(0) = ?$

反过来也一样。

## 但我们遇到一个根本困难

---

对于同一个  $i$ :

如果  $D_i = 1$ , 我们看到  $Y_i(1)$

但  $Y_i(0) = ?$

反过来也一样。

同一个人不可能同时处在两个世界



# Fundamental Problem of Causal Inference

---

我们永远缺少一个潜在结果。

Observed + Missing Counterfactual

# Fundamental Problem of Causal Inference

---

我们永远缺少一个潜在结果。

Observed + Missing Counterfactual

因果推断本质上是一个反事实缺失问题。

所以真正的问题不是「拟合得多好」

---

### Prediction

给定  $X$ ,  $Y$  是多少?

### Causal Inference

如果改变  $X$ ,  $Y$  会怎样?

所以真正的问题不是「拟合得多好」

---

### Prediction

给定  $X$ ,  $Y$  是多少?

### Causal Inference

如果改变  $X$ ,  $Y$  会怎样?

因果推断要为**缺失的反事实**找到可信替代。

## 从个体效应到平均效应

---

$$ATE = E[Y(1) - Y(0)]$$

## 从个体效应到平均效应

---

$$ATE = E[Y(1) - Y(0)]$$

ATT: 对已经接受处理的人, 平均处理效应是多少?

## 从个体效应到平均效应

---

$$ATE = E[Y(1) - Y(0)]$$

ATT：对已经接受处理的人，平均处理效应是多少？

我们通常无法识别每个人的  $\tau_i$ ，  
但可能识别某个群体的**平均效应**。

## 谁可以替代看不到的反事实？

---

一个使用 AI 的学生，  
他「如果不用 AI」的成绩从哪里来？



## 谁可以替代看不到的反事实？

---

一个使用 AI 的学生，  
他「如果不用 AI」的成绩从哪里来？

另一个没用 AI 的学生？

## 谁可以替代看不到的反事实？

---

一个使用 AI 的学生，  
他「如果不用 AI」的成绩从哪里来？

另一个没用 AI 的学生？

他们真的可比吗？

## 谁可以替代看不到的反事实？

---

一个使用 AI 的学生，  
他「如果不用 AI」的成绩从哪里来？


另一个没用 AI 的学生？

他们真的可比吗？

Causal inference = finding a credible comparison


# 为什么 Randomized Experiment 是基准?

---




# 为什么 Randomized Experiment 是基准?

---



平均意义上，处理组与对照组  
在 treatment 之前可比。


# 为什么 Randomized Experiment 是基准?



平均意义上，处理组与对照组在 treatment 之前可比。

$$D \perp \{Y(1), Y(0)\}$$

## 为什么 Randomized Experiment 是基准？



平均意义上，处理组与对照组在 treatment 之前可比。

$$D \perp \{Y(1), Y(0)\}$$

这个式子只需要「认识」，不需要推导。

## Randomization 做了什么？

---

不是：让回归更显著



## Randomization 做了什么?

---

不是：让回归更显著

创造了可信的 counterfactual

## Randomization 做了什么？

---

不是：让回归更显著

创造了可信的 counterfactual

在平均意义上，对照组帮助我们估计  
处理组缺失的反事实结果。

## 现实中通常没有随机实验

---

教育不能随意随机分配  
城市政策不是随机出台  
企业选择融资方式并不随机  
AI 使用也通常是自选择

## 现实中通常没有随机实验

---

教育不能随意随机分配  
城市政策不是随机出台  
企业选择融资方式并不随机  
AI 使用也通常是自选择

**Observational Data**

## 现实中通常没有随机实验

---

教育不能随意随机分配  
城市政策不是随机出台  
企业选择融资方式并不随机  
AI 使用也通常是自选择

**Observational Data**

我们必须自己创造「可信比较」。

## Control Variables 的因果解释

---

$$\{Y(1), Y(0)\} \perp D \mid X$$

Conditional Independence / Unconfoundedness ——这里只认识，不做推导。

## Control Variables 的因果解释

---

$$\{Y(1), Y(0)\} \perp D \mid X$$

如果在  $X$  相同的人中，treatment 近似随机，  
那么我们可以在「相似的人」之间比较。

Conditional Independence / Unconfoundedness —— 这里只认识，不做推导。

## Control Variables 的因果解释

---

$$\{Y(1), Y(0)\} \perp D \mid X$$

如果在  $X$  相同的人中，treatment 近似随机，  
那么我们可以在「相似的人」之间比较。

除此之外，还需要「有得比」：同类  $X$  中最好**同时存在** treatment 与 control (Overlap / Common Support)。

Conditional Independence / Unconfoundedness ——这里只认识，不做推导。



# 「控制」的新理解

---

本科 其他条件不变



第三讲 FWL: 剔除  $Z$  能解释的 variation



第四讲 为什么这部分 **variation** 应该被剔除?

# 「控制」的新理解

---

本科 其他条件不变



第三讲 FWL: 剔除  $Z$  能解释的 variation



第四讲 为什么这部分 **variation** 应该被剔除?

剔除以后，比较真的更可信吗？

# 「控制」的新理解

---



剔除以后，比较真的更可信吗？

统计控制 → 因果识别

## 一个经验研究其实有四个层次

---

### Estimand

我到底想估计什么？

### Identification

为什么数据能够告诉我？

### Estimator

怎么计算？

### Inference

这个估计有多不确定？

## 一个经验研究其实有四个层次

---

### Estimand

我到底想估计什么？

### Identification

为什么数据能够告诉我？

### Estimator

怎么计算？

### Inference

这个估计有多不确定？

Research Design 位于 Identification 与 Estimator 之间。

## 一个经验研究其实有四个层次

---

### Estimand

我到底想估计什么？

### Identification

为什么数据能够告诉我？

### Estimator

怎么计算？

### Inference

这个估计有多不确定？

Research Design 位于 Identification 与 Estimator 之间。

$\text{Estimand} \neq \text{Identification} \neq \text{Estimation} \neq \text{Inference}$

## 问题二小结

---

①

因果效应是反事实比较

②

我们永远缺少一个潜在结果

③

核心是找到可信的  
comparison group

## 问题二小结

---

①

因果效应是反事实比较

②

我们永远缺少一个潜在结果

③

核心是找到可信的  
comparison group

后面的现代计量方法，  
就是不同场景下寻找不同的「可信比较」。



---

问题三

# 现代计量方法究竟在寻找什么？

后面的 FE、IV、DID、RD 为什么都在解决同一个问题？

相关 ▶ 反事实 ▶ 识别

## 先回到 FWL

---

$$X = \hat{X}(Z) + \tilde{X}$$

## 先回到 FWL

---

$$X = \hat{X}(Z) + \tilde{X}$$

$$\tilde{Y} = \beta \tilde{X} + \text{error}$$

$$X = \hat{X}(Z) + \tilde{X}$$

$$\tilde{Y} = \beta \tilde{X} + \text{error}$$

**Which variation identifies  $\beta$ ?**

## 第四讲再多问一步

---

Where does the identifying variation come from?

## 第四讲再多问一步

---

Where does the identifying variation come from?

不仅要有 variation，还要问：

## 第四讲再多问一步

---

Where does the identifying variation come from?

不仅要有 variation，还要问：

Why should we trust it?

# 现代计量方法地图

---

Controls

DID

Fixed Effects

RD

IV


ML / DML

**Credible Comparison  
+  
Identifying Variation**




# 现代计量方法地图

---




# 现代计量方法地图

---




# 现代计量方法地图



not an identification strategy by itself

## OLS + Controls

---




比较条件相似的人。

**Conditional Comparison**

## OLS + Controls

---




比较条件相似的人。

**Conditional Comparison**


假设：控制  $X$  后，treatment 足够接近随机。

## Fixed Effects: 自己和自己比



不同企业／个人之间  
存在大量**固定差异**。

## Fixed Effects: 自己和自己比



不同企业／个人之间  
存在大量**固定差异**。


$$X_{it} - \bar{X}_i$$

**within variation**

后续面板数据专题系统讲。

## Instrumental Variables: 只用「外部推动」的部分

---




后面 IV 专题再正式定义这些条件。



## Instrumental Variables: 只用「外部推动」的部分

---




一个好的工具变量  $Z$  需要:

- ▶ 能够推动  $X$ ;
- ▶ 不与影响  $Y$  的其他未观测因素纠缠;
- ▶ 对  $Y$  的影响只能通过  $X$ 。

后面 IV 专题再正式定义这些条件。

## Instrumental Variables: 只用「外部推动」的部分




一个好的工具变量  $Z$  需要:

- ▶ 能够推动  $X$ ;
- ▶ 不与影响  $Y$  的其他未观测因素纠缠;
- ▶ 对  $Y$  的影响只能通过  $X$ 。

$X$  中由  $Z$  推动的 variation

后面 IV 专题再正式定义这些条件。

## Instrumental Variables: 只用「外部推动」的部分



一个好的工具变量  $Z$  需要:


- ▶ 能够推动  $X$ ;
- ▶ 不与影响  $Y$  的其他未观测因素纠缠;
- ▶ 对  $Y$  的影响只能通过  $X$ 。

$X$  中由  $Z$  推动的 variation

Externally Induced Variation


后面 IV 专题再正式定义这些条件。

## DID: 比较变化，而不是水平



$$\Delta Y_T - \Delta Y_C$$

## DID: 比较变化，而不是水平




$$\Delta Y_T - \Delta Y_C$$

**Differential Change**


后续正式学习 Parallel Trends。

## RD: 只比较 cutoff 附近




cutoff 两侧非常接近的人，treatment status 却不同。

## RD: 只比较 cutoff 附近



cutoff 两侧非常接近的人，treatment status 却不同。

## Machine Learning / DML: 更灵活地净化




FWL

Linear partialling out



## Machine Learning / DML: 更灵活地净化




FWL

Linear partialling out

DML

Flexible nuisance estimation

# Machine Learning / DML: 更灵活地净化



FWL

Linear partialling out

DML

Flexible nuisance estimation

Machine Learning 本身不是识别策略

## 这些方法都在回答同一个识别问题

---

**Credible Comparison**  
+  
**Identifying Variation**

Controls → 条件可比  
FE → 同一个体内部  
IV → 外生推动

DID → 相对变化  
RD → 阈值附近  
ML/DML → 更好地净化

## 这些方法都在回答同一个识别问题

Credible Comparison  
+  
Identifying Variation

Controls → 条件可比  
FE → 同一个体内部  
IV → 外生推动

DID → 相对变化  
RD → 阈值附近  
ML/DML → 更好地净化

方法不同，但都要回答：哪一部分 variation 在识别  $\beta$ ? 为什么这部分 variation 值得相信?

# 现代计量的真正 workflow

---



Research Design 的作用，是让 identification assumptions 更可信。

# 现代计量的真正 workflow



不是：

回归 → p-value → 结论

Research Design 的作用，是让 identification assumptions 更可信。

# 现代计量的真正 workflow



不是：

回归 → p-value → 结论

先问识别，再跑回归。

Research Design 的作用，是让 identification assumptions 更可信。

## 把 AI一成绩案例重新走一遍

---

### Question

AI 是否提高成绩?

### Estimand

平均因果效应?

### Threats

Ability / Motivation /  
Reverse causality /  
Selection



## 把 AI—成绩案例重新走一遍

---

### Question

AI 是否提高成绩?

### Estimand

平均因果效应?

### Threats

Ability / Motivation /  
Reverse causality /  
Selection

### Design

Controls? FE? IV?  
Other design?

### Estimator

对应估计方法

### Inference

Robust / Cluster SE 等

## 把 AI—成绩案例重新走一遍

---

### Question

AI 是否提高成绩?

### Estimand

平均因果效应?

### Threats

Ability / Motivation /  
Reverse causality /  
Selection

### Design

Controls? FE? IV?  
Other design?

### Estimator

对应估计方法

### Inference

Robust / Cluster SE 等

先问识别，再跑回归。

## 本讲三个问题：现在能回答了吗？

---

### ① 好回归为何不等于因果？

相关关系可能混入混杂、反向因果、选择和错误控制。

## 本讲三个问题：现在能回答了吗？

---

### ① 好回归为何不等于因果？

相关关系可能混入混杂、反向因果、选择和错误控制。

### ② 因果效应是什么？

实际结果与反事实结果之间的比较。

## 本讲三个问题：现在能回答了吗？

---

### ① 好回归为何不等于因果？

相关关系可能混入混杂、反向因果、选择和错误控制。

### ② 因果效应是什么？


实际结果与反事实结果之间的比较。

### ③ 现代方法在寻找什么？

可信的 comparison 与 identifying variation。

## 从这里开始，进入中级计量

---



## 第五讲 面板数据与固定效应

## 第五讲 面板数据与固定效应

如果个体之间有大量不可观测差异，  
我们能不能让「同一个人自己和自己比」？



## 第五讲 面板数据与固定效应

如果个体之间有大量不可观测差异，  
我们能不能让「同一个人自己和自己比」？

从 identifying variation 出发理解 Fixed Effects

$$0 < P(D = 1 \mid X) < 1$$

$$0 < P(D = 1 \mid X) < 1$$

每类  $X$  中最好**同时存在** treatment 与 control。

$$0 < P(D = 1 \mid X) < 1$$

每类  $X$  中最好**同时存在** treatment 与 control。

学生问到「相似的人根本不存在怎么办」时使用。

## 附录 A2 | Pre-treatment vs Post-treatment

---

### Pre-treatment

家庭背景  
入学前能力  
出生地区

### Post-treatment

职业  
当前户籍  
treatment 后行为

## 附录 A2 | Pre-treatment vs Post-treatment

---

### Pre-treatment

家庭背景  
入学前能力  
出生地区


### Post-treatment

职业  
当前户籍  
treatment 后行为

Post-treatment variables 要高度谨慎。


## 附录 A3 | 总效应与直接效应

---



## 附录 A3 | 总效应与直接效应

---



Total effect  $\neq$  Direct effect



主处理变量的 identification 成立，  
不代表每个 **control** 的系数都有因果含义。

主处理变量的 identification 成立，  
不代表**每个 control 的系数**都有因果含义。

用于回应实证论文中常见的一种误读。

## 参考文献

---

张子尧、黄炜（2025）：《实证研究中的控制变量选择：原理与原则》，  
《管理世界》2025 年第 10 期

Rubin, D. B. (1974)

Imbens, G. W. & Rubin, D. B. (2015)

Pearl, J. (2009)

Angrist, J. D. & Pischke, J.-S. (2009, 2014)

Chernozhukov, V. et al. (2018)