
第四讲 从相关到因果

现代计量经济学真正想解决什么问题？

$\hat{\beta} \stackrel{?}{=} \text{因果效应}$

中级计量经济学 | 张呈磊

相关 · 反事实 · 识别

从「会回归」到「会建模」

第二讲 回归 → 参数估计 → 假设检验



第三讲 函数形式 → 控制变量 → FWL → 模型诊断

从「会回归」到「会建模」

第二讲 回归 → 参数估计 → 假设检验



第三讲 函数形式 → 控制变量 → FWL → 模型诊断

我们已经可以做出一个「统计上不错」的回归模型。

从「会回归」到「会建模」

第二讲 回归 → 参数估计 → 假设检验



第三讲 函数形式 → 控制变量 → FWL → 模型诊断

我们已经可以做出一个「统计上不错」的回归模型。

这就够了吗？

一个看起来很漂亮的结果

被解释变量: Score

AI use	1.50*** (0.30)
--------	-------------------

Controls (控制变量)	已控制
Functional form (函数形式)	已检验
Diagnostics (模型诊断)	通过

与第三讲末尾那张「完美」结果卡是同一个模型。

一个看起来很漂亮的结果

被解释变量: Score

AI use	1.50*** (0.30)
--------	-------------------

Controls (控制变量)	已控制
-----------------	-----

Functional form (函数形式)	已检验
------------------------	-----

Diagnostics (模型诊断)	通过
--------------------	----

与第三讲末尾那张「完美」结果卡是同一个模型。

一个显著、稳健、诊断良好的系数，
为什么仍然可能只是**相关关系**？

一个看起来很漂亮的结果

被解释变量: Score

AI use	1.50*** (0.30)
--------	-------------------

Controls (控制变量)	已控制
-----------------	-----

Functional form (函数形式)	已检验
------------------------	-----

Diagnostics (模型诊断)	通过
--------------------	----

与第三讲末尾那张「完美」结果卡是同一个模型。

一个显著、稳健、诊断良好的系数，
为什么仍然可能只是**相关关系**？

$\hat{\beta} \stackrel{?}{=} \text{Causal Effect (因果效应)}$

我们已经从数据得到信息，然后呢？



我们已经从数据得到信息，然后呢？



Data AI 使用时间、学生成绩、学生能力、其他
观测变量
数据只是观测记录。

我们已经从数据得到信息，然后呢？



Data AI 使用时间、学生成绩、学生能力、其他观测变量

数据只是观测记录。

Information $\hat{\beta}_{AI} = 1.50^{***}$ ，即 AI use $\uparrow \iff$ Score $\uparrow$

这属于统计规律／相关信息。

我们已经从数据得到信息，然后呢？



Data AI 使用时间、学生成绩、学生能力、其他观测变量

数据只是观测记录。

Information $\hat{\beta}_{AI} = 1.50^{***}$ ，即 $AI\ use \uparrow \iff Score \uparrow$

这属于统计规律／相关信息。

Knowledge 如果我们真的改变一个学生的 AI 使用，他的成绩会怎样？

What happens if we intervene?

我们已经从数据得到信息，然后呢？



Data AI 使用时间、学生成绩、学生能力、其他观测变量

数据只是观测记录。

Information $\hat{\beta}_{AI} = 1.50^{***}$ ，即 $AI\ use \uparrow \iff Score \uparrow$

这属于统计规律／相关信息。

Knowledge 如果我们真的改变一个学生的 AI 使用，他的成绩会怎样？

What happens if we intervene?

相关告诉我们「世界呈现出什么规律」；

因果帮助我们理解「如果改变一个因素，会发生什么」。

我们已经从数据得到信息，然后呢？



Data AI 使用时间、学生成绩、学生能力、其他观测变量

数据只是观测记录。

Information $\hat{\beta}_{AI} = 1.50^{***}$ ，即 $AI\ use \uparrow \iff Score \uparrow$

这属于统计规律／相关信息。

Knowledge 如果我们真的改变一个学生的 AI 使用，他的成绩会怎样？

What happens if we intervene?

相关告诉我们「世界呈现出什么规律」；

因果帮助我们理解「如果改变一个因素，会发生什么」。

经验经济学要从相关信息走向可解释、可干预的知识，**因果推断是关键一步**。

为什么经济学不能满足于相关关系？

延长教育年限，会不会提高收入？

给企业补贴，会不会增加创新？

降息，会不会刺激投资？

为什么经济学不能满足于相关关系？

延长教育年限，会不会提高收入？

给企业补贴，会不会增加创新？

降息，会不会刺激投资？

一旦问题变成「如果改变 X ，会发生什么」，我们就在问**因果问题**。

今天三个问题

① 为什么一个「好回归」

仍然不等于因果？

发现问题

观察到的比较可能被污染

今天三个问题

① 为什么一个「好回归」

仍然不等于因果？

发现问题

观察到的比较可能被污染

② 因果效应
到底是什么？

定义目标

真正需要的是反事实比较

今天三个问题

① 为什么一个「好回归」

仍然不等于因果？

发现问题

观察到的比较可能被污染

② 因果效应
到底是什么？

定义目标

真正需要的是反事实比较

③ 现代计量方法
究竟在寻找什么？

解决问题

寻找可信比较与可信
variation

今天三个问题

① 为什么一个「好回归」

仍然不等于因果？

发现问题

观察到的比较可能被污染

② 因果效应
到底是什么？

定义目标

真正需要的是反事实比较

③ 现代计量方法
究竟在寻找什么？

解决问题

寻找可信比较与可信
variation

发现问题 → 定义目标 → 寻找解决方案

相关 → 反事实 → 识别



问题一

为什么一个「好回归」仍然不等于因果？

Controls + Robust SE + Diagnostics, 为什么还不够？



相关 ▶ 反事实 ▶ 识别

遗漏变量：最熟悉的麻烦





总体相关（Overall correlation）／能力相同者之间（Within-ability）

遗漏变量：最熟悉的麻烦



总体相关（Overall correlation）／能力相同者之间（Within-ability）

遗漏变量：最熟悉的麻烦





总体相关（Overall correlation）／能力相同者之间（Within-ability）

AI 使用多的学生成绩更高，这背后可能是 AI，也可能只是能力（Ability）。

也就是说：X 与其他影响 Y 的因素纠缠在一起，因此回归系数可能混入其他作用。

遗漏变量：最熟悉的麻烦



总体相关（Overall correlation）／能力相同者之间（Within-ability）

AI 使用多的学生成绩更高，这背后可能是 AI，也可能只是能力（Ability）。

也就是说：X 与其他影响 Y 的因素纠缠在一起，因此回归系数可能混入其他作用。

$$E(u \mid AI) \neq 0 \quad \text{线性简化情形下即 } Cov(AI, u) \neq 0$$

总体斜率（slope）里混入了能力差异带来的那部分。

回忆第三讲：FWL 留下的一个重要直觉

$$X \longrightarrow \tilde{X} \qquad Y \longrightarrow \tilde{Y}$$

回忆第三讲：FWL 留下的一个重要直觉

$$X \longrightarrow \tilde{X} \quad Y \longrightarrow \tilde{Y}$$
$$\tilde{Y} = \beta \tilde{X} + \tilde{u}$$

回忆第三讲：FWL 留下的一个重要直觉

$$X \longrightarrow \tilde{X} \quad Y \longrightarrow \tilde{Y}$$

$$\tilde{Y} = \beta \tilde{X} + \tilde{u}$$

控制 Z 之后， β 利用的是 X 剩余的 **variation**。

回忆第三讲：FWL 留下的一个重要直觉

$$X \longrightarrow \tilde{X} \quad Y \longrightarrow \tilde{Y}$$

$$\tilde{Y} = \beta \tilde{X} + \tilde{u}$$

控制 Z 之后， β 利用的是 X 剩余的 **variation**。



回忆第三讲：FWL 留下的一个重要直觉

$$X \longrightarrow \tilde{X} \quad Y \longrightarrow \tilde{Y}$$

$$\tilde{Y} = \beta \tilde{X} + \tilde{u}$$

控制 Z 之后， β 利用的是 X 剩余的 **variation**。



FWL：先净化，再比较——但第四讲要在它之上**再问一步**。

控制变量越多越好吗？

控制变量不是越多越好

控制变量越多越好吗？

控制变量不是越多越好

思考 研究教育对收入的影响，职业要不要控制？

Education

?

Income

控制变量越多越好吗？

控制变量不是越多越好

思考 研究教育对收入的影响，职业要不要控制？


Education

?

Income


先不要急着回答——看两种可能的结构。

Mediator (中介变量): 控制会改变你估计的东西



参考：张子尧、黄炜（2025）


Mediator (中介变量): 控制会改变你估计的东西



教育的一部分回报，正是来自**进入更高薪职业的机会**。

参考：张子尧、黄炜（2025）

Mediator（中介变量）：控制会改变你估计的东西




教育的一部分回报，正是来自**进入更高薪职业的机会**。

如果研究的是教育对收入的**总作用**，
控制职业可能**切断**教育的一部分作用路径。

参考：张子尧、黄炜（2025）

Mediator（中介变量）：控制会改变你估计的东西



教育的一部分回报，正是来自**进入更高薪职业的机会**。


如果研究的是教育对收入的**总作用**，
控制职业可能**切断**教育的一部分作用路径。

控制以后，我们回答的问题变了。

这实际上意味着 estimand（估计目标）发生了变化。


参考：张子尧、黄炜（2025）

更麻烦：职业还可能是 Collider（对撞变量）



拓展： $Education \not\perp Ability \mid Occupation$


更麻烦：职业还可能是 Collider（对撞变量）



在**所有进入相同高薪职业**的人中，
学历较低的人，是否往往需要**更高能力**？

拓展： $Education \not\perp Ability \mid Occupation$

更麻烦：职业还可能是 Collider（对撞变量）




在**所有进入相同高薪职业**的人中，
学历较低的人，是否往往需要**更高能力**？

原来：Education 与 Ability 可不相关

控制 Occupation 后：二者**反而产生关联**

拓展： $Education \not\perp Ability \mid Occupation$

更麻烦：职业还可能是 Collider（对撞变量）



在**所有进入相同高薪职业**的人中，
学历较低的人，是否往往需要**更高能力**？


原来：Education 与 Ability 可不相关

控制 Occupation 后：二者**反而产生关联**

而 Ability 又影响 Income

拓展： $Education \not\perp Ability \mid Occupation$

更麻烦：职业还可能是 Collider（对撞变量）



在**所有进入相同高薪职业**的人中，
学历较低的人，是否往往需要**更高能力**？

原来：Education 与 Ability 可不相关

控制 Occupation 后：二者**反而产生关联**


而 Ability 又影响 Income

Bad Control（错误控制） $\Rightarrow$ Selection Bias（选择偏误）

拓展：Education $\not\propto$ Ability | Occupation

三种最基本的因果结构

Confounder (混杂变量)




通常需要认真控制

Mediator (中介变量)



是否控制取决于研究问题


Collider (对撞变量)



机械控制可能制造偏误

三种最基本的因果结构

Confounder (混杂变量)




通常需要认真控制

Mediator (中介变量)



是否控制取决于研究问题

Collider (对撞变量)




机械控制可能制造偏误

变量该不该控制，取决于**因果结构**，而不是相关性大小。

还有一种麻烦：方向可能反过来




还有一种麻烦：方向可能反过来



成绩较差的学生，
会不会反而更依赖 AI？

还有一种麻烦：方向可能反过来




$AI \leftrightarrow Score$

成绩较差的学生，
会不会反而**更依赖 AI**？

两种机制都说得通，
数据本身不会告诉你哪一个是真的。

还有一种麻烦：方向可能反过来



$AI \leftrightarrow Score$

成绩较差的学生，
会不会反而**更依赖 AI**？

两种机制都说得通，
数据本身不会告诉你哪一个是真的。

相关关系本身不能告诉我们**因果方向**。

把「内生性」重新理解一下

Identification Problem (识别问题)

用于估计 β 的 variation
与其他影响 Y 的因素纠缠

把「内生性」重新理解一下

Identification Problem (识别问题)

用于估计 β 的 variation
与其他影响 Y 的因素纠缠

Estimand Problem (估计目标问题)

控制以后，我们实际上
改变了想估计的问题

把「内生性」重新理解一下

Identification Problem (识别问题)

用于估计 β 的 variation
与其他影响 Y 的因素**纠缠**

Estimand Problem (估计目标问题)

控制以后，我们实际上
改变了想估计的问题

$$E(u | X) \neq 0$$

线性简化情形下即 $Cov(X, u) \neq 0$

把「内生性」重新理解一下

Identification Problem (识别问题)

用于估计 β 的 variation
与其他影响 Y 的因素**纠缠**

Estimand Problem (估计目标问题)

控制以后，我们实际上
改变了想估计的问题

$$E(u | X) \neq 0 \quad \text{线性简化情形下即 } Cov(X, u) \neq 0$$

问题就变成：这部分 variation **值得相信**吗？

问题一收束：只需要记住两句话

规范的回归 $\neq$ 可信的因果效应

问题一收束：只需要记住两句话

规范的回归 $\neq$ 可信的因果效应

控制变量越多 $\neq$ 识别越好

问题一收束：只需要记住两句话

规范的回归 $\neq$ 可信的因果效应

控制变量越多 $\neq$ 识别越好

那么，我们到底想识别的「因果效应」是什么？

我们已经知道「什么不够」——但「因果」究竟是什么？

$$\hat{\beta} \stackrel{?}{=} \text{因果效应}$$

我们已经知道

显著 $\neq$ 因果

控制很多变量 $\neq$ 因果

诊断通过 $\neq$ 因果

我们已经知道「什么不够」——但「因果」究竟是什么？

$\hat{\beta} \stackrel{?}{=} \text{因果效应}$

我们已经知道

显著 $\neq$ 因果

控制很多变量 $\neq$ 因果

诊断通过 $\neq$ 因果

但还缺一个更基本的问题

我们所谓的「因果效应」，
到底是什么？

我们已经知道「什么不够」——但「因果」究竟是什么？

$\hat{\beta} \stackrel{?}{=} \text{因果效应}$

我们已经知道

显著 $\neq$ 因果

控制很多变量 $\neq$ 因果

诊断通过 $\neq$ 因果

但还缺一个更基本的问题

我们所谓的「因果效应」，
到底是什么？

在讨论「如何识别」之前，必须先知道**我们到底想识别什么。**

问题二

因果效应到底是什么？

因果不是「两个不同的人有差异」。

相关 ▶ 反事实 ▶ 识别

先区分两句话

AI 使用更多的学生，
平均成绩更高。

Correlation（相关关系）

先区分两句话

AI 使用更多的学生，
平均成绩更高。

Correlation（相关关系）

如果让同一个学生
使用 AI、而不是不使用 AI，
他的成绩会怎样？

Causal Question（因果问题）

先区分两句话

AI 使用更多的学生，
平均成绩更高。

Correlation（相关关系）

如果让同一个学生
使用 AI、而不是不使用 AI，
他的成绩会怎样？

Causal Question（因果问题）

关联（Association） $\neq$ 干预（Intervention）

同一个学生，两个可能世界

为了把反事实讲清楚，下面暂时把 AI 使用简化为二元处理（treatment）：使用 AI 记为 $D = 1$ ，不使用 AI 记为 $D = 0$ 。

同一个学生

World 1
使用 AI
 $Y_i(1)$

World 0
不使用 AI
 $Y_i(0)$

同一个学生，两个可能世界

为了把反事实讲清楚，下面暂时把 AI 使用简化为二元处理（treatment）：使用 AI 记为 $D = 1$ ，不使用 AI 记为 $D = 0$ 。

同一个学生

World 1
使用 AI
 $Y_i(1)$

World 0
不使用 AI
 $Y_i(0)$

$$\tau_i = Y_i(1) - Y_i(0) \quad \text{个体因果效应}$$

本讲最重要的公式

同一个学生，两个可能世界

为了把反事实讲清楚，下面暂时把 AI 使用简化为二元处理（treatment）：使用 AI 记为 $D = 1$ ，不使用 AI 记为 $D = 0$ 。

同一个学生

World 1
使用 AI
 $Y_i(1)$

World 0
不使用 AI
 $Y_i(0)$

$$\tau_i = Y_i(1) - Y_i(0) \quad \text{个体因果效应}$$

本讲最重要的公式

因果效应问的不是「张三和李四差多少？」
而是：同一个单位在两个可能世界中的差异。

Fundamental Problem of Causal Inference

因果推断的根本问题

对于同一个 i :

Fundamental Problem of Causal Inference

因果推断的根本问题

对于同一个 i :

如果 $D_i = 1$, 我们看到 $Y_i(1)$; 但 $Y_i(0) = ?$

Fundamental Problem of Causal Inference

因果推断的根本问题

对于同一个 i :

如果 $D_i = 1$, 我们看到 $Y_i(1)$; 但 $Y_i(0) = ?$
反过来也一样。

Fundamental Problem of Causal Inference

因果推断的根本问题

对于同一个 i :

如果 $D_i = 1$, 我们看到 $Y_i(1)$; 但 $Y_i(0) = ?$
反过来也一样。

同一个人不可能同时处在两个世界

Fundamental Problem of Causal Inference

因果推断的根本问题

对于同一个 i :

如果 $D_i = 1$, 我们看到 $Y_i(1)$; 但 $Y_i(0) = ?$
反过来也一样。

同一个人不可能同时处在两个世界

我们永远缺少一个潜在结果。

观测到的结果 + 缺失的反事实

Observed + Missing Counterfactual

Fundamental Problem of Causal Inference

因果推断的根本问题

对于同一个 i :

如果 $D_i = 1$, 我们看到 $Y_i(1)$; 但 $Y_i(0) = ?$
反过来也一样。

同一个人不可能同时处在两个世界

我们永远缺少一个潜在结果。

观测到的结果 + 缺失的反事实

Observed + Missing Counterfactual

因果推断本质上是一个反事实缺失问题。

所以真正的问题不是「拟合得多好」

Prediction (预测)

给定 D , Y 是多少?

Causal Inference (因果推断)

如果改变 D , Y 会怎样?

所以真正的问题不是「拟合得多好」

Prediction (预测)

给定 D , Y 是多少?

Causal Inference (因果推断)

如果改变 D , Y 会怎样?

预测关注「会发生什么」; 因果关注「如果我改变它, 会发生什么」。

从个体效应到平均效应

$$ATE = E[Y(1) - Y(0)]$$

ATE: 平均处理效应 (Average Treatment Effect)

个体反事实不可同时观察，
但可能识别某个群体的**平均效应**。

拓展：ATT（处理组平均处理效应）——已经接受 treatment 的人，平均处理效应是多少？

谁可以替代看不到的反事实？

思考 一个使用 AI 的学生，
他「如果不用 AI」的成绩从哪里来？

谁可以替代看不到的反事实？

思考 一个使用 AI 的学生，
他「如果不用 AI」的成绩从哪里来？

另一个没用 AI 的学生？

为什么另一个学生可以代表他的反事实？

谁可以替代看不到的反事实？

思考 一个使用 AI 的学生，
他「如果不用 AI」的成绩从哪里来？

另一个没用 AI 的学生？

为什么另一个学生可以代表他的**反事实**？

他们真的**可比**吗？

谁可以替代看不到的反事实？

思考 一个使用 AI 的学生，
他「如果不用 AI」的成绩从哪里来？

另一个没用 AI 的学生？

为什么另一个学生可以代表他的**反事实**？

他们真的**可比**吗？

因果推断 = 找到可信的比较对象

两种常见的因果推断语言

Potential Outcomes / Rubin

潜在结果框架 / Rubin 框架

核心问题：我们真正想比较什么？

$$Y_i(1), \quad Y_i(0)$$

$$\tau_i = Y_i(1) - Y_i(0)$$

用「两个潜在世界」定义因果效应。

两种常见的因果推断语言

Potential Outcomes / Rubin

潜在结果框架 / Rubin 框架

核心问题：我们真正想比较什么？

$$Y_i(1), \quad Y_i(0)$$

$$\tau_i = Y_i(1) - Y_i(0)$$

用「两个潜在世界」定义因果效应。

Causal DAG / Causal Structure

因果图 / 因果结构

核心问题：为什么现实比较可能不可信？

$$Ability \rightarrow AI, \quad Ability \rightarrow Score, \\ AI \rightarrow Score$$

用它分析哪些变量该控制、哪些不该。

两种常见的因果推断语言

Potential Outcomes / Rubin

潜在结果框架 / Rubin 框架

核心问题：我们真正想比较什么？

$$Y_i(1), \quad Y_i(0)$$

$$\tau_i = Y_i(1) - Y_i(0)$$

用「两个潜在世界」定义因果效应。

Causal DAG / Causal Structure

因果图 / 因果结构

核心问题：为什么现实比较可能不可信？

$$\begin{aligned} Ability &\rightarrow AI, \quad Ability \rightarrow Score, \\ AI &\rightarrow Score \end{aligned}$$

用它分析哪些变量该控制、哪些不该。


Potential Outcomes 与 Causal DAG 不是互相排斥的两种方法，
而是现代因果推断中常见的两种表达语言，可以**互补使用**。

因果图告诉我们：张三和李四为什么可能不能直接比；

Potential Outcomes 告诉我们：理想情况下应该让「张三和另一个世界的张三」相比。


Further Reading: Imbens & Rubin — Potential Outcomes / Pearl — Causal DAG、SCM

从「两种语言」到 Identification




这不是说三个框架有严格的理论先后顺序，而是**本课程的认知顺序**：
先发现现实比较为什么会出问题；再定义理想的因果比较；最后问如何从数据中恢复它。

为什么 Randomized Experiment (随机实验) 是基准?



Random Assignment /
Treatment / Control

为什么 Randomized Experiment (随机实验) 是基准?



Random Assignment /
Treatment / Control


平均意义上，处理组与对照组
在 treatment 之前可比。

不是：让回归更显著。

$$D \perp \{Y(1), Y(0)\}$$

随机分配使 treatment 与潜在结果
在平均意义上没有系统关系。

为什么 Randomized Experiment (随机实验) 是基准?



Random Assignment /
Treatment / Control

理想的反事实不可见 → 需要可信的比较组 → 随机实验提供一个基准答案。

平均意义上，处理组与对照组
在 treatment 之前**可比**。

不是：让回归更显著。

$$D \perp \{Y(1), Y(0)\}$$

随机分配使 treatment 与潜在结果
在平均意义上没有系统关系。

Randomization 创造了可信的**比较组**

在**平均意义**上，对照组帮助我们估计
处理组**缺失的反事实结果**。

现实中通常没有随机实验

教育不能随意随机分配
城市政策不是随机出台
企业选择融资方式并不随机
AI 使用也通常是自选择

现实中通常没有随机实验

教育不能随意随机分配
城市政策不是随机出台
企业选择融资方式并不随机
AI 使用也通常是自选择

观测数据 (Observational Data)

现实中通常没有随机实验

教育不能随意随机分配
城市政策不是随机出台
企业选择融资方式并不随机
AI 使用也通常是自选择

观测数据 (Observational Data)

没有随机实验时，我们怎样从观测数据中找到可信比较？

现实中通常没有随机实验

教育不能随意随机分配
城市政策不是随机出台
企业选择融资方式并不随机
AI 使用也通常是自选择

观测数据 (Observational Data)

没有随机实验时，我们怎样从观测数据中找到可信比较？

这就是 Identification 问题

问题二结束后，我们面临一个新的难题

1. 我们已经定义了因果效应

$$\tau_i = Y_i(1) - Y_i(0)$$

$Y_i(1)$ 和 $Y_i(0)$ 不能同时看到

谁可以替代那个看不到的反事实？

问题二结束后，我们面临一个新的难题

1. 我们已经定义了因果效应

$$\tau_i = Y_i(1) - Y_i(0)$$

2. 但反事实不可观察

$Y_i(1)$ 和 $Y_i(0)$ 不能同时看到

谁可以替代那个看不到的反事实？

问题二结束后，我们面临一个新的难题

1. 我们已经定义了因果效应

$$\tau_i = Y_i(1) - Y_i(0)$$

2. 但反事实不可观察

$Y_i(1)$ 和 $Y_i(0)$ 不能同时看到

3. 所以现实研究必须回答

谁可以替代那个看不到的反事实？

问题二结束后，我们面临一个新的难题

1. 我们已经定义了因果效应

$$\tau_i = Y_i(1) - Y_i(0)$$

2. 但反事实不可观察

$Y_i(1)$ 和 $Y_i(0)$ 不能同时看到

3. 所以现实研究必须回答

谁可以替代那个看不到的反事实？

问题二定义了「想要什么」；问题三开始解决「怎样得到它」。

问题三

现代计量方法究竟在寻找什么？

后面的 FE、IV、DID、RD 为什么都在解决同一个问题？

相关 ▶ 反事实 ▶ 识别

理想的比较看不见，现实数据能给我们什么？

理想的因果比较

$$Y_i(1) - Y_i(0)$$

同一个单位的两个可能世界

?

数据中的现实比较

$$D = 1 \quad \text{vs.} \quad D = 0$$

两组不同的人

理想的比较看不见，现实数据能给我们什么？

理想的因果比较

$$Y_i(1) - Y_i(0)$$

同一个单位的两个可能世界

?

数据中的现实比较

$$D = 1 \quad \text{vs.} \quad D = 0$$

两组不同的人

什么时候「现实中的比较」可以替代理想的反事实比较？

理想的比较看不见，现实数据能给我们什么？

理想的因果比较

$$Y_i(1) - Y_i(0)$$

同一个单位的两个可能世界

?

数据中的现实比较

$$D = 1 \quad \text{vs.} \quad D = 0$$

两组不同的人

什么时候「现实中的比较」可以替代理想的反事实比较？

这就是 Identification

一个经验研究其实有四个层次

我们已经知道「想估计什么」；但「想估计什么」与「数据能不能告诉我们」不是一回事。

Estimand (估计目标)

我到底想估计什么？

Identification (识别)

为什么数据能够告诉我？

Estimator (估计量)

怎么计算？

Inference (推断)

这个估计有多不确定？

估计目标 $\neq$ 识别 $\neq$ 估计 $\neq$ 推断

(Estimand 这一格，第二部分已经答了：ATE)

一个经验研究其实有四个层次

我们已经知道「想估计什么」；但「想估计什么」与「数据能不能告诉我们」不是一回事。

Estimand (估计目标)

我到底想估计什么？

Identification (识别)

为什么数据能够告诉我？

Estimator (估计量)

怎么计算？

Inference (推断)

这个估计有多不确定？

估计目标 $\neq$ 识别 $\neq$ 估计 $\neq$ 推断 (Estimand 这一格，第二部分已经答了：ATE)

Research Design 的核心任务，
是让 **Identification Assumptions** 更可信，
而不是让系数更显著。

一个经验研究其实有四个层次

我们已经知道「想估计什么」；但「想估计什么」与「数据能不能告诉我们」不是一回事。

Estimand (估计目标)

我到底想估计什么？

Identification (识别)

为什么数据能够告诉我？

Estimator (估计量)

怎么计算？

Inference (推断)

这个估计有多不确定？

估计目标 $\neq$ 识别 $\neq$ 估计 $\neq$ 推断 (Estimand 这一格，第二部分已经答了：ATE)

Research Design 的核心任务，
是让 **Identification Assumptions** 更可信，
而不是让系数更显著。

现代计量要找的：可信的比较 + 可信的 identifying variation

控制变量什么时候可能帮助因果识别？

问题二的结论：因果效应是反事实比较，而我们永远缺少一个潜在结果——所以要找**可信的比较组**。

一、要「可比」

控制处理前特征以后，
处理组和对照组要**足够相似**

控制变量什么时候可能帮助因果识别？

问题二的结论：因果效应是反事实比较，而我们永远缺少一个潜在结果——所以要找**可信的比较组**。

一、要「可比」

控制处理前特征以后，
处理组和对照组要**足够相似**

二、要「有得比」

相似的人中，最好
既有人接受处理，也有人没有

控制变量什么时候可能帮助因果识别？

问题二的结论：因果效应是反事实比较，而我们永远缺少一个潜在结果——所以要找**可信的比较组**。

一、要「可比」

控制处理前特征以后，
处理组和对照组要**足够相似**

二、要「有得比」

相似的人中，最好
既有人接受处理，也有人没有

控制变量**不会自动**创造因果识别；
关键在于「控制以后是否真的形成**可信比较**」。

控制变量什么时候可能帮助因果识别？

问题二的结论：因果效应是反事实比较，而我们永远缺少一个潜在结果——所以要找**可信的比较组**。

一、要「可比」

控制处理前特征以后，
处理组和对照组要**足够相似**

二、要「有得比」

相似的人中，最好
既有人接受处理，也有人没有

控制变量**不会自动**创造因果识别；
关键在于「控制以后是否真的形成**可信比较**」。

后面的现代计量方法，就是在不同场景下寻找不同的**可信比较**。

从 FWL 的直觉再往前走一步

$$X \longrightarrow \tilde{X} \qquad Y \longrightarrow \tilde{Y}$$

从 FWL 的直觉再往前走一步

$$\begin{aligned} X &\longrightarrow \tilde{X} & Y &\longrightarrow \tilde{Y} \\ \tilde{Y} &= \beta \tilde{X} + \tilde{u} \end{aligned}$$

从 FWL 的直觉再往前走一步

$$X \longrightarrow \tilde{X} \quad Y \longrightarrow \tilde{Y}$$

$$\tilde{Y} = \beta \tilde{X} + \tilde{u}$$

控制以后，OLS 使用的是 X 剩余的 **variation**。

从 FWL 的直觉再往前走一步

$$X \longrightarrow \tilde{X} \quad Y \longrightarrow \tilde{Y}$$

$$\tilde{Y} = \beta \tilde{X} + \tilde{u}$$

控制以后，OLS 使用的是 X 剩余的 variation。

这部分 variation
从哪里来？

Where does the identifying variation come from?

从 FWL 的直觉再往前走一步

$$X \longrightarrow \tilde{X} \quad Y \longrightarrow \tilde{Y}$$
$$\tilde{Y} = \beta \tilde{X} + \tilde{u}$$

控制以后，OLS 使用的是 X 剩余的 **variation**。

这部分 variation
从哪里来？

Where does the identifying variation come from?

为什么值得相信？

Why should we trust it?

后面的中级计量，其实都在回答同一个问题

这一讲不要求你学会这些方法——只要求看懂它们**共同在问什么**。

第一层 Identification / Research Design (识别 & 研究设计)

Controls
条件可比

Fixed Effects
组内变化

IV
外部推动

DID
相对变化

RD
阈值附近


后面的中级计量，其实都在回答同一个问题

这一讲不要求你学会这些方法——只要求看懂它们**共同在问什么**。



后面的中级计量，其实都在回答同一个问题


这一讲不要求你学会这些方法——只要求看懂它们**共同在问什么**。



六种方法，是六种不同的「反事实替代」方式（ML/DML 只做调整，不创造识别）。

后面的中级计量，其实都在回答同一个问题


这一讲不要求你学会这些方法——只要求看懂它们**共同在问什么**。



六种方法，是六种不同的「反事实替代」方式（ML/DML 只做调整，不创造识别）。

后面的中级计量，其实都在回答同一个问题

这一讲不要求你学会这些方法——只要求看懂它们**共同在问什么**。



六种方法，是六种不同的「反事实替代」方式（ML/DML 只做调整，不创造识别）。

谁和谁在比较？

这部分 identifying variation 为什么可信？

后面的每一种方法，都问同样两个问题

Q1 它用谁来替代**看不到的反事实**？

Q2 为什么这个替代**值得相信**？

方法	用什么替代看不到的反事实
Controls	在条件相似的人之间寻找反事实
Fixed Effects	从同一个体的组内变化中寻找更可信的比较
IV	利用外部推动带来的 variation
DID	用未处理组的相对变化构造反事实趋势
RD	用 cutoff 附近非常相似的人构造局部比较
ML / DML	更灵活地做调整与残差化，但本身不创造 Identification

后面的每一种方法，都问同样两个问题


Q1 它用谁来替代**看不到的反事实**？

Q2 为什么这个替代**值得相信**？

方法	用什么替代看不到的反事实
Controls	在条件相似的人之间寻找反事实
Fixed Effects	从同一个体的组内变化中寻找更可信的比较
IV	利用外部推动带来的 variation
DID	用未处理组的相对变化构造反事实趋势
RD	用 cutoff 附近非常相似的人构造局部比较
ML / DML	更灵活地做调整与残差化，但本身不创造 Identification


识别假设来自研究设计——这两个问题，整门中级计量课都会一直问下去。

Fixed Effects: 利用同一个体的组内变化



不同企业／个人之间，存在大量**不随时间变化**的固定差异。

Fixed Effects: 利用同一个体的组内变化




不同企业／个人之间，存在大量不随时间变化的固定差异。

$X_{it} - \bar{X}_i$ 组内变异

within variation

去掉不随时间变化的固定差异后，
利用同一个体随时间发生的变化。

Fixed Effects: 利用同一个体的组内变化



不同企业／个人之间，存在大量不随时间变化的固定差异。


$X_{it} - \bar{X}_i$ 组内变异

within variation

去掉不随时间变化的固定差异后，
利用同一个体随时间发生的变化。

可以粗略理解为：更多利用「同一个体不同时期」的比较，而不是不同个体之间的水平差异。

Fixed Effects: 利用同一个体的组内变化



不同企业／个人之间，存在大量**不随时间变化**的固定差异。

$X_{it} - \bar{X}_i$ **组内变异**


within variation

去掉不随时间变化的固定差异后，
利用同一个体随时间发生的变化。

可以粗略理解为：更多利用「同一个体不同时期」的比较，而不是不同个体之间的水平差异。

思考 组内 variation 也**不自动**等于因果——时间变化的遗漏变量、反向因果、同时性仍然可能存在。

Fixed Effects: 利用同一个体的组内变化



不同企业／个人之间，存在大量**不随时间变化**的固定差异。

$X_{it} - \bar{X}_i$ **组内变异**

within variation


去掉不随时间变化的固定差异后，
利用同一个体随时间发生的变化。

可以粗略理解为：更多利用「同一个体不同时期」的比较，而不是不同个体之间的水平差异。

思考 组内 variation 也**不自动**等于因果——时间变化的遗漏变量、反向因果、同时性仍然可能存在。

我们仍然需要问：为什么这部分 within variation **值得相信**？

Instrumental Variables (工具变量): 只用「外部推动」的部分



后面 IV 专题再正式定义这些条件。

Instrumental Variables (工具变量): 只用「外部推动」的部分



一个好的工具变量 Z 需要:

- 能够推动 X ;
- 不与影响 Y 的其他未观测因素纠缠;
- 对 Y 的影响只能通过 X 。

后面 IV 专题再正式定义这些条件。

Instrumental Variables (工具变量): 只用「外部推动」的部分




一个好的工具变量 Z 需要:

- 能够推动 X ;
- 不与影响 Y 的其他未观测因素纠缠;
- 对 Y 的影响只能通过 X 。

只使用由外部因素推动的那部分 variation

后面 IV 专题再正式定义这些条件。

Instrumental Variables (工具变量): 只用「外部推动」的部分



一个好的工具变量 Z 需要:

- ▶ 能够推动 X ;
- ▶ 不与影响 Y 的其他未观测因素纠缠;
- ▶ 对 Y 的影响只能通过 X 。


只使用由外部因素推动的那部分 variation

外部推动的变异

Externally Induced Variation

后面 IV 专题再正式定义这些条件。

Instrumental Variables (工具变量): 只用「外部推动」的部分



一个好的工具变量 Z 需要:

- 能够推动 X ;
- 不与影响 Y 的其他未观测因素纠缠;
- 对 Y 的影响只能通过 X 。

只使用由外部因素推动的那部分 variation


外部推动的变异

Externally Induced Variation

后面 IV 专题再正式定义这些条件。


Q1 → 外部推动的那部分 variation; Q2 → 与影响 Y 的其他因素不纠缠。

DID: 比较相对变化，而不是直接比较水平



后续正式学习平行趋势（Parallel Trends）。


DID: 比较相对变化，而不是直接比较水平



$\Delta Y_T - \Delta Y_C$: 比较相对变化，而不是直接比较水平

后续正式学习平行趋势（Parallel Trends）。

DID: 比较相对变化, 而不是直接比较水平




$\Delta Y_T - \Delta Y_C$: 比较相对变化, 而不是直接比较水平

后续正式学习平行趋势 (Parallel Trends)。


Q1 → 未处理组的相对变化; Q2 → 平行趋势是否成立 (后续专题展开)。

RD (断点回归): 只比较 **cutoff** (断点) 附近



断点两侧非常接近的人，处理状态（treatment status）却不同。


RD (断点回归): 只比较 **cutoff** (断点) 附近



比较 cutoff 两侧**非常接近**的单位

断点两侧非常接近的人，处理状态 (treatment status) 却不同。


RD (断点回归): 只比较 cutoff (断点) 附近



比较 cutoff 两侧非常接近的单位

断点两侧非常接近的人，处理状态 (treatment status) 却不同。
局部比较 (Local Comparison)

RD (断点回归): 只比较 cutoff (断点) 附近




比较 cutoff 两侧非常接近的单位

断点两侧非常接近的人，处理状态 (treatment status) 却不同。

局部比较 (Local Comparison)


Q1 → cutoff 另一侧非常接近的人; Q2 → 断点两侧在附近足够相似。

ML / DML (机器学习 / 双重机器学习): 更灵活地净化



FWL
线性残差化
(Linear partialling out)

ML / DML (机器学习 / 双重机器学习): 更灵活地净化




FWL

线性残差化
(Linear partialling out)

DML (双重机器学习)
更灵活地估计 nuisance
functions
(模型里不关心的那部分)、
做 residualization

ML / DML (机器学习 / 双重机器学习): 更灵活地净化



FWL

线性残差化

(Linear partialling out)

DML (双重机器学习)

更灵活地估计 nuisance
functions

(模型里不关心的那部分)、
做 residualization

机器学习本身不是 Identification Strategy (识别策略)

识别假设来自研究设计, 机器学习主要帮助估计。

把 AI—成绩案例重新走一遍



研究问题	AI 是否提高成绩?
估计目标	平均因果效应
识别的威胁	Ability / Motivation / Reverse causality / Selection
研究设计	Controls? FE? IV? Other design?
估计量	对应估计方法
推断	Robust / Cluster SE (稳健 / 聚类标准误) 等

Research Design (研究设计) 的作用,
是让 identification assumptions 更可信。

把 AI—成绩案例重新走一遍



研究问题	AI 是否提高成绩?
估计目标	平均因果效应
识别的威胁	Ability / Motivation / Reverse causality / Selection
研究设计	Controls? FE? IV? Other design?
估计量	对应估计方法
推断	Robust / Cluster SE (稳健 / 聚类标准误) 等

Research Design (研究设计) 的作用,
是让 identification assumptions 更可信。

不是: 回归 $\rightarrow$ p 值 $\rightarrow$ 结论。

把 AI—成绩案例重新走一遍



研究问题	AI 是否提高成绩?
估计目标	平均因果效应
识别的威胁	Ability / Motivation / Reverse causality / Selection
研究设计	Controls? FE? IV? Other design?
估计量	对应估计方法
推断	Robust / Cluster SE (稳健 / 聚类标准误) 等

Research Design (研究设计) 的作用,
是让 identification assumptions 更可信。

不是: 回归 $\rightarrow$ p 值 $\rightarrow$ 结论。


先问识别, 再跑回归。

回到第一讲：我们如何从数据走向知识？



相关 → 反事实 → 识别
可信比较 + 可信 variation

回到第一讲：我们如何从数据走向知识？



相关 → 反事实 → 识别
可信比较 + 可信 variation

回到第一讲：我们如何从数据走向知识？



Data 观测数据

Information 统计规律 / 相关关系

相关 → 反事实 → 识别
可信比较 + 可信 variation

回到第一讲：我们如何从数据走向知识？



相关 → 反事实 → 识别
可信比较 + 可信 variation

Data 观测数据

Information 统计规律 / 相关关系

Causal Knowledge 如果改变 X , Y 会怎样？

回到第一讲：我们如何从数据走向知识？



相关 → 反事实 → 识别
可信比较 + 可信 variation

Data 观测数据

Information 统计规律 / 相关关系

Causal Knowledge 如果改变 X , Y 会怎样？

回到第一讲：我们如何从数据走向知识？



Data 观测数据

Information 统计规律 / 相关关系

Causal Knowledge 如果改变 X , Y 会怎样？

相关 → 反事实 → 识别
可信比较 + 可信 variation

问题一 为什么相关不够？
现实比较被**污染**

问题二 真正想比较什么？
 $Y_i(1) - Y_i(0)$

问题三 反事实看不见？
可信比较 + 可信 variation

回到第一讲：我们如何从数据走向知识？



Data 观测数据

Information 统计规律 / 相关关系

Causal Knowledge 如果改变 X , Y 会怎样？

相关 → 反事实 → 识别
可信比较 + 可信 variation

问题一 为什么相关不够？
现实比较被**污染**


问题二 真正想比较什么？
 $Y_i(1) - Y_i(0)$

问题三 反事实看不见？
可信比较 + 可信 variation

现代计量不只是从数据中寻找相关；
而是在识别假设下努力获得**可信的因果知识**。

因果推断让我们从「描述世界」，进一步走向「理解世界如何运行」。


一条逻辑链



真正需要带走的五句话

- ① 显著回归不等于因果效应
- ② 因果问题问的是「如果改变 X ，会发生什么？」
- ③ 因果效应本质上是反事实比较
- ④ 根本困难是反事实不可同时观察
- ⑤ 现代计量的核心是寻找可信比较，并解释 identifying variation 为什么可信

一条逻辑链



真正需要带走的五句话

- ① 显著回归不等于因果效应
- ② 因果问题问的是「如果改变 X ，会发生什么?」
- ③ 因果效应本质上是反事实比较
- ④ 根本困难是反事实不可同时观察
- ⑤ 现代计量的核心是寻找可信比较，并解释 identifying variation 为什么可信

以前看到结果问「显著吗?」——
现在还要问「为什么它可以解释成因果效应?」

下一讲

第五讲 面板数据与固定效应



下一讲

第五讲 面板数据与固定效应

如果个体之间存在大量
不随时间变化的不可观测差异，
我们能不能转而利用
「**同一个体随时间的变化**」？



下一讲

第五讲

面板数据与固定效应

如果个体之间存在大量
不随时间变化的不可观测差异，
我们能不能转而利用
「**同一个体随时间的变化**」？



从 within variation 的角度理解 Fixed Effects（固定效应）

附录 A1 | Unconfoundedness 与 Overlap (正式条件)

$$\{Y(1), Y(0)\} \perp D \mid W$$

Conditional Independence (条件独立) / Unconfoundedness (无混淆性)

$$0 < P(D = 1 \mid W) < 1$$

Overlap / Common Support (重叠 / 共同支撑)

以后正式学习 treatment effects / PSM / DML 时再展开。

附录 A1 | Unconfoundedness 与 Overlap (正式条件)

$$\{Y(1), Y(0)\} \perp D \mid W$$

Conditional Independence (条件独立) / Unconfoundedness (无混淆性)

$$0 < P(D = 1 \mid W) < 1$$

Overlap / Common Support (重叠 / 共同支撑)

每类 W 中最好**同时存在** treatment (处理) 与 control (对照)。

以后正式学习 treatment effects / PSM / DML 时再展开。

附录 A2 | Pre-treatment vs Post-treatment (处理前 vs 处理后)

Pre-treatment (处理前变量)

家庭背景
入学前能力
出生地区

Post-treatment (处理后变量)

职业
当前户籍
treatment 后行为

附录 A2 | Pre-treatment vs Post-treatment (处理前 vs 处理后)

Pre-treatment (处理前变量)


家庭背景
入学前能力
出生地区

Post-treatment (处理后变量)


职业
当前户籍
treatment 后行为

Post-treatment variables (处理后变量) 要**高度谨慎**。

附录 A3 | 总效应与直接效应



附录 A3 | 总效应与直接效应



总效应 (Total effect) $\neq$ 直接效应 (Direct effect)

附录 A4 | 控制变量的系数为什么通常不能做因果解释

主处理变量的 identification（识别）成立，
不代表每个 **control**（控制变量）的系数都有因果含义。

附录 A5 | 术语对照（一）· 相关与反事实

English	中文	一句话解释
Confounder	混杂变量	同时影响 X 与 Y ，不控制会污染估计
Mediator	中介变量	$X \rightarrow M \rightarrow Y$ 的作用路径；控制它会改变研究问题
Collider	对撞变量	同时被 X 与 Y 影响；控制它反而制造偏误
Bad Control	错误控制	控制了不该控制的变量，引入选择偏误
Selection Bias	选择偏误	样本进入方式本身与结果相关
Reverse Causality	反向因果	真实的因果方向与设想相反
Measurement Error	测量误差	变量测不准，估计被稀释
Counterfactual	反事实	「若没做这个处理会怎样」的那个结果
Potential Outcome	潜在结果	$Y(1)$ 与 $Y(0)$ ：同一个人在两个世界的结果
ATE / ATT	平均处理效应	全体 / 处理组的平均因果效应

附录 A6 | 术语对照（二）· 识别与推断

English	中文	一句话解释
Overlap / Common Support	重叠 / 共同支撑	每类 W 中处理组与对照组都得有人
Unconfoundedness	无混淆性	控制 W 后处理近似随机（即条件独立）
Estimand	估计目标	你到底想估计哪一个量
Identification	识别	凭什么说这份数据能回答这个问题
Estimator	估计量	具体用哪个公式去算
Inference	推断	这个估计有多不确定
Research Design	研究设计	让识别假设更可信的整体安排
Fixed Effects	固定效应	同一个体自己和自己比（组内变异）
Instrumental Variables	工具变量	只用外部推动的那部分变异
Difference-in-Differences	双重差分	比较相对变化，而不是比较水平
Regression Discontinuity	断点回归	只比较断点两侧非常接近的人
DML	双重机器学习	用机器学习更灵活地做残差化

符号约定： D = treatment, W = controls / covariates, Y = outcome; 问题一的因果结构（Confounder / Mediator / Collider）沿用 X （处理） / Z （混杂）。

参考文献

中文文献

张子尧、黄炜 (2025): 《实证研究中的控制变量选择: 原理与原则》, 《管理世界》2025 年第 10 期。

英文文献

Angrist, J. D., & Pischke, J.-S. (2009). *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton University Press.

Angrist, J. D., & Pischke, J.-S. (2015). *Mastering 'Metrics: The Path from Cause to Effect*. Princeton University Press.

Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68.

Imbens, G. W., & Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction*. Cambridge University Press.

Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2nd ed.). Cambridge University Press.

Rubin, D. B. (1974). Estimating causal effects of treatments in randomized and nonrandomized studies. *Journal of Educational Psychology*, 66(5), 688–701.
