第十讲

机器学习在计量经济学中的应用

从预测，到控制变量，再到“谁受益更多”

从熟悉的 OLS 出发，理解新方法为什么有用。

中级计量经济学丨应用经济学研究生丨张呈磊

这一讲，沿着三个问题往前走

一、机器学习：能否学习复杂关系？

从已有企业学规律，预测新企业；理解灵活性与过拟合。

二、DML：怎样用机器学习辅助因果效应估计？

从 OLS 的“控制变量”出发，走到双重机器学习。

三、因果森林：怎样估计、呈现和验证异质性？

从分组比较出发，走到因果树和因果森林。

先说清**在解决什么问题**，再理解方法和公式。

问题一

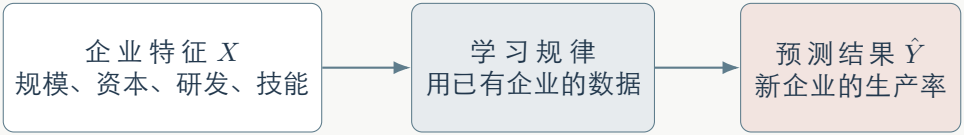
机器学习与计量经济学

从“能预测什么”出发，理解能力与边界。

一、机器学习 ▸ 二、双重机器学习 ▸ 三、因果森林

先从一个熟悉的任务开始：预测生产率

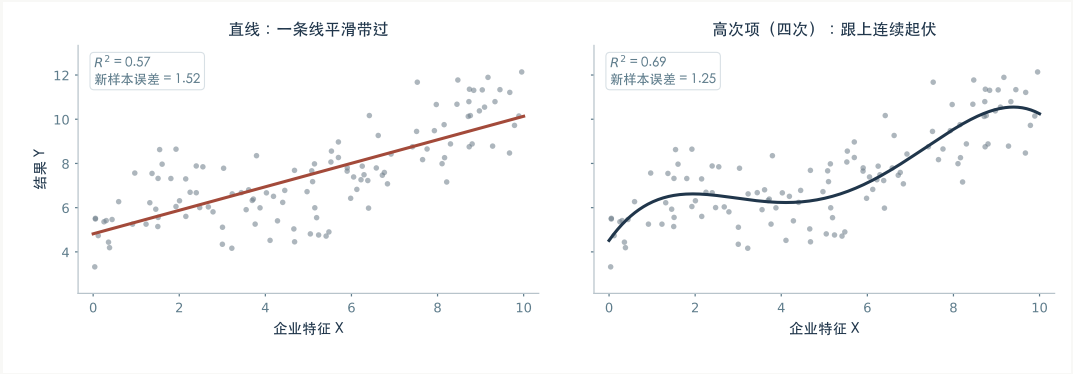
给你一批企业资料，怎样预测一家新企业的劳动生产率？



你熟悉的 OLS 已经能做这件事：用一条拟合关系来预测。

本讲先看：当关系更复杂时，怎样把预测做得更好？

这条关系一定要画成直线吗?



教学示意：同一批带噪声的散点；左图直线平滑带过，右图高次项跟上起伏。

选模型包含**研究者的判断**，但还要接受**理论**和**新样本表现**的检验。

“复杂关系”具体是什么意思?

非线性：影响不是一条直线

研发投入从低到中等，收益可能很大；从高到更高，收益可能递减。

交互：一个因素的作用取决于另一个因素

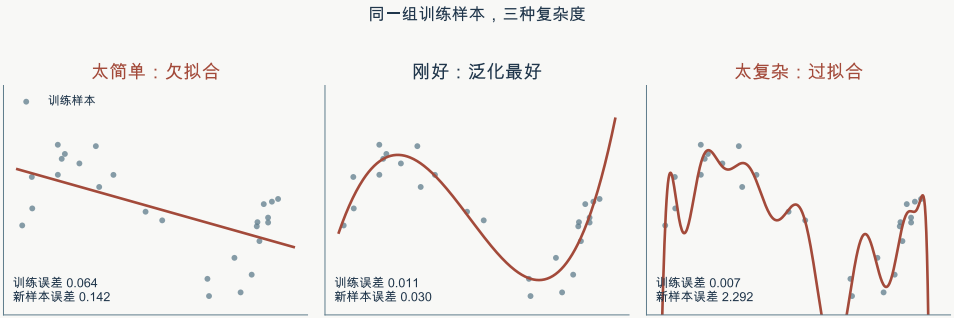
同样增加研发，技能充足与技能不足的企业，生产率变化可能不同。

高维：可能相关的特征很多

规模、年龄、行业、地区、资本、研发、技能，以及它们的组合。

OLS 也能加入平方项和交互项；机器学习帮助我们**更灵活地选择和拟合关系**。

拟合得越来越贴，为什么反而可能预测更差？



比较图中的“新样本误差”：中间约 0.030，右边约 2.292。来自本图教学模拟。

过拟合：连这批样本里的**偶然噪声**也记住了，换一批数据就失灵。

偏差与方差：两种不同的“学不好”

偏差大：方法太僵硬

真实关系是弯的，却总用直线。
即使反复换样本，平均来看仍会偏离真实规律。

规律没有学够。

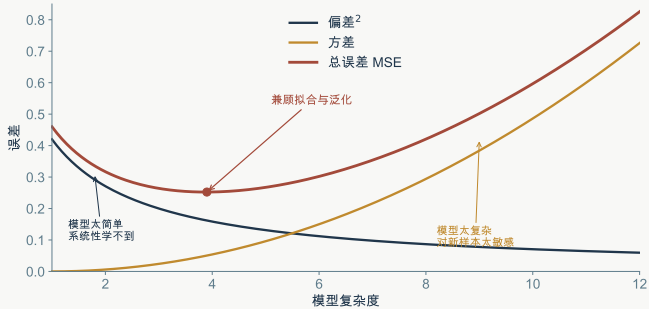
方差大：方法太敏感

模型紧跟每个样本点。
换一批训练企业，预测曲线就可能大幅改变。

把偶然性学得太多。

“方差”指**换训练样本时预测的波动**，不是企业生产率本身的差异。

偏差—方差权衡：我们追求新样本上的总误差小



$$\text{预测均方误差} = \text{偏差}^2 + \text{模型方差} + \text{不可约噪声}$$

平方损失下、对重复训练样本取平均的分解；图是典型示意，并非所有模型都呈 U 形。

与 OLS 估计量的 MSE 分解是**同一思想**，这里研究的是预测函数。

怎样知道模型真的学到了规律？留出新数据



训练

学出参数或规则。
相当于做练习题。

验证

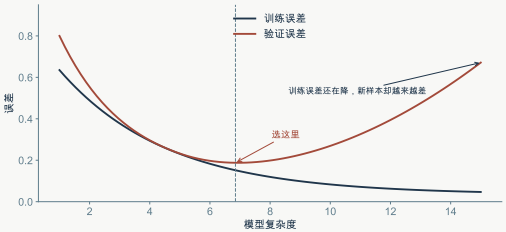
比较模型与复杂度。
相当于模拟考试。

测试

模型选定后评价。
保留到最后的考试。

70/15/15 只是示例；关键是**最终评价的数据没有参与模型选择**。

复杂度怎样选？看验证表现，不只看训练表现



训练误差：在见过的企业上错多少？

验证误差：在没用于训练的企业上错多少？

选择验证表现好的复杂度。轮流留出验证，就是**交叉验证**的基本想法。

“泛化能力”就是：从已有样本学到的规律，能否用于新样本。

先认识三种工具，不必先背算法

Lasso：给系数加约束

压缩系数，有些会被压到零；既控制复杂度，也进行变量选择。

决策树：一层层提问

先问“规模是否较大”，再问“研发是否较高”，把企业分到不同组预测。

随机森林：综合很多棵树

让不同树看不同的样本或候选特征，再综合预测，缓解单树的不稳定。

今天关心它们**能承担什么任务**；算法细节可以课后再学。

三个训练概念，各回答一个问题

概念	回答什么	例子
损失函数	预测错得有多严重?	平方误差
复杂度控制	怎样避免学得过头?	系数惩罚、限制树深
优化与搜索	怎样找到参数或规则?	解析求解、梯度下降、搜索切点

有些方法最小化“损失 + 惩罚”，有些通过限制结构控制复杂度。

三者各有作用；**不存在所有机器学习都照搬的一条训练公式**。

预测准确，为什么还不能直接回答因果问题?

预测问题

看到一家企业的规模、研发和数字化程度，预测它的生产率。

关心：**它会是多少?**

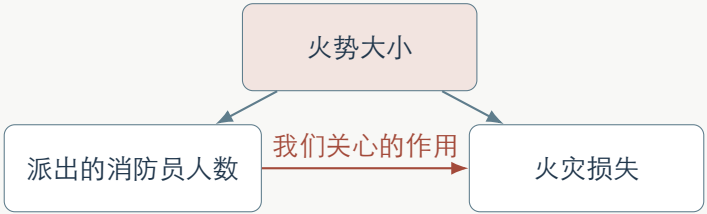
因果问题

让这家企业提高数字化程度，其他条件适当保持可比，生产率会怎样改变?

关心：**改变它会怎样?**

数字化较高的企业，也可能本来就拥有更好的管理、人才和资本。

消防员越多，损失越大：能据此少派消防员吗？



火势大时，既会派更多消防员，也更可能造成大损失。即使消防员能减少损失，观察到的相关关系仍可能为正。

预测可以利用相关性；因果研究需要排除**共同原因造成的混淆**。

先回顾：五类因果识别方法怎样建立可比性？

方法	怎样寻找可比对象	关键前提或局限
RCT：随机对照试验	随机分配处理与对照	分配落实；关注失访、干扰
OLS + 控制变量 与固定效应	控制可观测背景；扣除 不随时间变化的个体差异	条件外生性；时变遗漏 因素仍可能造成混淆
IV：工具变量	用外生工具推动处理变化	相关性、外生性、排除限制
DID：双重差分	用对照组变化构造反事实	平行趋势、无预期效应等
RD：断点回归	比较门槛两侧的局部对象	连续性、无精确操纵等

固定效应可控制部分不可观测差异，但不会自动消除所有内生性。

先说明**为什么能比较**，再选择怎样估计；机器学习也遵循这个顺序。

既然预测不等于因果，为什么还要结合?

计量研究先回答

我们想估什么效应?
谁与谁可以比较?
凭什么具有因果解释?

机器学习帮助完成

把复杂的背景关系估得更灵活;
在多种特征中寻找可能的效应差异。

例如：研究数字化的效应时，需要控制规模、研发等差异;
这些背景特征与数字化、生产率的关系，可能很复杂。

识别假设提供比较的依据；机器学习帮助我们**把比较做得更细致**。

沿着同一个企业问题，走向两条应用路线

双重机器学习 DML

当控制关系复杂时，怎样估计数字化对生产率的效应?

从控制变量与残差出发。

因果森林

数字化对哪些企业更有效? 效应怎样随特征变化?

从分组与效应差异出发。

这两条路线可以结合；最后会用一篇论文看它们怎样在同一项研究中配合。

问题二

双重机器学习

先理解“控制”，再理解为什么要灵活地控制。

回到 OLS：我们到底想估什么？

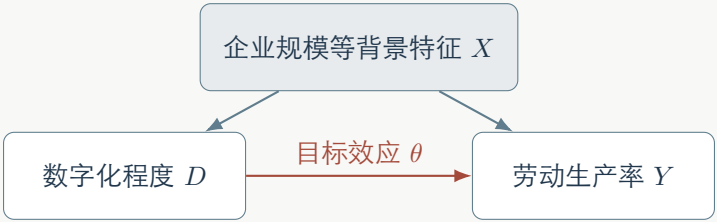
Y	劳动生产率：我们想解释的结果
D	数字化程度：我们关心的核心变量（本部分为连续变量）
X	规模、资本、研发、技能等：需要考虑的背景特征

$$Y = \alpha + \theta D + X'\gamma + u$$

本部分先用一个共同斜率 θ 概括效应；它表示 D 增加一单位对应的 Y 变化，因果解释另需识别假设。

我们关心的是 θ；加入 X，是为了让数字化程度不同的企业**更可比**。

为什么要控制规模？避免把原有优势算给数字化



如果大企业本来就更数字化、生产率也更高，直接比较可能把规模的作用混进去。

控制的直觉：比较**背景相近**的企业，而不是把所有差异都归给 D。

残差，就是“比这类企业通常的水平多多少”

数字化程度

实际值 $D = 8$

根据背景特征预测 $\hat{D} = 6$

$$\widetilde{D} = 8 - 6 = \mathbf{2}$$

比同类企业通常水平高 2。

劳动生产率

实际值 $Y = 20$

根据背景特征预测 $\hat{Y} = 15$

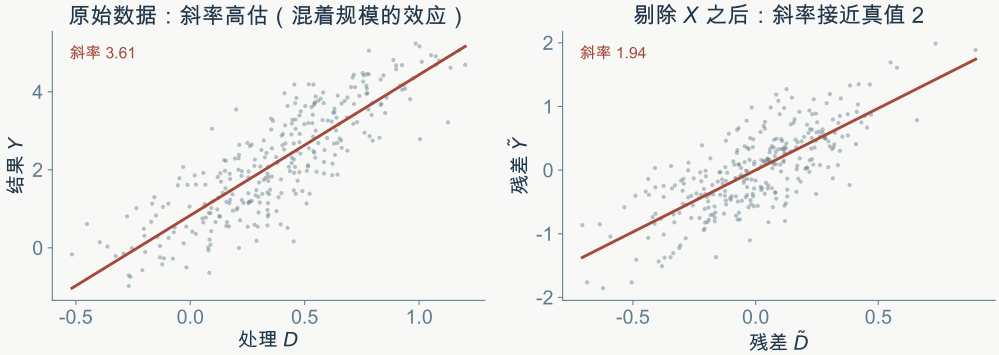
$$\widetilde{Y} = 20 - 15 = \mathbf{5}$$

比同类企业通常水平高 5。

接下来用**很多家企业**比较：数字化高于预期时，生产率是否也高于预期?

仅说明残差含义的教学数值；不能用一家企业的 5/2 来估计因果效应。

看图理解控制：扣除共同影响后，斜率变了



讲义教学模拟：直接回归斜率约 3.61；线性控制后的残差回归斜率约 1.94；设定真值为 2。

右图比较的是两种“高于预期”的程度；**样本估计接近真值，不必恰好等于真值**。

FWL 定理：同一个 OLS 系数，可以分三步算

1. 从数字化中扣除背景特征能解释的部分

用 D 对 X 做 OLS，取残差 $\widetilde{D}$。

2. 从生产率中扣除同样的背景特征

用 Y 对同一组 X 做 OLS，取残差 $\widetilde{Y}$。

3. 用剩下的变化作比较

用 $\widetilde{Y}$ 对 $\widetilde{D}$ 回归，斜率等于完整 OLS 中 D 的系数。

FWL 的贡献：把“加入控制变量”改写成**先扣除、再比较**。

同一样本、同一组线性控制（含截距），且无完全共线性；因果解释另需假设。

新的问题：扣除背景影响，一定要用直线吗？

FWL 给了我们一个有用的分工：先预测背景部分，再比较剩余部分。

传统线性辅助回归

研究者事先规定规模、研发等怎样进入：一次项？平方项？哪些交互项？

可以尝试的改进

让机器学习更灵活地预测 D 和 Y 中能够由 X 解释的部分。

延续**残差化的思想**，放宽辅助关系的形式；后面还要处理估计误差与过拟合。

机器学习先做两件熟悉的事：预测平均水平

预测数字化

对于具有这些特征的企业，数字化程度通常是多少?

$$m(X) = E[D \mid X]$$

机器学习给出估计 $\hat{m}(X)$。

预测生产率

对于具有这些特征的企业，劳动生产率通常是多少?

$$g(X) = E[Y \mid X]$$

机器学习给出估计 $\hat{g}(X)$。

$E[\cdot \mid X]$ 就读成“给定这些特征时的平均值”；帽子表示从数据估出来。

再用两种“高于预期”的程度估计目标系数

$$\widetilde{D}_i = D_i - \hat{m}(X_i), \qquad \widetilde{Y}_i = Y_i - \hat{g}(X_i)$$

数字化的剩余变化 $\longleftrightarrow$ 生产率的剩余变化

$$\hat{\theta} = \frac{\sum_i \widetilde{D}_i \widetilde{Y}_i}{\sum_i \widetilde{D}_i^2}$$

这是残差对残差、通过原点的回归斜率；正式 DML 要使用后面介绍的样本外残差。

只扣除 X 能预测的部分，保留**背景相近企业之间仍存在的数字化差异**。

为什么不能“换成机器学习，直接回归就结束”?

第一种担心：预测总会有误差

哪怕总体预测更好，某些企业仍会被预测偏高或偏低。
这些误差会不会明显带偏我们关心的系数?

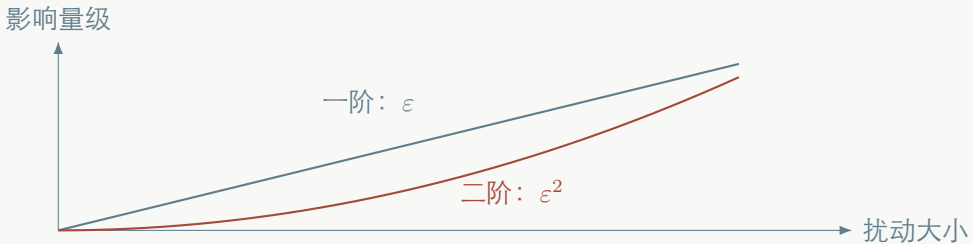
第二种担心：模型可能记住了训练样本

若把噪声也学进去，训练样本的残差就可能失真。
再用这些残差估效应，会不会把偶然性也当成证据?

DML 把**正交估计方程**与**交叉拟合**配合起来，处理这两方面的问题。

正交性：让辅助预测的小误差，不直接放大

我们希望：辅助预测稍微估错，目标效应的估计不要立刻跟着跑。



量级示意：曲线只表示一阶与二阶的量级差异；实际估计误差并不严格等于某个辅助预测误差的平方。

“正交”指**总体估计方程**对辅助函数在真值附近的小扰动**一阶不敏感**。

两种“正交”，不是同一件事

残差回归的斜率，满足一个熟悉的最小二乘条件：

$$\sum_i \widetilde{D}_i\big(\widetilde{Y}_i - \hat{\theta}\widetilde{D}_i\big) = 0$$

OLS 残差正交性

给定回归数据，OLS 选系数，使解释变量与回归残差的样本内积为零。这是最小二乘的一阶条件。

DML 的 Neyman 正交性

在正确构造的估计方程和相应模型条件下，辅助函数在真值附近的小扰动，不会对总体估计方程产生一阶影响。

Neyman 正交性是估计方程的数学性质，不需要另做“正交性检验”；但它不保证有限样本无偏，也不意味着辅助函数可以随意估计——有效推断还需识别假设、收敛条件和交叉拟合。

两者相关，但不是同一概念：**OLS 是样本残差正交，DML 是总体一阶不敏感**。

交叉拟合：给一家企业预测时，先不让模型看它

想象一个极端情况：模型记住了每家企业的 D 和 Y。

训练样本上的两组残差都接近零，剩余比较就失去了有效信息。

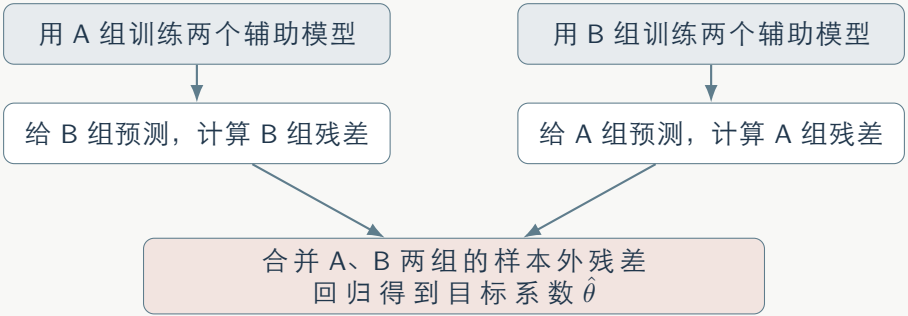
解决思路

用其他企业训练模型，再给这家企业预测。
它自己的 D 和 Y 不参与生成它的预测值。

这是灵活模型复用训练数据的风险；常规低维 OLS 使用同一样本，并不因此自动失效。

交叉拟合让残差来自**未使用该观测训练的模型**，缓解过拟合造成的依赖。

两折交叉拟合：每家企业都轮到一次“被留出”



A 组训练，预测 B 组；B 组训练，预测 A 组；**合并全部样本外残差再回归**。

三个概念，用三个动词记住

概念	核心动作	在本讲中做什么
交叉验证	**选模型**	比较验证误差，选择复杂度和参数
交叉拟合	**造残差**	每个观测的预测来自其他折训练的模型
正交估计方程	**估系数**	减弱辅助函数小误差的一阶影响

调参也应在相应训练折内部完成，避免留出折的信息提前泄漏。

交叉拟合与正交性**相互配合**；它们都不能修复遗漏的共同原因。

现在把 DML 完整走一遍

1. 明确 D、Y、X 和目标效应，说明为什么可以作因果比较

2. 分折：训练折内部先做模型选择与交叉验证调参，再拟合两个辅助预测模型

3. 预测留出折并取残差；轮换，得到每家企业的样本外残差

4. 汇总残差，用正交估计方程估计 θ

5. 计算适当标准误和区间，解释效应大小及不确定性

外层：交叉拟合产生样本外残差；内层：训练折内部用交叉验证选超参数。若超参数事先固定，可不做交叉验证；若要数据驱动调参，不能让留出折的信息泄漏进来。

研究设计**先于**算法；最后报告的也不只是一个点估计。

DML 相比熟悉的 OLS，主要改变了什么？

	传统线性 OLS 控制	本讲的部分线性 DML
怎样控制背景	研究者指定函数形式	灵活预测两个辅助关系
可能的优势	关系简单时直接、稳定	复杂关系下减少形式错设
主要困难	漏掉非线性或交互	辅助预测误差、额外推断条件
共同前提	因果解释都需要可信的识别假设	

DML 的优势是**有条件的**；不是把 OLS 换个名字就总能更准。

用模拟检验这个判断：先把真实答案设为 2

为什么用模拟?

真实研究不知道正确答案；模拟可以先设定真实效应 $\theta = 2$，再检查方法能否找回来。

保持什么，改变什么?

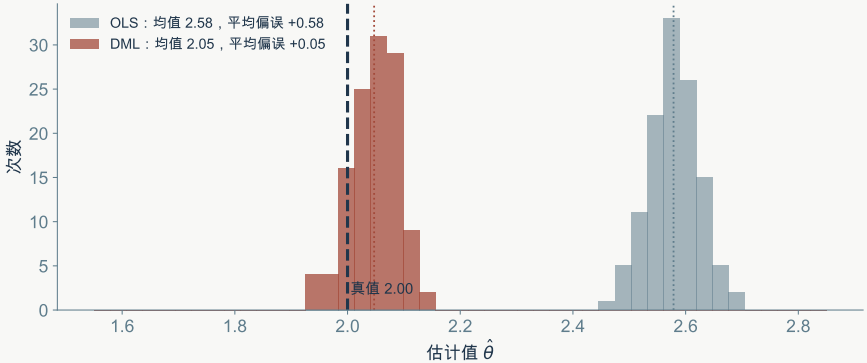
识别条件按构造成立；改变控制关系的非线性强度。
OLS 只线性控制 X；DML 使用随机森林和交叉拟合。

看两件事

估计值是否接近 2? 给出的置信区间是否具有合理覆盖率?

这里比较的是**估计方法的表现**；算法没有替我们解决识别问题。

复杂控制关系下：DML 的估计更接近设定真值



原课件模拟：120 次重复，每次 $n = 2000$；OLS 均值 2.58，DML 均值 2.05；真值 2.00。

本实验中，简单线性控制遗漏了部分复杂关系，**不只是“有没有加入 X”的问题**。

换成简单线性关系，OLS 就可能已经足够

情景	真值	OLS 均值	DML 均值
简单线性	2.00	1.99	2.02
复杂非线性	2.00	2.56	2.03

原课件另一批模拟：每个情景 40 次重复、每次 $n = 2000$；与前页 120 次重复不是同一批结果。

线性情景下两种方法都接近真值，原模拟中 OLS 的波动也更小。

方法选择要看**关系有多复杂、数据有多少、辅助预测能学到什么**。

估得更接近，不等于置信区间就已经可靠

点估计：离答案多近?

在基准非线性模拟中，DML 的平均偏误约为 $+0.05$。

区间：能否反映不确定性?

标为 95% 的置信区间，在这批重复模拟中的实际覆盖率约为 79%。

覆盖率：重复抽样并构造区间，**有多少比例的区间包含真值**。这里仍明显低于名义上的 95%，提示有限样本推断并不理想。覆盖率用于模拟评价推断方法；真实研究通常报告系数、标准误、p 值和置信区间，而不是模拟覆盖率。

正交性与交叉拟合提供方法基础，**不保证任何有限样本都表现良好**。

要把 DML 结果当作因果证据，还需要什么？

比较可信

根据因果角色选择 X，重点考虑处理之前的共同原因；给定 X 后，企业之间的比较可信。

数据有信息

背景相近的企业仍有数字化差异；辅助预测学得足够好，样本支持相应推断。

不确定性算得合适

使用与 DML 对应的方差估计；存在企业内或其他组内相关时，考虑适当聚类与分析。

理论主要给出**适当条件下的大样本保证**；不是有限样本自动无偏。

中国案例：企业经营改善，员工会跟着涨工资吗？

企业“蛋糕”变大，员工能分到多少？

研究对象

中国工业企业，2002–2007 年；张晨等（2023）的 DML 研究。

结果 Y：工资增长

企业人均工资增速。

核心变量 D：经营改善

以人均增加值增速度量租金增长。

增加值可理解为产出扣除中间投入后新创造的价值；这里的“租金”不是房租，也不直接等于会计利润。

直接比较还不够：规模、资本、行业等背景可能同时影响 D 和 Y。

张晨、万相昱、姬小曼、徐超（2023），《劳动经济研究》11(4)：38–62，第 42–45 页。

把 DML 用到工资问题：分别扣除背景的影响

沿用刚才的“先扣除，再比较”，换成真实研究中的变量。

第一条预测：工资增速

用背景 X 预测 Y，留下

$$\widetilde{Y} = Y - \hat{g}(X).$$

“工资比背景所预测的高多少?”

第二条预测：增加值增速

用背景 X 预测 D，留下

$$\widetilde{D} = D - \hat{m}(X).$$

“经营改善比背景所预测的多多少?”

X 包括规模、资本密度、存货、出口、上期工资增速、地区和行业等。
论文比较多种辅助学习器；这里用本讲符号解释其 Partialling Out 路线。

交叉拟合得到样本外残差，再用正交估计方程估计目标系数。

依据张晨等（2023）第 42–45 页；流程按本讲 DML 框架作教学说明。

工资案例的发现：灵活控制有用，识别仍要论证

DML 的辅助学习器	系数估计	95% 置信区间
Lasso（线性）	0.050	[0.049, 0.052]
随机森林	0.039	[0.038, 0.040]
梯度提升树	0.038	[0.036, 0.039]
神经网络	0.037	[0.036, 0.038]

均取原文表 1 的 Partialling Out 结果；四行都是 DML，并非 OLS 与 DML 的对照。

D、Y 均为增速（百分点）。以随机森林为例：D 高 10 个百分点，对应 Y 平均高约 0.39 个百分点。

论文另借税制改革研究因果问题；DML 本身不消除内生性。

张晨等（2023），表 1；税制改革分析见第四部分。[原文]。

用自己的话把 DML 讲完

先把背景能解释的部分扣掉，再比较剩下的变化。

为什么加入机器学习?

背景关系可能很复杂，需要更灵活地估计。

为什么不止是两次预测?

正交方程减弱辅助误差的一阶影响，交叉拟合缓解训练样本复用的问题。

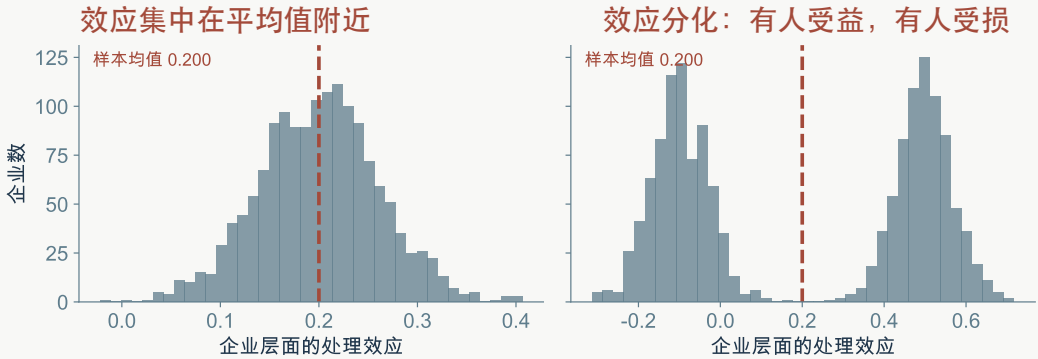
到这里，我们估的是一个目标效应；接下来问：**不同企业的效应会一样吗?**

问题三

因果森林

从“平均有多大”，走向“对谁更有效”。

同一个平均效应，背后可能是两个世界



人为设定的两个模拟世界，样本平均效应都为 0.20；右图既有正效应，也有负效应。

只报告平均值，会遗漏**收益落在谁身上、谁可能受损**的重要信息。

ATE 与 CATE：平均是对谁取的?

本部分把数字化改成二元试点：$W = 1$ 参加，$W = 0$ 不参加；与前一部分连续的 D 区分。

ATE：目标总体的平均效应

把目标总体中的企业放在一起看，试点平均带来多大变化?

CATE：给定特征的企业，平均效应有多大?

例如：对于规模较小、研发较高的企业，试点平均带来多大变化?

$$\tau(x) = E[Y(1) - Y(0) \mid X = x]$$

$Y(1)$、$Y(0)$ 是参加与不参加时的潜在结果；**CATE 仍是平均效应**。

先用熟悉的办法：分组，或加入交互项

分组比较

分别估计小企业和大企业的效应，看两组是否不同。

交互项

让数字化效应随规模、研发等特征变化；形式由研究者事先指定。

新的困难

效应可能同时取决于规模、研发、技能、行业。
分组组合很多，每组样本又越来越少。

树与森林尝试从数据中寻找**有信息的分组规则**；传统分组仍然有价值。

四类企业：计算机应该怎样分组?

沿用讲义教学案例。四类企业等权，每类内试点与对照各占一半且可比；数值为组均值。

企业类型	未参加试点	参加试点	效应差值
小企业、低研发	10	11	1
小企业、高研发	10	15	5
大企业、低研发	20	21	1
大企业、高研发	20	25	5

如果让计算机自动分组，应该先按**企业规模**切，还是按**研发水平**切?

普通决策树：怎么切，才能更好地预测生产率？

普通树先问：哪种切法能让各组的生产率预测更准？

按规模切

小企业平均生产率：11.5
大企业平均生产率：21.5
两组均值差 10

按研发切

低研发平均生产率：15.5
高研发平均生产率：17.5
两组均值差 2

每组都用组内均值预测；普通树比较候选切法，选择让**组内预测误差下降更多**的那一刀。

普通树会尝试不同变量和阈值，自动选择让叶内预测误差更小的切法。

四类企业等权、组内处理与对照各占一半；数值为组均值。这里只比较两种切法，不展开残差平方和计算。

因果树：怎么切，才能发现处理效应差异?

同一组企业数据，但目标从“预测生产率”换成“估计处理效应”。

按规模切

小企业效应：$(1+5)/2=3$

大企业效应：$(1+5)/2=3$

两组效应**没有差异**。

按研发切

低研发效应：$(1+1)/2=1$

高研发效应：$(5+5)/2=5$

两组效应相差 **4**。

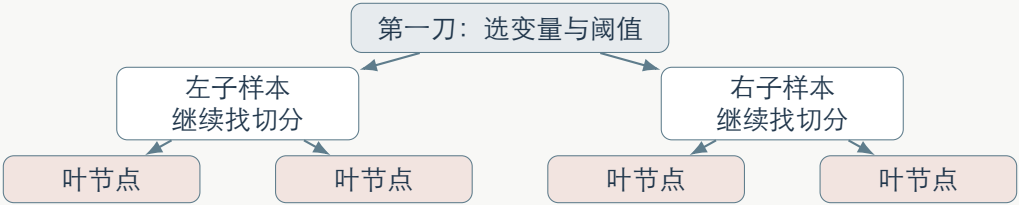
在随机实验或可比条件下，叶内效应可以用**处理组均值 − 对照组均值**估计。

普通树关注生产率水平，因果树关注处理效应异质性，因此可能选择不同的切分变量。

正式因果树的切分标准还要考虑估计精度与叶节点样本量，不是机械地最大化组间效应差。

一棵树不止一刀：递归切分

第一刀之后，左右子样本里还可以继续寻找新的切分规则。



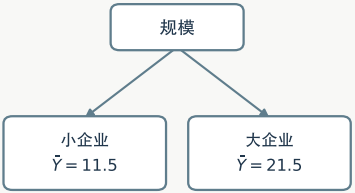
递归：每一步都在当前子样本中重复；　**停止**：最小叶样本量、最大树深度、误差改善不足。

一棵树不是一个变量、一次切分，而是由**多次切分形成的一套完整规则**。

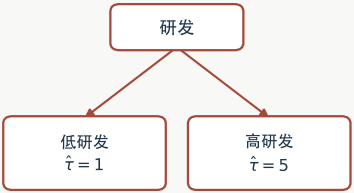
四类企业案例只有两层：按研发切后，组内不再有真实效应差异；不要把它理解成一定会继续按规模切。

普通树与因果树：结构相似，目标不同

普通树：按预测误差切 → 选“规模”



因果树：按效应差异切 → 选“研发”



普通树按规模切：叶内预测 11.5 / 21.5；因果树按研发切：叶内效应 1 / 5。

树的结构相似，但选择切分规则的目标不同：普通树预测结果，因果树估计效应异质性。

同一片叶子，不等于因果可比

换一个观察性数据情境：某高研发叶节点中，数字化企业平均 25，未数字化企业 20。

看起来

叶内均值差 $= 25 - 20 = 5$。
这 5 个单位能全部解释为数字化的因果效应吗?

还差两个条件

1. **重叠性**：叶内处理与对照都要足够。
2. **因果可比性**：识别假设下才可比；同叶不消除混杂。

不能直接这样读。

数字化企业可能同时有更好的管理、人才；同叶不会消除这些差异。

因果森林不能自动解决内生性；它估计的是**条件平均效应**。

教学数值，仅说明读法，不是论文结果。

从一棵树到森林：为什么要很多棵树？

一棵树换一批样本就可能变；森林让很多棵结构不同的树共同判断。



一棵树的问题：换一批样本，第一刀可能就变；切得太细，叶内效应也不稳定。

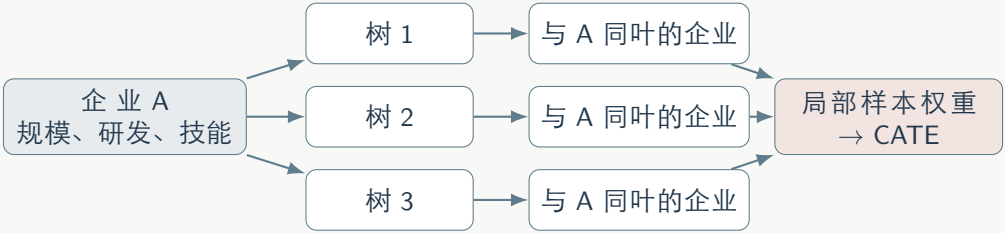
森林的做法：从同一份数据反复抽取不同子样本，训练数百棵结构不同的因果树；每棵树可用多个变量、多次切分。

经典随机森林常用有放回 Bootstrap；因果森林实现也可能用无放回子采样。

森林是**同一份数据上的大量相关树**，不是数百次独立研究。

企业 A 的 CATE：先从它在各棵树中的位置开始

把企业 A 的特征分别代入每棵树，看它和哪些训练企业落在同一个叶节点。



同一棵树只给出**一组**局部参考企业；不同树给出的样本不同。

森林把这些局部信息合成为企业 A 的**权重**。

森林不是对 A 单独回归，而是用很多棵树为 A 找**一组局部参考企业**。

因果森林最终输出什么?

森林通过大量树形成局部参考权重，再用相应的估计方法得到 CATE 预测：

$$\hat{\tau}(X_A) = 4.8 \quad \text{（教学示意）}$$

· 不是对 A 单独做一次回归;
· 不是观察到 A 的真实个体处理效应;
· 它是“具有 A 这组特征的企业”的条件平均。

实际广义因果森林通常用森林权重求解局部估计方程，不宜简单说成对所有树叶节点效应求算术平均。

企业	规模	研发	CATE
A	大	高	4.8
B	小	低	1.2
C	大	低	2.0

教学模拟，仅示意输出形式。

进一步可以：画 CATE 分布、比较群体平均效应、分析高低效应群体的特征。

森林输出**条件平均效应**；CATE 预测不等于企业真实个体处理效应。

诚实估计：把“选分组”和“估效应”分开

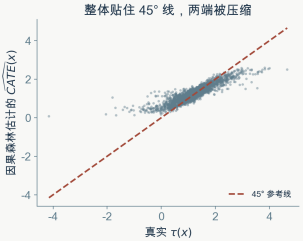
先看数据挑“差异最大的组”，再用同一数据报告差异，容易挑中噪声。



诚实估计：把**选择分组**与**估计叶内效应**分开，减少“既挑分组又估效应”的偏误。

它缓解自适应分组偏误；**不等于消除混杂，也不等于独立测试**。

森林估得怎样？差异可信吗？



教学模拟：森林能识别高低，但估计有误差；真实效应相同，预测值也可能散开。

森林预测排序；评估样本估计群组效应并检验差异。

1. 用训练样本训练森林；
2. 评估样本按预测 CATE 分高、低组；
3. 估计各组平均效应（含混杂调整）；
4. 检验两组效应之差。

	低组	高组
组平均效应	1.2	4.5
差异	3.3	
p 值	0.01	

教学模拟；群组效应与 p 值来自评估样本的估计与推断，不是对训练样本 CATE 预测求平均。

两组分别显著/不显著，不等于两组差异显著；要检验**差异本身**。

因果森林与传统异质性回归，究竟有什么不同?

	传统交互项回归	因果森林
研究问题	哪些企业效应更大?	哪些企业效应更大?
异质性形式	研究者事先设定	从数据中灵活学习
最终估计	回归系数及交互项	条件平均处理效应函数
结果呈现	系数表、组间差异检验	CATE 图、群组效应表
统计推断	标准误与显著性检验	需有效的组间差异与不确定性评估

两者研究的是同一个经济学问题，只是估计异质性的方式更灵活；不要简单说森林一定优于交互项回归。

先问“要回答什么”，再问“用哪种估计方式”。

接下来看两篇真实论文：一篇展示因果森林的结果，一篇展示 DML 与因果森林的配合。

因果森林实际案例 | AI 治理政策的效果，对所有企业都一样吗?

一项全国性政策，为什么会在企业之间产生不同效果?

制度背景与识别

2023 年 7 月《生成式人工智能服务管理暂行办法》发布；各省治理强度不同。

连续型 DID：治理强度 × 政策后；因果森林只做异质性分析。

数据与变量

2020H2–2025H1 A 股；4,553 家、35,423 个观测。

Y：劳动生产率（对数）；D：治理强度 × 政策后。

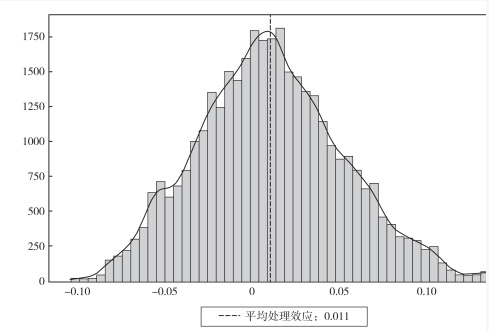
基准结果

DID 系数 0.0107^{***}（SE 0.0035）；控制企业、年份、行业—年份 FE。赵晶等（2026），表 2 第（1）列。

作者先用交互项检验三个预设调节因素，再用因果森林探索非线性与复杂异质性。

平均效应为正，但“平均”可能掩盖了企业之间的巨大差异。

因果森林实际案例丨估计出大量 CATE 之后，研究者看到了什么?



横轴：CATE 预测值；纵轴：企业数；虚线：平均处理效应约 0.011。

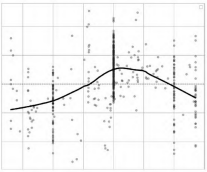
左尾有负值，右尾有高值：同一政策，不同企业响应差异很大。

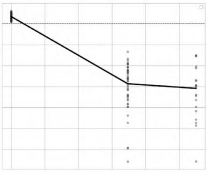
注意： CATE 分布的离散，不自动证明真实异质性显著；CATE 是条件平均，不是每家企业的真实个体效应。

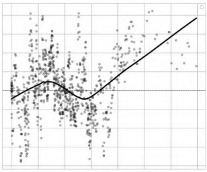
森林把“平均效应”展开成分布图；它提出异质性问题，尚未完成统计检验。

赵晶等（2026），图 1，第 160 页。

因果森林实际案例丨政策效应如何随企业特征变化?


（a）AI动态认知


（b）合规压力


（c）政府支持

（a）AI 动态认知

先升，后略降。

（b）合规压力

递减并转负。

（c）政府支持

低处近零，随后升。

高效应组画像：政府支持更高、合规压力更低、AI 动态认知更高；这是画像，不是机制证明。

AI 动态认知、合规压力和政府支持与预测政策效应的异质性变化相关。

赵晶等（2026），图 2、图 3，第 161–162 页。

综合案例 | 数字乡村建设：先看平均效应

数字乡村建设是否提升脱贫地区个体的技能与未来信心？

数据与变量

2018、2020 年 CFPS；县域数字乡村指数；36 个脱贫县、4,528 人。

Y_1：职业 ISEI（扶智）；Y_2：未来信心 1–5 分（扶志）；D：县域数字乡村指数。

结果	系数	SE
扶智：ISEI	0.095**	(0.048)
扶志：信心	0.006*	(0.003)

表 1 第（3）（6）列；控制县域、年份 FE 及 1–3 次项；$N = 4{,}528$；县级聚类 SE；5 折交叉拟合、101 次重复。

系数为正且显著；处理变量是连续指数，不能读成“处理组减对照组”。DML 给出平均效应，不消除遗漏变量等识别问题。

先看平均效应；下一步再问“对谁更大”。

周迪等（2026），第 120–122 页。

综合案例丨平均有效，不等于对所有人效果相同

DML 告诉我们“平均有效”；因果森林进一步问：哪些群体受益更多？

扶智（技能）敏感群体

年龄偏大；女性；家庭抚养负担较重。

扶志（信心）敏感群体

面临健康风险；有一定资产基础；有户籍身份。

怎么得到

因果森林按可观测特征估计条件平均处理效应（CATE），再识别潜在高效应群体。

证据边界

正文第 126–127 页结论；附录 F 未提供，本页不重绘。

DML 估平均；森林研究异质性；两者都需要可信识别；同时使用不等于解决内生性。

先问“平均有多大”，再问“对谁更大”；两问都离不开可信识别。

整堂课连起来：从预测，到控制，再到异质性

机器学习：能否学习复杂关系？

预测、模型灵活性、过拟合；用新样本表现评价。

DML：怎样用机器学习辅助因果效应估计？

残差化、正交性、交叉拟合；估的是目标参数，不是预测值。

因果森林：怎样估计、呈现和验证异质性？

因果树、森林、CATE；用诚实估计与样本外检验区分真实差异和噪声。

贯穿始终的问题：**谁与谁可比，为什么可比，结论有多不确定？**

能回答这三个问题，就抓住了本讲的思想

1. 机器学习：能否学习复杂关系?
2. DML：怎样用机器学习辅助因果效应估计?
3. 因果森林：怎样估计、呈现和验证处理效应异质性?

机器学习让我们更灵活地分析数据，但它不能代替因果识别；模型得到的复杂结果，还必须经过统计推断与经济学解释。

下一讲预告 | 大模型的经济应用

读文本：识别经济信息

企业年报谈了哪些风险？政策文件强调什么？新闻表达何种预期?

提变量：把文字变成可分析的数据

从抽取信息、分类和打分出发，讨论怎样构造经济指标。

做研究：检验这些变量是否可信

与人工标注比较，检查稳定性、信息泄漏，以及如何进入计量分析。

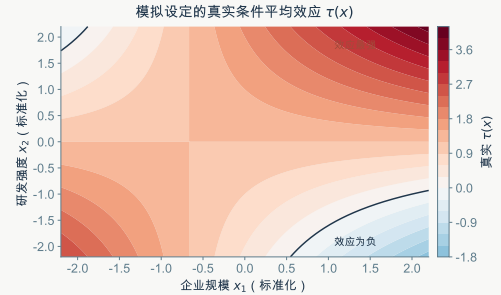
带着一个问题进入下一讲：**模型读懂了文字，怎样成为可信的经济证据?**

本讲主要参考文献

1. Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer.
2. Lovell, M. C. (1963). Seasonal adjustment of economic time series and multiple regression analysis. *Journal of the American Statistical Association*, 58(304), 993–1010.
3. Chernozhukov, V., et al. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68.
4. Athey, S., & Imbens, G. (2016). Recursive partitioning for heterogeneous causal effects. *Proceedings of the National Academy of Sciences*, 113(27), 7353–7360.
5. Wager, S., & Athey, S. (2018). Estimation and inference of heterogeneous treatment effects using random forests. *Journal of the American Statistical Association*, 113(523), 1228–1242.
6. 张晨、万相昱、姬小曼、徐超（2023）。企业会与员工共享发展成果吗？——来自机器学习的经验证据。《劳动经济研究》，11(4)，38–62。
7. 赵晶、刘家彤、谢泰宇（2026）。AI 治理如何赋能企业价值创造——基于“人—机”委托代理关系视角。《中国工业经济》，(5)，147–168。
8. 周迪、李书曼、王雪芹（2026）。数字赋能何以激发内生动力？——数字乡村建设的扶智扶志效应及其协同机制研究。《数量经济技术经济研究》，(9)，109–138。

配套阅读：《机器学习与计量经济学讲义》。其余图表与模拟沿用配套教学材料，具体口径见正文图注。

附录 A ｜真实 CATE 的二维异质性



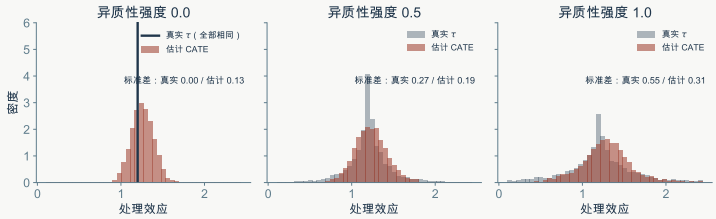
教学模拟：这是设定的真实 CATE，不是估计结果；结构为交互项 $0.45\,x_1x_2$，规模单独看不出差异

横轴：企业规模；纵轴：研发强度。
颜色越红，效应越大；蓝色区域效应为负。
同样的规模，在不同研发水平下，效应可能不同。

这张图用于说明多特征交互下的复杂异质性；主课件只保留四类企业案例。

只按一个特征分组，可能把交互关系平均掉。

附录 B | 真实效应相同，估计 CATE 也会散开

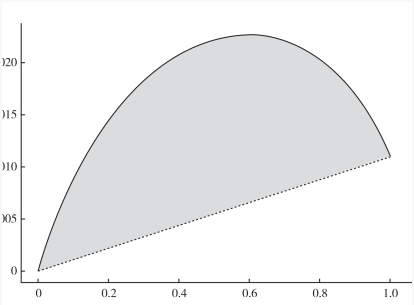


真实异质性强度	真实 CATE 标准差	估计 CATE 标准差
0.0	0.00	0.13
0.5	0.27	0.19
1.0	0.55	0.31

三档教学模拟。真实效应相同（第一行），估计 CATE 也会散开；仅凭离散程度不能证明真实异质性存在。

看见估计差异，只是提出问题；还需要检验差异是否超出抽样噪声。

附录 C | 从异质性到精准施策



实线：精准施策；虚线：随机干预。

只覆盖前 20% 企业时，平均处理效应已超过“全覆盖”。

覆盖约 60% 时，潜在增益约为整体干预的 2 倍。

含义：“漫灌”式全覆盖会浪费资源；“滴灌”式精准施策可能放大政策红利。

注意：这是基于模型的反事实模拟，不是已经实施的新政实验。

因果森林不只描述“谁受益”，还可以服务于“把资源给谁”的反事实分析。

赵晶等（2026），图 4，第 164 页；相关表述见第 163 页。

附录 D | 术语与完整对照

BLP / GATES / CLAN 各回答什么：

BLP：预测效应与哪些特征相关；GATES：高/低预测效应组的平均效应是否不同；CLAN：两组企业有哪些特征差异。

	DML	因果森林
主要关心	总体平均效应如何	对哪些群体效应更大
主要优势	灵活估计复杂控制关系，支持目标参数推断	学习复杂的效应异质性
结果形式	系数、标准误、置信区间	CATE 预测、群体差异及相关图表
共同要求	可信的因果识别条件	

两者不是互相替代；同一研究可以先用 DML 估平均效应，再用因果森林找异质性；是否使用 CausalForestDML 等具体实现，以原文为准。

先问“平均有多大”，再问“对谁更大”；两问都离不开可信识别。

附录 E | 六家企业切分的数值示例

用研发投入 X 预测劳动生产率 Y；每种切法都用叶内均值预测，再比较残差平方和。

企业	研发 X	生产率 Y
A	1	10
B	2	14
C	3	11
D	7	21
E	8	19
F	9	24

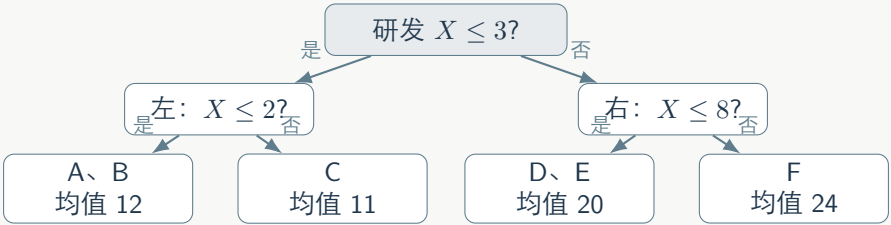
教学模拟，6 家企业。

切分	两叶均值	残差平方和
$X \le 2$	12.00 / 18.75	100.75
$X \le 3$	11.67 / 21.33	**21.33**
$X \le 7$	14.00 / 21.50	86.50
$X \le 8$	15.00 / 24.00	94.00

误差下降最多的，是第一刀 $X \le 3$。

每一刀都是“试遍候选切点、选叶内误差最小”的结果。

附录 E（续）| 递归切分与停止规则



每一步都在子样本里重复

左枝再试 $X \le 1$、$X \le 2$；右枝再试 $X \le 7$、$X \le 8$。

停下来的规则

最小叶样本量、最大深度、误差改善不足。

一棵树不是一个变量、一次切分，而是由多次切分形成的一套完整预测规则。